ESTATÍSTICA APLICADA

AULA 11

PROFESSOR

João Carlos Félix Souza

Estatística Aplicada

Aula 11 - Agenda

- Motivação e Conceitos Importantes
- Estacionariedade

Estatística Aplicada

Aula 11 - Agenda

Motivação e

Conceitos Importantes

Métodos de Previsão

Qualitativos

Baseados em opinião das pessoas:

- Clientes
- Vendedores
- Executivo

Métodos de Previsão

Quantitativos

Baseados em modelos matemático-estatísticos:

- Séries Temporais
  - Dados Históricos
- Corte Tranversal
  - Causa & Efeito

Métodos de Previsão

Quantitativos: Séries Temporais

Também denominados modelos **univariados**, pois as características de uma séries são analisadas exclusivamente a partir do comportamento da própria série.

Tipos de Dados

- **SÉRIE TEMPORAL**

  Observações sobre determinada variável coletadas sob intervalo regular de tempo. Exemplos:

  - **Inflação mensal de 1960 a 2000**
  - **PIB Trimestral durante o Governo Lula.**
  - **Taxa de Câmbio Diária R$/US$ de 1995 a 2004.**

Tipos de Dados

- **SÉRIE TEMPORAL**

  Conjunto de valores observados sequencialmente ordenadas ao longo do tempo.

MÊS/ANO	CotaçãoUS$
jan-04	2,941
fev-04	2,914
mar-04	2,909
abr-04	2,945
mai-04	3,129
jun-04	3,108
jul-04	3,027
ago-04	2,934
set-04	2,859
out-04	2,857
nov-04	2,731
dez-04	2,654

Métodos de Previsão

Quantitativos: Corte Transversal

Denominados modelos **multivariados,** em que as características de uma série são explicadas em função do comportamento de outras séries, permitindo assim que se considerem relações de dependência e causalidade.

Tipos de Dados

- **CORTE TRANSVERSAL**

Várias características em termos individuais num dado instante de tempo. Exemplos:

- **PIB de países europeus em 1990.**
- **Distribuição Etária da População Brasileira no Censo de 1980**

Tipos de Dados

- **CORTE TRANSVERSAL**

Os valores dos indicadores são analisados em um determinado período (mês, trimestre ou ano)

Unidade Federativa	PIB R$ Milhões
São Paulo	438.148
Rio de Janeiro	170.114
Minas Gerais	125.389
Rio Grande do Sul	104.451
Paraná	81.449
Bahia	62.103
Santa Catarina	51.828
Pernambuco	36.510
Distrito Federal	35.672
Goiás	31.299
Pará	25.530
Amazonas	25.030
Somatório	**1.187.523**

Principio Fundamental de Previsão

Previsões estão sujeitas a erros

- Envolvimento humano
- Comportamento da economia

Principios de Previsão

Específico pode implicar em maior erro

– Aplicação em famílias e/ou grupos

- o comportamento de itens individuais de um grupo é aleatório, mesmo quando o grupo tem características muito estáveis.

Principio Fundamental de Previsão

Longo Prazo pode implicar em maior erro

– Aplicação em horizonte temporal curto

- futuro próximo é menos incerto que o distante
- o amanhã tende a ser similar ao hoje.

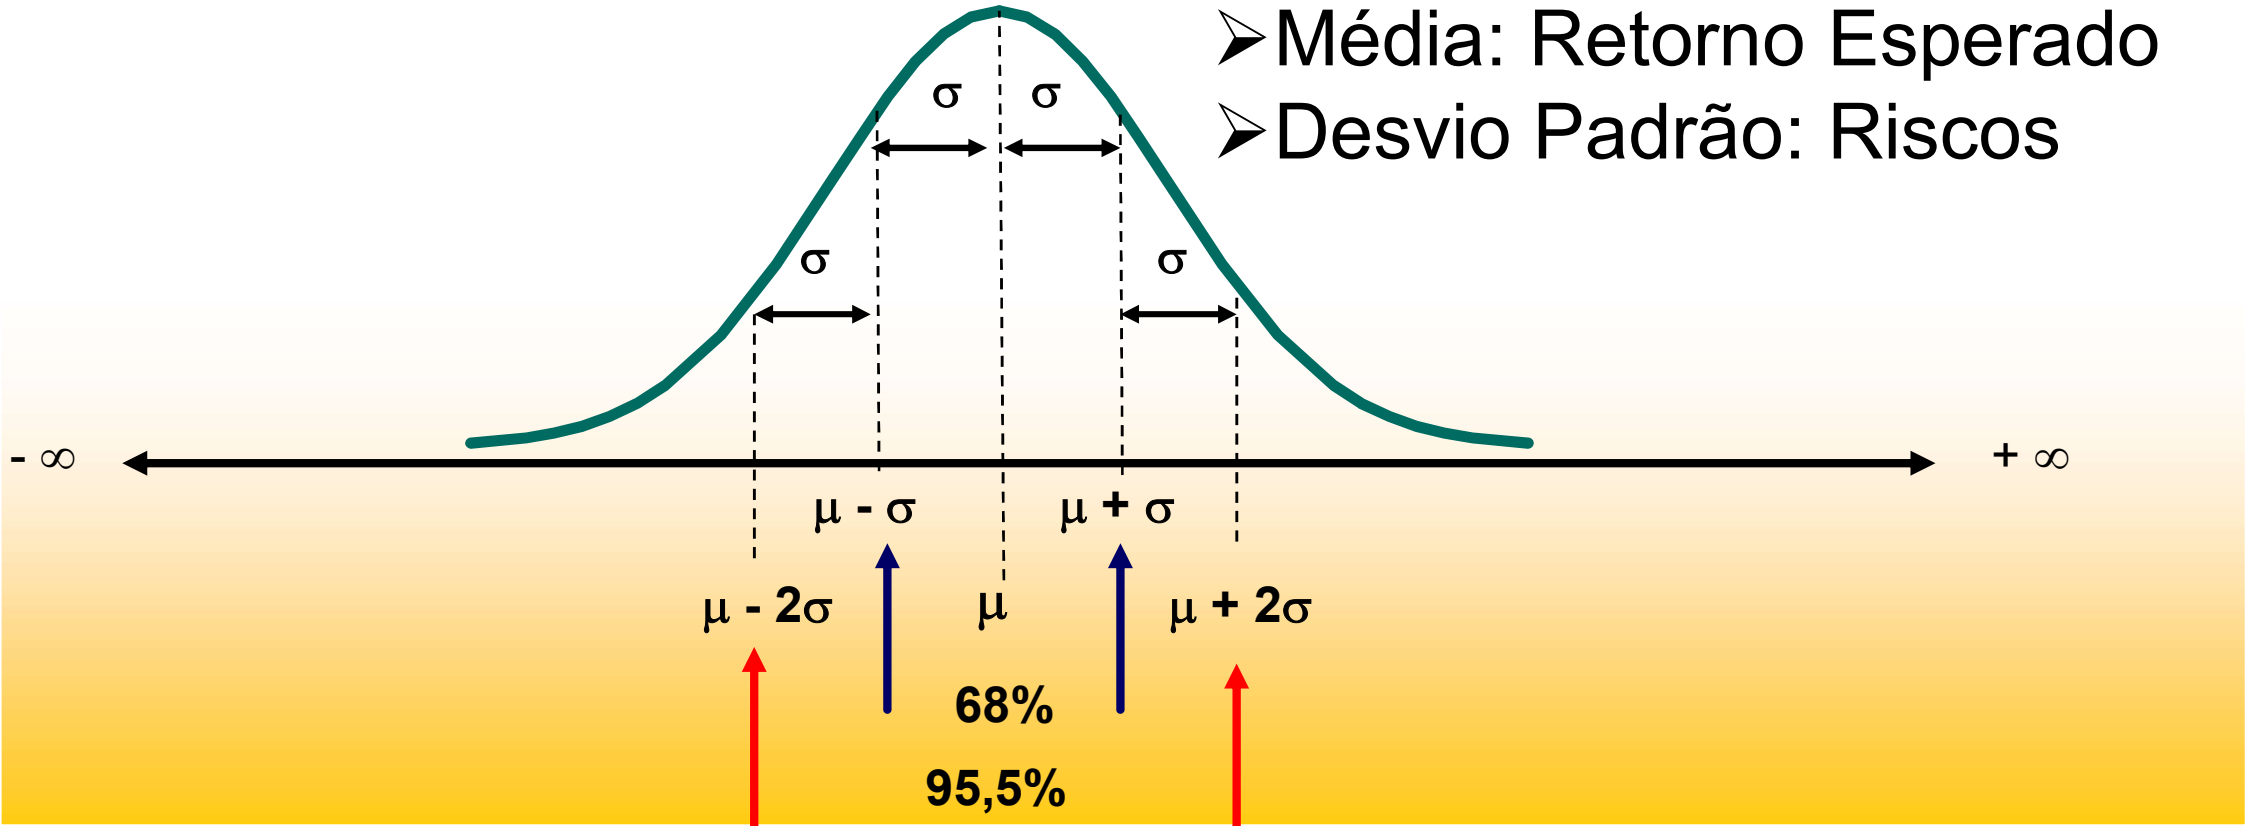
Previsão é uma ciência inexata.

Porém, métodos de previsão são fundamentais para o processo de tomada de decisão!

Motivação

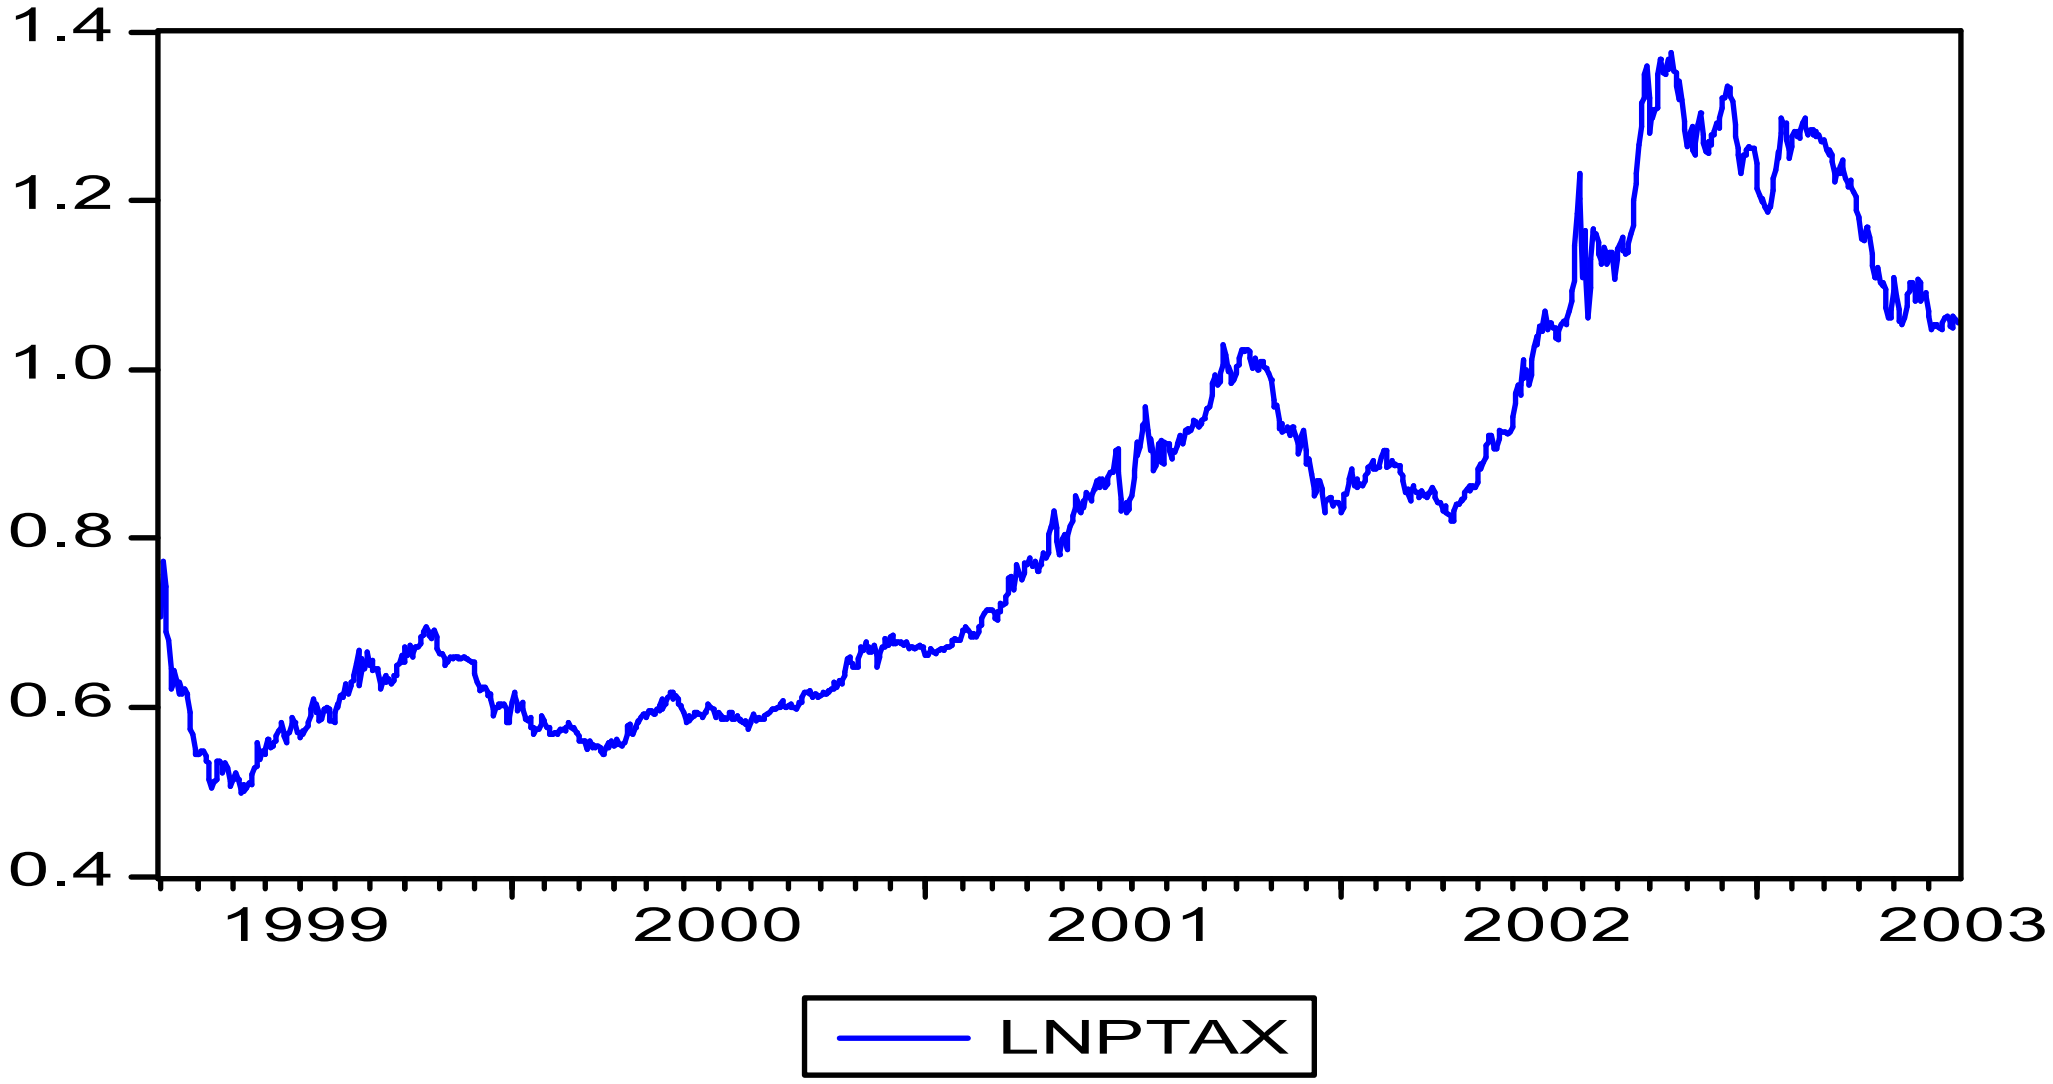
Teoria do Portifólio - Hipótese

- Retornos gerados por investimentos seguem Distribuição NORMAL



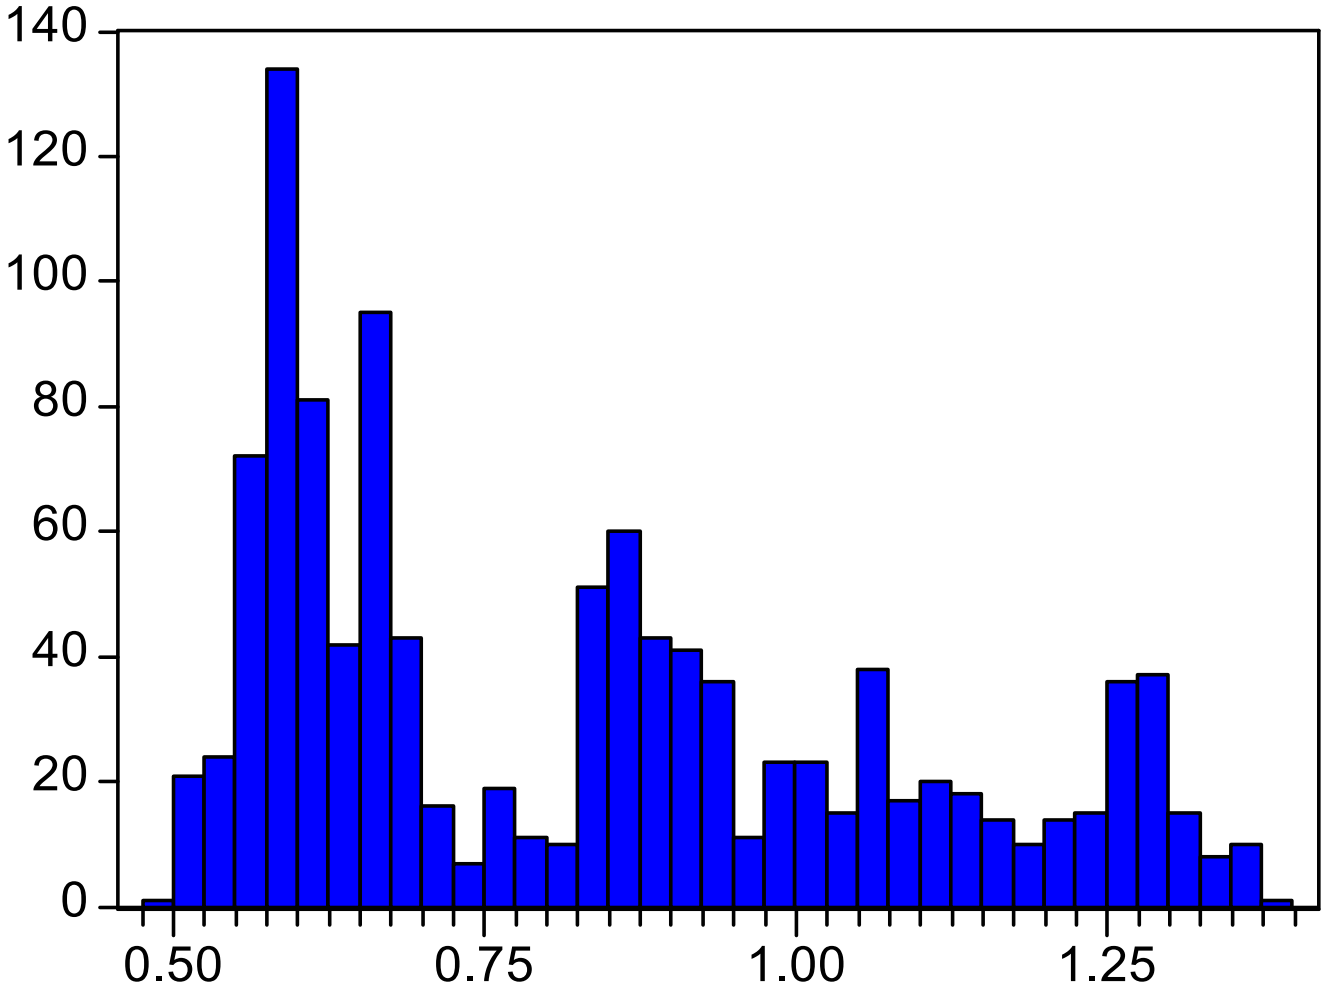
Motivação

Série temporal *ln(PTAX)* em nível – 26/02/1999 a 30/06/2003



Motivação

Estatística descritiva da série temporal *ln(PTAX)* em nível



Series: LNPTAX	
Sample 2/26/1999 6/30/2003	
Observations 1132	
Mean	0.829905
Median	0.801058
Maximum	1.375031
Minimum	0.498834
Std. Dev.	0.242373
Skewness	0.587105
Kurtosis	2.112225
Jarque-Bera	102.2061
Probability	0.000000

Motivação

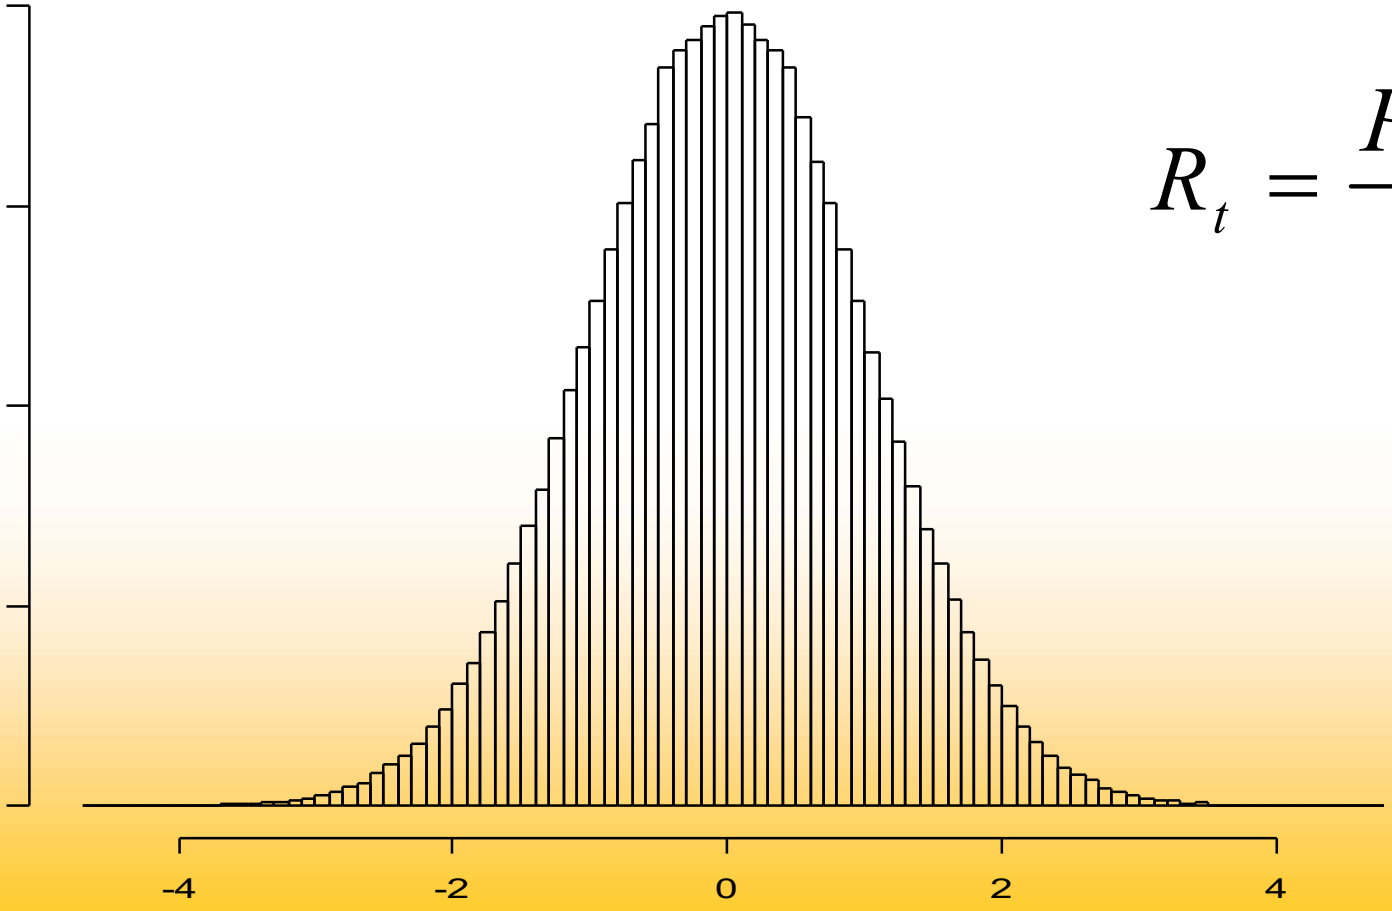


Preços não seguem distribuição NORMAL, pois não apresentam valores NEGATIVOS.

Preços seguem distribuição LogNormal, pois podem assumir qualquer valores entre zero e infinito.

Motivação

Retorno Discreto



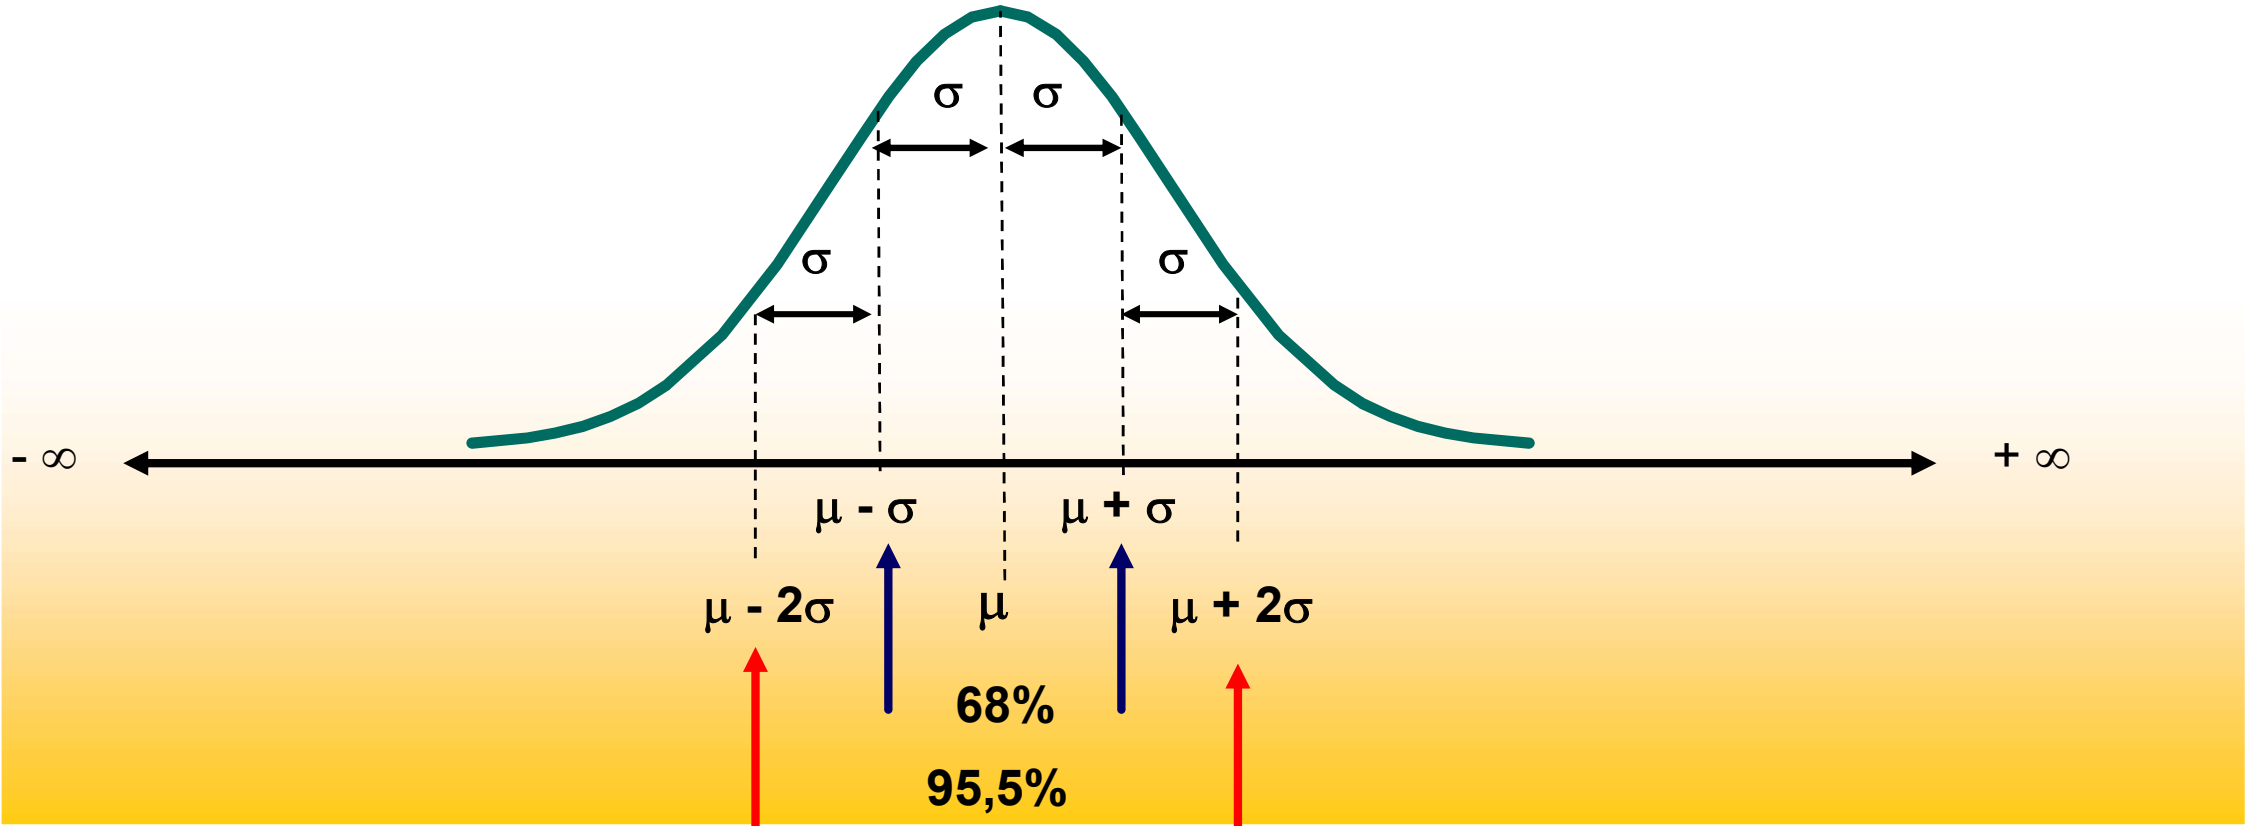
$$R_t = \frac{P_t - P_{t-1}}{P_{t-1}}$$

Motivação

Retorno Contínuo

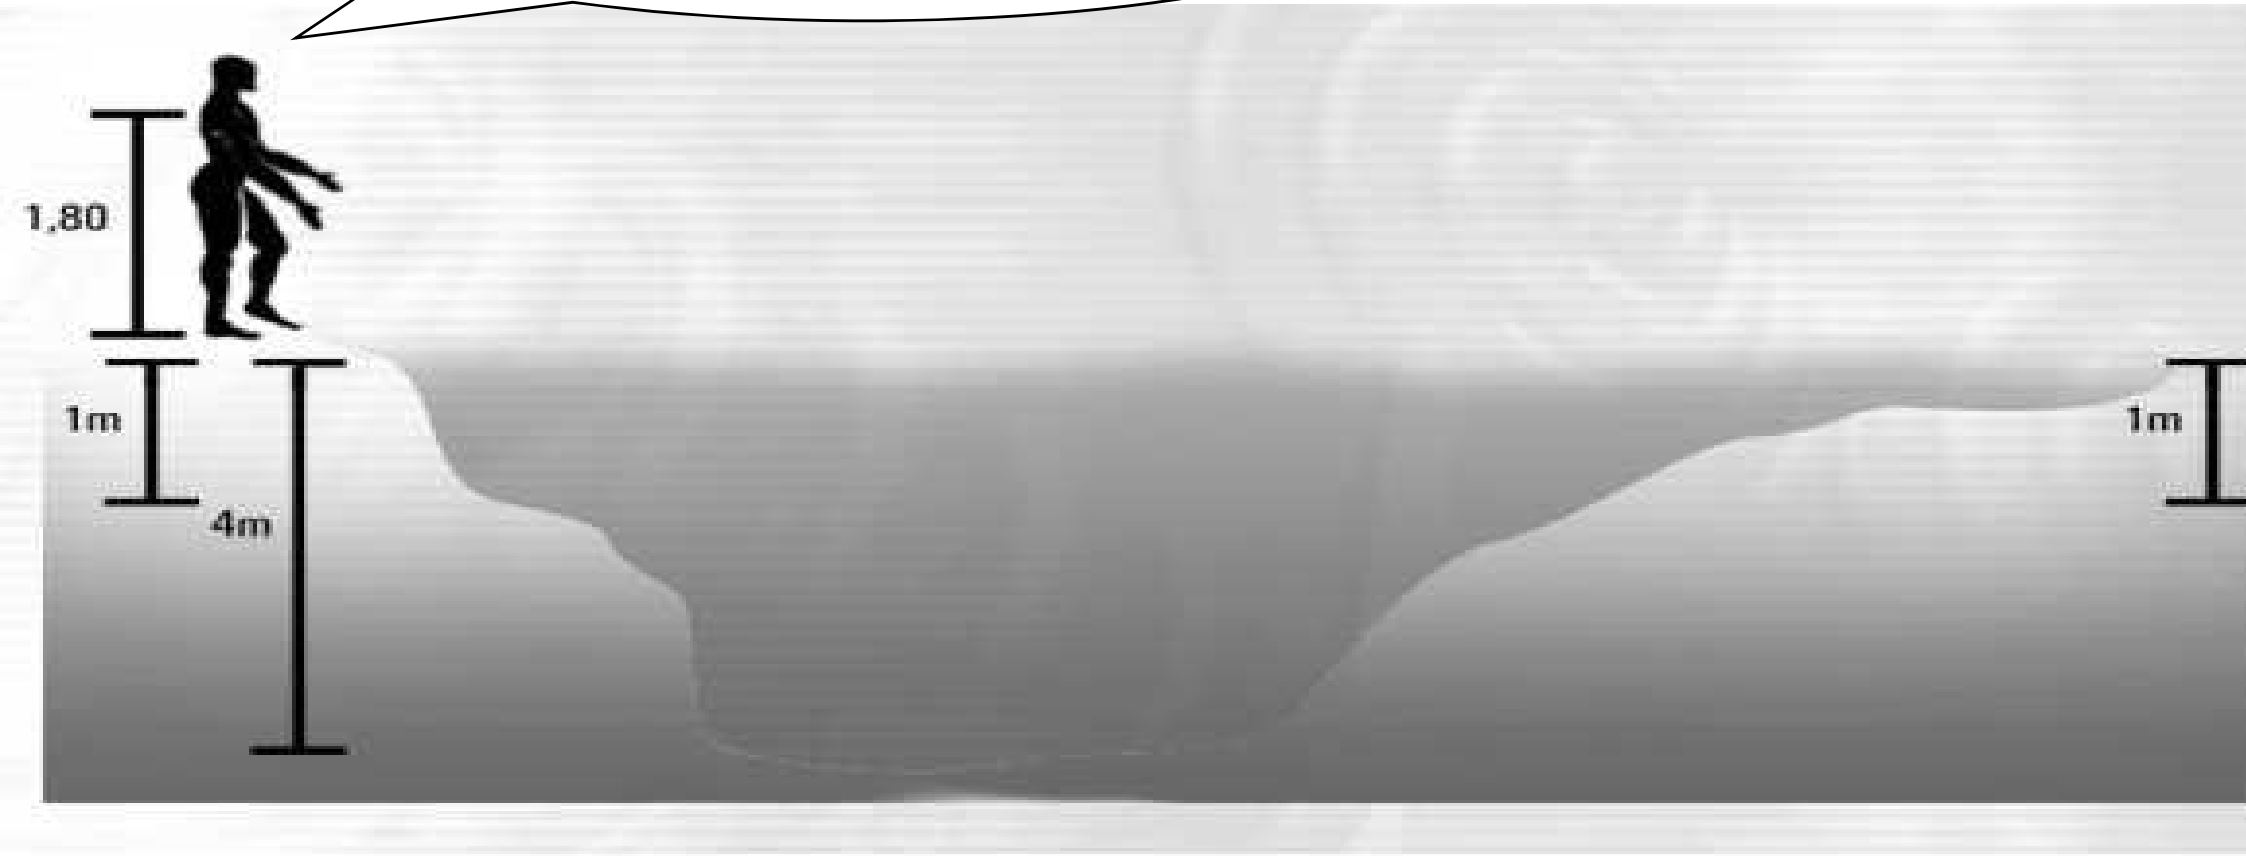
$$p_t = \ln(P_t)$$

$$r_t = \ln(1 + R_t) = (p_t - p_{t-1})$$



Assimetria

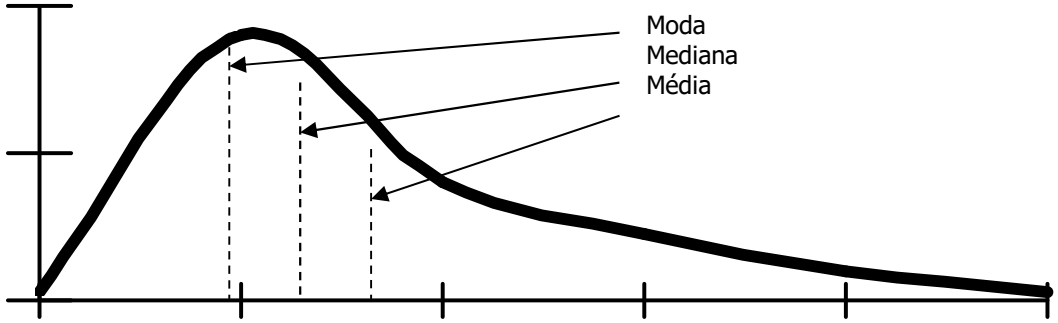
Dado que profundidade média é de 1,80 metros, posso chegar CAMINHANDO até a outra margem. Ainda bem, pois NÃO SEI NADAR!!!



Assimetria

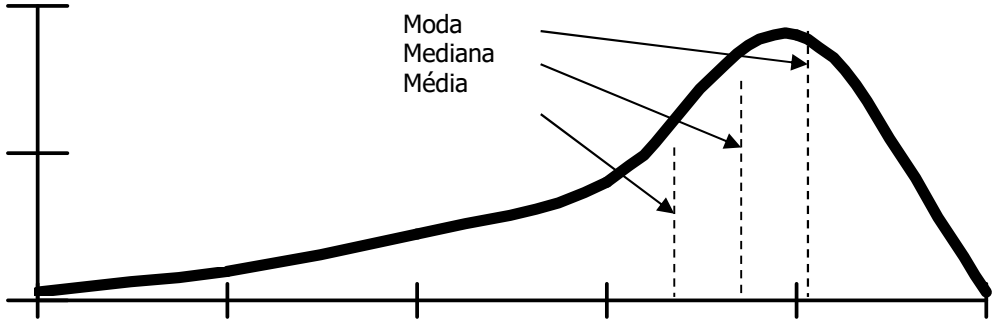
Positiva

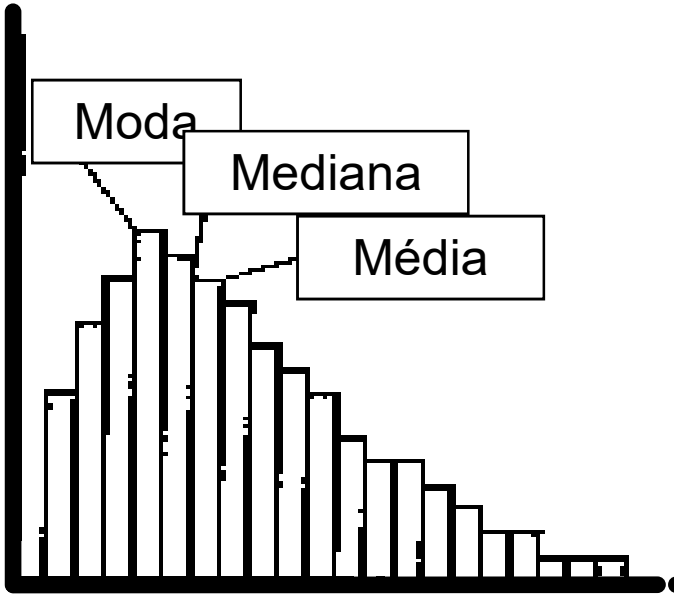
Assimetria à Direita

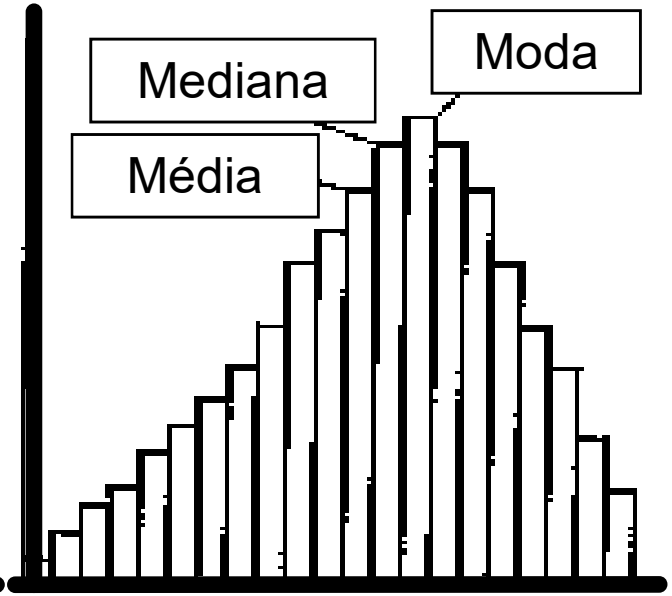


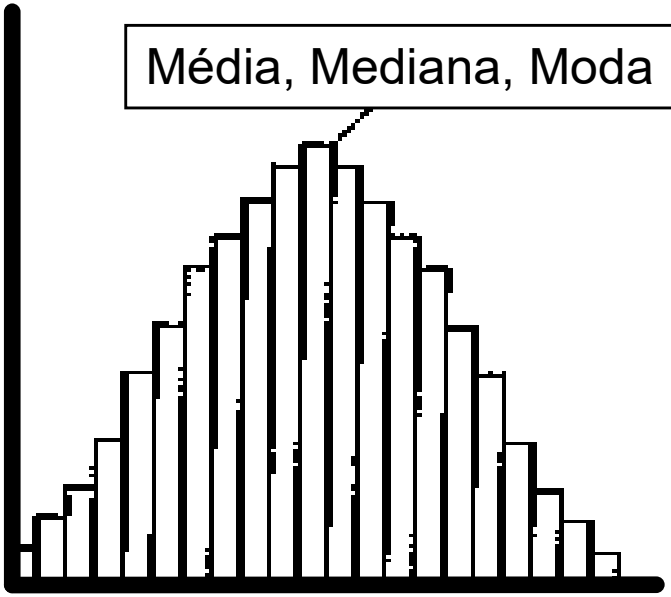
Negativa

Assimetria à Esquerda









Assimetria

- Teste de Hipóteses para Normalidade:
  - H_0: Distribuição é Normal
  - H_1: Distribuição NÃO é Normal

- Estatística do teste p/ ASSIMETRIA: $Z_A = \frac{A}{\sqrt{\frac{6}{n}}}$

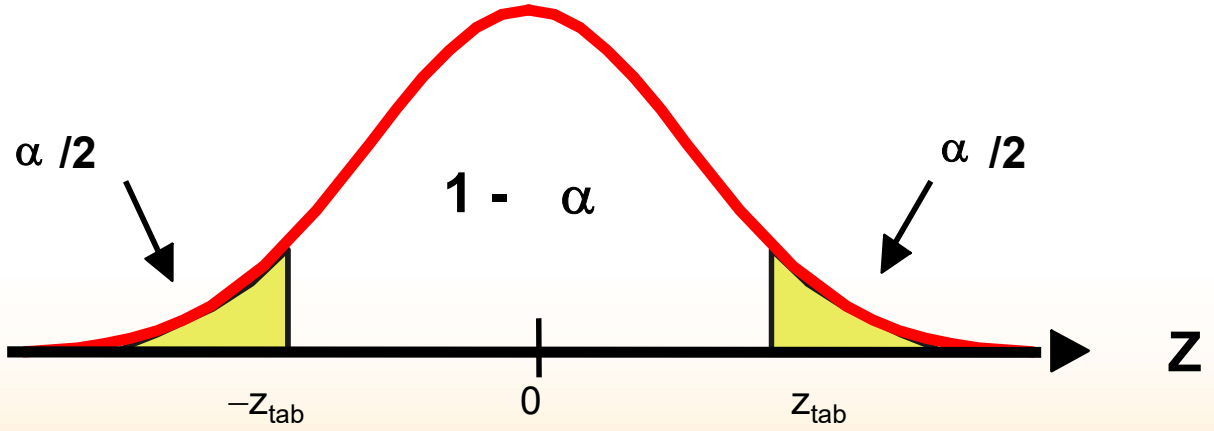
$$A^{Momentos} = \frac{1}{n} \times \sum_{i=1}^{n} \left(\frac{x_i - \overline{X}}{s_X} \right)^3$$

$\overline{X}$ = Média amostral da variável aleatória X
$A^{Momentos}$ = Coeficiente de Assimetria via Momentos
n = Tamanho da amostra
x_i = I-ésima observação da variável aleatória X
s_X = Desvio-padrão amostral da variável aleatória X

Assimetria

Teste Bilateral

$$Z_A \sim N(\mu = 0 ; \sigma = 1)$$



Se $Z_A \notin [-z_{tab} ; +z_{tab}]$, rejeita-se H_o ao nível de significância α.

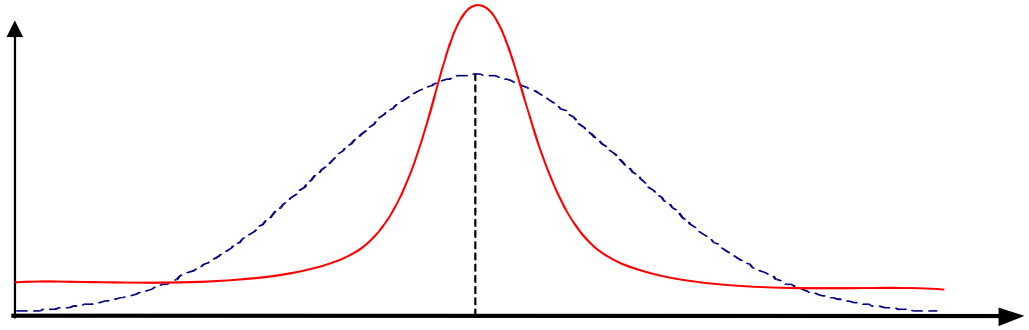
Curtose

- Influência de grandes flutuações
- Distribuição com caudas pesadas

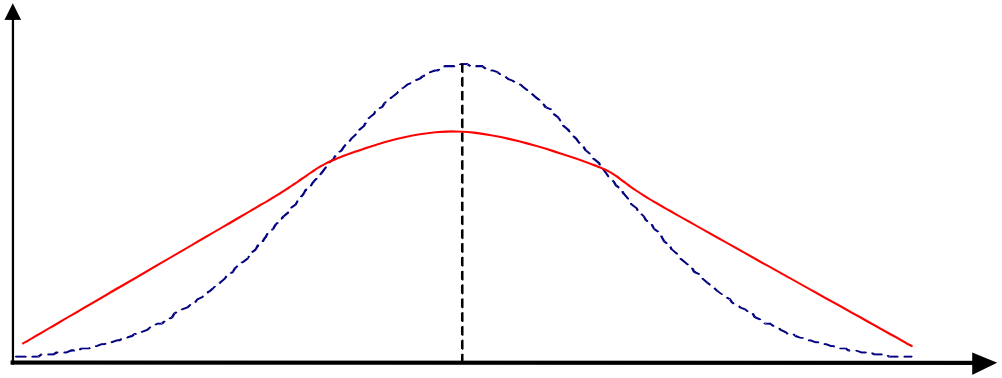


Curtose

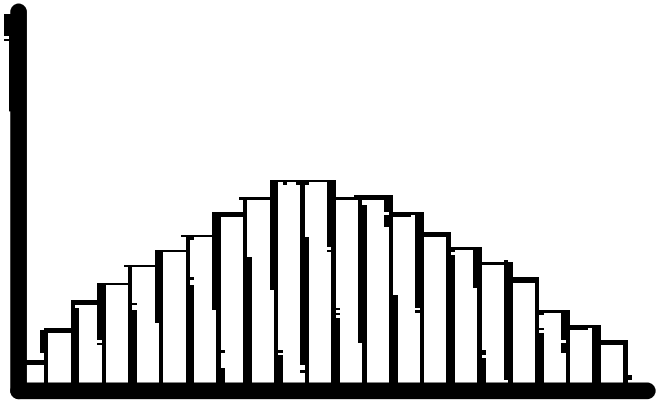
Leptocúrtica



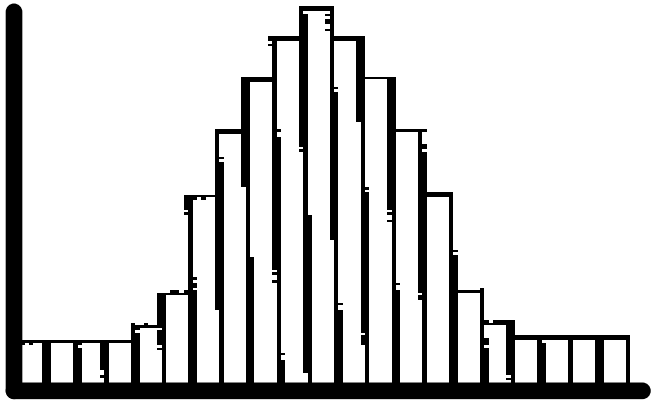
Platicúrtica



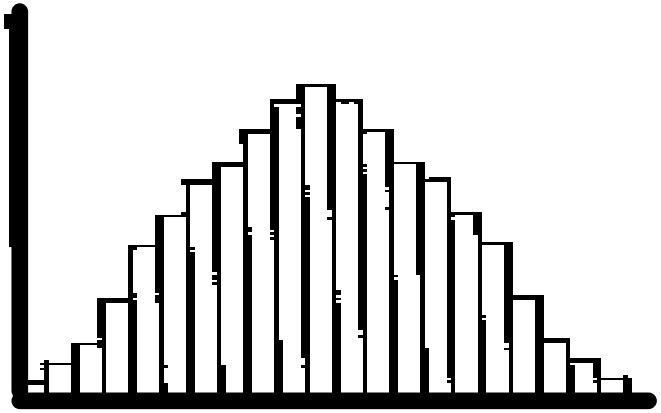
Platicúrtica



Leptocúrtica



Mesocúrtica



Curtose

- Teste de Hipóteses para Normalidade:
  - H_0: Distribuição é Normal
  - H_1: Distribuição NÃO é Normal

- Estatística do teste p/ CURTOSE: $Z_K = \dfrac{(K-3)}{\sqrt{\dfrac{24}{n}}}$

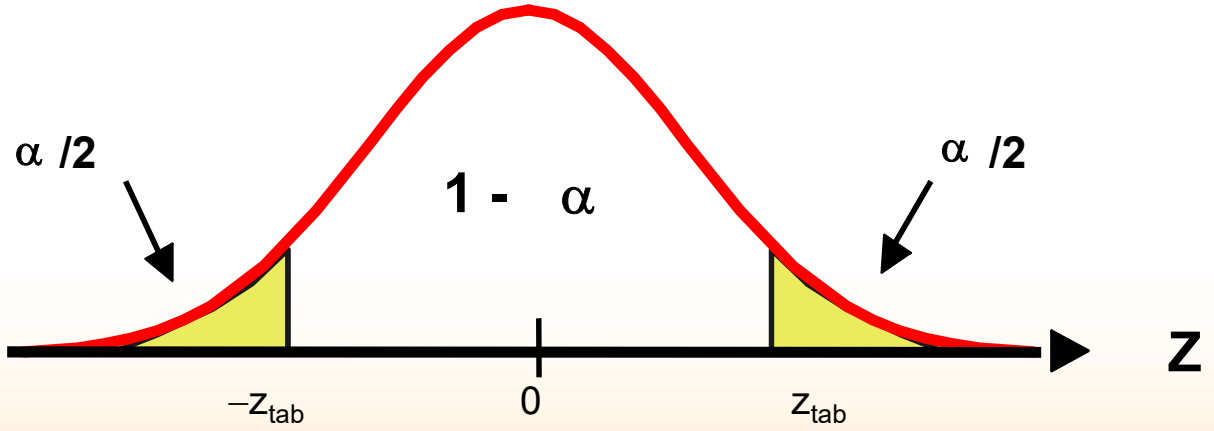
$$K^{Momentos} = \frac{1}{n} \times \sum_{i=1}^{n} \left(\frac{x_i - \overline{X}}{s_X} \right)^4$$

$\overline{X}$ = Média amostral da variável aleatória X
$K^{Momentos}$ = Coeficiente de Curtose via Momentos
n = Tamanho da amostra
x_i = I-ésima observação da variável aleatória X
s_X = Desvio-padrão amostral da variável aleatória X

Curtose

Teste Bilateral

$$Z_K \sim N(\mu = 0 ; \sigma = 1)$$

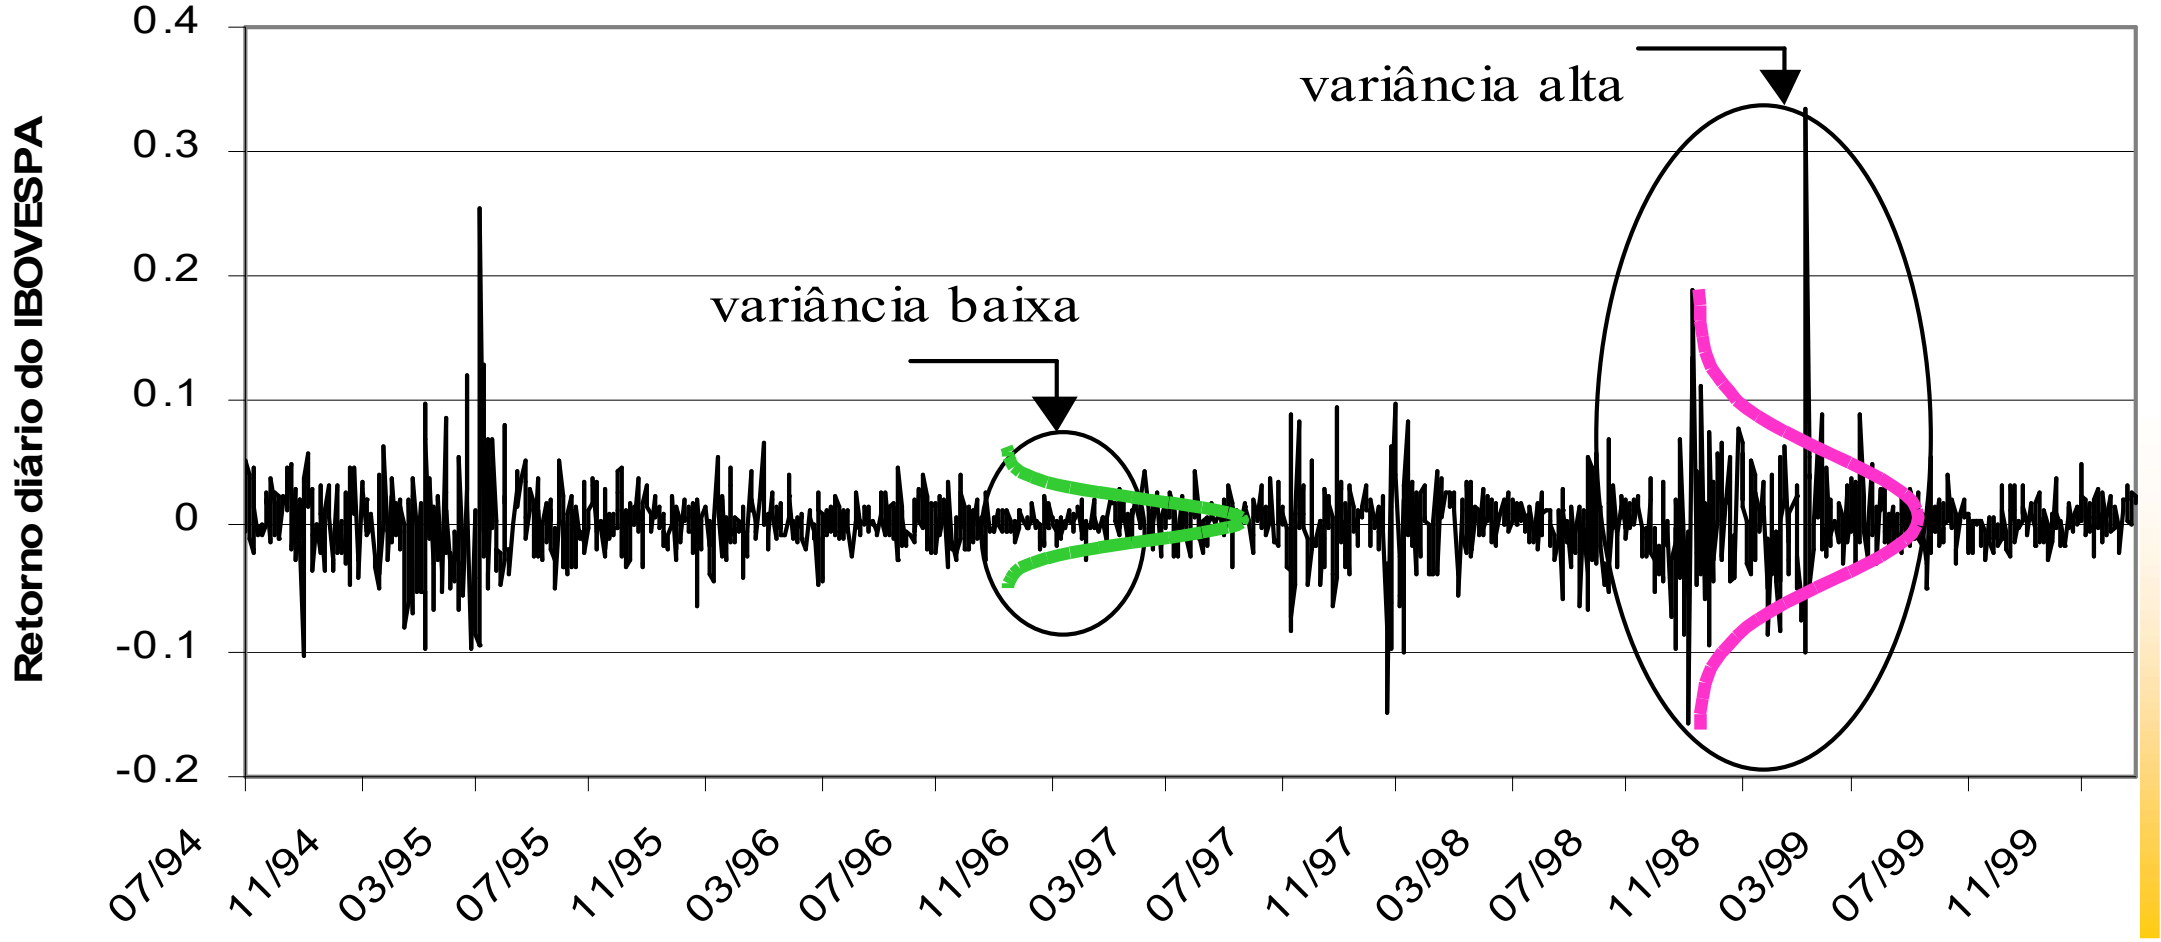


Se $Z_K \notin [-z_{tab} ; +z_{tab}]$, rejeita-se H_o ao nível de significância α.

Leptocurtose

Comparativamente, à distribuição NORMAL:

- Caudas Pesadas: maior freqüência de flutuações excessivamente ampla
- Baixa dispersão: maior freqüência de períodos com pequena flutuação



Leptocurtose

- Observada na curva de distribuição dos retornos, quando registradas grandes flutuações periódicas nos preços do ativos.

- Em mercados em que a negociação é descontínua, tais como bolsa de valores que fecham à noite e nos fins-de-semana, grandes flutuações nos preços dos ativos apresentam maior probabilidade de ocorrência.

Leptocurtose

- As informações sobre preços de ativos podem ser publicadas quando o mercado está fechado e exercem impacto a partir da reabertura do mercado.

- Logo, são observadas flutuações entre os preços de fechamento no momento anterior e o momento posterior de abertura.

Leptocurtose

- Flutuações de preços são melhor observáveis em dados diários e/ou semanais.

- Fortes flutuações resultam em freqüências de grandes ganhos ou de grandes perdas superiores ao que seria esperado, caso as negociações em mercado ocorressem de forma contínua.

Teste Jarque-Bera

- Teste de Hipóteses para Normalidade:
  - H_0: Distribuição é Normal
  - H_1: Distribuição NÃO é Normal

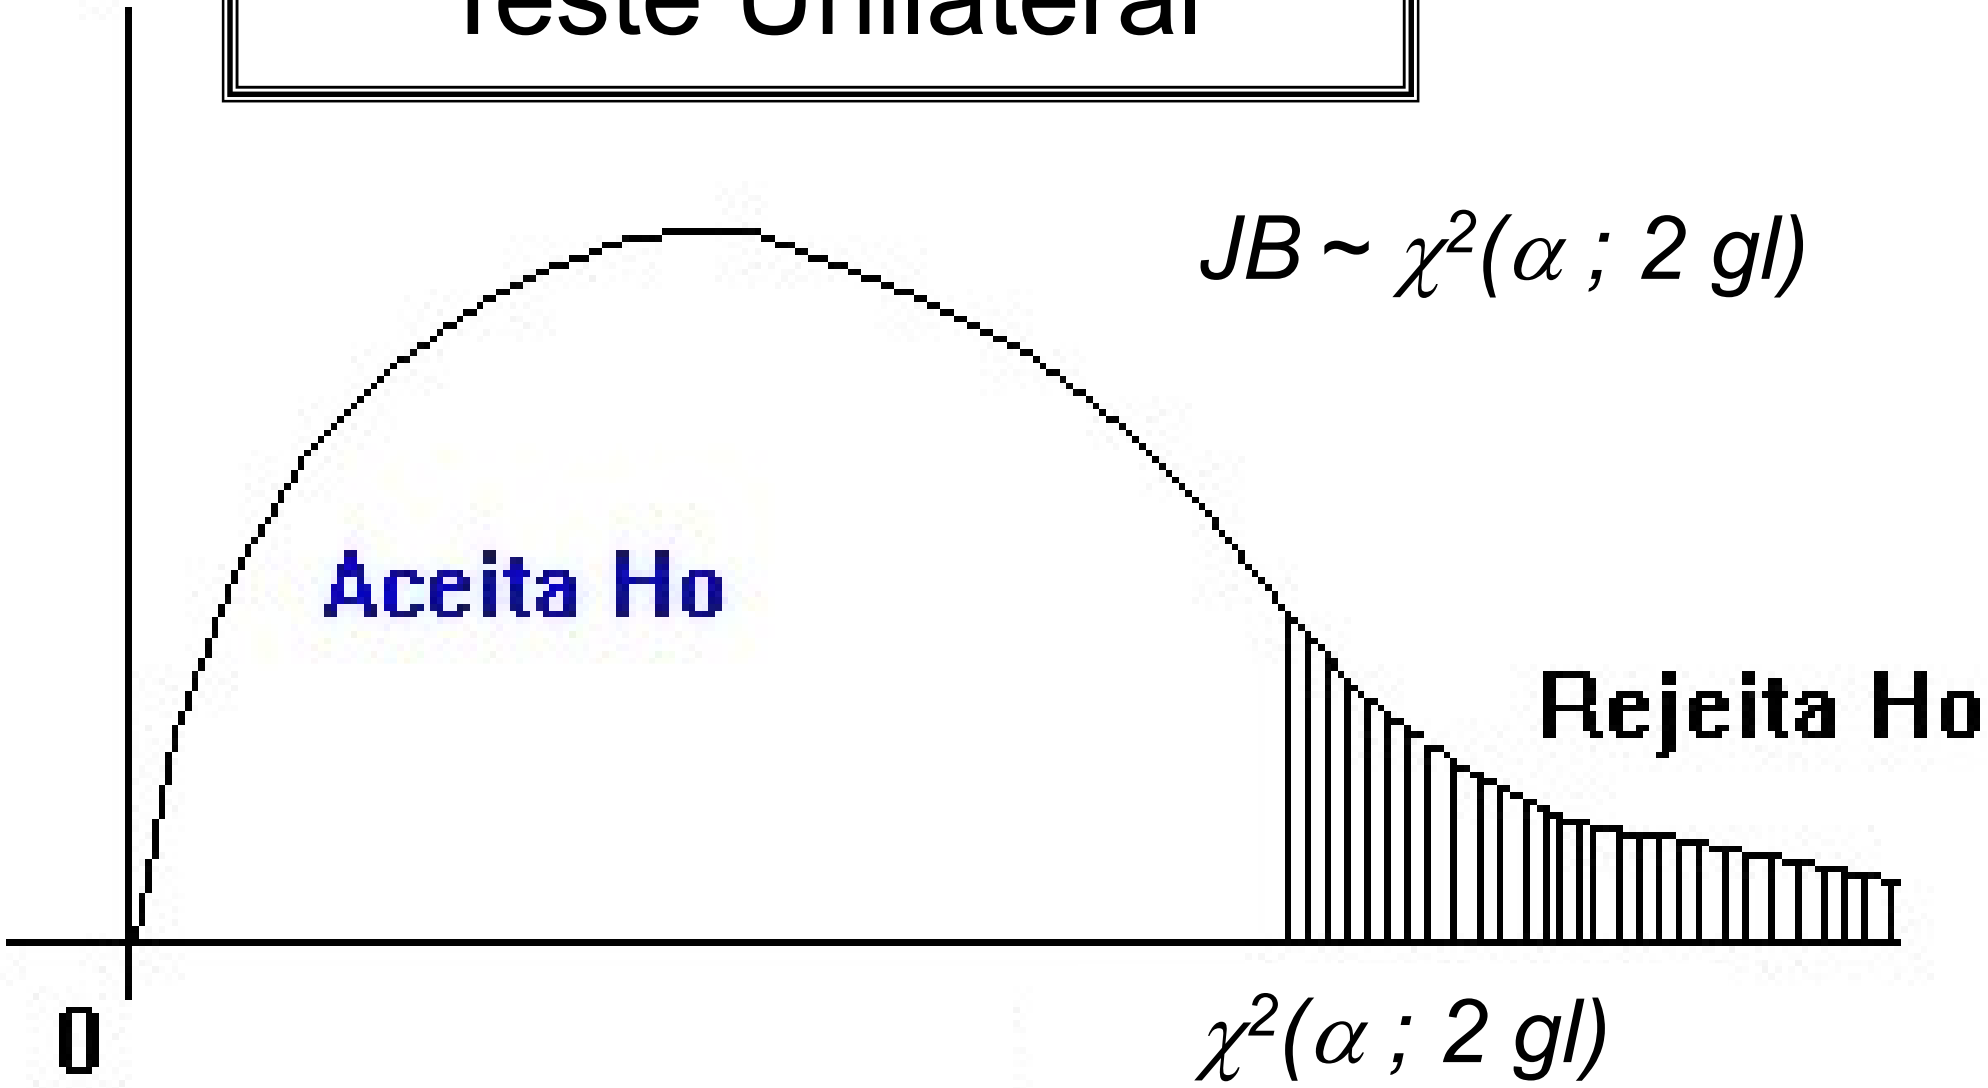
- Estatística do teste Jarque-Bera:

$$JB = Z_A^2 + Z_K^2$$

$$JB \sim \chi^2(\alpha\,;\,2\ gl)$$

Teste Jarque-Bera

Teste Unilateral



Teste Jarque-Bera

P-Valor: $P(\chi^2_{tabelado} > JB)$

Quanto mais próxima de ZERO estiver a expressão

$P(\chi^2_{tab} > JB)$, maior a crença de que JB seja MAIOR que χ^2_{tab}

Por exemplo: $P(\chi^2_{tab} > JB) = 0{,}000 \rightarrow P(\chi^2_{tab} < JB) = 100\%$

Então, a hipótese de NÃO Normalidade pode ser aceita, pois:

REJEITA-SE H_0: Distribuição é Normal

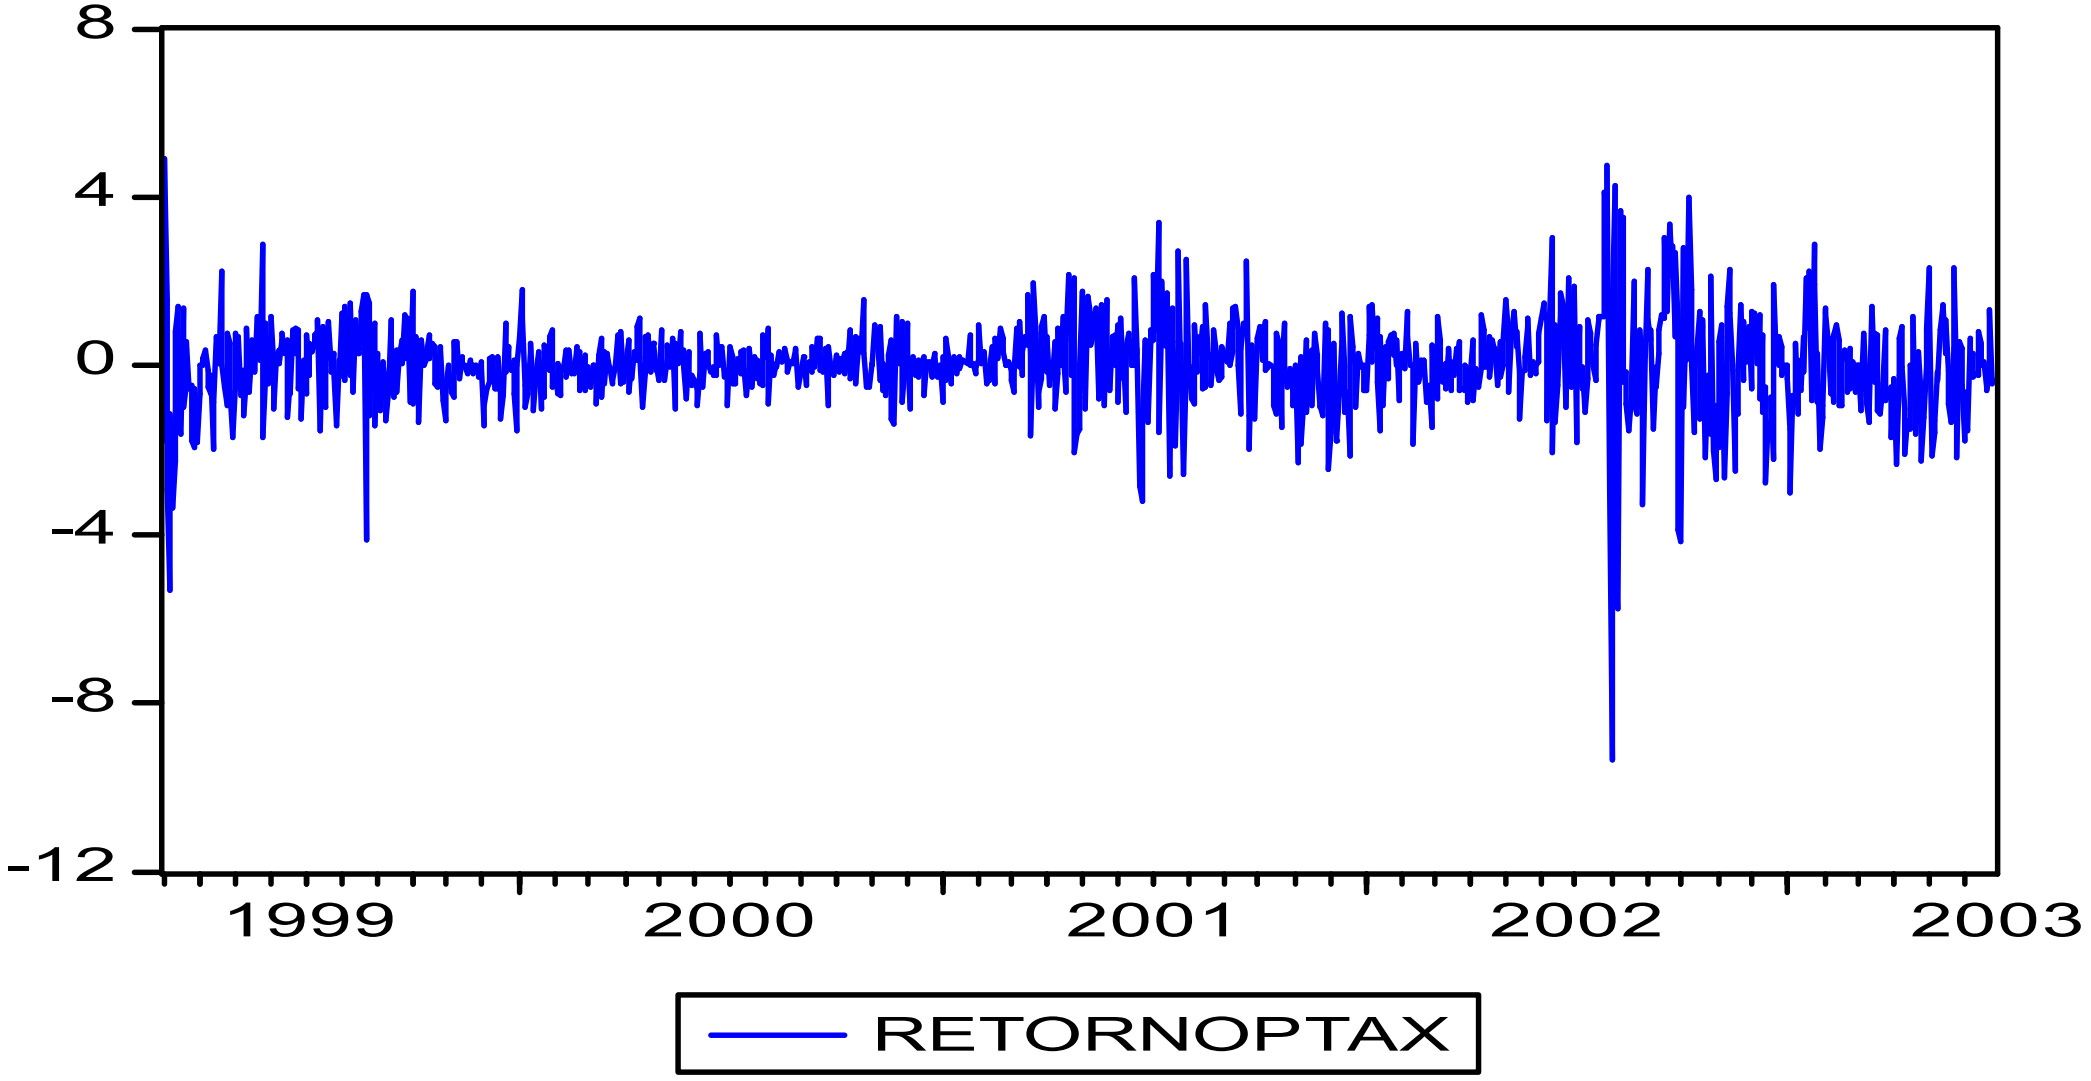
ACEITA-SE H_1: Distribuição NÃO é Normal

Por exemplo: sejam $\alpha = 5\%$ e $P(\chi^2_{tab} > JB) = 0{,}0499 = 4{,}99\%$,

Conclusão: A hipótese de Normalidade deve ser rejeitada.

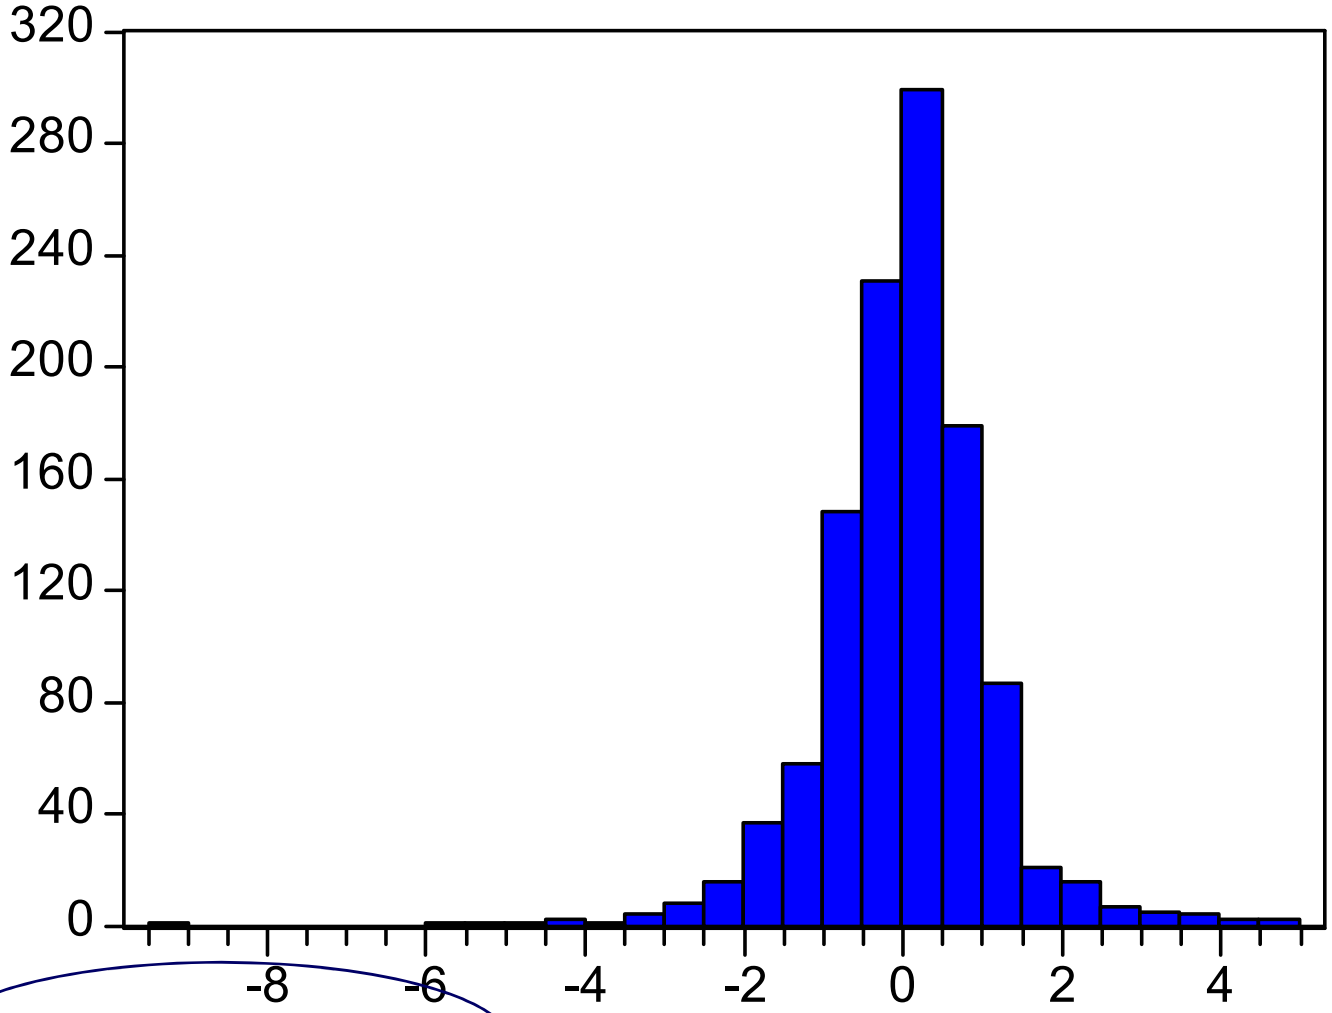
Fatos Estilizados

Série temporal retornos *ln(PTAX)* – 01/03/1999-30/06/2003



Fatos Estilizados

Estatística descritiva da série de retornos de *ln(PTAX).*

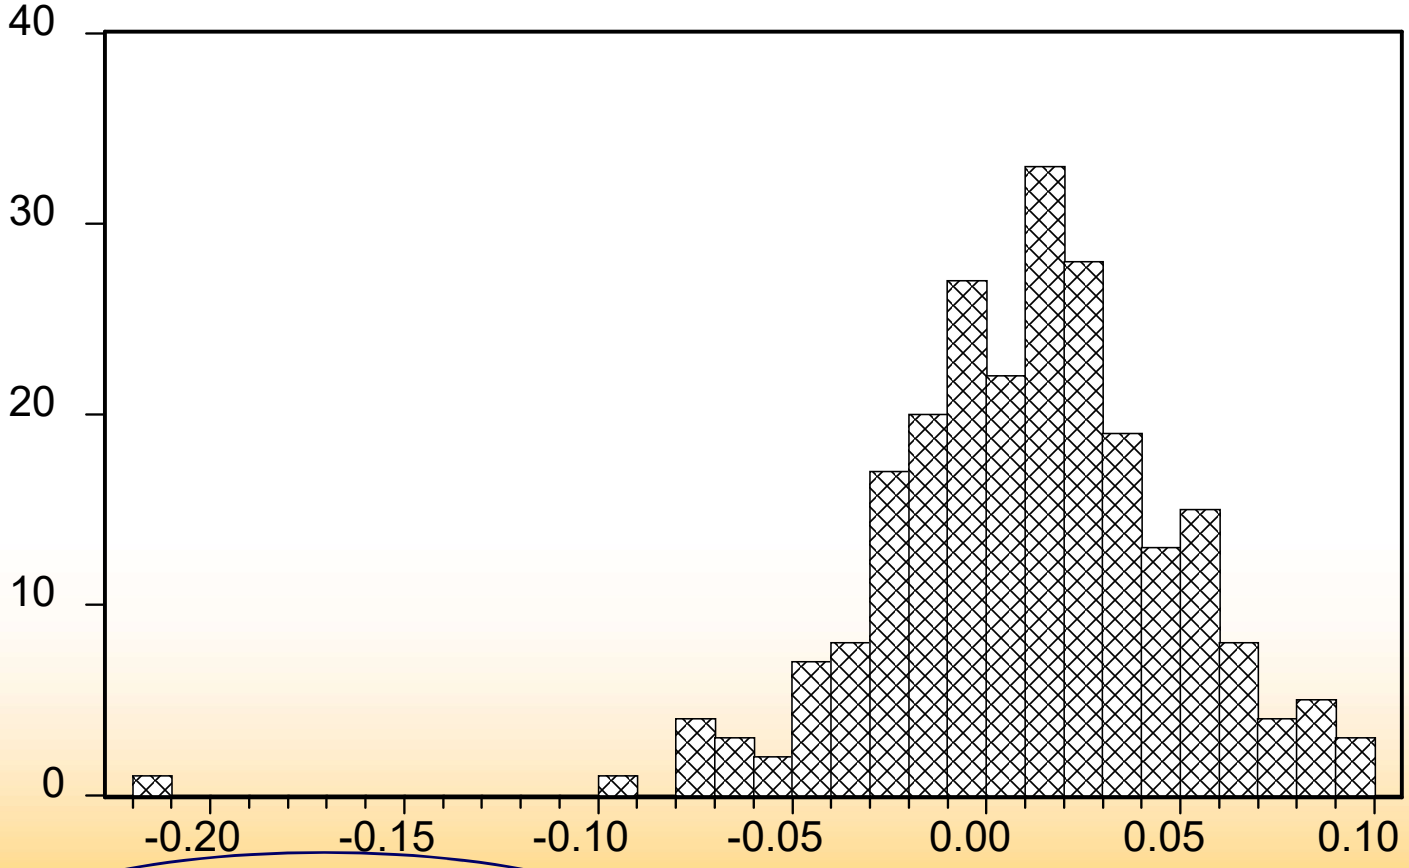


Series: RETORNOPTAX	
Sample 3/01/1999 6/30/2003	
Observations 1131	
Mean	0.029176
Median	0.015339
Maximum	4.925019
Minimum	-9.359265
Std. Dev.	1.084034
Skewness	-0.693809
Kurtosis	11.02184
Jarque-Bera	3123.228
Probability	0.000000

P-value = 0.00 → Rejeita-se H_0 → Distribuição NÃO Normal

Fatos Estilizados

Retornos Índice FTSE – Bolsa Valores UK



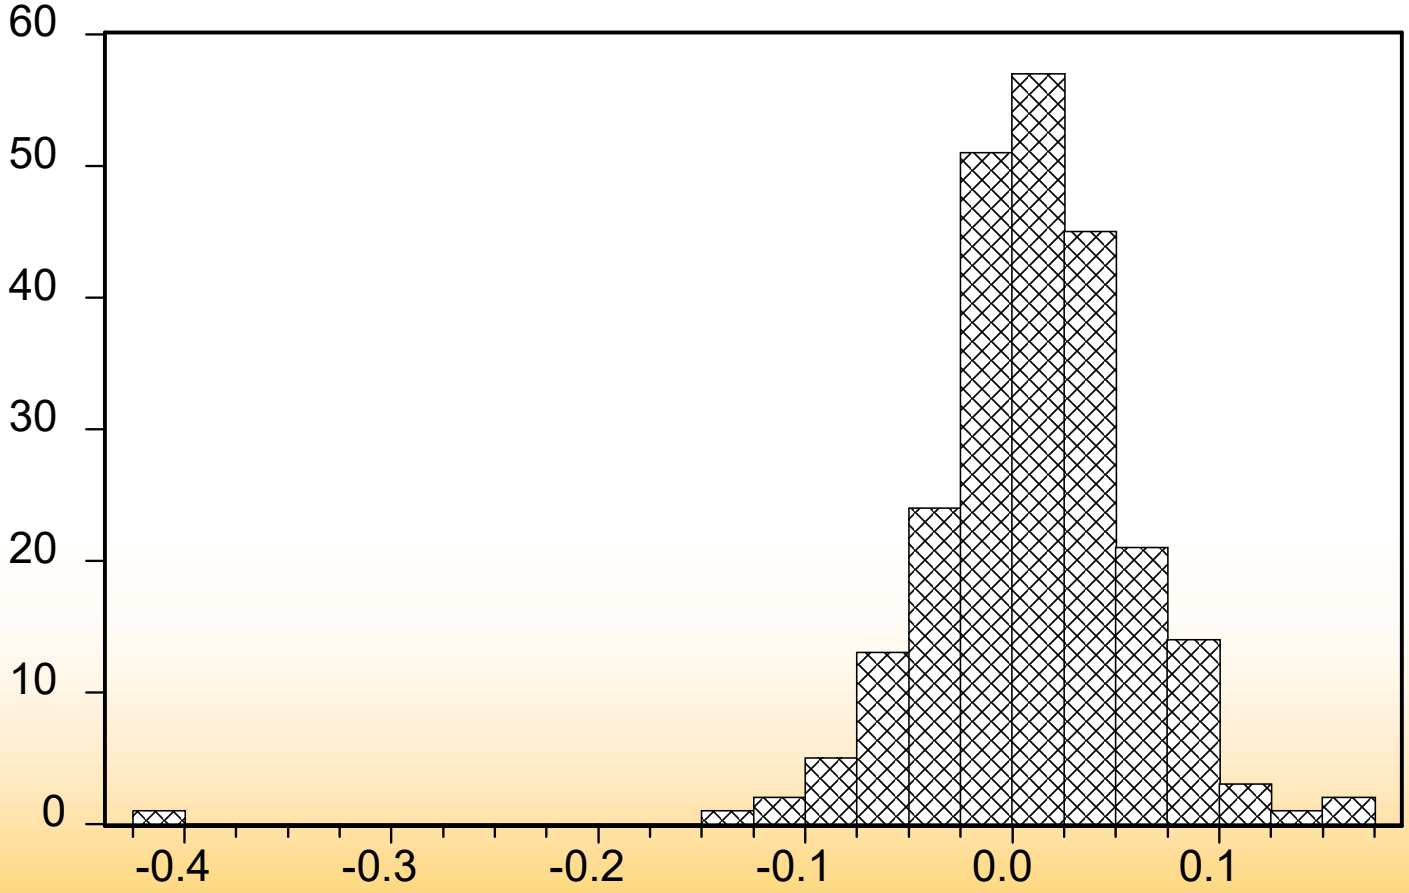
Series: RT
Sample 1981M02 2001M01
Observations 240

Mean	0.010296
Median	0.012761
Maximum	0.094293
Minimum	-0.219390
Std. Dev.	0.038330
Skewness	-0.943359
Kurtosis	7.638189
Jarque-Bera	250.7251
Probability	0.000000

P-value = 0.00 → Rejeita-se H_0 → Distribuição NÃO Normal

Fatos Estilizados

Retornos Índice ASX – Bolsa Valores Austrália

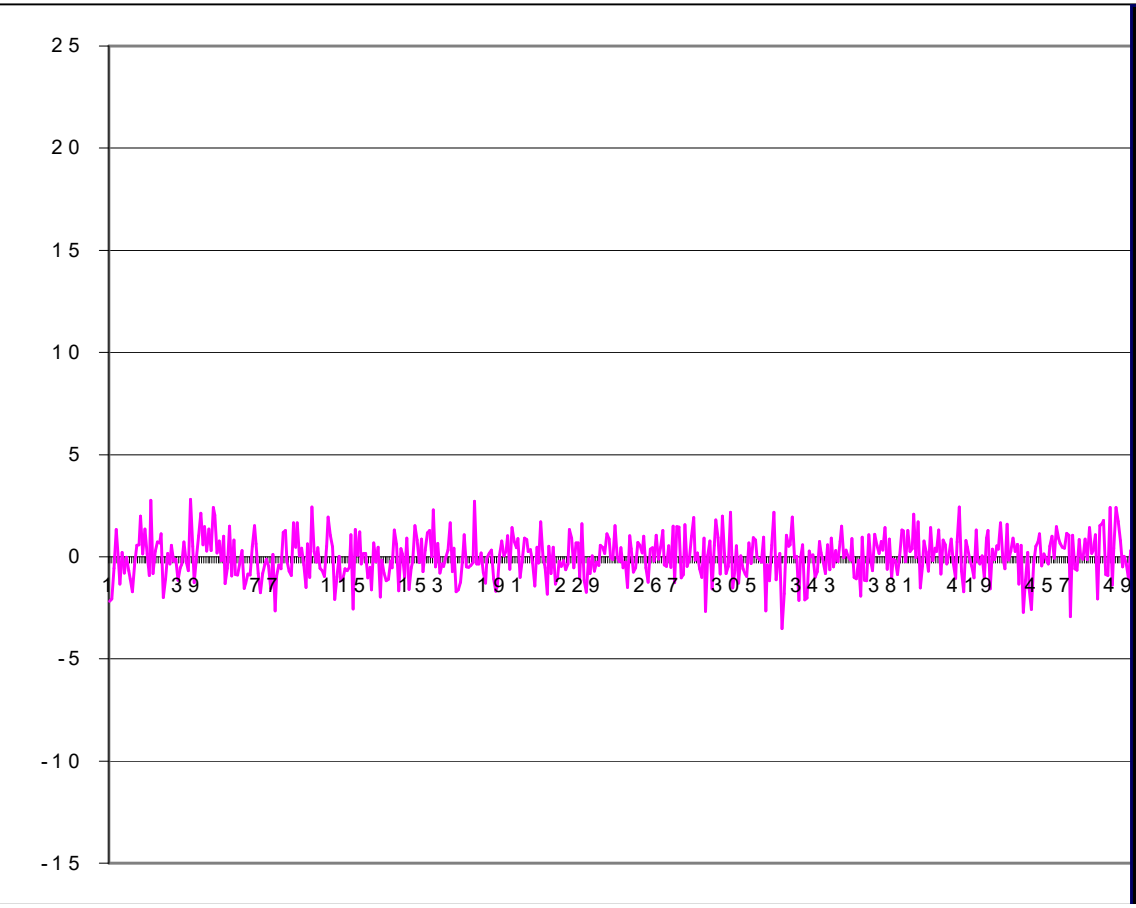


Series: RT	
Sample 1981M02 2001M01	
Observations 240	
Mean	0.008395
Median	0.008532
Maximum	0.154030
Minimum	-0.424631
Std. Dev.	0.053812
Skewness	-2.102938
Kurtosis	19.44229
Jarque-Bera	2880.383
Probability	0.000000

P-value = 0.00 → Rejeita-se H_0 → Distribuição NÃO Normal

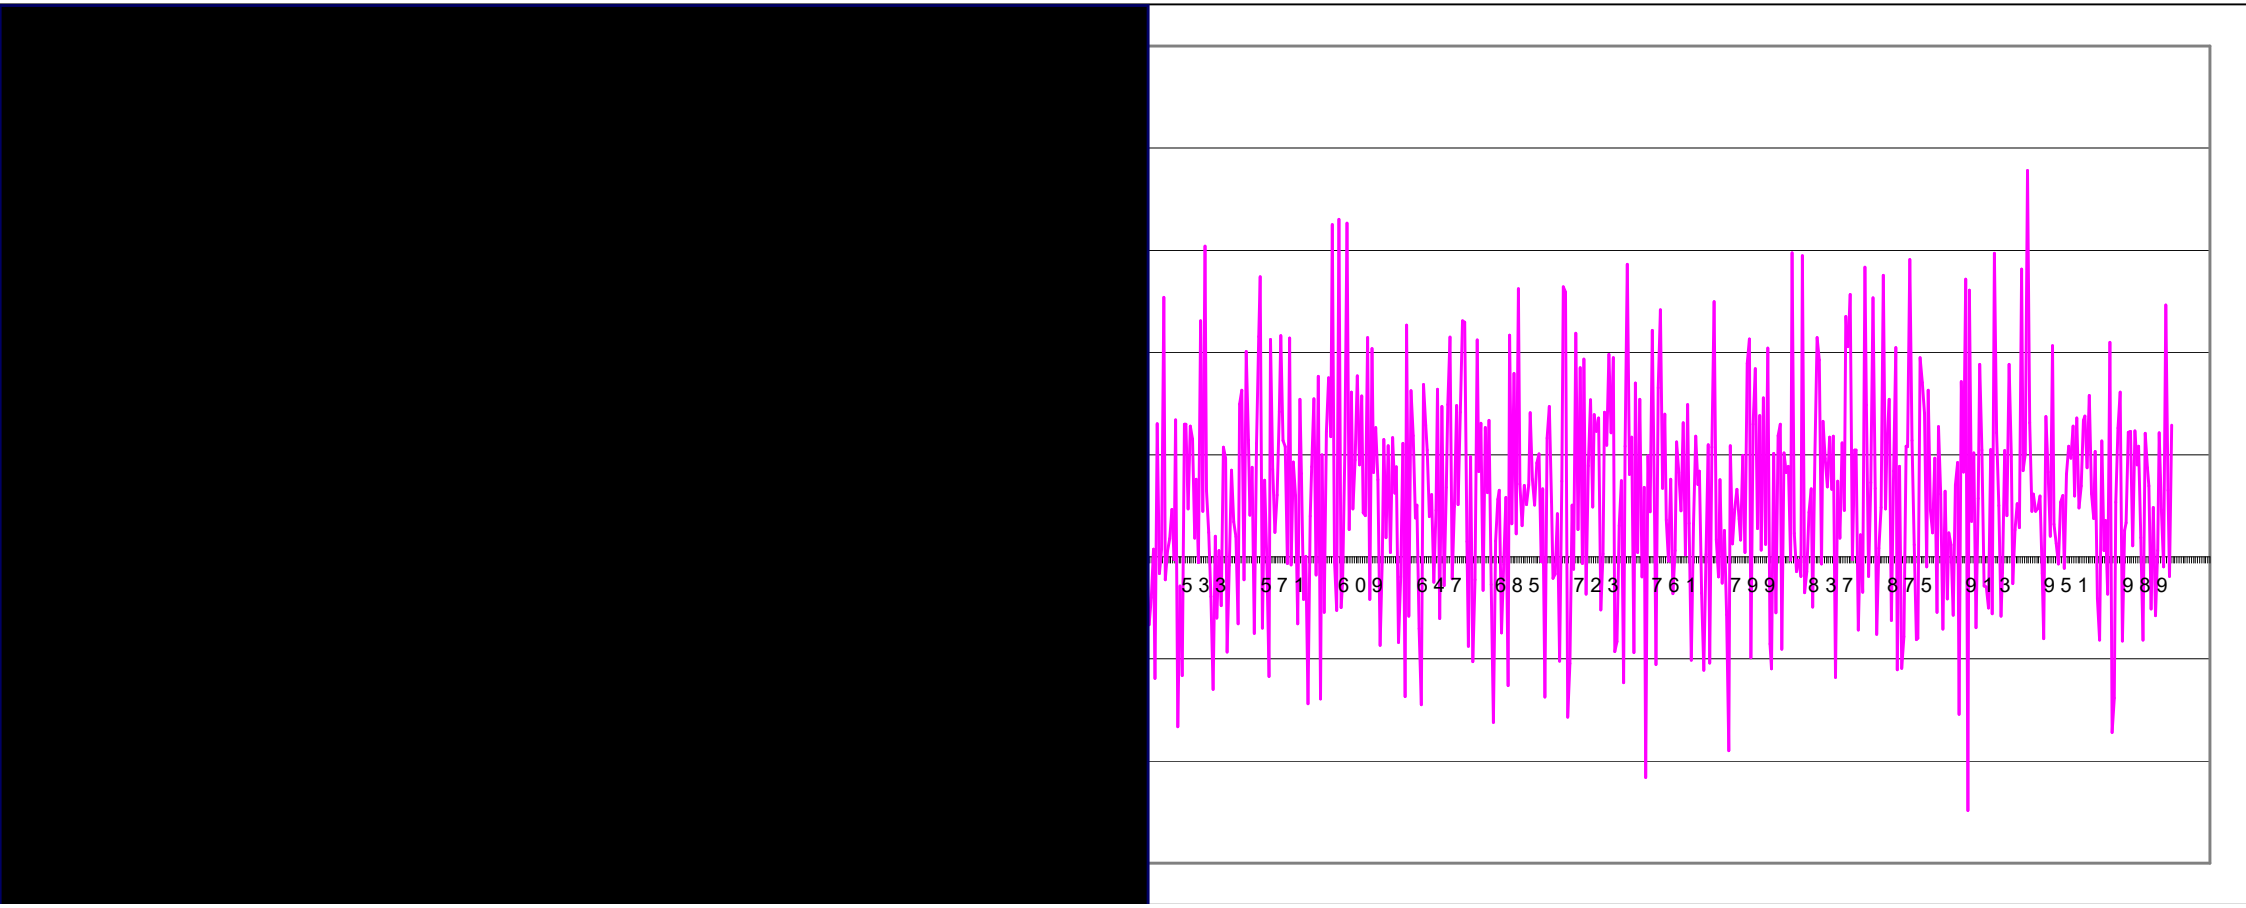
Motivação

Até 1980, acadêmicos e profissionais de mercado financeiro assumiam a hipótese de volatilidade homocedástica (constante) dos retornos



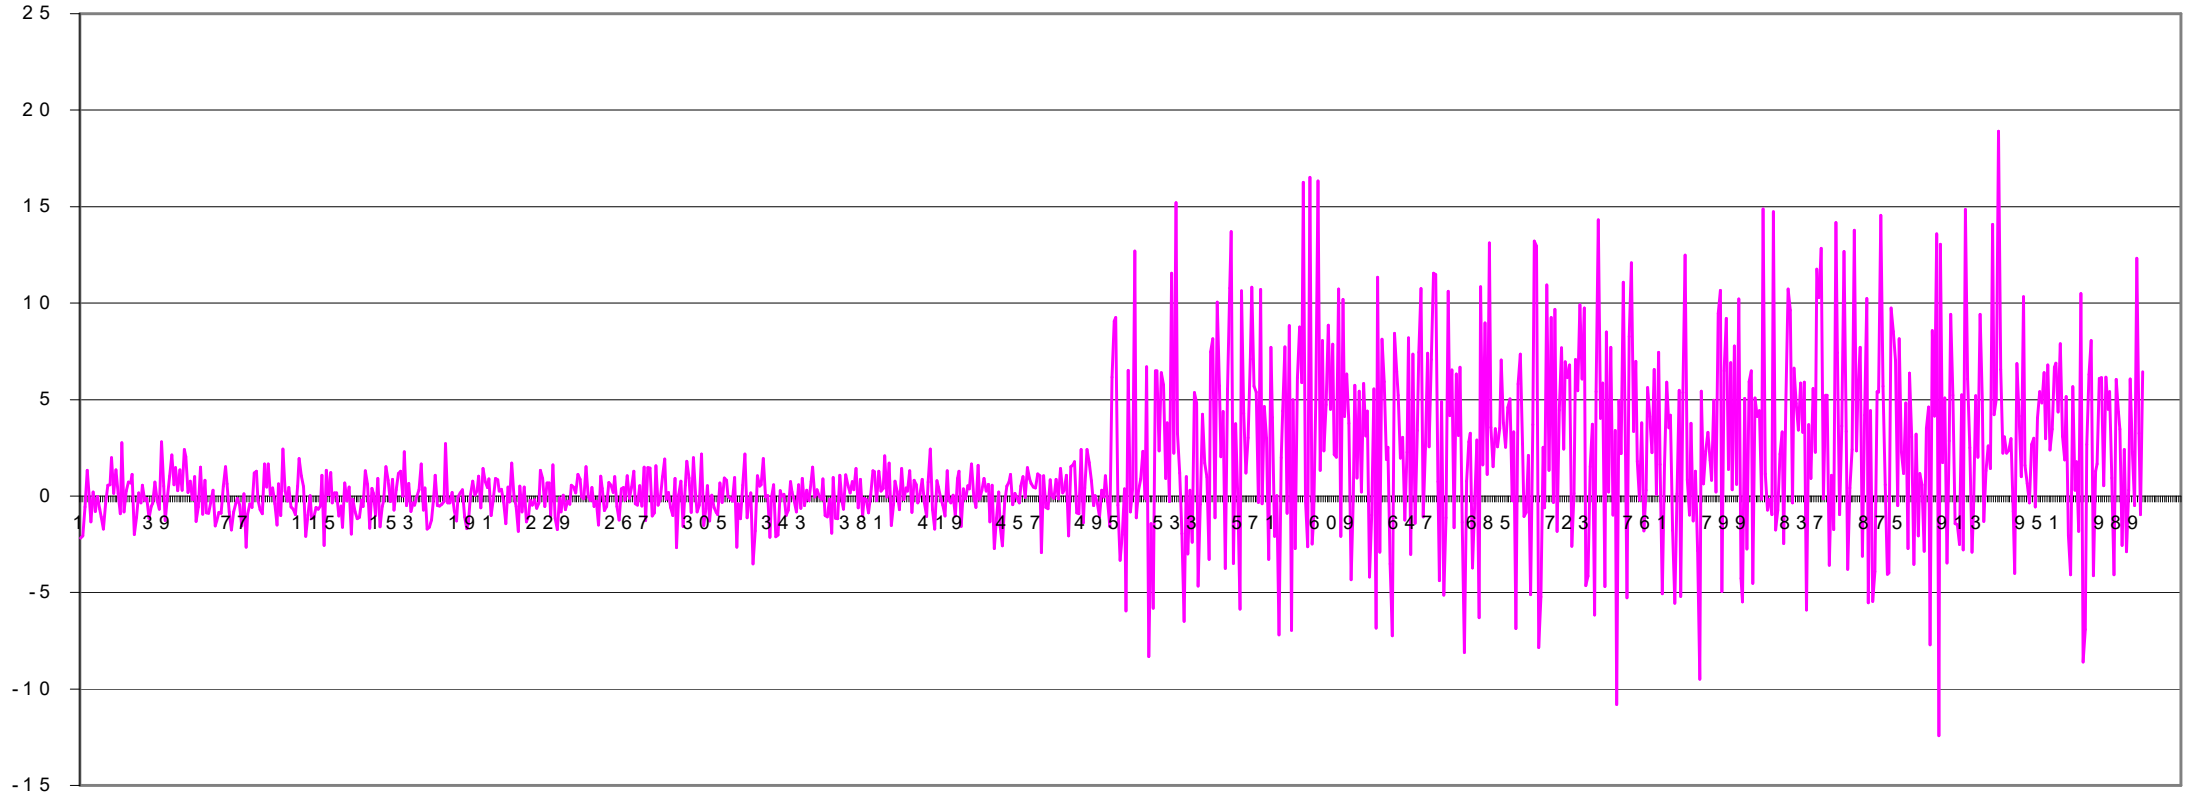
Motivação

Até 1980, acadêmicos e profissionais de mercado financeiro assumiam a hipótese de volatilidade homocedástica (constante) dos retornos



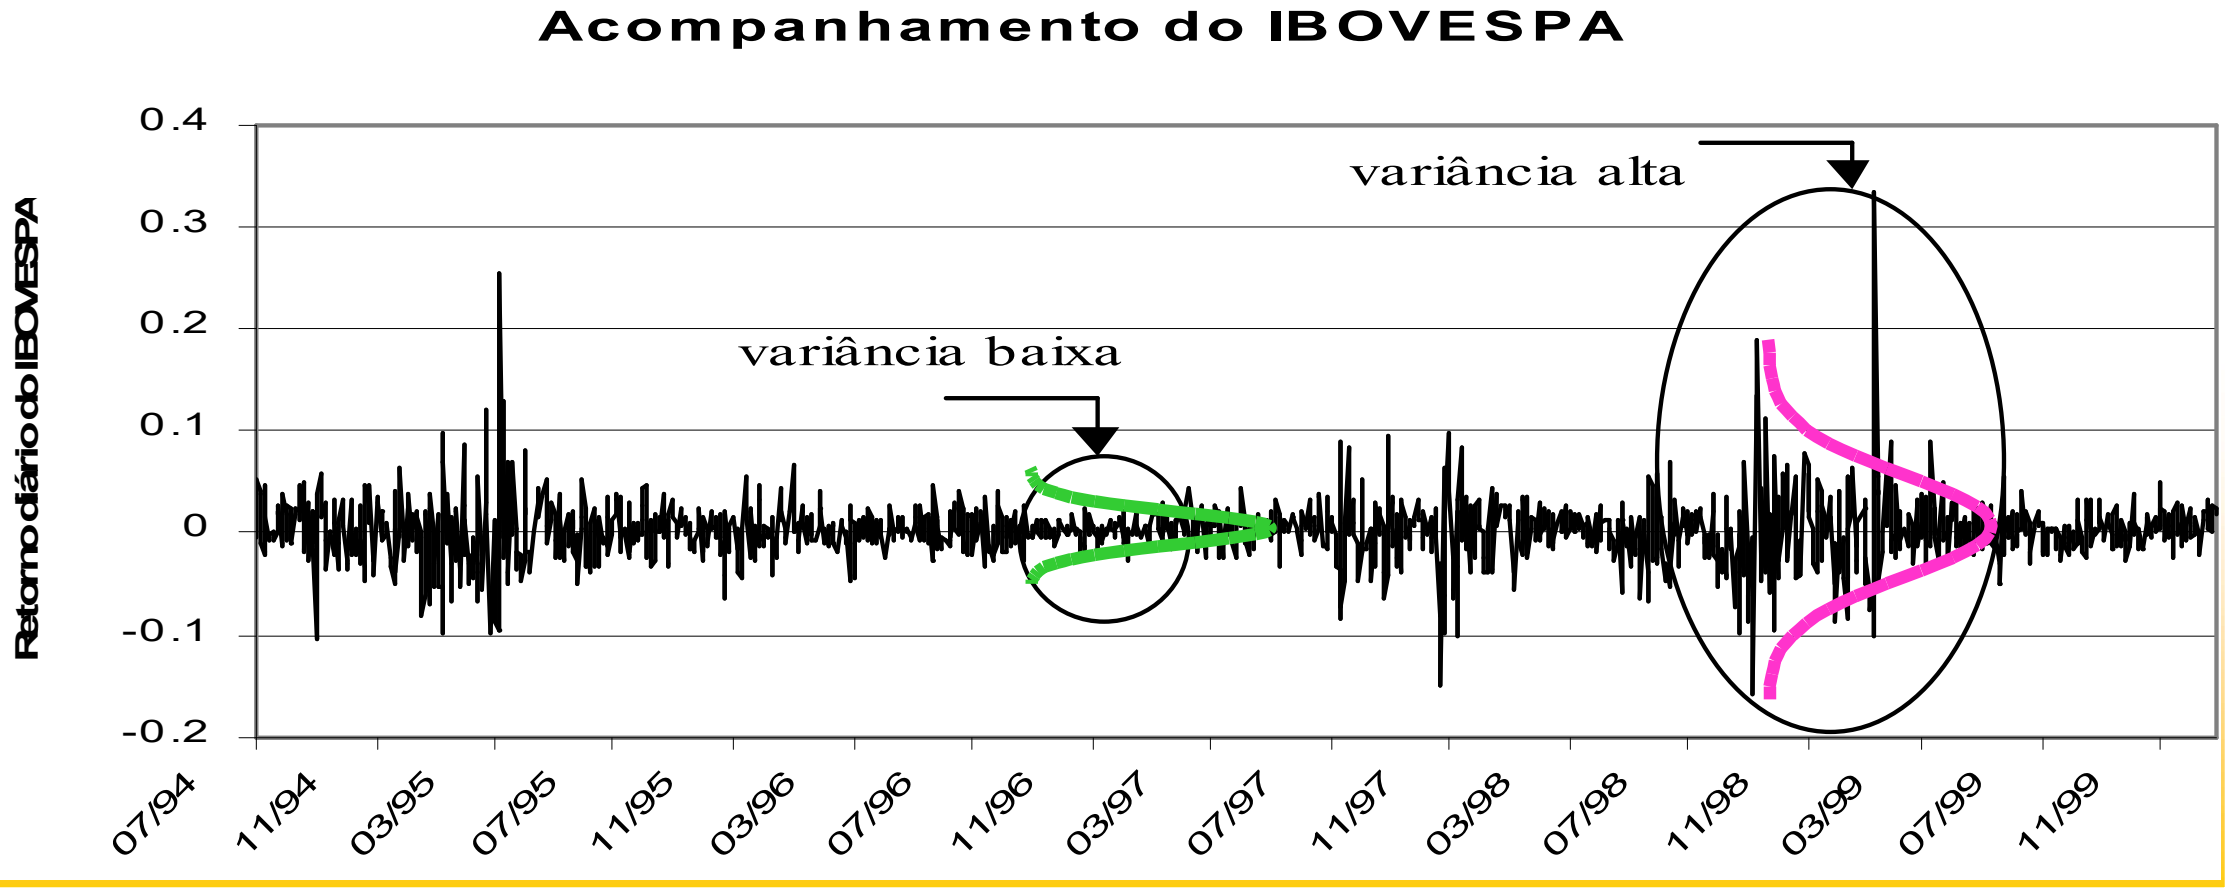
Motivação

Em realidade, a volatilidade nos retornos é HETEROCEDÁSTICA → variável ao longo tempo: pequenas varições nos retornos são seguidas por grandes variações nos retornos e vice-versa.



Variância Heterocedástica

Agrupamentos nos retornos de um ativo implicam em variância não constante → heterocedasticidade.



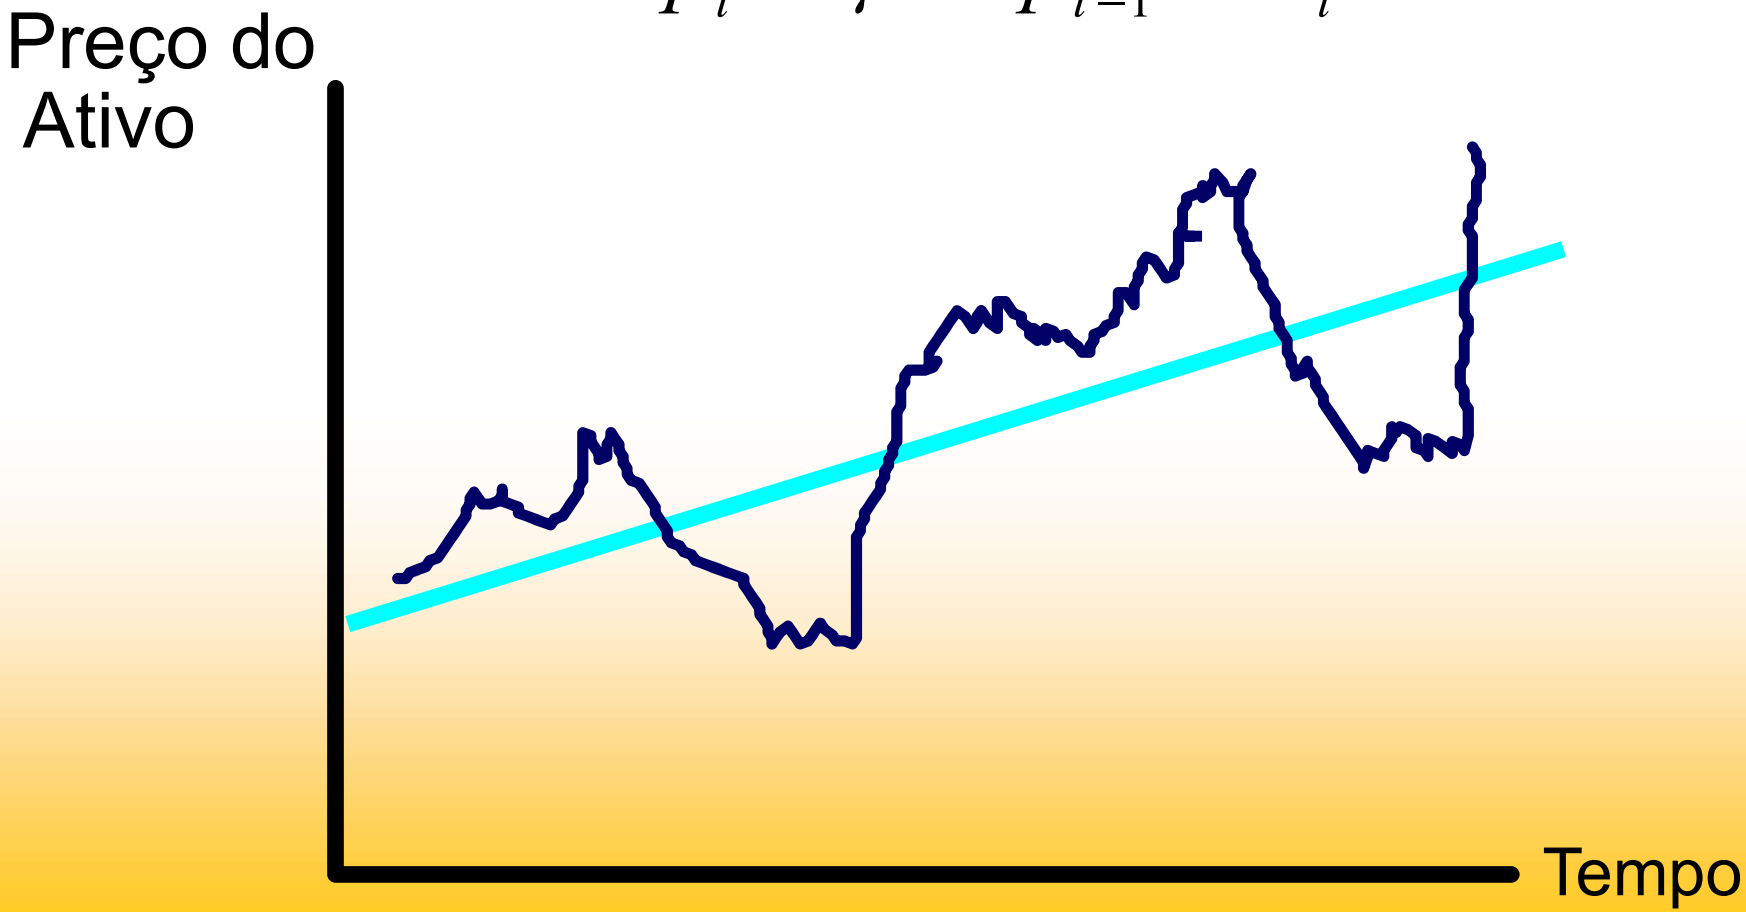
Retornos Autocorrelacionados

- Série temporal dos quadrados dos retornos com significativa autocorrelação
  - aglomerados de volatilidade
- Previsão de preços de ativos financeiros:
  - DIREÇÃO flutuação: DIFÍCIL
  - TAMANHO flutuação: MENOS DIFÍCIL

Fatos Estilizados

- Passeio Aleatório (*Random Walk*)

$$p_t = \mu + p_{t-1} + \sigma_t$$

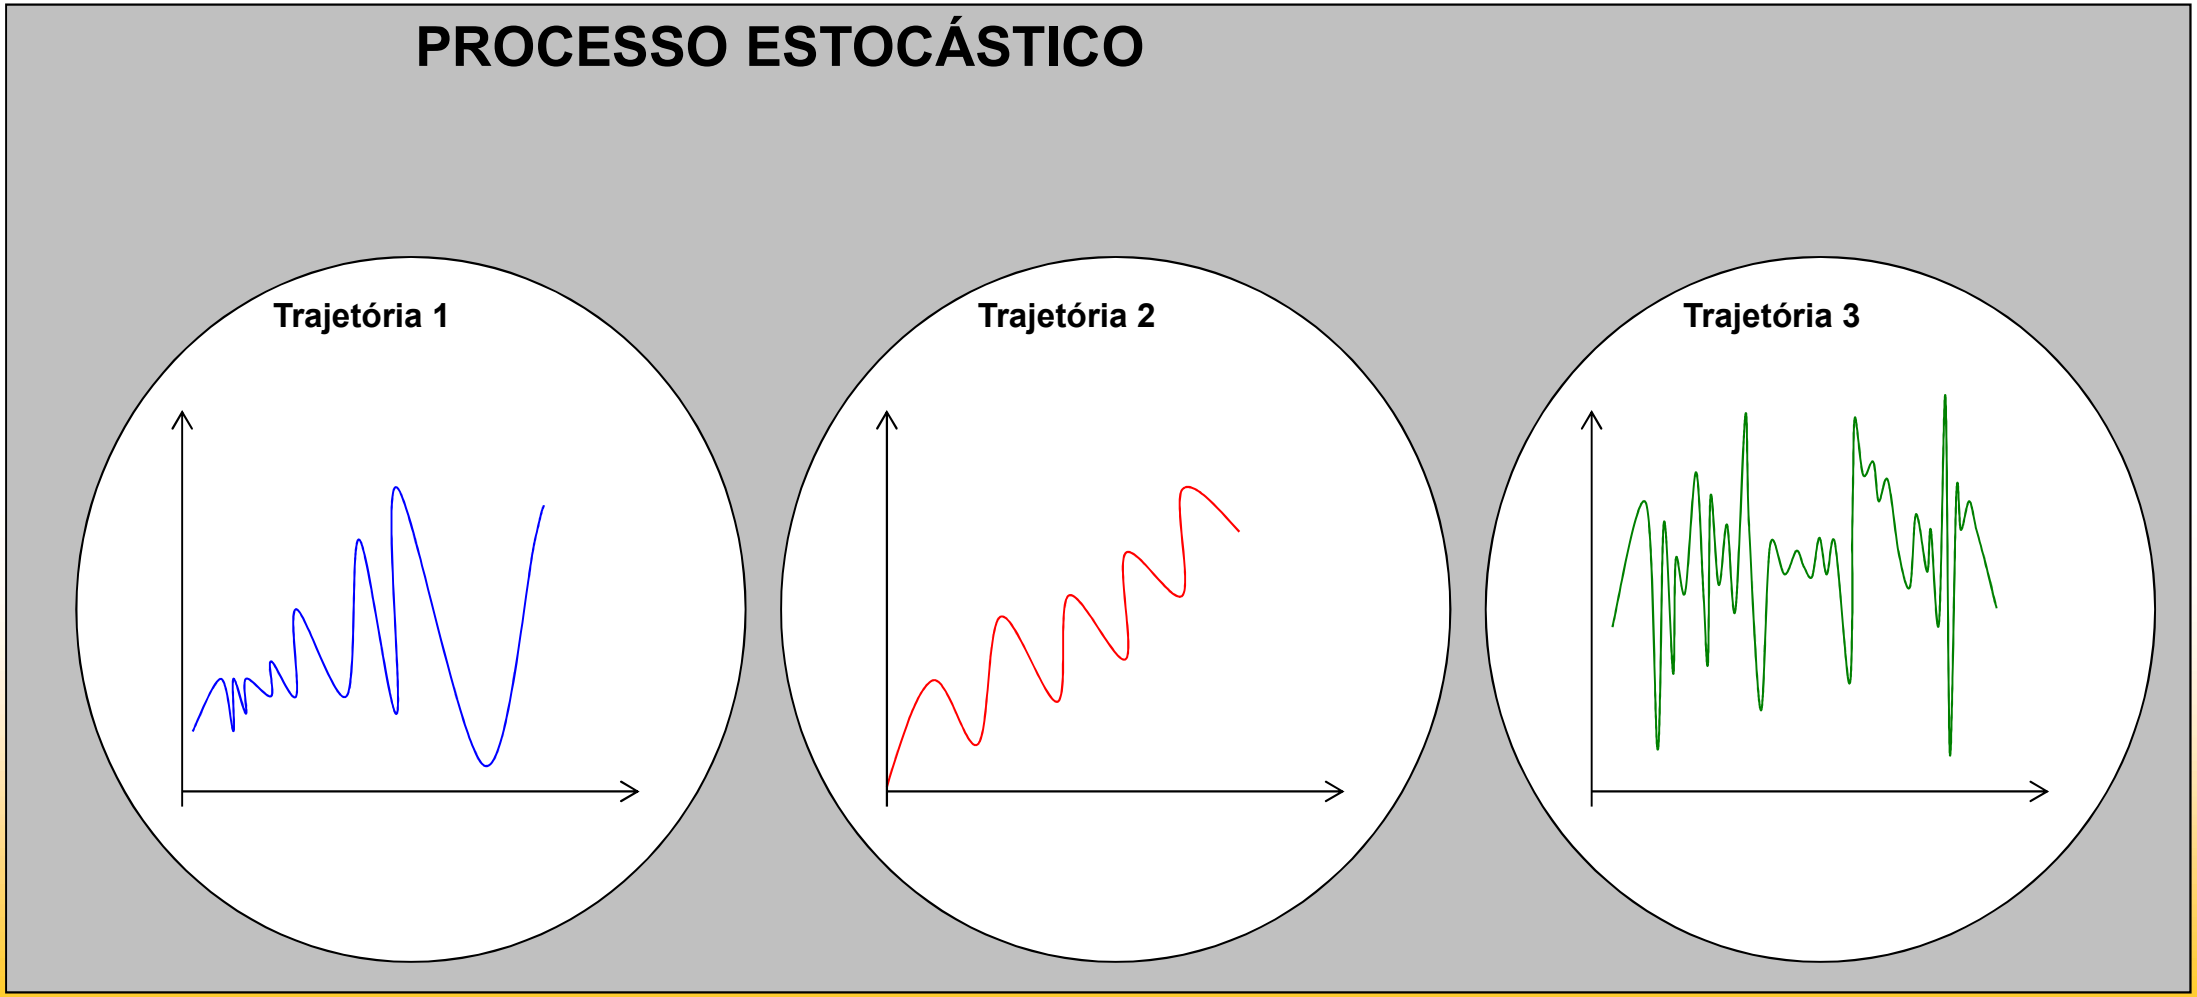


Fatos Estilizados

- Passeio Aleatório (*Random Walk*)
  - $p_t = \mu + p_{t-1} + \sigma_t$
- Variância, σ_t^2, é função do tempo:
  - Processo estocástico com variância condicional
  - Processo estocástico heterocedástico
  - Processo estocástico NÃO estacionário

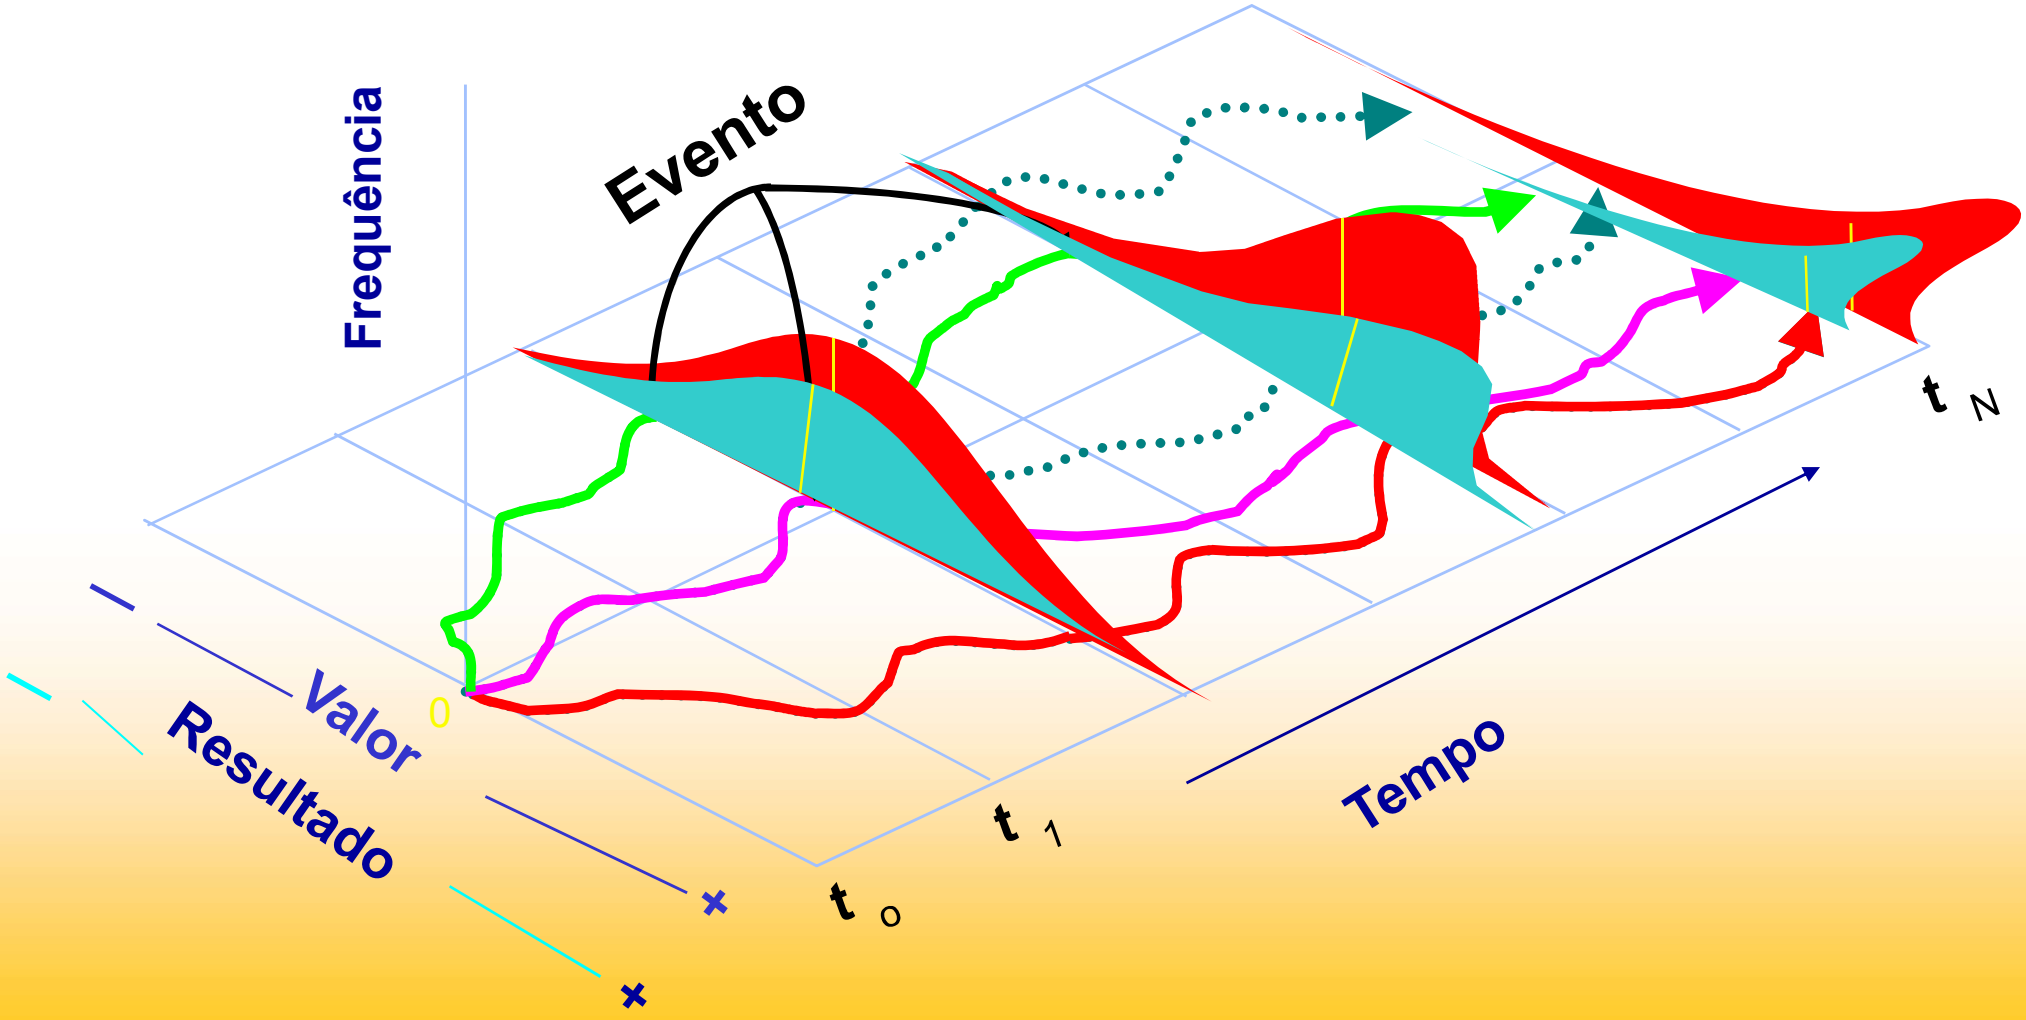
Processos Estocásticos

- Sequência de variáveis aleatórias x_t definidas em um espaço de probabilidades.



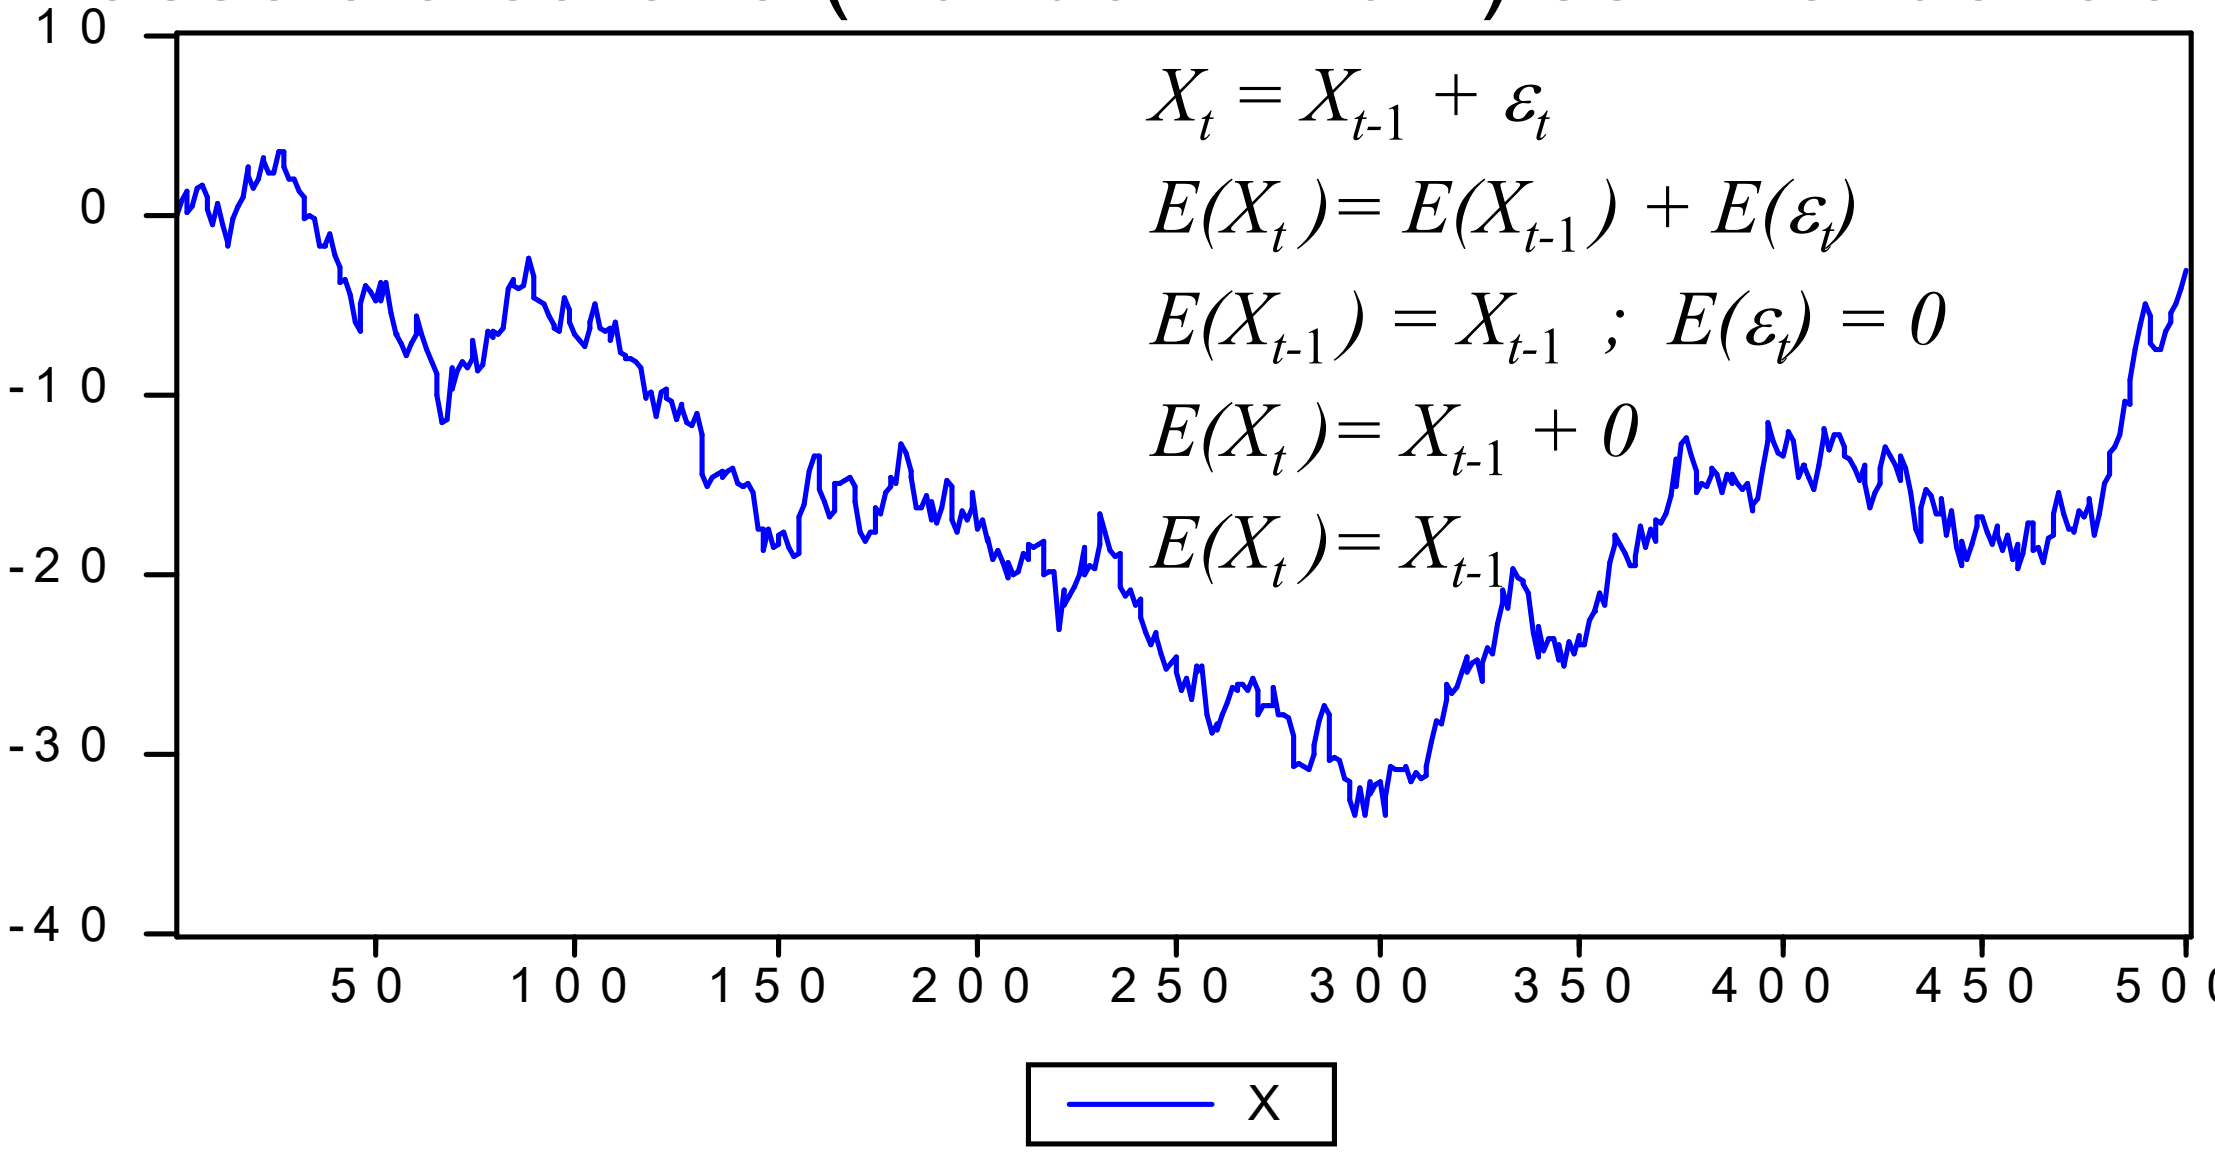
Processos Estocásticos

- Sequências de variável aleatória x_t definidas em um espaço de probabilidades.



Previsão Séries Temporais

Passeio aleatório (*Random Walk*) sem tendência



Previsão Séries Temporais

Média Móvel Ponderada

$$X_t = \frac{(\phi_1 X_{t-1} + \phi_2 X_{t-2} + \ldots + \phi_n X_{t-n})}{(\phi_1 + \phi_2 + \ldots + \phi_n)} = \frac{\sum_{i=1}^{n} \phi_i X_{t-i}}{\sum_{i=1}^{n} \phi_i}$$

Σ = operador somatório

X_t = previsão variável aleatória *X* momento *"t"*

X_{t-i} = observação variável aleatória *X* momento *"t-i"*, tal que $i = 1, 2, \ldots, n$

ϕ_i = peso atribuído à observação do momento *"t-i"*

Previsão Séries Temporais

Média Móvel Ponderada

- Vantagens:
  - Técnica simples e bastante utilizada
  - Parcimônia → requer menor quantidade de dados

- Utilizar quando se objetiva atribuir diferentes pesos às observações passadas
  - Dado que $0 \leq \phi_i \leq 1$, então:
    - ✓Quando X for relativamente estável: $\phi_1 < \phi_2 < \ldots < \phi_n$
    - ✓Quando X for relativamente instável: $\phi_1 > \phi_2 > \ldots > \phi_n$

- Cuidado: Necessário conhecer o processo gerador de dados para atribuir os diferentes pesos.

Previsão Séries Temporais

Exemplo

Foram observados os seguintes valores de uma ação na 6a.-feira das últimas 5 semanas: X = {23; 22; 25; 24; 23}

Realize previsão do valor da ação para a 6a.-feira desta semana, conforme os seguintes métodos:

i) passeio aleatório sem tendência

ii) média móvel simples

iii) média móvel ponderada1: ϕ = {35%; 25%; 20%; 15%; 5%}

iv) média móvel ponderada2: ϕ = {5%; 15%; 20%; 25%; 35%}

Previsão Séries Temporais

Passeio Aleatório

$$X_t = X_{t-1} + \varepsilon_t$$

$$E(X_t) = E(X_{t-1}) + E(\varepsilon_t)$$

$$E(X_{t-1}) = X_{t-1} = 23$$

$$E(\varepsilon_t) = 0$$

$$E(X_t) = 23 + 0$$

$$E(X_t) = 23{,}0$$

Média Móvel Simples

$$X_t = \left(\sum_{i=1}^{n} X_{t-i}\right) \div n$$

$$E(X_t) = X_{t-1} + X_{t-2} + X_{t-3} + X_{t-4} + X_{t-5}$$

$$E(X_t) = (23 + 22 + 25 + 24 + 23) \div 5$$

$$E(X_t) = 23{,}4$$

Previsão Séries Temporais

Média Ponderada 1

$$X_t = (\sum_{i=1}^{n} \phi_i \, X_{t-i}) \div (\sum_{i=1}^{n} \phi_i)$$

$\Sigma\phi_i \, X_{t-i} = \phi_1 \, X_{t-1} + \phi_2 \, X_{t-2} + \phi_3 \, X_{t-3} + \phi_4 \, X_{t-4} + \phi_5 \, X_{t-5} =$
$= 35\% x 23 + 25\% x 22 + 20\% x 25 + 15\% x 24 + 5\% x 23$

$\Sigma\phi_i \, X_{t-i} = 23,3$

$\Sigma\phi_i = = \phi_1 + \phi_2 + \phi_3 + \phi_4 + \phi_5$

$\Sigma\phi_i = 35\% + 25\% + 20\% + 15\% + 5\% = 100\% = 1$

$E(X_t) = (\Sigma\phi_i \, X_{t-i}) \div (\Sigma\phi_i) = 23,3 \div 1$

$E(X_t) = 23,3$

Média Ponderada 2

$$X_t = (\sum_{i=1}^{n} \phi_i \, X_{t-i}) \div (\sum_{i=1}^{n} \phi_i)$$

$\Sigma\phi_i \, X_{t-i} = \phi_1 \, X_{t-1} + \phi_2 \, X_{t-2} + \phi_3 \, X_{t-3} + \phi_4 \, X_{t-4} + \phi_5 \, X_{t-5} =$
$= 5\% x 23 + 15\% x 22 + 20\% x \; 25 + 25\% x 24 + 35\% \; x 23$

$\Sigma\phi_i \, X_{t-i} = 23,3$

$\Sigma\phi_i = = \phi_1 + \phi_2 + \phi_3 + \phi_4 + \phi_5$

$\Sigma\phi_i = 5\% + 15\% + 20\% + 25\% + 35\% = 100\% = 1$

$E(X_t) = (\Sigma\phi_i \, X_{t-i}) \div (\Sigma\phi_i) = 23,3 \div 1$

$E(X_t) = 23,5$

Previsão Séries Temporais

Exemplo - Resultados

i) passeio aleatório sem tendência: $ 23,00

ii) média móvel simples: $ 23,40

iii) média móvel ponderada 1: $ 23,30

iv) média móvel ponderada 2: $ 23,50

Qual é o correto???

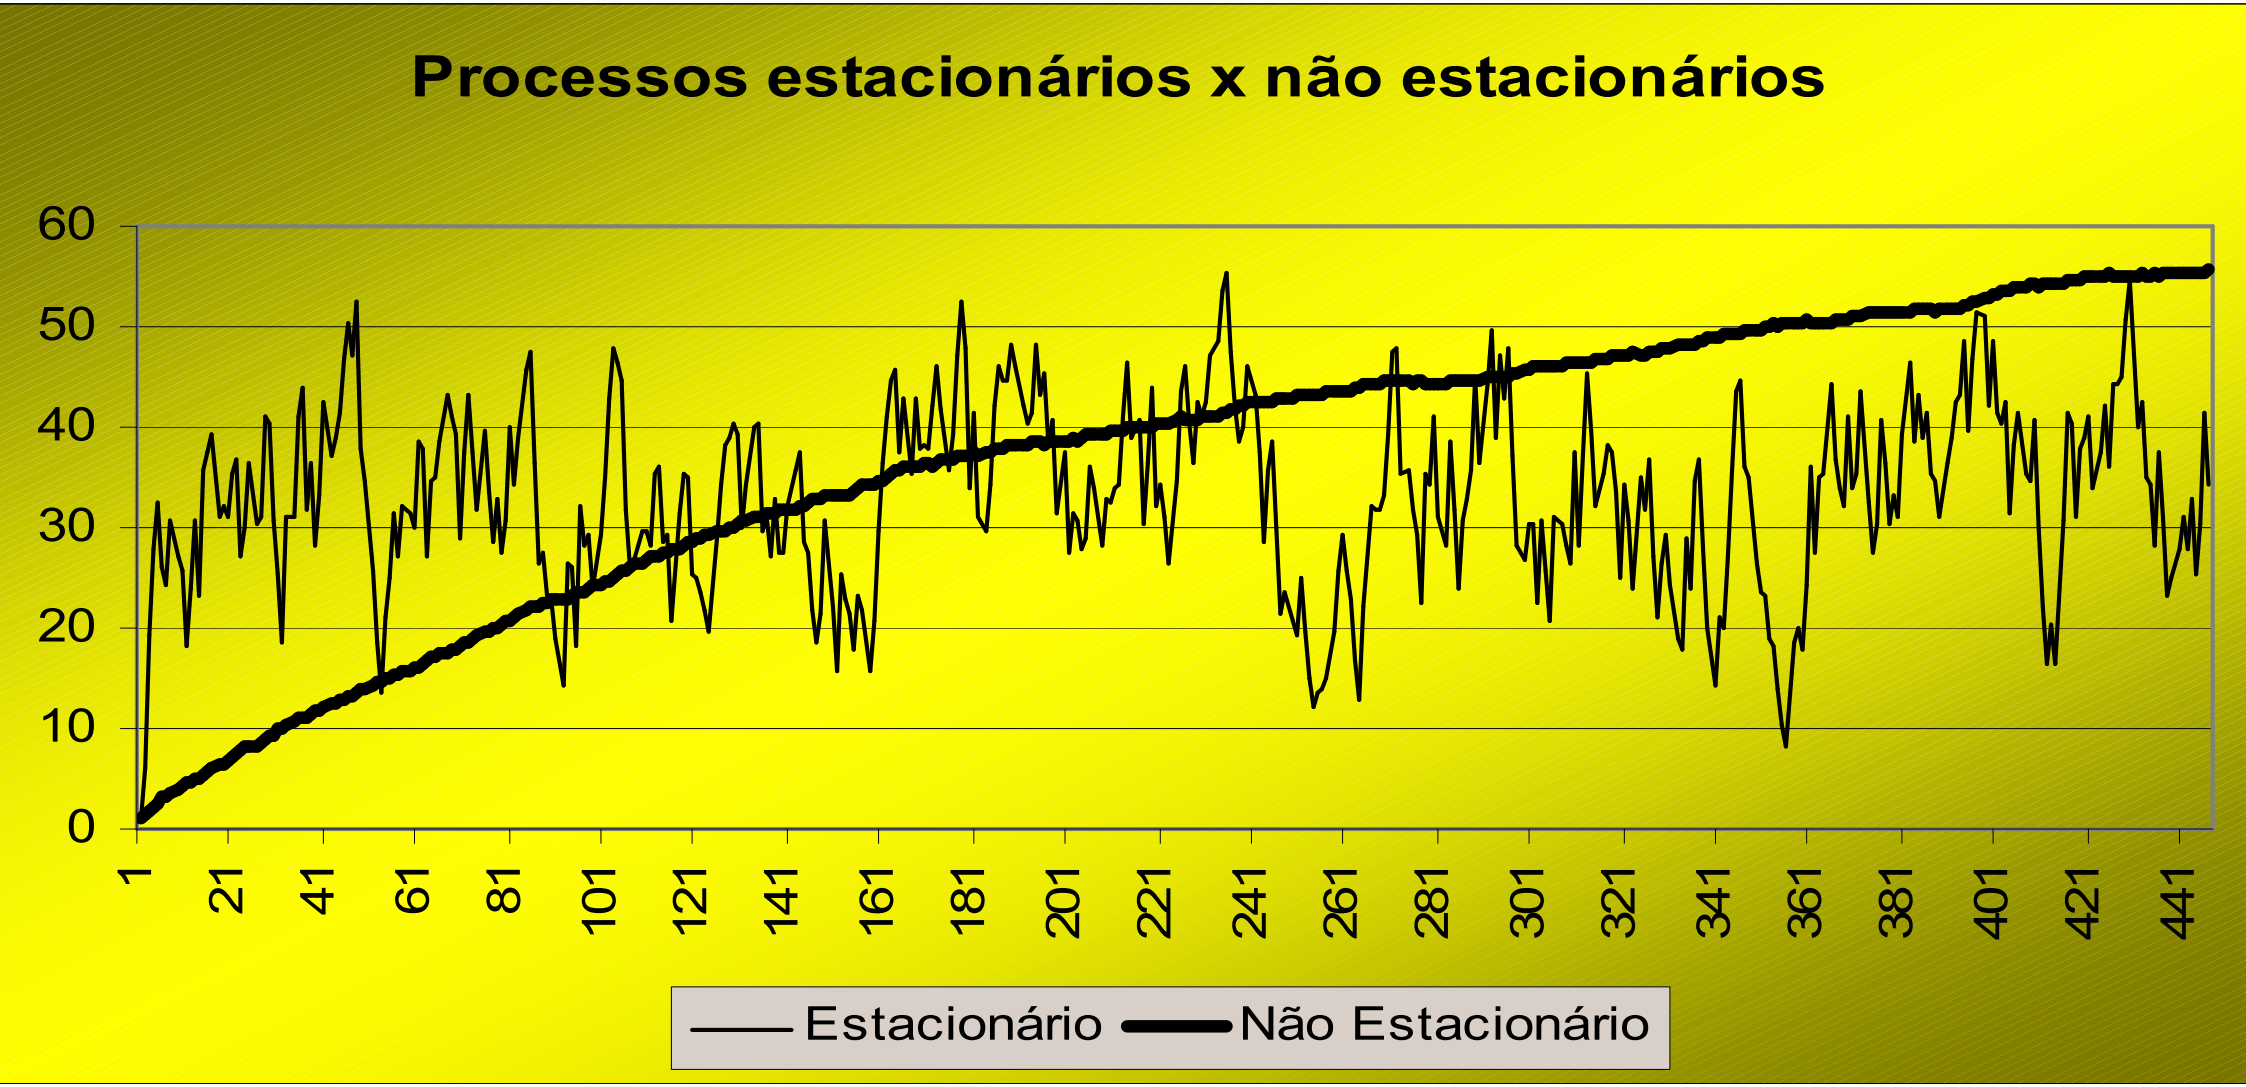
Estatística Aplicada

Aula 11 - Agenda

Estacionariedade

Estacionariedade

Condição para realizar previsões



Estacionariedade

Condição para realizar previsões

- Importância 1:
  - Hipóteses do método de Mínimos Quadrados Ordinários
- Importância 2:
  - Regressão Espúria

Estacionariedade

Condição para realizar previsões

- Na especificação de modelos de regressão, é preciso evitar relacionar séries temporais não estacionárias.
- Fundamental testar se uma série é estacionária ou não, antes de usá-la em uma regressão.

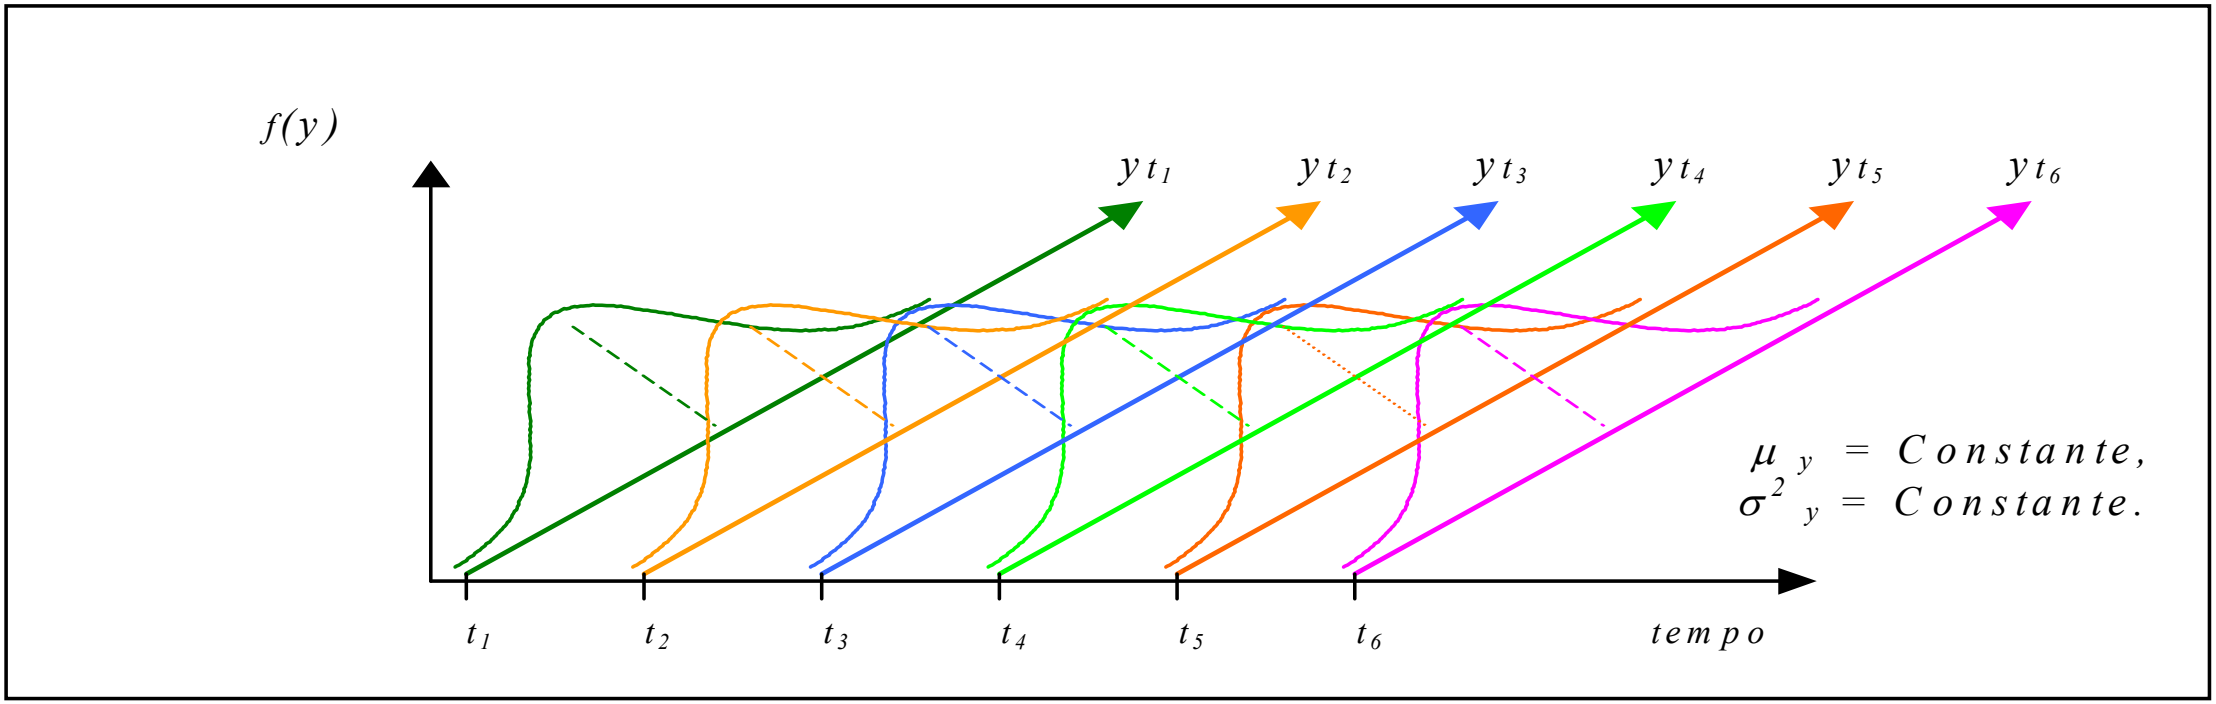
Estacionariedade

Importância 1: Hipóteses do Método

- Uso de variáveis NÃO-estacionárias
  - Violação das hipóteses do método de Mínimos Quadrados Ordinários
    - ✓ Testes estatísticos usuais não válidos para atestar a qualidade dos estimadores amostrais dos parâmetros populacionais

Série Temporal Estacionária

Uma série temporal é dita estacionária se suas propriedades estatísticas não mudam com o tempo.

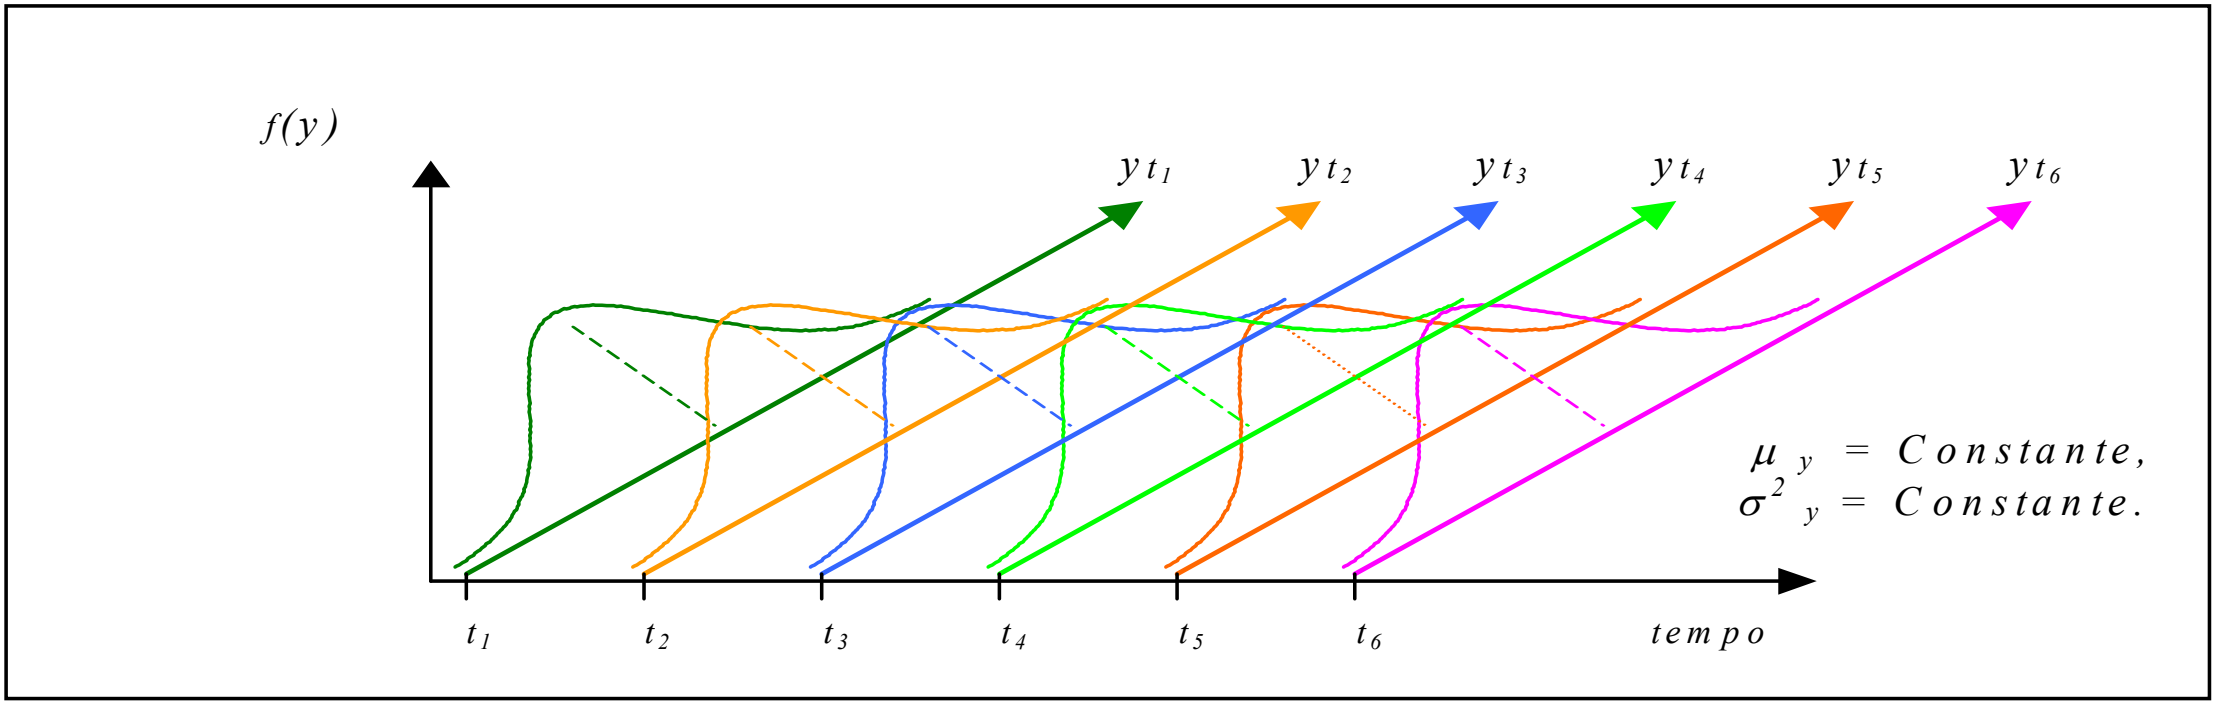


Série Temporal Estacionária

$E(Y_t) = \mu_Y \rightarrow$ constante; $\forall t,\ t = 1, 2, \ldots, n.$

$Var(Y_t) = \sigma^2_Y \rightarrow$ constante; $\forall t,\ t = 1, 2, \ldots, n.$

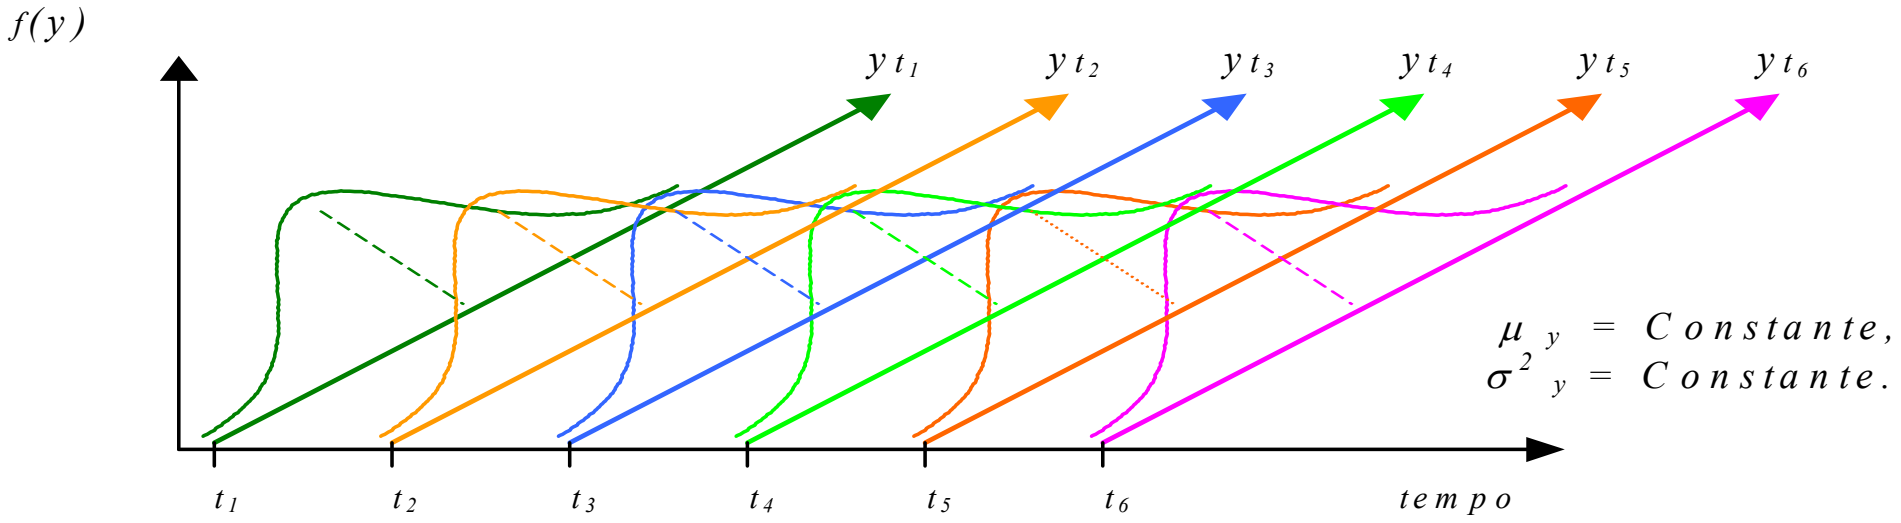
$Cov(Y_t, Y_{t+k}) = \gamma_k \rightarrow$ constante; $\forall t,\ t = 1, 2, \ldots, n;\ 0 \leq k \leq (n-1)$



Série Temporal Estacionária

$Cov(Y_t, Y_{t+k}) = \gamma_k \;;\; \forall t,\ t = 1, 2, \ldots, n;\ 0 \leq k \leq (n-1).$

A covariância entre valores defasados da série depende apenas da defasagem, isto é, da "*distância*" temporal entre eles.



Série Temporal Estacionária

$$Cov(Y_t, Y_{t+4}) = \gamma_4 \rightarrow \text{constante}$$

$$Cov(Y_{10}, Y_{14}) = Cov(Y_{13}, Y_{17}) = Cov(Y_{16}, Y_{20})$$

$$Cov(Y_t, Y_{t+6}) = \gamma_6 \rightarrow \text{constante}$$

$$Cov(Y_{10}, Y_{16}) = Cov(Y_{13}, Y_{19}) = Cov(Y_{16}, Y_{22})$$

Série Temporal Estacionária

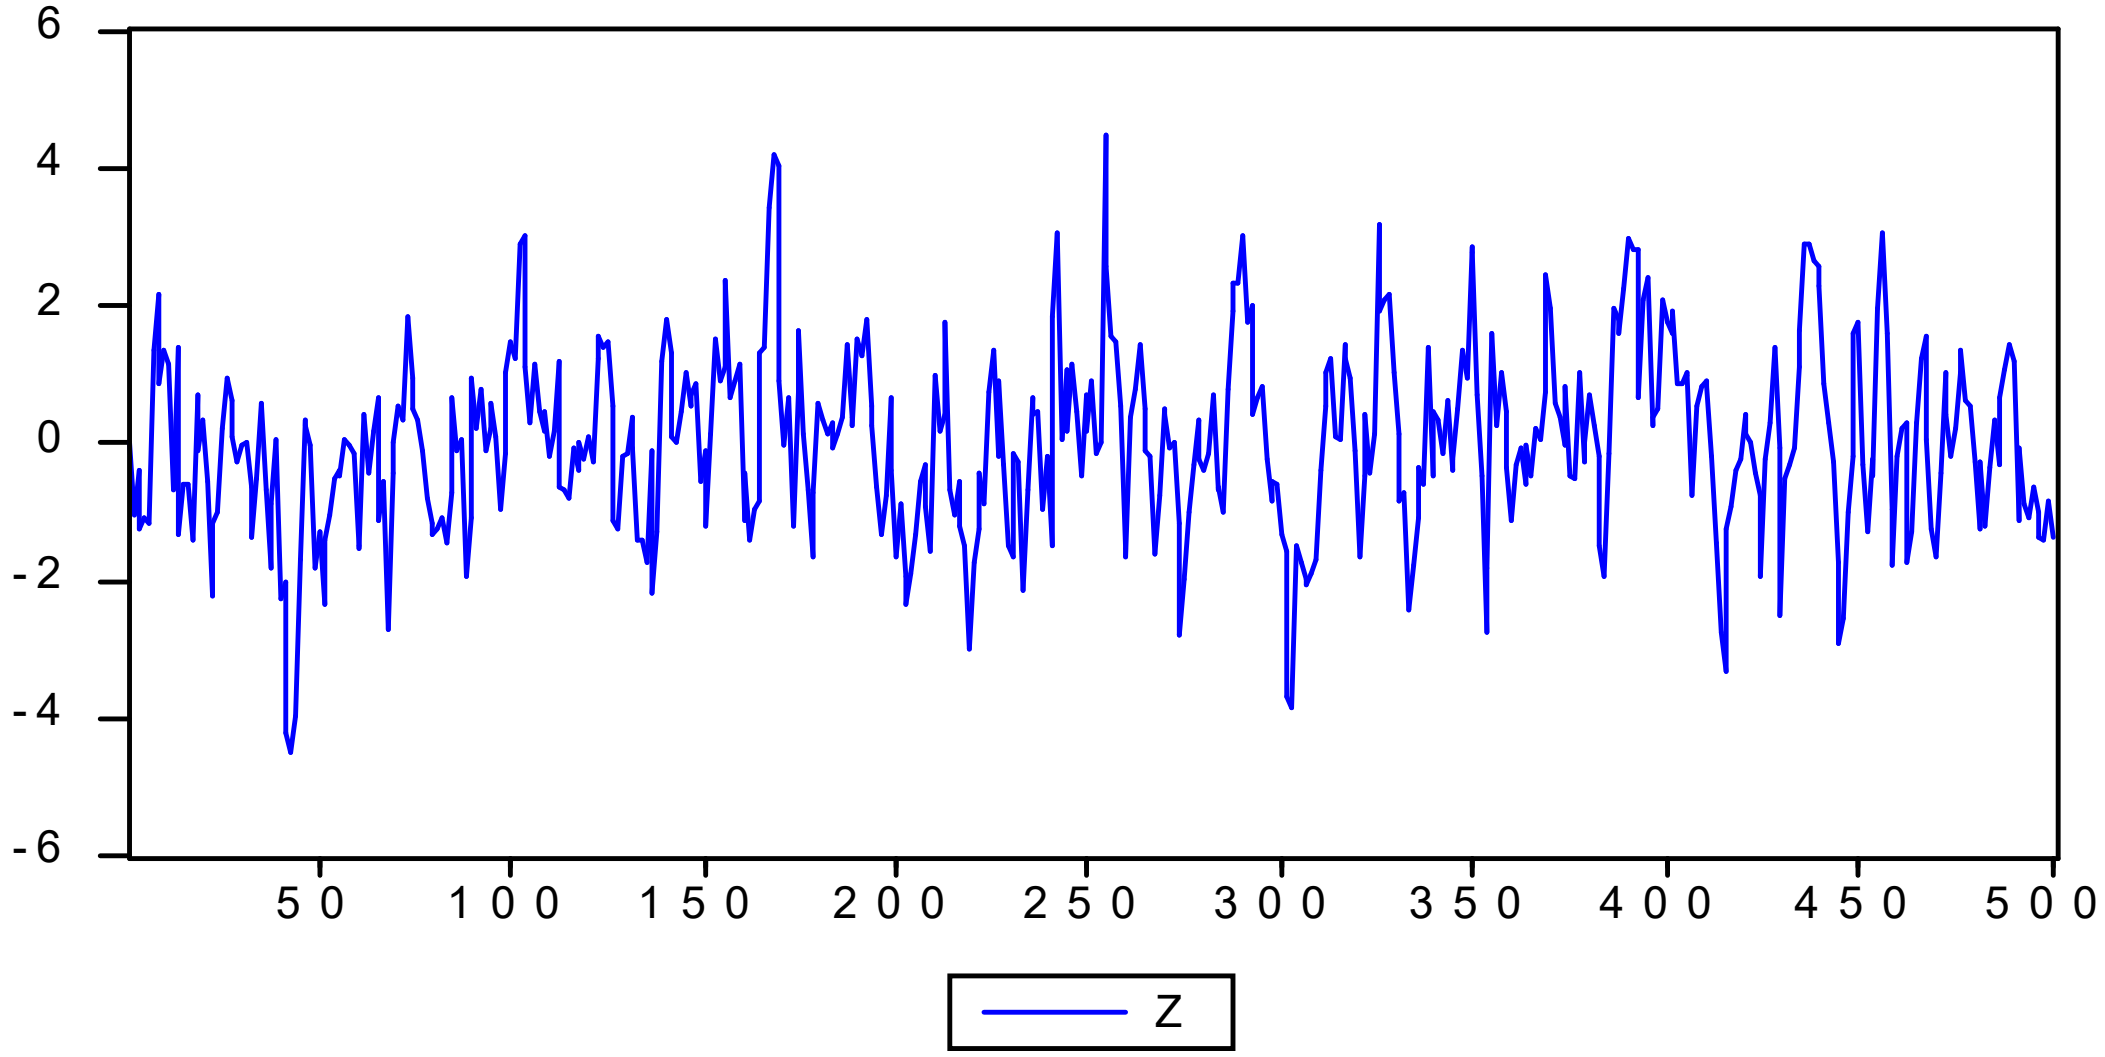
$$Cov(Y_t, Y_{t+k}) = \gamma_k \;;\; \forall t,\ t = 1, 2, \ldots, n;\ 0 \leq k \leq (n-1).$$

- Significa que se, por exemplo, $\gamma_1 > 0$, então um valor "alto" de Y no presente momento provavelmente será seguido de um valor também alto de Y no próximo momento.

- A hipótese de que os γ_k sejam estáveis no tempo, permite que se use essa informação para prever valores futuros da série.

Série temporal estacionária

Processo de Ruído Branco

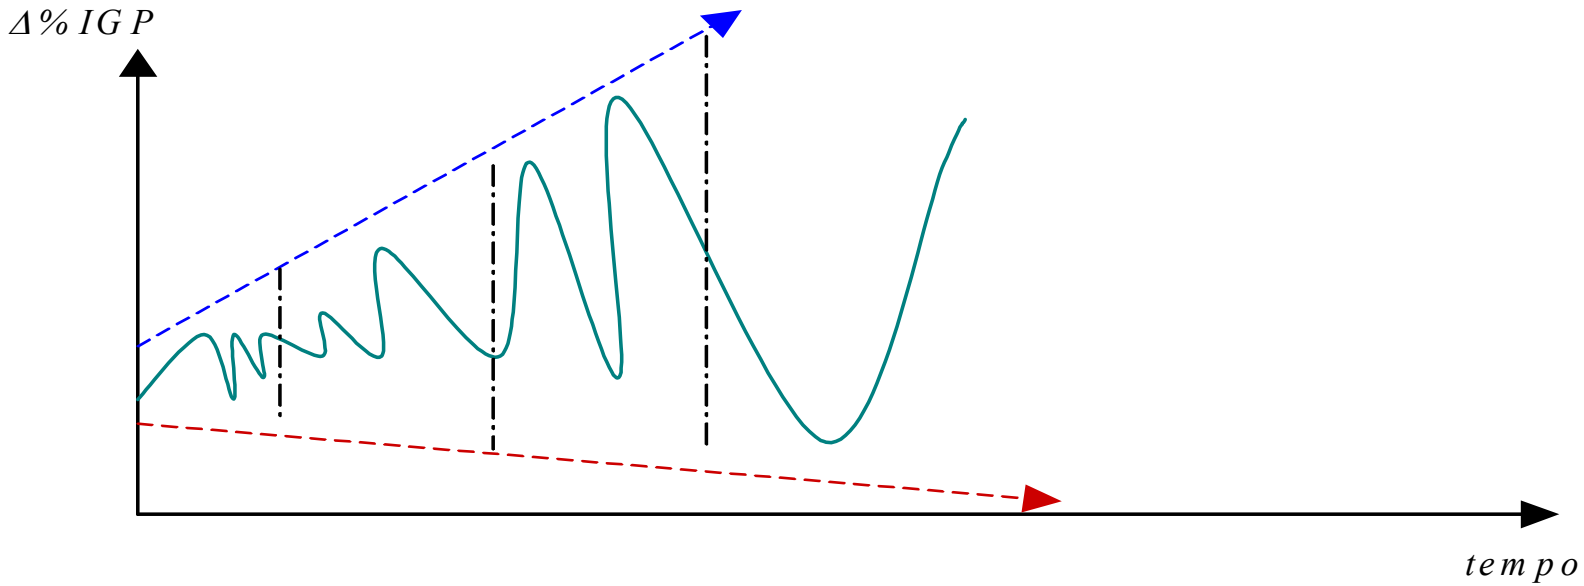


Série Temporal NÃO-Estacionária

$E(Y_t) = f(t) \rightarrow$ NÃO-constante; e/ou,

$Var(Y_t) = g(t) \rightarrow$ NÃO-constante; e/ou,

$Cov(Y_t, Y_{t+k}) = \gamma(t) \rightarrow$ NÃO-constante; $k \neq 0$.

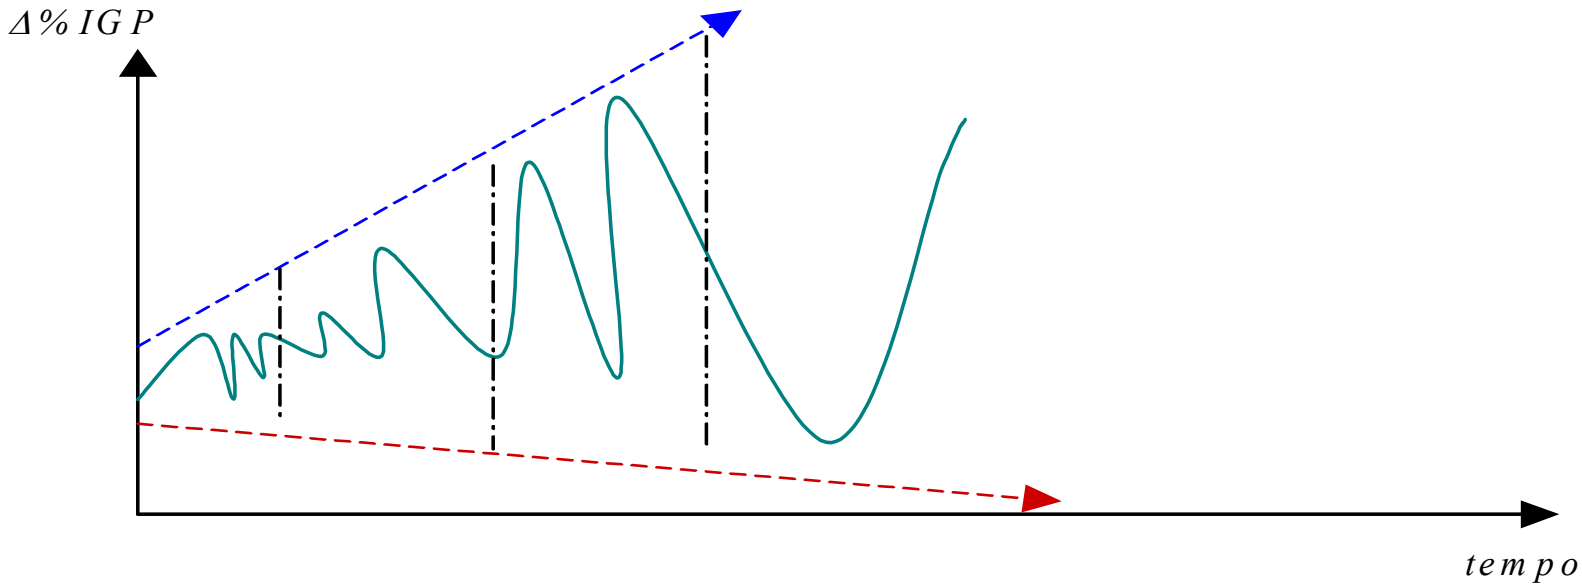


Série Temporal NÃO-Estacionária

A média varia ao longo da série.

A variância varia ao longo da série

Se a tendência for não-linear, as covariâncias também se alterarão ao longo do tempo.

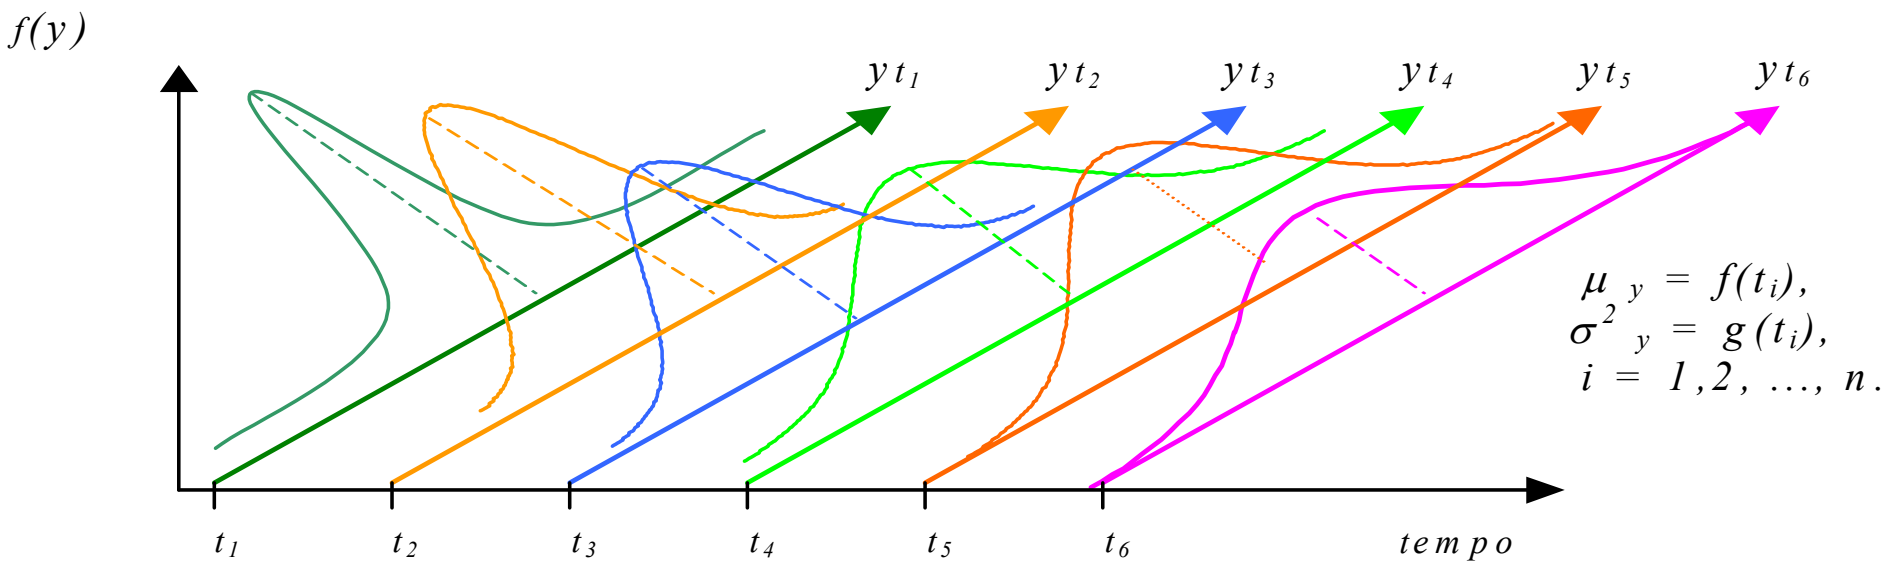


Série Temporal NÃO-Estacionária

$E(Y_t) = f(t) \rightarrow$ NÃO-constante; e/ou,

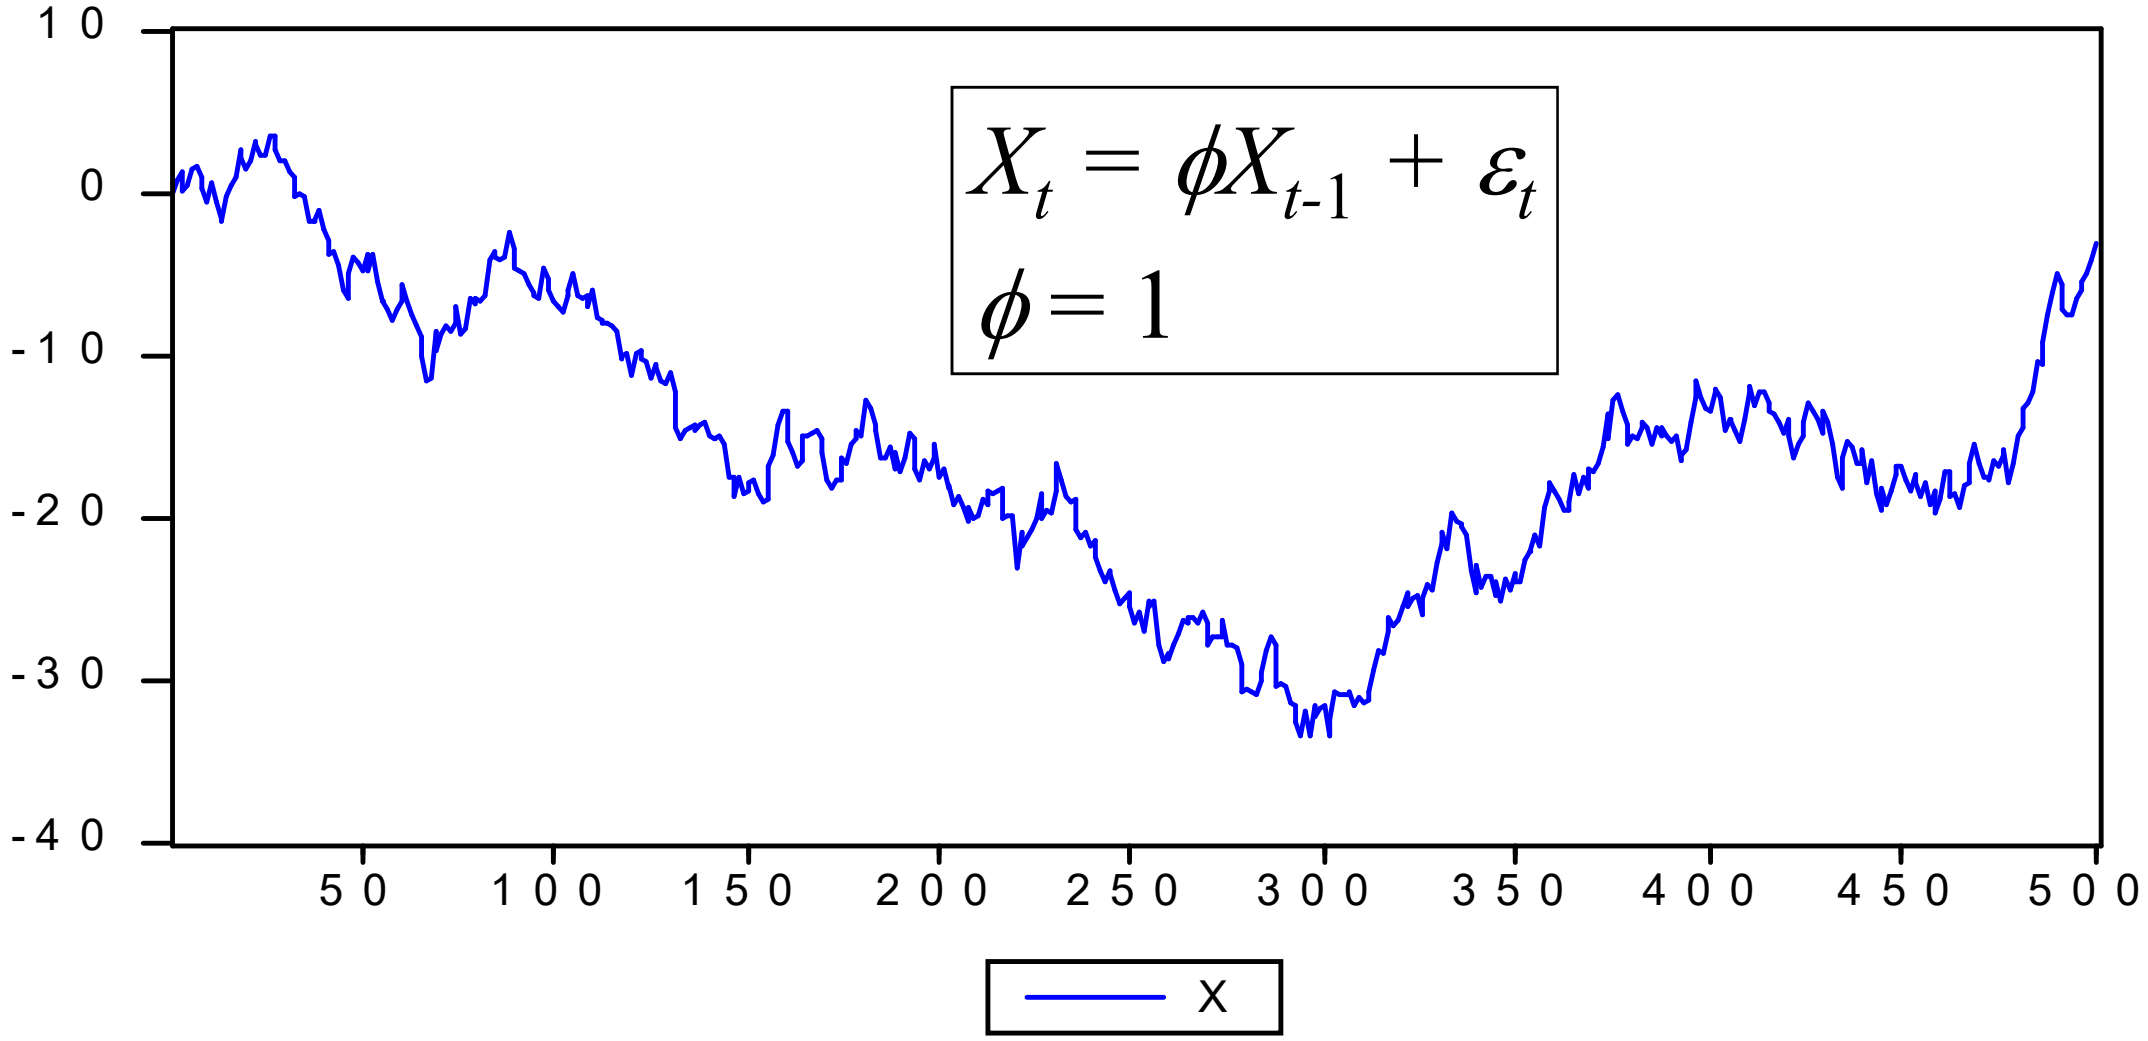
$Var(Y_t) = g(t) \rightarrow$ NÃO-constante; e/ou,

$Cov(Y_t, Y_{t+k}) = \gamma(t) \rightarrow$ NÃO-constante; $k \neq 0$.



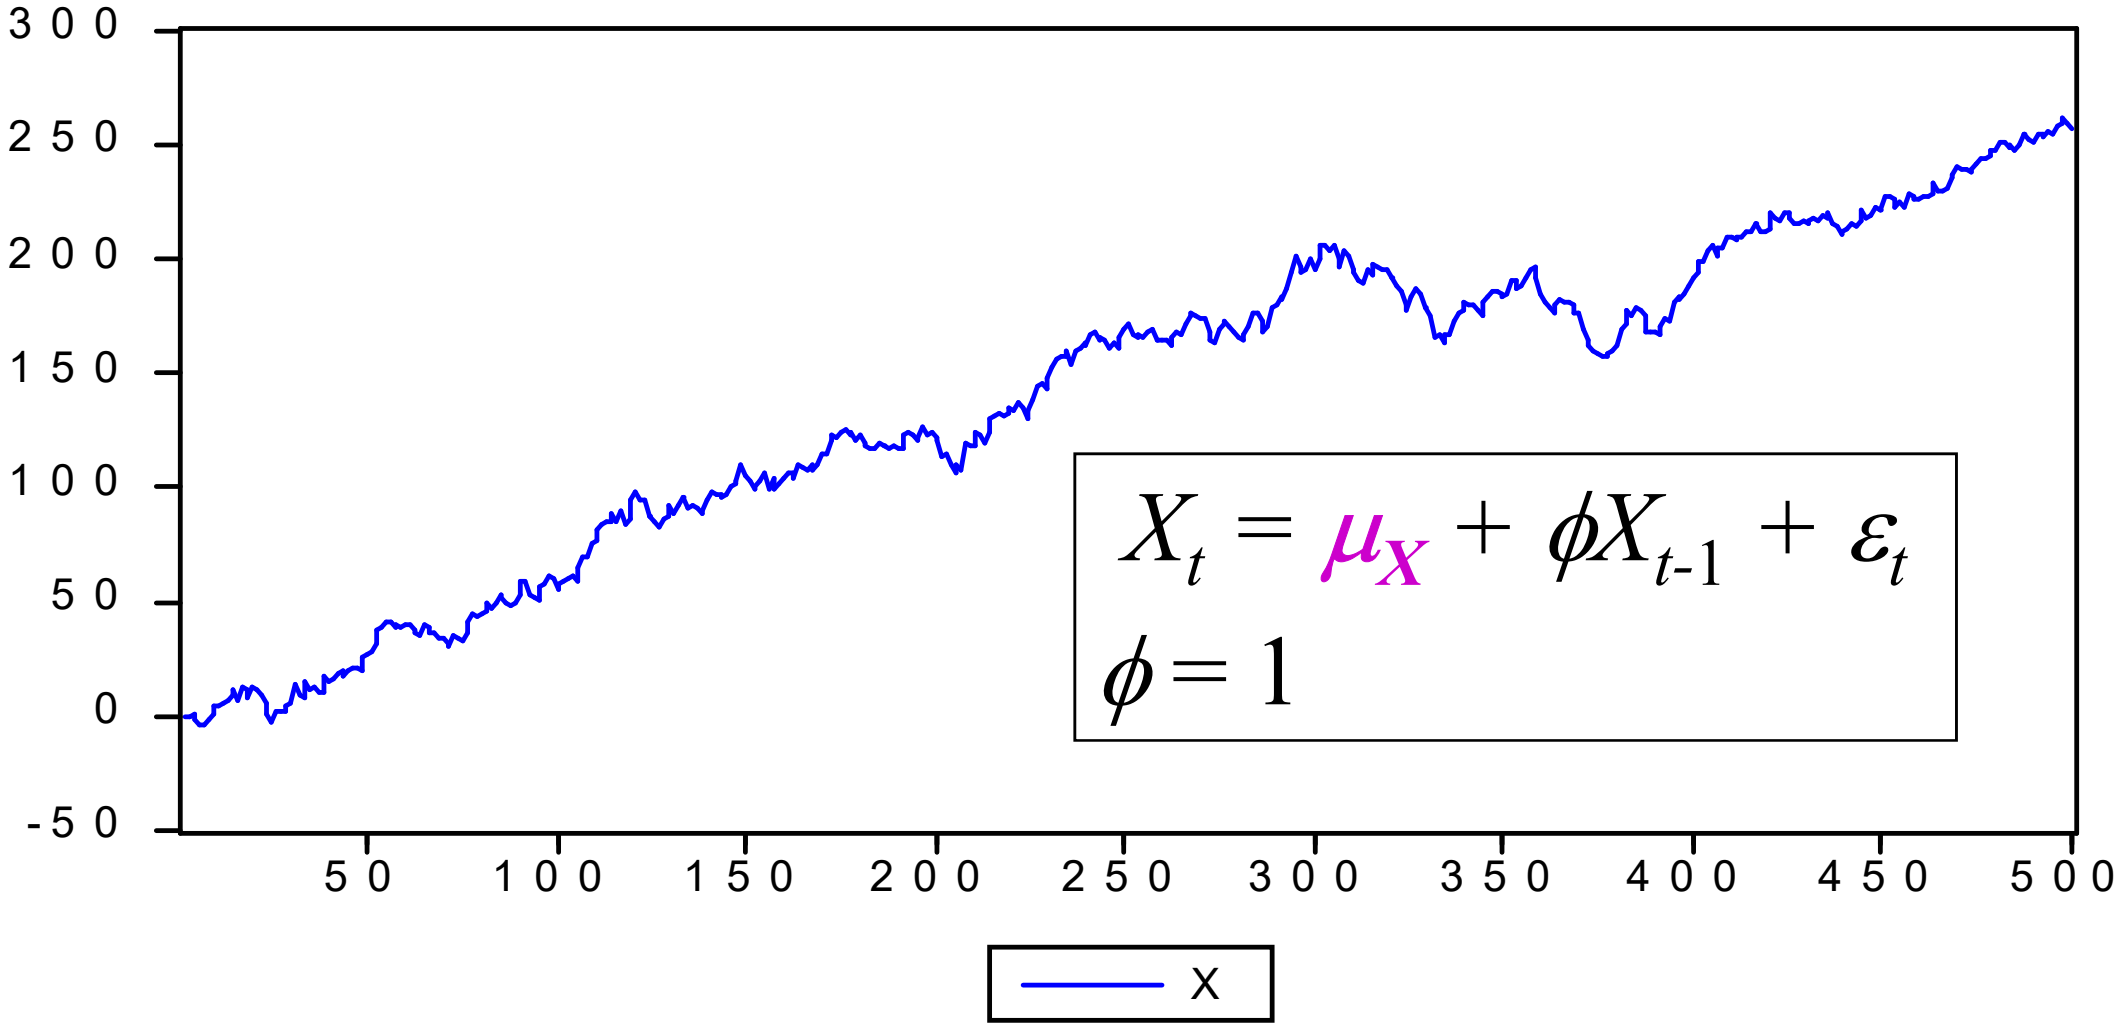
Tipos de NÃO-Estacionariedade

Processo **SEM** tendência

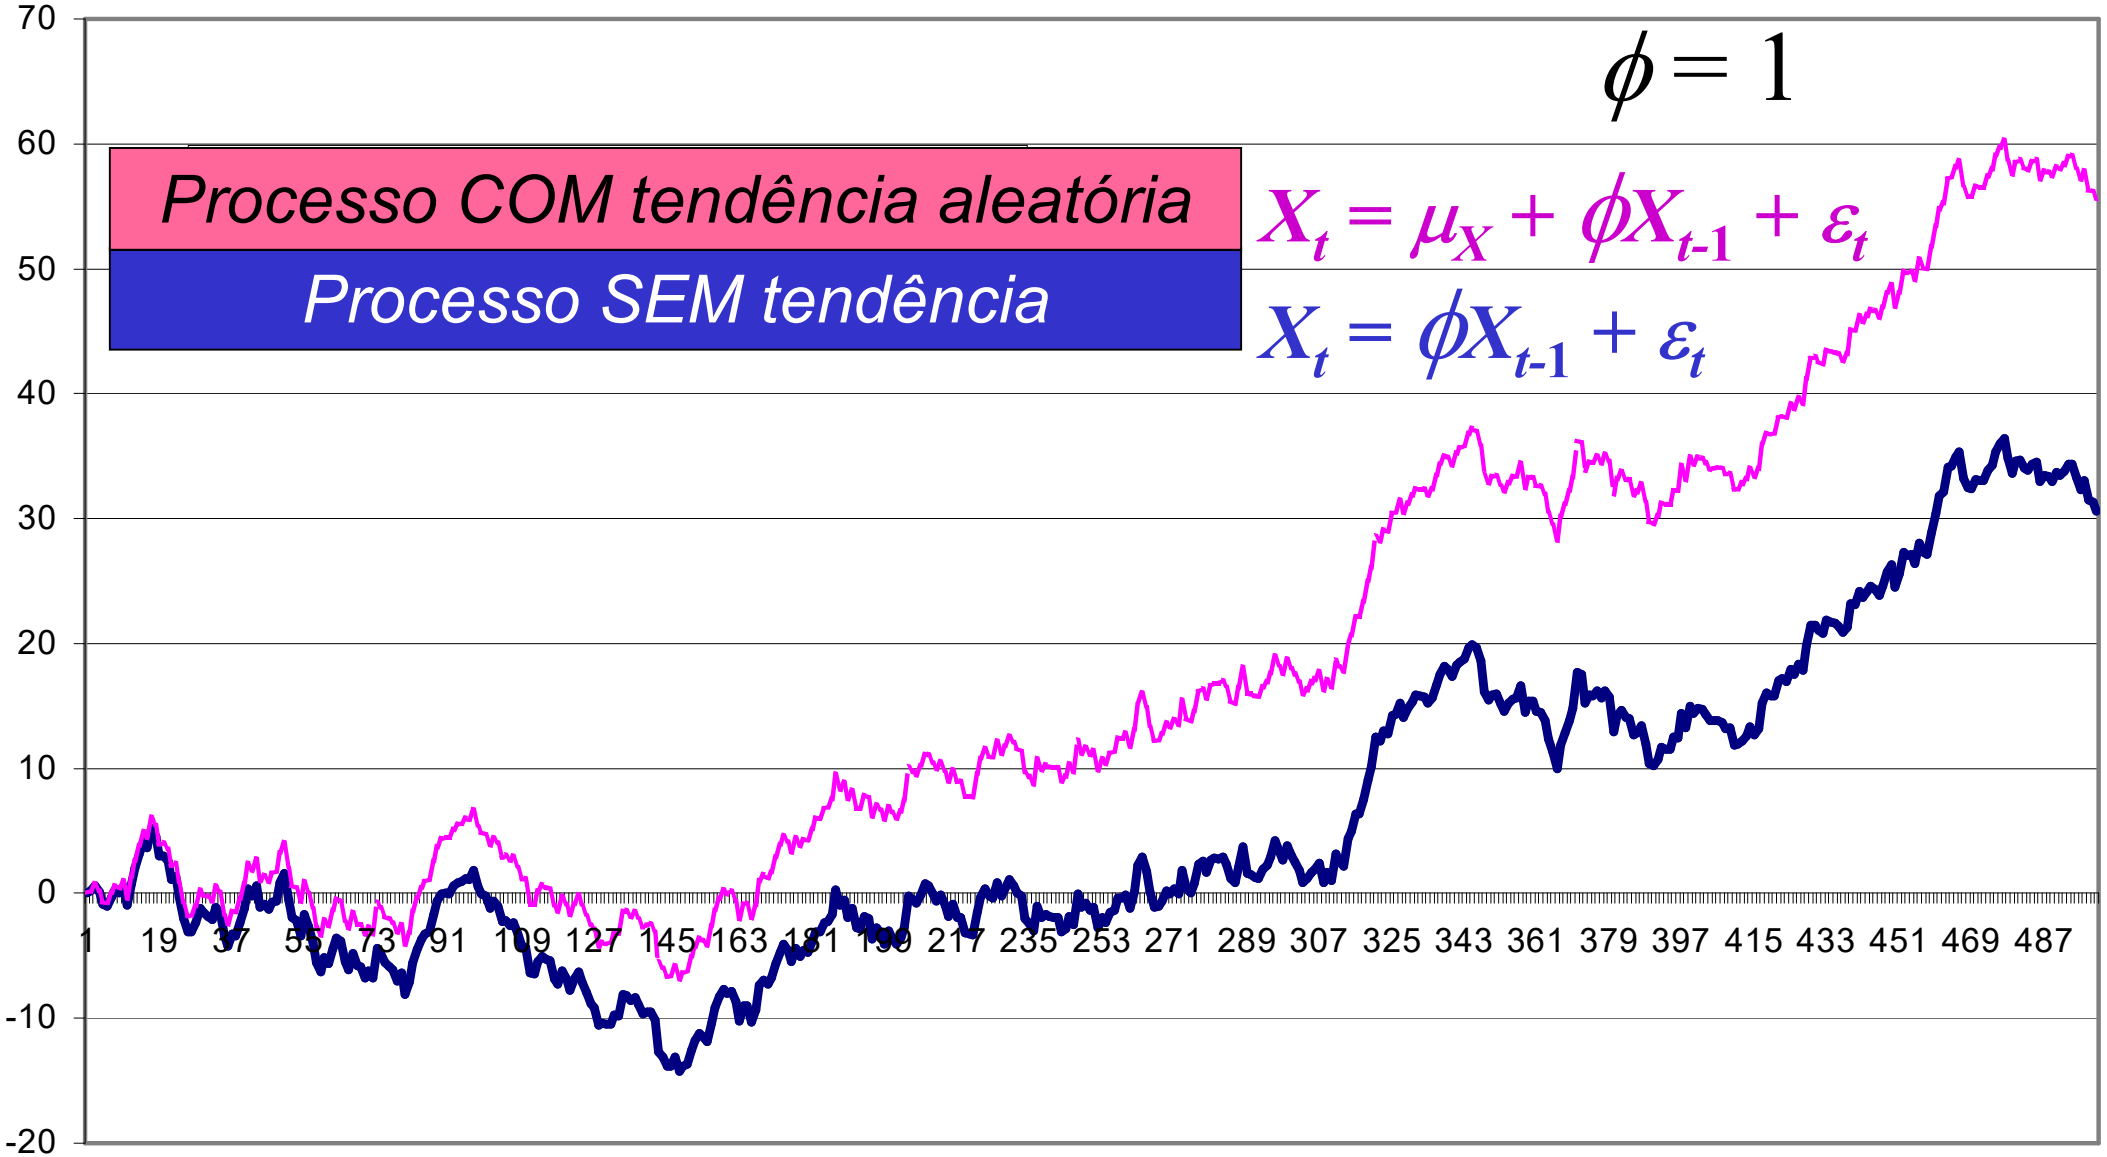


Tipos de NÃO-Estacionariedade

Processo **COM** tendência aleatória

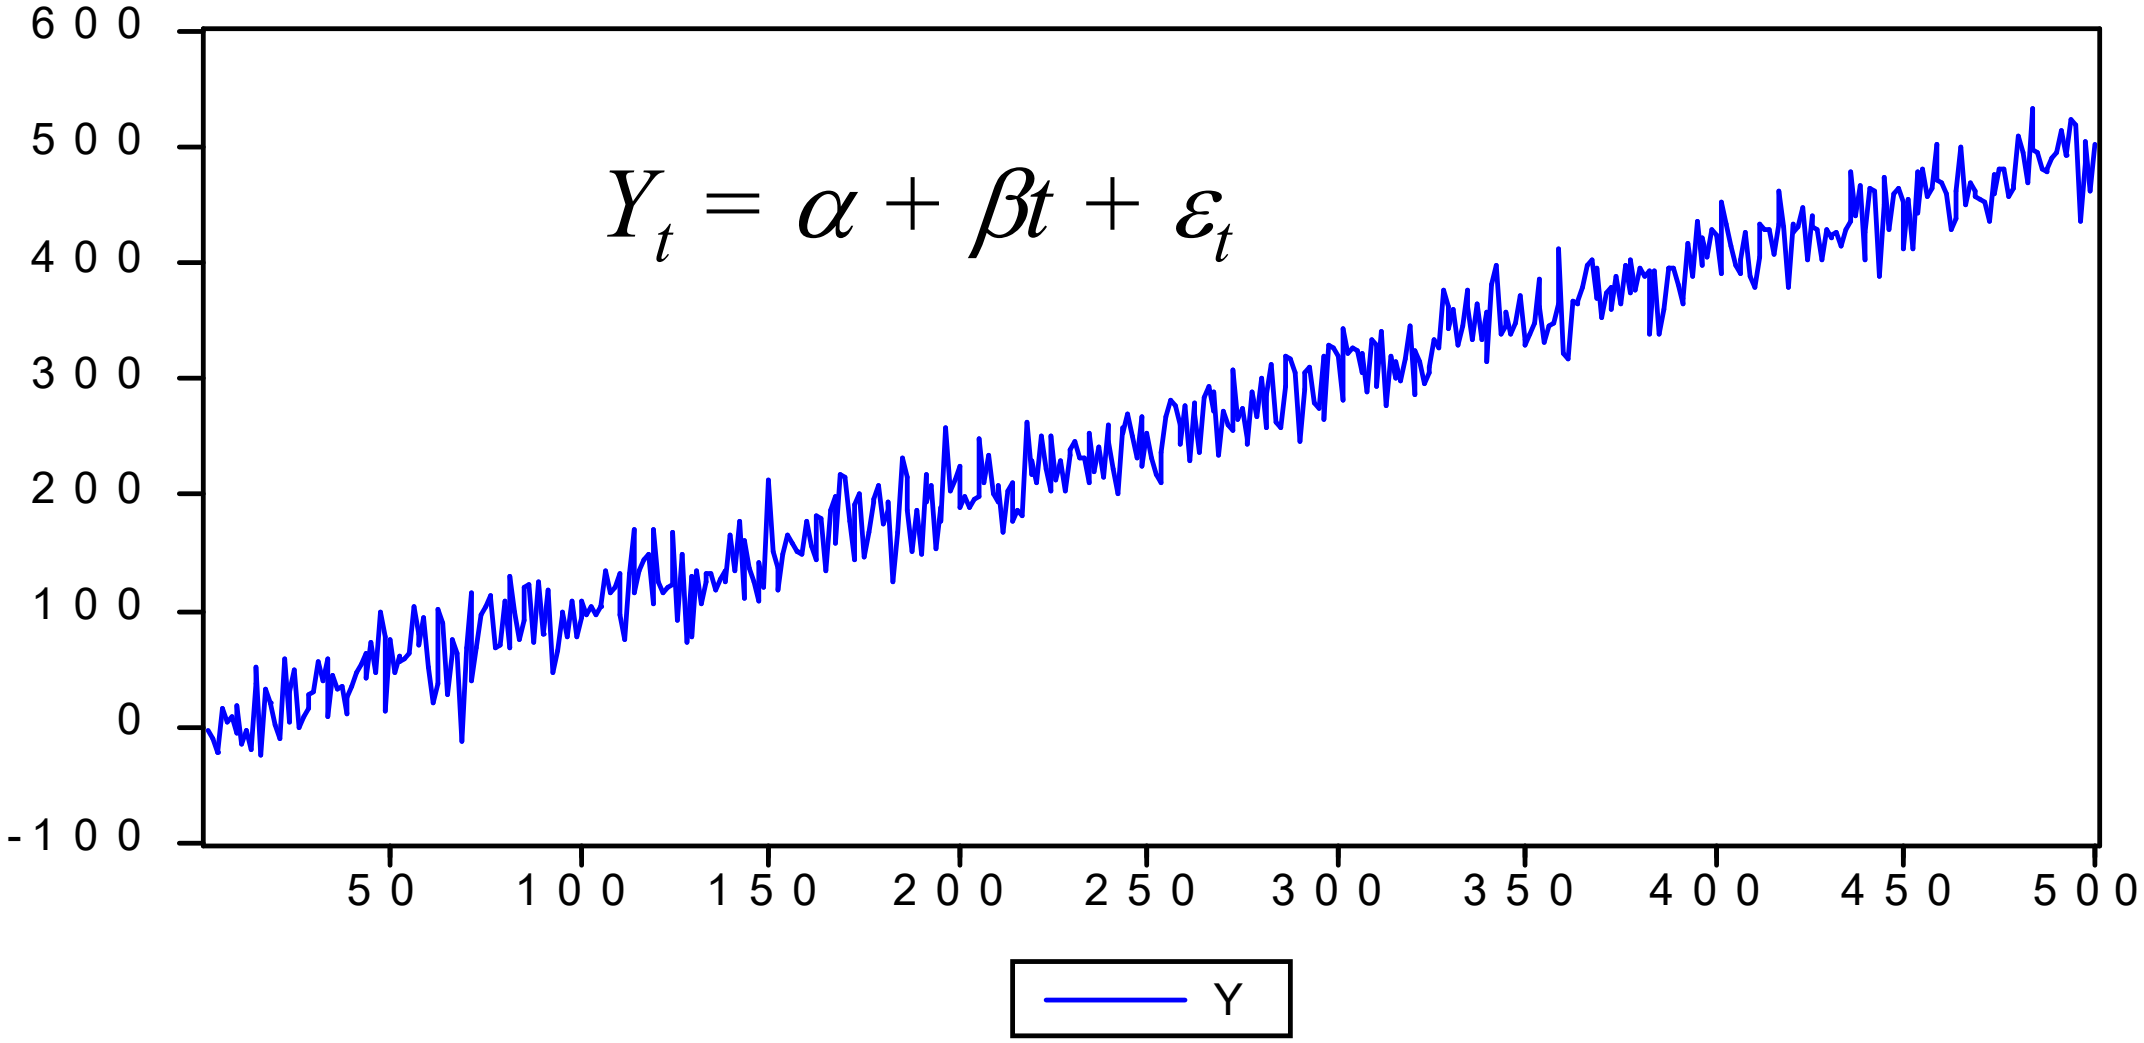


Tipos de NÃO-Estacionariedade



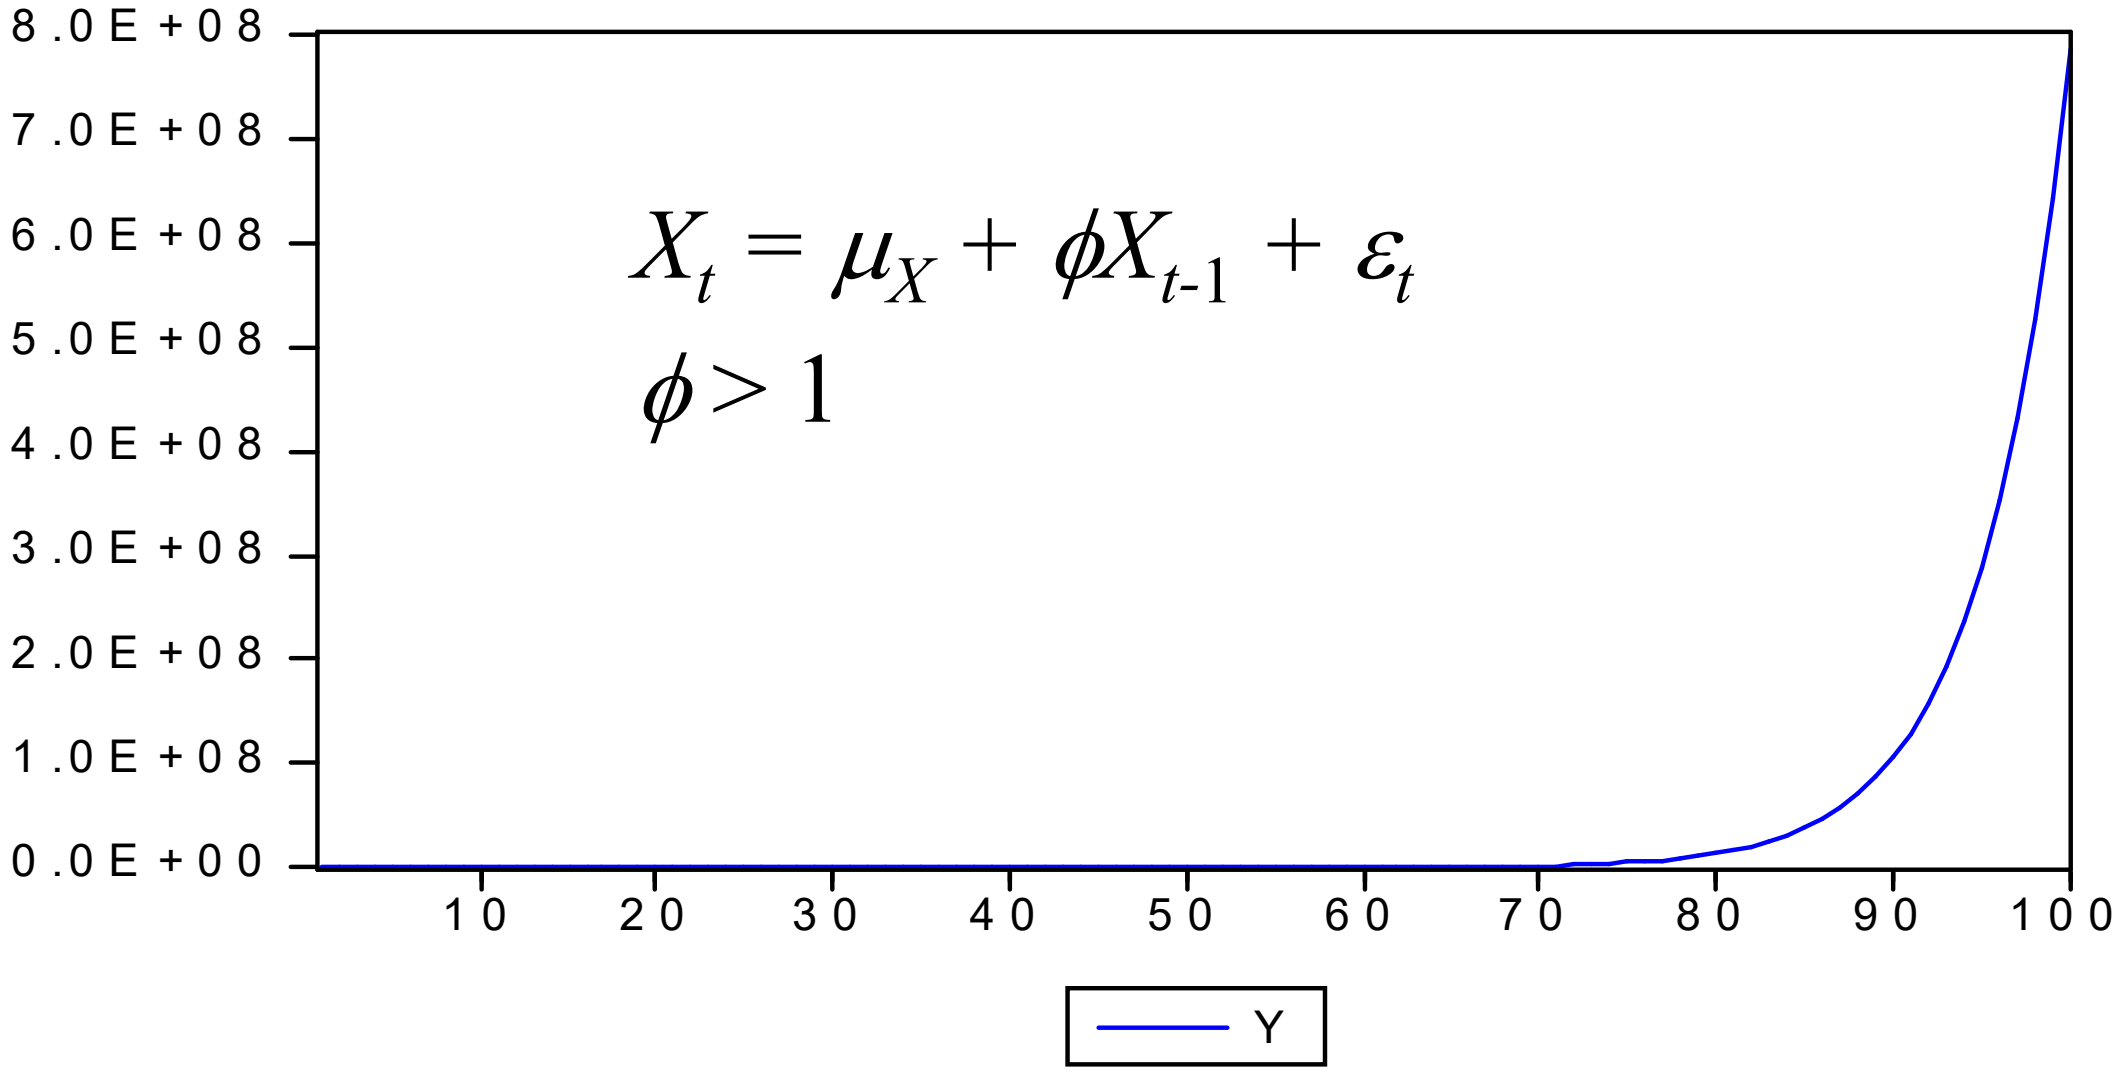
Tipos de NÃO-Estacionariedade

Processo com tendência determinística



Tipos de NÃO-Estacionariedade

Processo com tendência explosiva



$$X_t = \mu_X + \phi X_{t\text{-}1} + \varepsilon_t$$

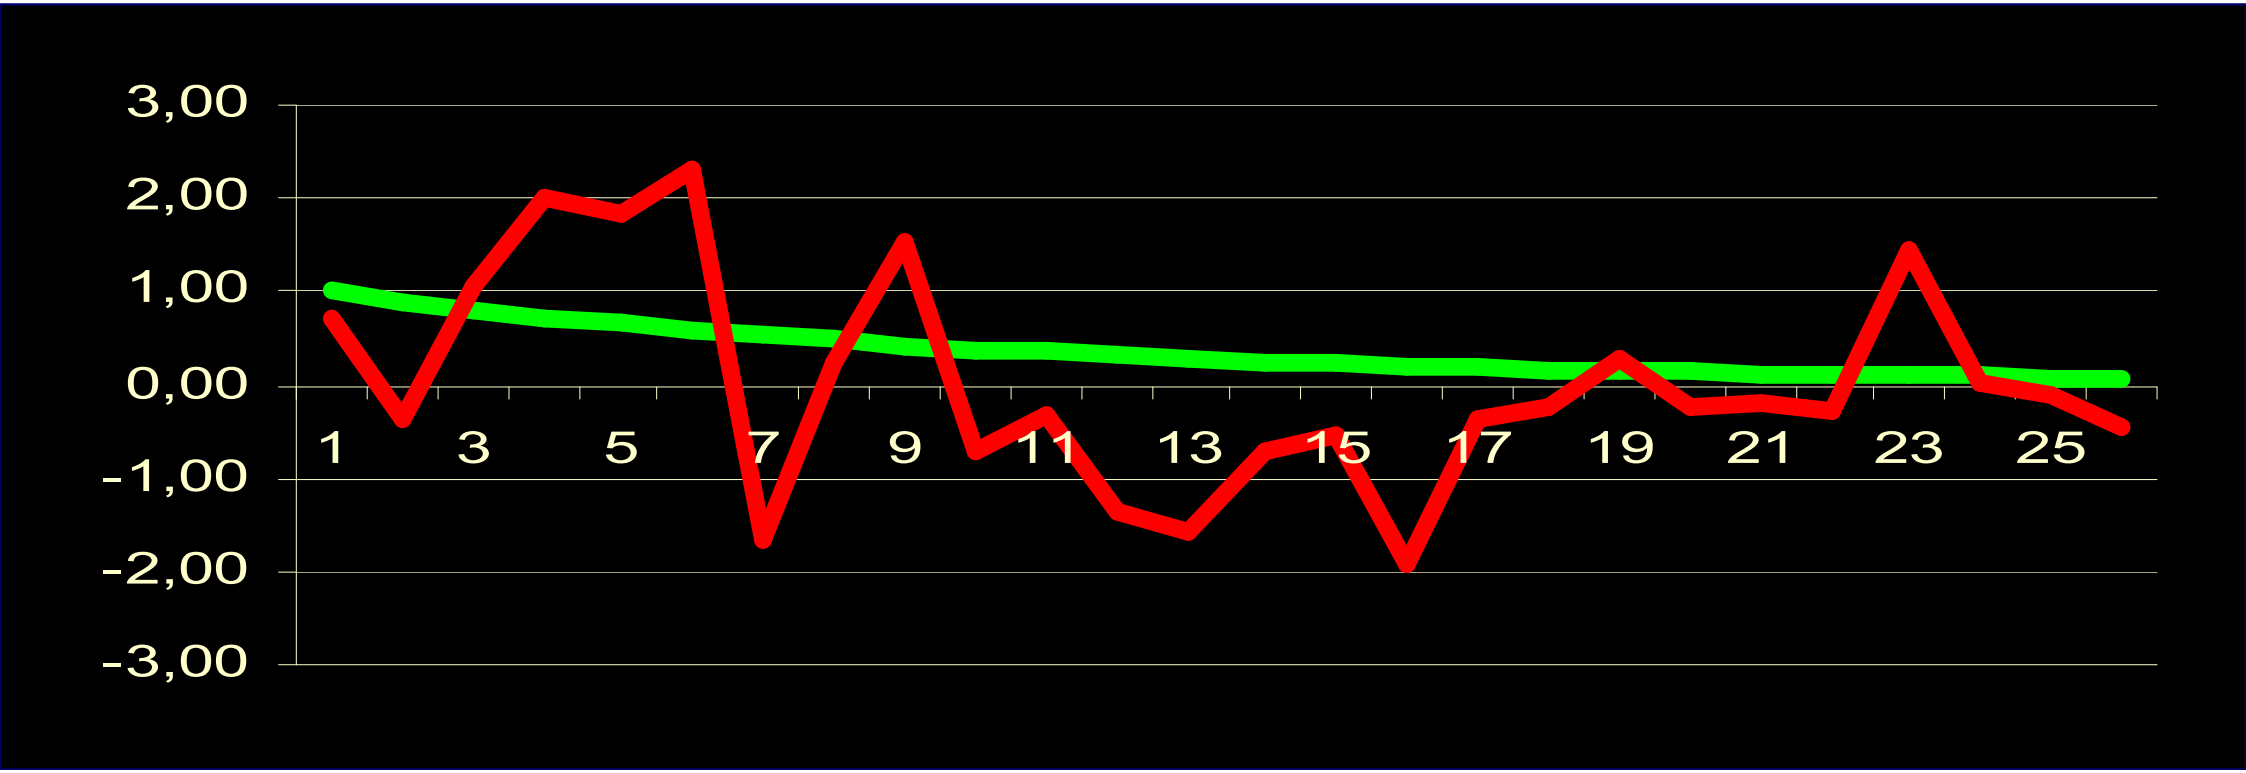
$$\phi > 1$$

Processo com tendência convergente

Impacto dos choques são decrescentes

$$Y_t = \phi Y_{t-1} + \varepsilon_t$$

$$\phi < 1 \Rightarrow \phi^T \rightarrow 0 \text{ , tal que } T \rightarrow \infty$$



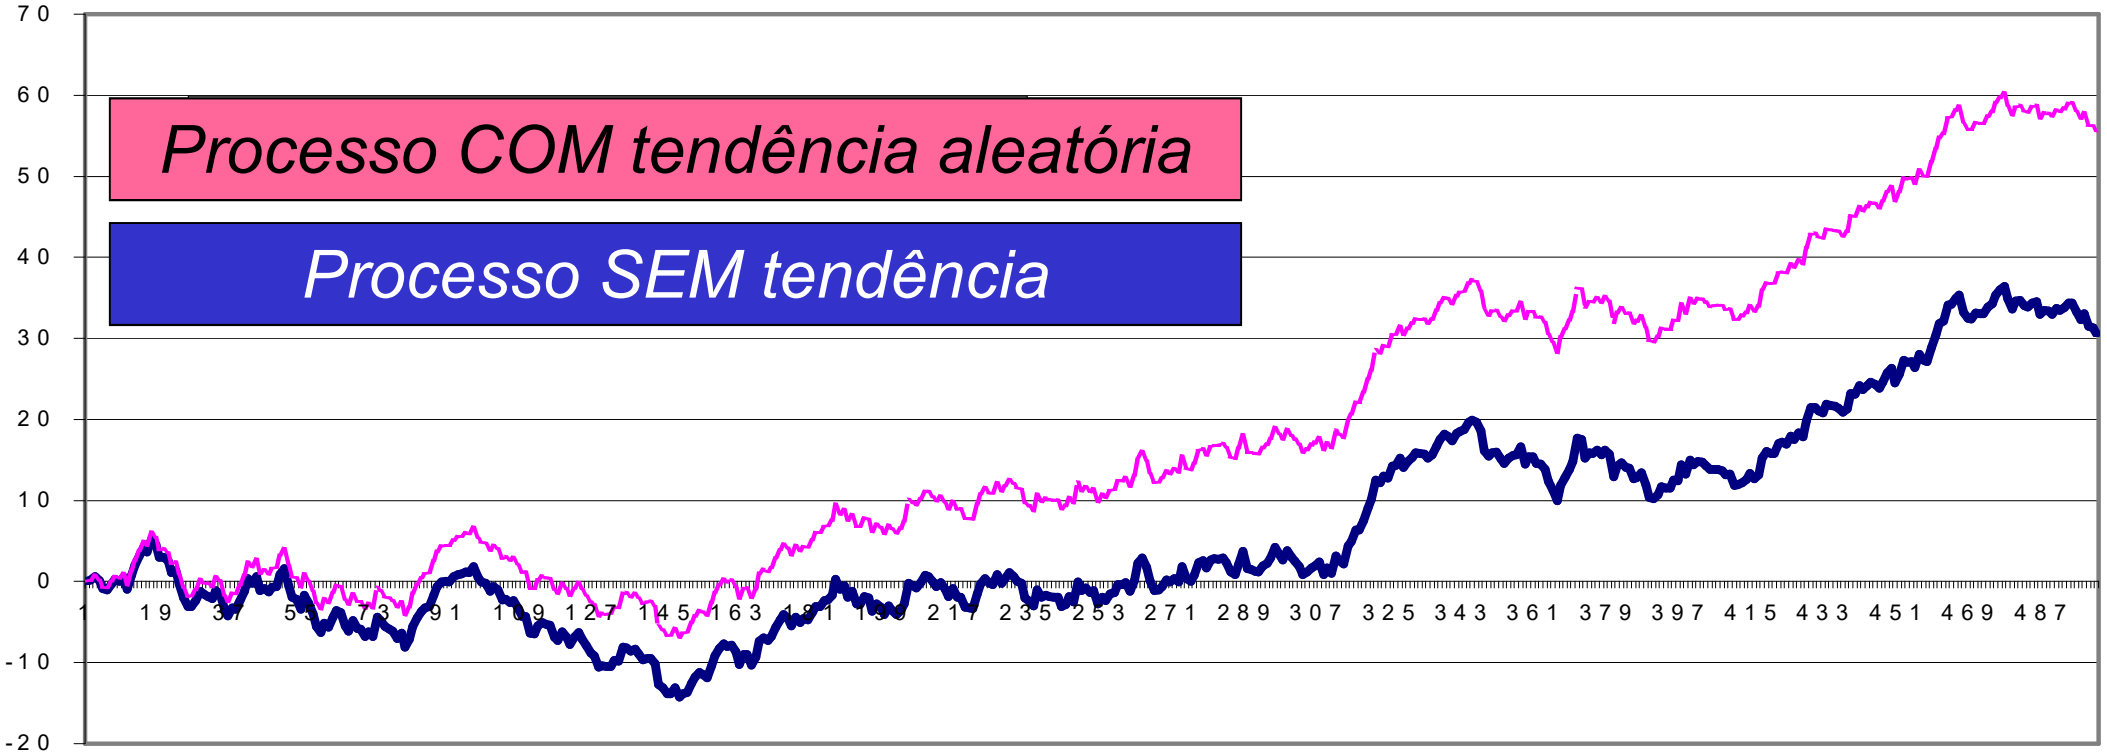
Processo NÃO-estacionário

Impacto dos choques são persistentes

$$X_t = \mu_X + \phi X_{t-1} + \varepsilon_t$$

$$X_t = \phi X_{t-1} + \varepsilon_t$$

$$\phi = 1 \Rightarrow \phi^T \to 1, \quad \forall T$$

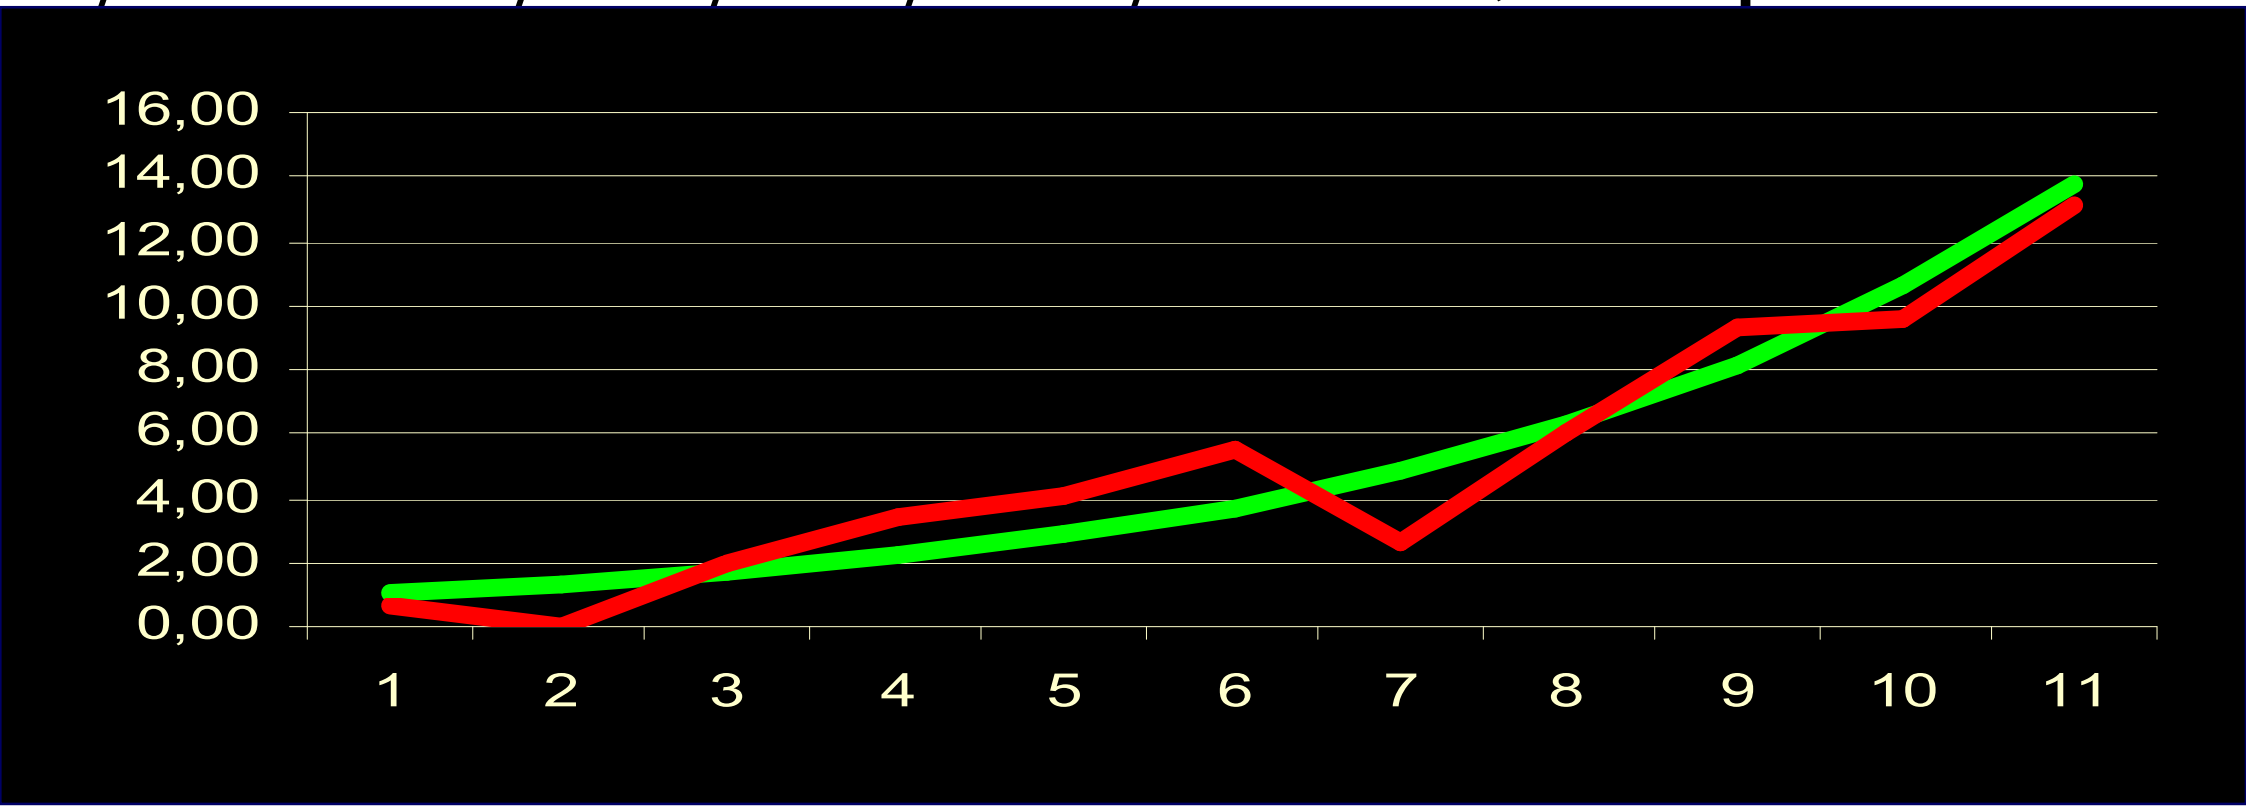


Processo com tendência explosiva

Impacto dos choques são crescentes

$$Y_t = \phi Y_{t-1} + \varepsilon_t$$

$\phi > 1 \Rightarrow \phi^1 < \phi^2 < \phi^3 < \phi^T \rightarrow \infty$, tal que $T \rightarrow \infty$



Tipos de NÃO-Estacionariedade

Em geral, o caso explosivo é ignorado e usa-se $\phi = 1$ para caracterizar a NÃO-estacionaridade

- $\phi > 1$
  - não descreve muitos dados de séries temporais em economia e finanças.
  - Assume choques na série temporal são persistentes e propagados de forma crescentes ao longo do tempo.

Tipos de NÃO-Estacionariedade

Processo tendência ALEATÓRIA

- Estacionariedade: diferenciação da série

Sejam: $\Delta X_t = X_t - X_{t-1}$ e $LX_t = X_{t-1}$

Então: $(1-L)\, X_t = X_t - L\, X_t = X_t - X_{t-1}$

Considerando o caso: $X_t = \mu_X + X_{t-1} + \varepsilon_t$

Subtraindo X_{t-1} de ambos os lados:

$$(X_t) - X_{t-1} = (\mu_X + X_{t-1} + \varepsilon_t) - X_{t-1}$$

$$\Delta X_t = \mu_X + \varepsilon_t$$

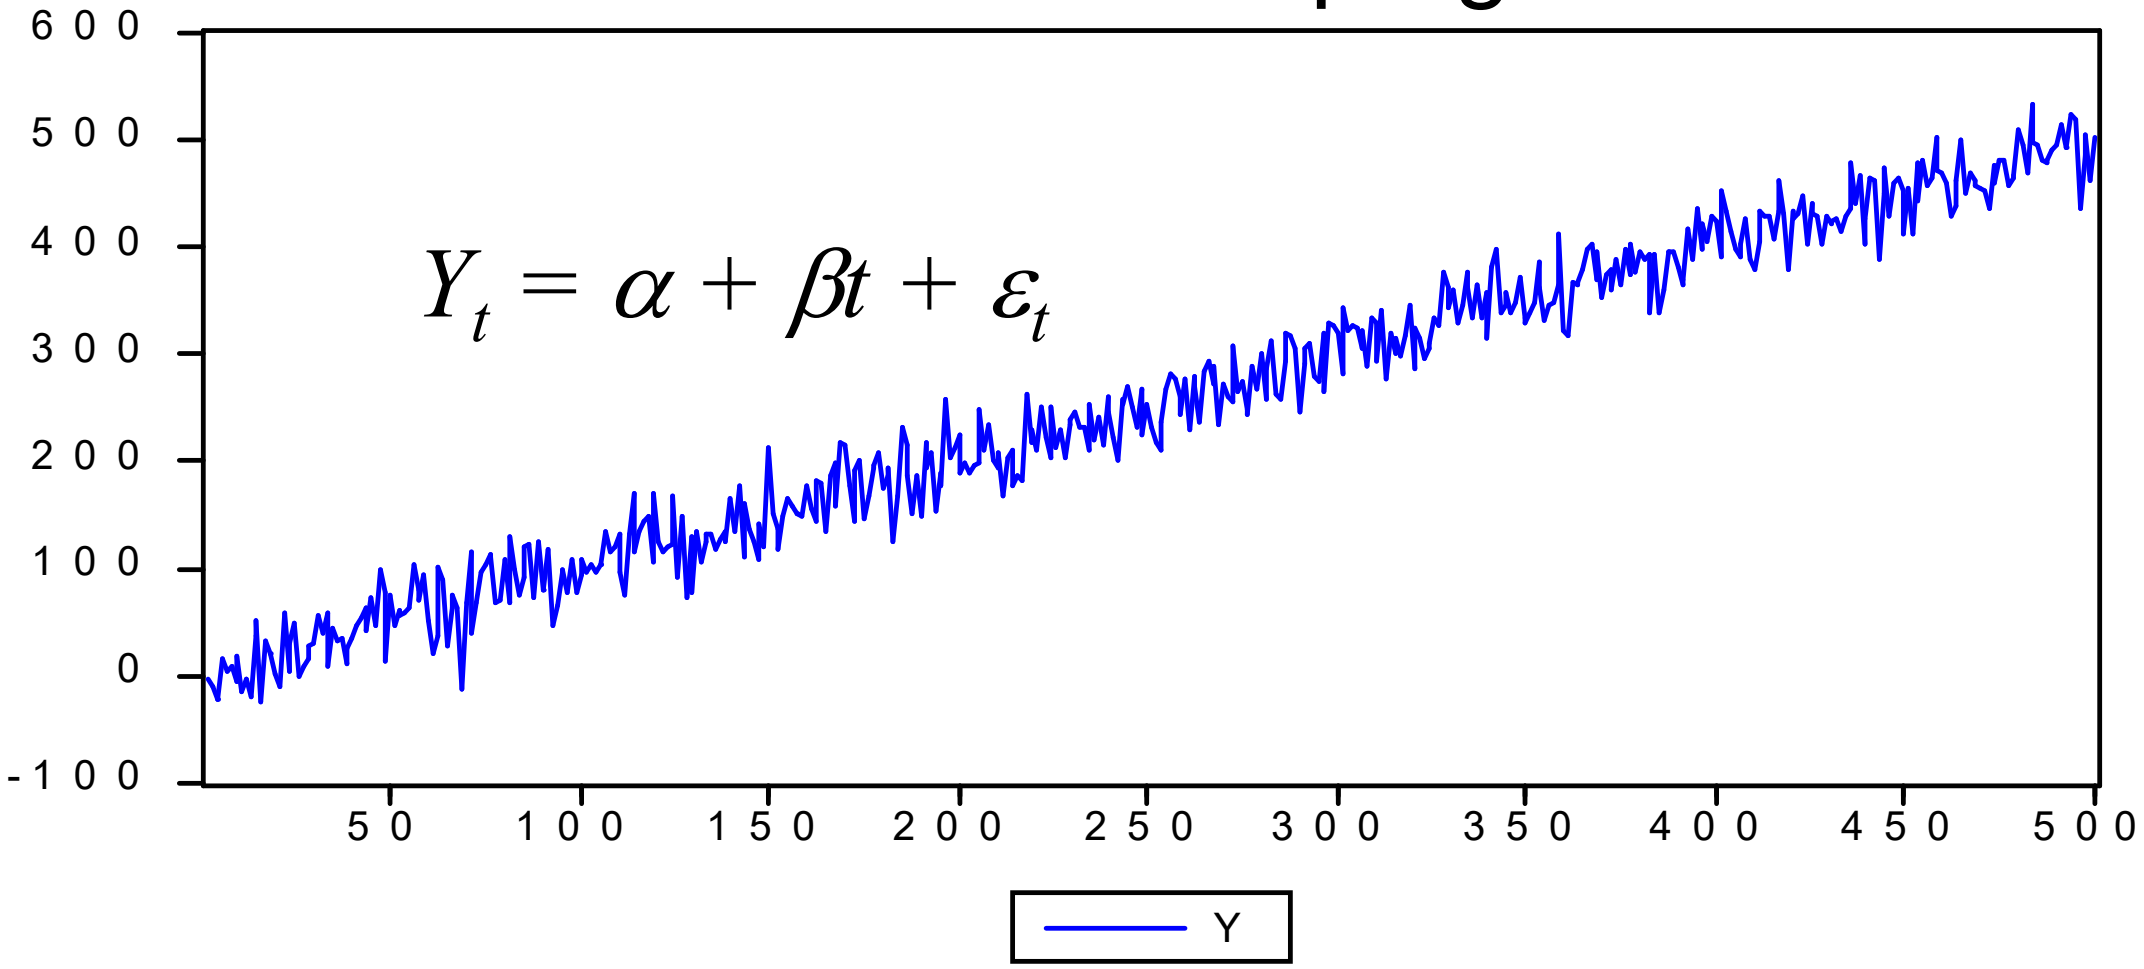
Tipos de NÃO-Estacionariedade

- A literatura de Econometria concentra-se no modelo de Série NÃO-estacionárias com tendência ALEATÓRIA
- Modelo de séries temporais NÃO-estacionárias com tendência DETERMINÍSTICA não descreve adequadamente grande parte das séries econômicas e das financeiras

Tipos de NÃO-Estacionariedade

Processo tendência DETERMINÍSTICA

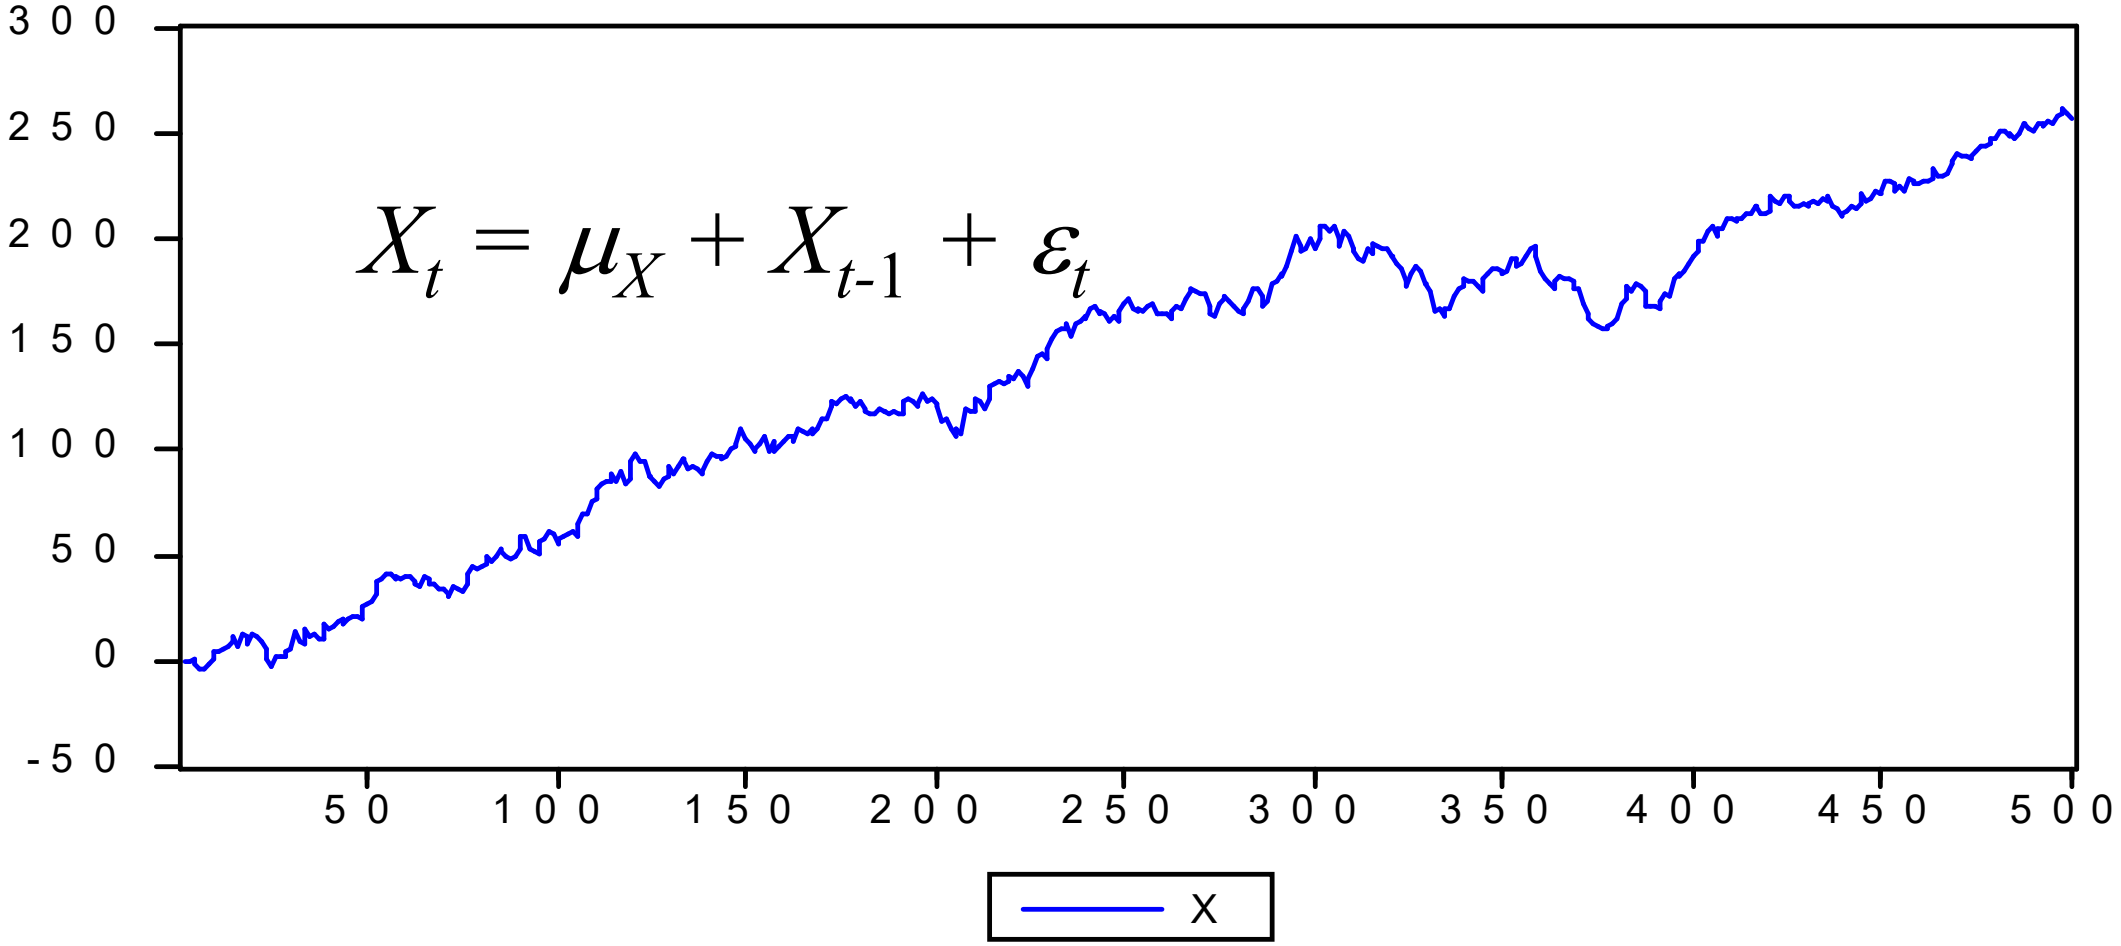
- Estacionariedade: expurgo da tendência



Tipos de NÃO-Estacionariedade

Processo tendência ALEATÓRIA

- Estacionariedade: diferenciação da série



Tipos de NÃO-Estacionariedade

Processo tendência ALEATÓRIA

- Estacionariedade: diferenciação da série

Sejam: $\Delta X_t = X_t - X_{t-1}$ e $LX_t = X_{t-1}$

Então: $(1-L)\, X_t = X_t - L\, X_t = X_t - X_{t-1}$

Considerando o caso: $X_t = \mu_X + X_{t-1} + \varepsilon_t$

Subtraindo X_{t-1} de ambos os lados:

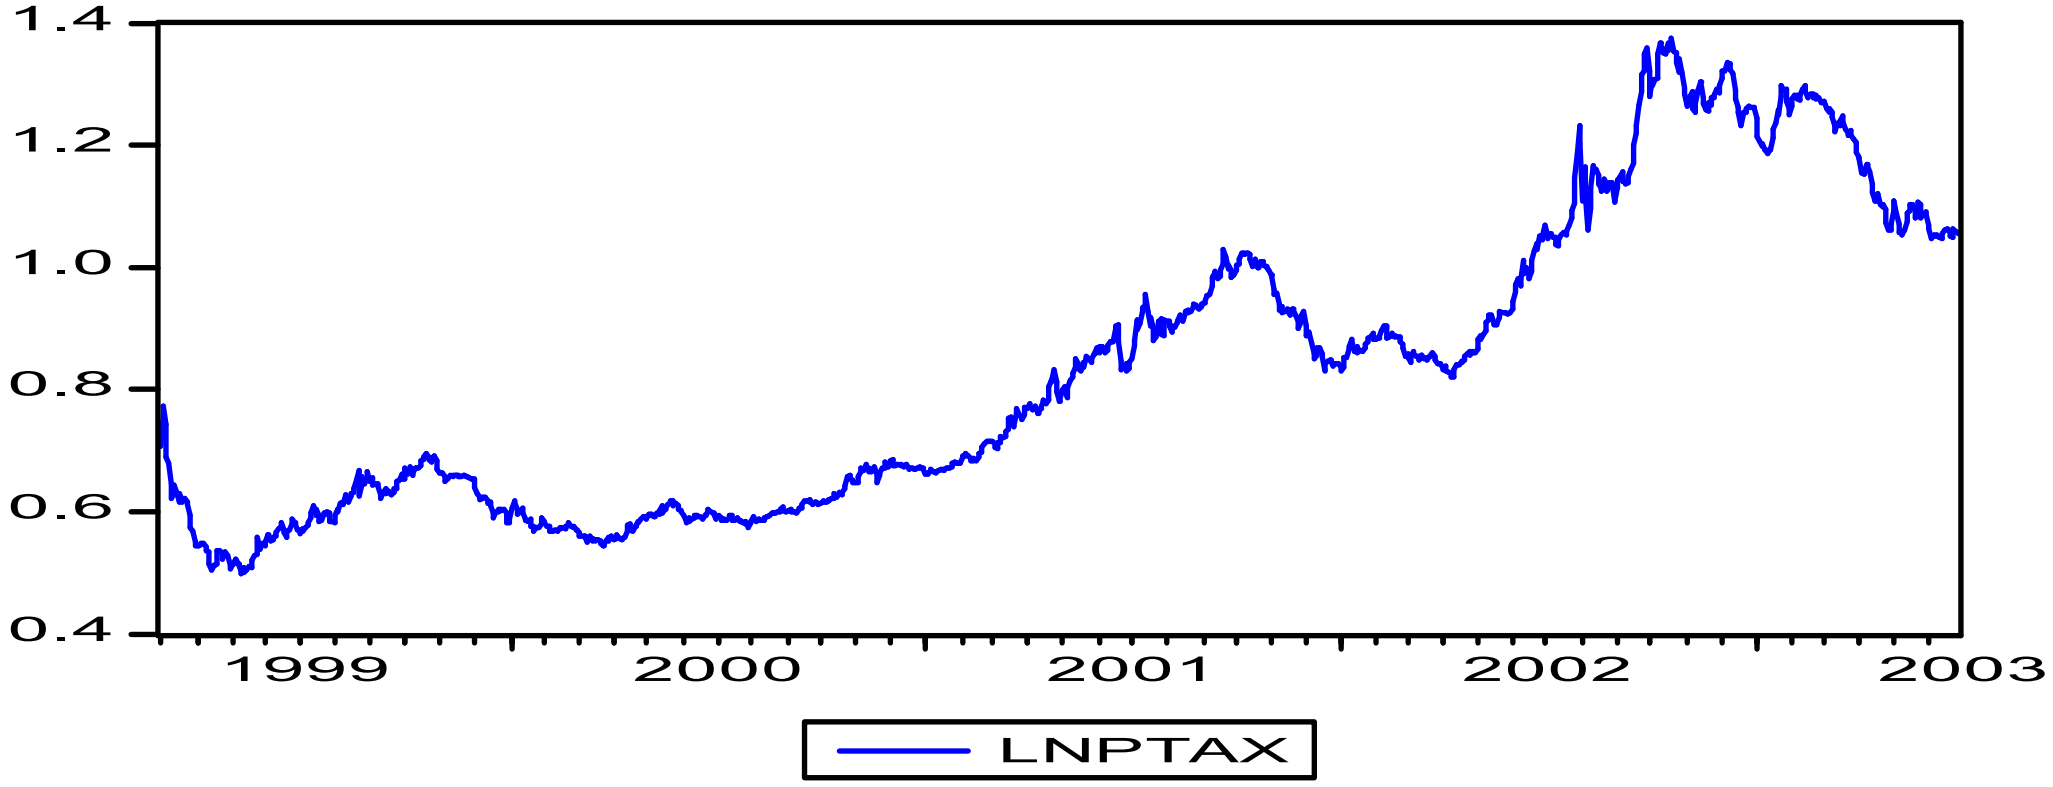
$$(X_t) - X_{t-1} = (\mu_X + X_{t-1} + \varepsilon_t) - X_{t-1}$$

$$\Delta X_t = \mu_X + \varepsilon_t$$

Fatos Estilizados

- Variáveis em nível tendem para NÃO-estacionariedade. Exemplo: preços

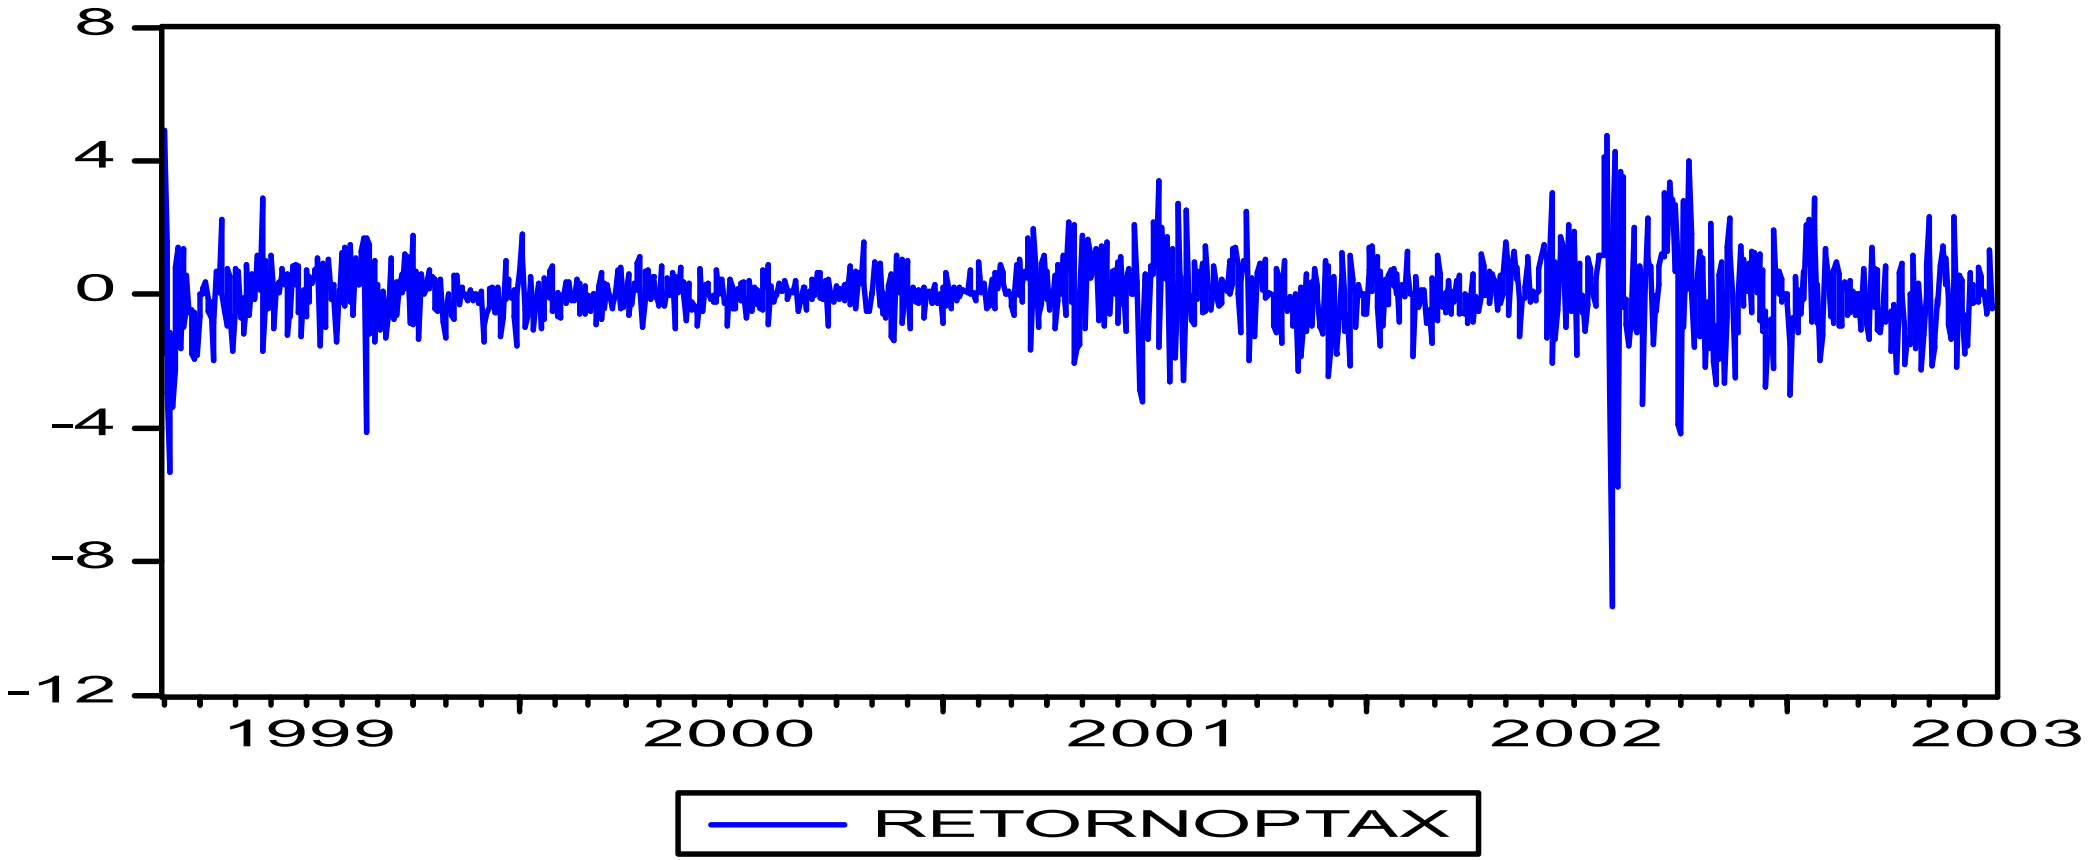
Série temporal *ln(PTAX)* em nível – 26/02/1999 a 30/06/2003



Fatos Estilizados

- Retornos tendem para estacionariedade.

Série temporal retornos *ln(PTAX)* – 01/03/1999-30/06/2003



Estacionariedade

Importância 2: Regressão Espúria

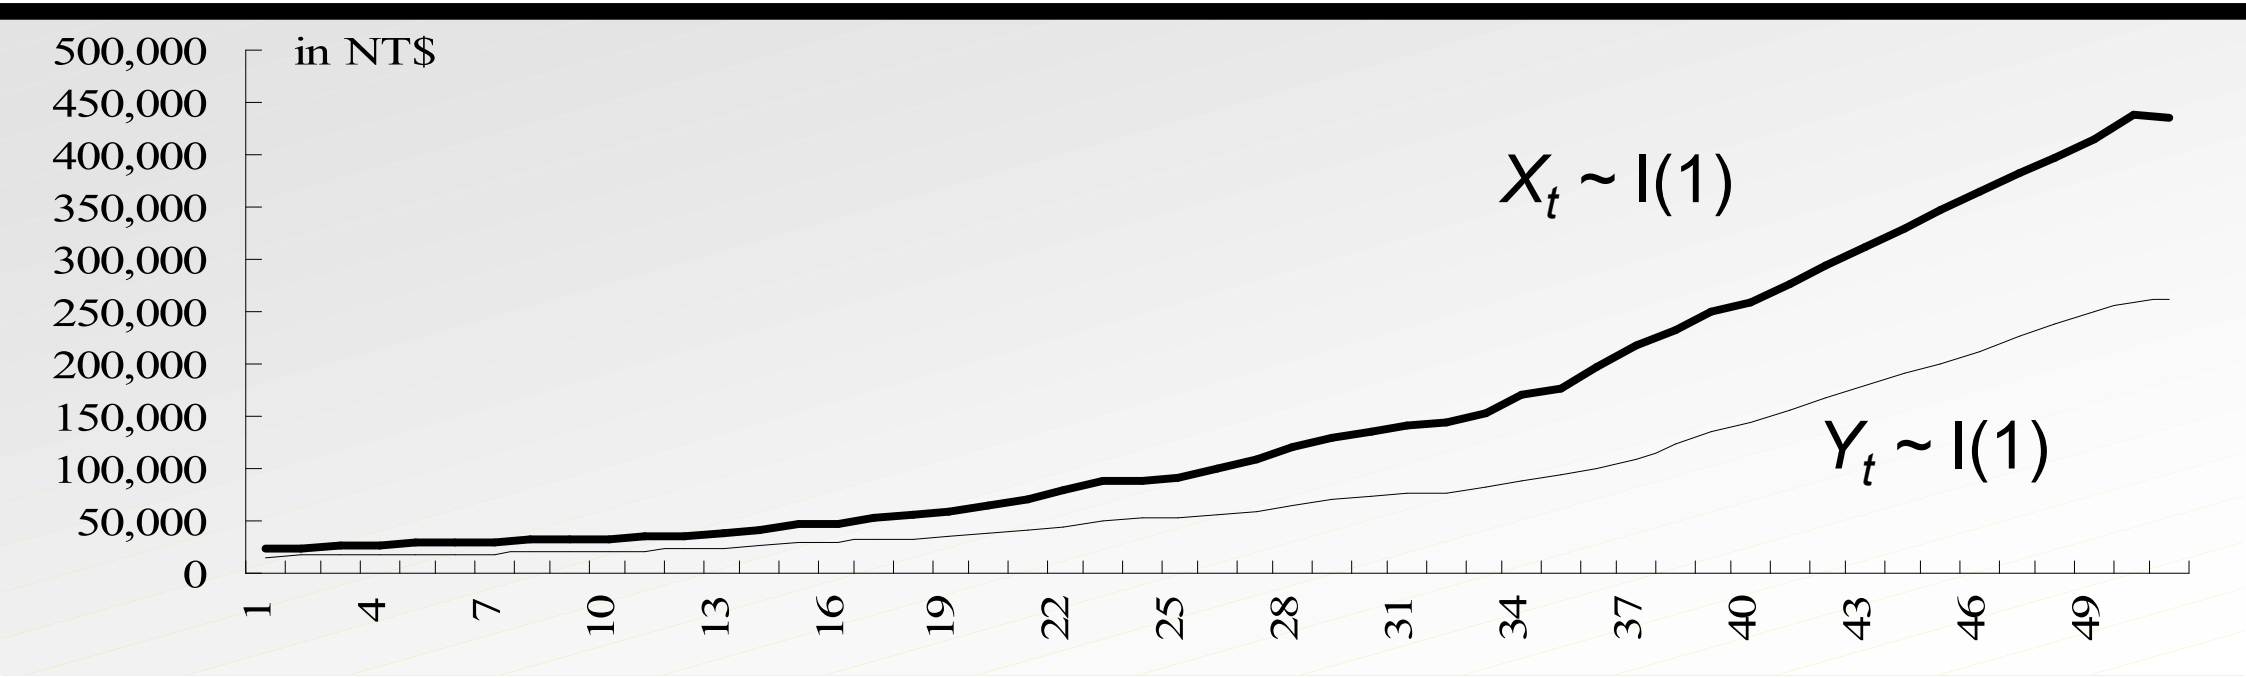
- Diversas variáveis macroeconômicas são NÃO-estacionárias em nível, pois apresentam tendências
  - Regressão entre duas variáveis totalmente descorrelacionadas em termos teóricos, mas que apresentam tendência ao longo do tempo.
    - ✓ Testes estatísticos com valores bastante altos, porém sem respaldo teórico.

Regressão Espúria

- Sejam duas variáveis aleatórias, Y e X, com processos NÃO-estacionários de geração de dados

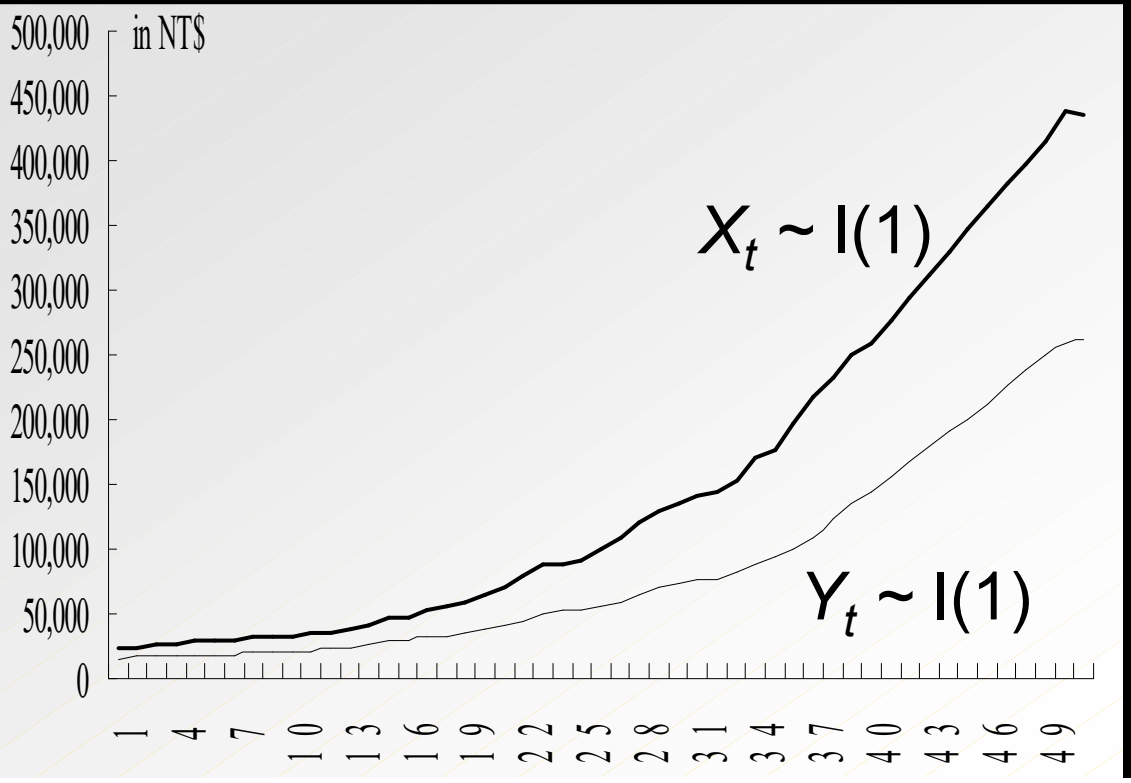
- Considere o modelo em que:
  - Y é variável EXPLICADA e
  - X é variável EXPLICATIVA

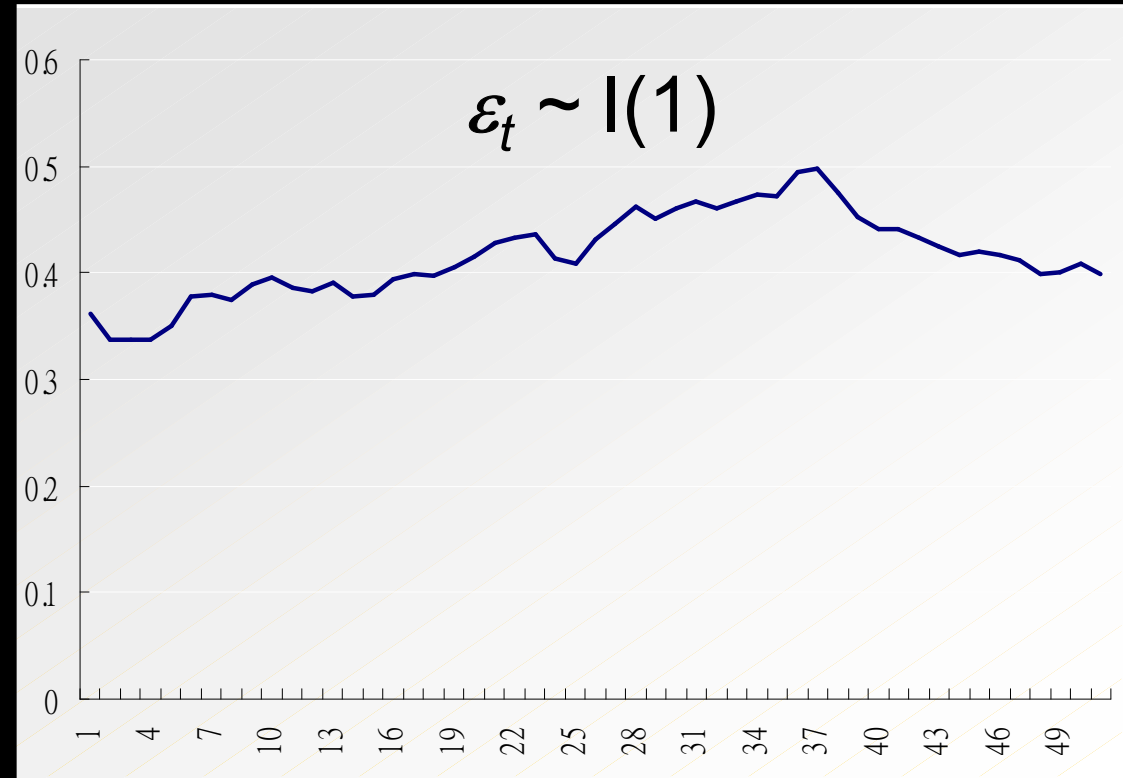
$$Y_t = \beta_0 + \beta_1 X_t + \varepsilon_t$$
$$\hat{Y}_t = b_0 + b_1 X_t + e_t$$



Regressão Espúria

- Se o termo de erro populacional (ε), estimado pelo resíduo amostral (e), for:
  - NÃO-estacionário
    - ✓ a regressão será **ESPÚRIA**





Tipos de NÃO-Estacionariedade

- Se a série NÃO-estacionária $\{X_t\}$ for diferenciada 1 vez e a série $\{\Delta X_t\}$ for estacionária, $\{X_t\}$ é dita integrada de ordem "1"
- Formalizando, tem-se:
  - $\{X_t\}$ é NÃO-estacionária
  - $\{X_t\}$ contém 1 (uma) raiz unitária
  - $\{X_t\} \sim I(1)$
  - $\{\Delta^1 X_t\}$ é estacionária

Tipos de NÃO-Estacionariedade

- Se a série NÃO-estacionária $\{X_t\}$ for diferenciada 2 vezes e a série $\{\Delta^2 X_t\}$ for estacionária, $\{X_t\}$ é dita integrada de ordem "2"
- Formalizando, tem-se:
  - $\{X_t\}$ é NÃO-estacionária
  - $\{X_t\}$ contém 2 raízes unitárias
  - $\{X_t\} \sim I(2)$
  - $\{\Delta^2 X_t\}$ é estacionária

Tipos de NÃO-Estacionariedade

- Se a série NÃO-estacionária $\{X_t\}$ for diferenciada "d" vezes e a série $\{\Delta^d X_t\}$ for estacionária, $\{X_t\}$ é dita integrada de ordem "d"
- Formalizando, tem-se:
  - $\{X_t\}$ é NÃO-estacionária
  - $\{X_t\}$ contém "d" raízes unitárias
  - $\{X_t\} \sim I(d)$
  - $\{\Delta^d X_t\}$ é estacionária

Regressão Espúria

- Duas séries X e Y formam regressão espúria se:
  - Ambas as séires são NÃO-estacionárias
  - Ambas séries são integradas de mesma ordem “d”:
    - ✓ $Y_t \sim I(d)$
    - ✓ $X_t \sim I(d)$
  - Combinação linear das 2 séries é integrada de ordem “d”:
    - ✓ $(Y_t - X_t) \sim I(d)$
  - Resíduos são NÃO-estacionários
    - ✓ Erro Aleatório: $\varepsilon_t \sim I(d)$
    - ✓ Resíduo: $e_t \sim I(d)$

Teste de Raiz Unitária

- Passo 1:
  - Testar a estacionariedade da série temporal em nível, $\{X_t\}$.
    - Caso positivo: $X_t \sim I(0)$.
    - Caso negativo: $X_t \sim I(d)$, *tal que* $d > 0$.
- Passo 2:
  - Caso a série temporal em nível, $\{X_t\}$,não seja estacionária, tomar a sua 1a. diferença: $\Delta X_t = X_t - X_{t-1}$
  - Testar a estacionariedade da série temporal em 1a. Diferença, $\{\Delta X_t\}$
    - Caso positivo: $\Delta X_t \sim I(0)$ *e* $X_t \sim I(1)$.
    - Caso negativo: $X_t \sim I(d)$, *tal que* $d > 0$.
- Passo 3:
  - Caso a série temporal em 1a. diferença, $\{\Delta X_t\}$, não seja estacionária, tomar a 2a. diferença de X_t
  - Repetir o teste e demais procedimentos.
  - Pare quando encontrar uma série que seja $I(0)$

Teste de Raiz Unitária

- Seja: $\Delta^4 X_t \sim I(0)$, então:
  - $\Delta^3 X_t \sim I(1)$
  - $\Delta^2 X_t \sim I(2)$
  - $\Delta^1 X_t \sim I(3)$
- Portanto, $X_t \sim I(4)$.
- Em Economia e em Finanças, raramente as séries temporais apresentam mais de uma raiz unitária.
- Logo, majoritariamente, tem-se:
  - $X_t \sim I(1)$ e $\Delta^1 X_t \sim I(0)$

Estatística Aplicada

Aula 12 - Agenda

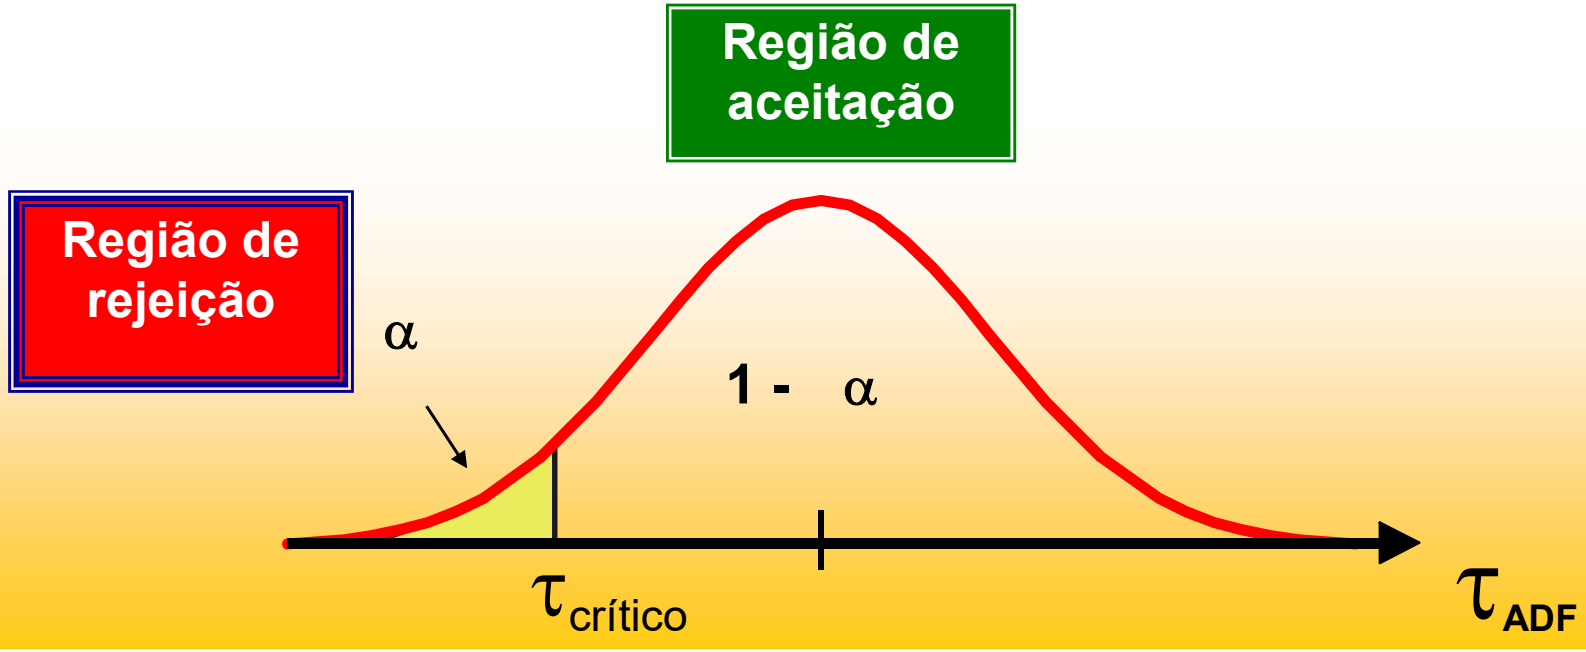
Teste de Raiz Unitária

Teste "τ" de Dickey-Fuller

O método formal para se testar se uma série é estacionária é o teste de raiz unitária.

H_0: Série tem Raiz Unitária: NÃO Estacionária

H_1: Série NÃO tem Raiz Unitária: Estacionária



Teste "τ" de Dickey-Fuller

Considere o processo: $X_t = \phi X_{t-1} + \varepsilon_t$

Subtraindo X_{t-1} de ambos os lados:

$$(X_t) - X_{t-1} = (\phi X_{t-1} + \varepsilon_t) - X_{t-1}$$

$$X_t - X_{t-1} = \phi X_{t-1} - X_{t-1} + \varepsilon_t$$

$$X_t - X_{t-1} = (\phi - 1) X_{t-1} + \varepsilon_t$$

Sejam: $\Delta X_t = X_t - X_{t-1}$ e $\psi = \phi - 1$

Então: $\Delta X_t = \psi X_{t-1} + \varepsilon_t$

Teste "τ" de Dickey-Fuller

H_0: Série tem Raiz Unitária: NÃO Estacionária

H_1: Série NÃO tem Raiz Unitária: Estacionária

Formato 1: $X_t = \phi X_{t-1} + \varepsilon_t$

Formato 2: $\Delta X_t = \psi X_{t-1} + \varepsilon_t$

- $\phi \geq 1$ ou $\psi \geq 0$ implica série NÃO-estacionária.
- Rejeição de H_0 ($\psi < 0$ e $\phi < 1$) implica que a série é estacionária.
- Opta-se pelo teste baseado no **formato 2** porque explicita a ordem de diferenciação da série temporal.

Teste "τ" de Dickey-Fuller

Dickey-Fuller propuseram 3 tipos de testes

Passeio Aleatório *versus* AR(1) **SEM** intercepto e **SEM** tendência temporal

Modelo Tipo 1: $\Delta X_t = \psi X_{t-1} + \varepsilon_t$

Passeio Aleatório *versus* AR(1) **COM** intercepto e **SEM** tendência temporal

Modelo Tipo 2: $\Delta X_t = \xi_X + \psi X_{t-1} + \varepsilon_t$

Passeio Aleatório *versus* AR(1) **COM** intercepto e **COM** tendência temporal

Modelo Tipo 3: $\Delta X_t = \xi_X + \psi X_{t-1} + \lambda t + \varepsilon_t$

Teste "τ" de Dickey-Fuller

Teste de Hipóteses

$H_0: \psi \geq 0$

$H_1: \psi < 0$

Estatística de Teste:

$$\tau^{calc} = \frac{(b_X - \psi)}{Erro \quad Padrão \quad b_X}$$

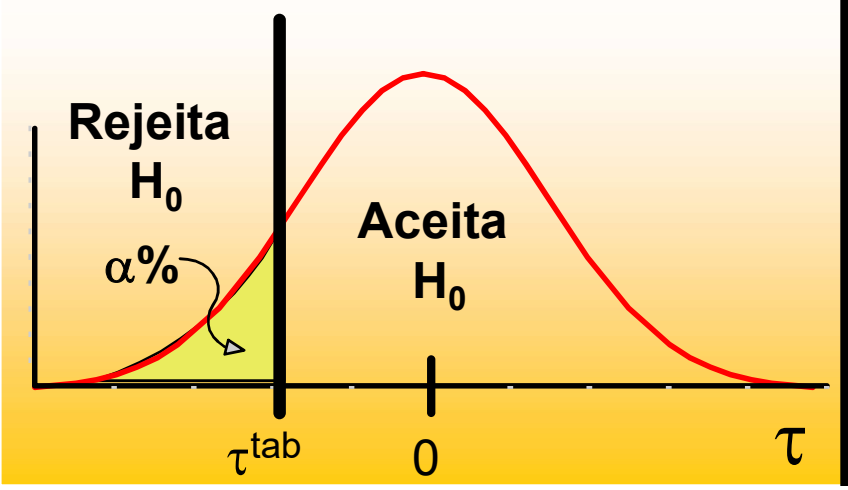
Nível Significancia = α%

Graus liberdade = n – 1 – k

valor crítico: τ^{tab}

Comparativo:

$$\tau^{tab} \leq \tau^{calc}$$



Significance level	10%	5%	1%
C.V. for constant but no trend	-2.57	-2.86	-3.43
C.V. for constant and trend	-3.12	-3.41	-3.96

Table 4.1: Critical Values for DF and ADF Tests (Fuller, 1976, p373).

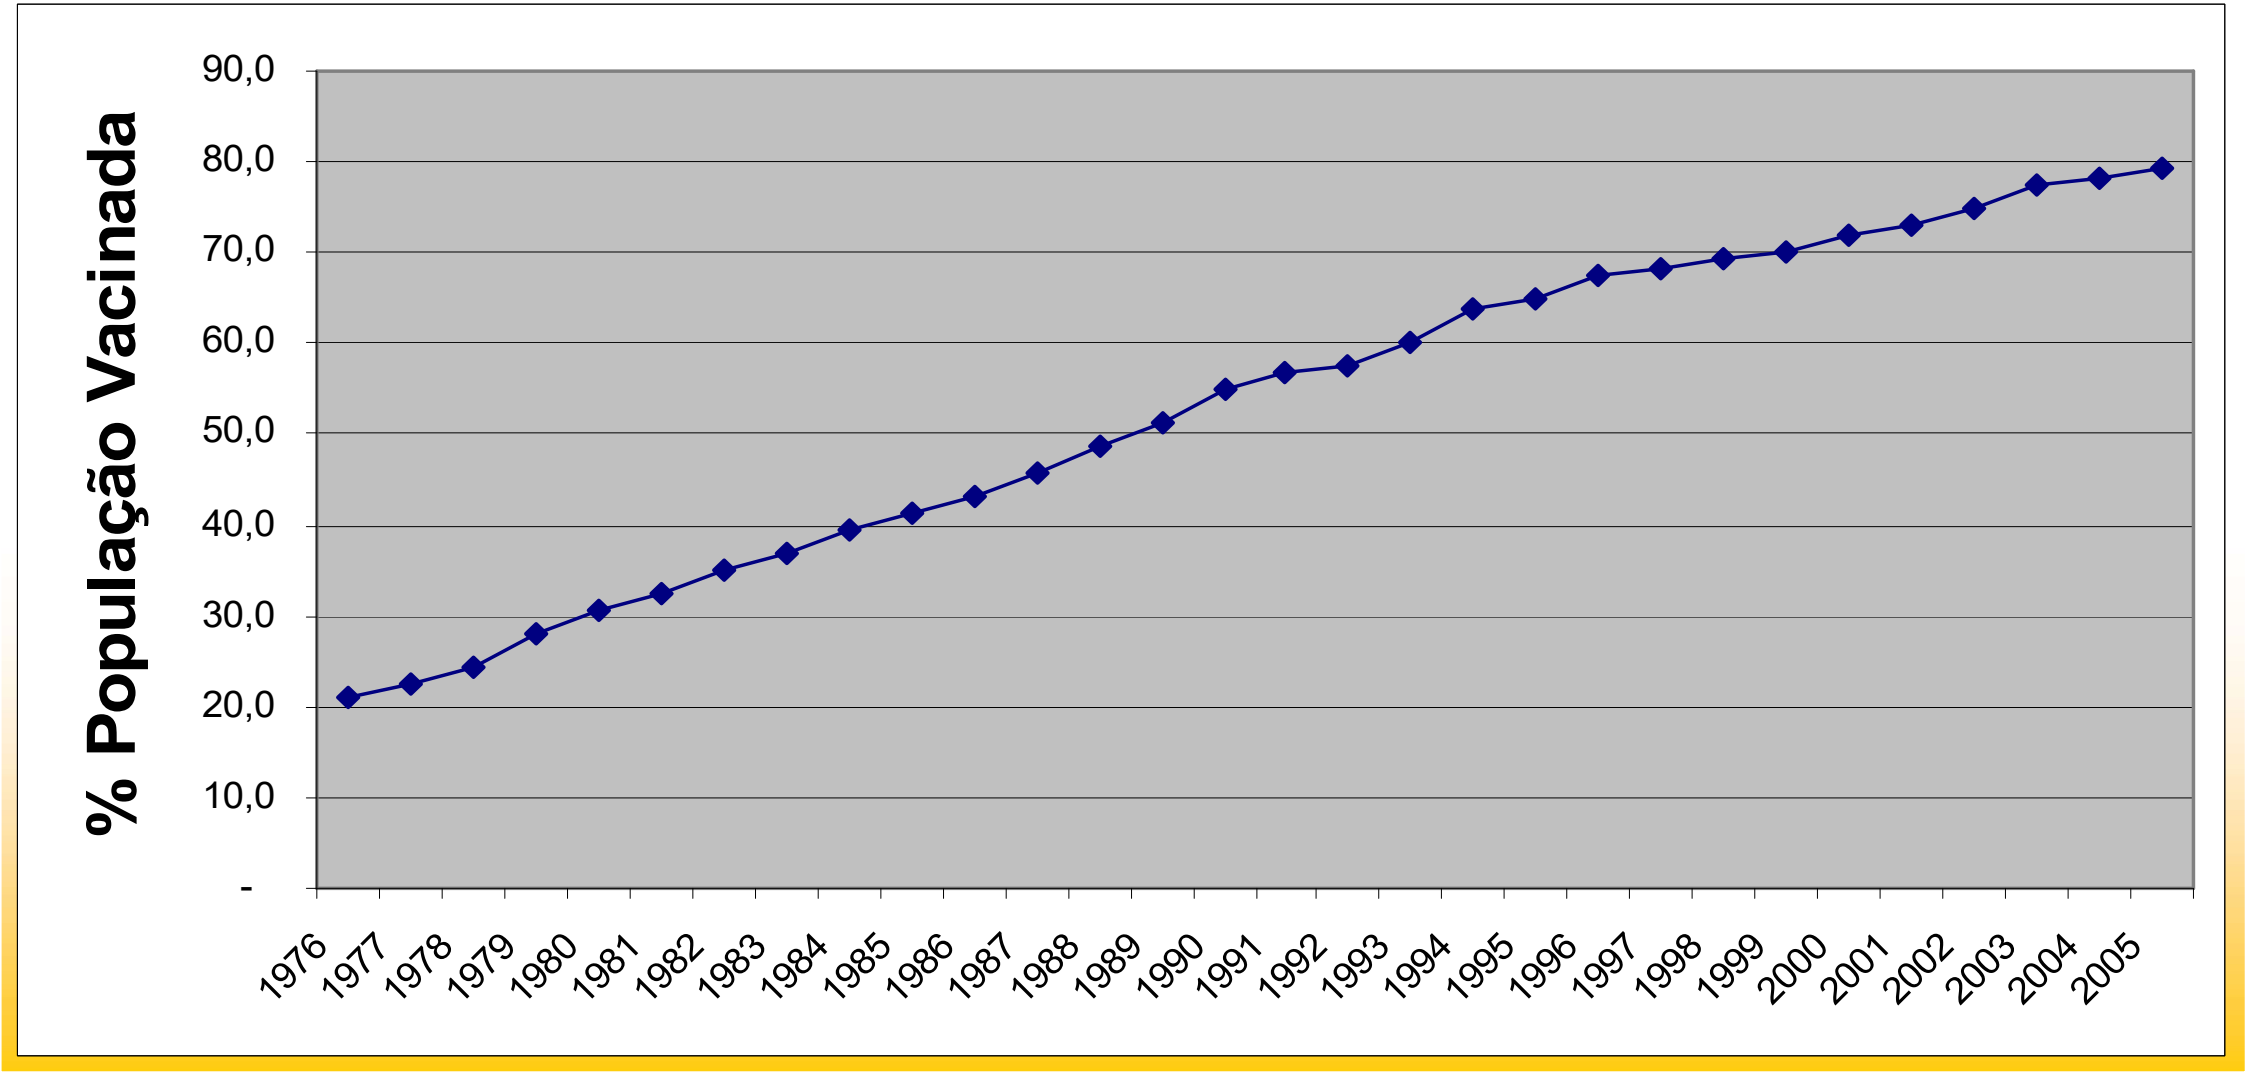
Exemplo

Considere os dados amostrais sobre a evolução da vacinação contra a febre amarela e a produção de grãos de determinado país nos últimos 30 anos.

Aplique o Teste de Raiz Unitária de Dickey-Fuller sobre as series temporais em nível e conclua sobre a estacionariedade das séries em nível.

Teste "τ" de Dickey-Fuller

Evolução Vacinação Febre Amarela em nível



Teste “τ” de Dickey-Fuller

Ano	Vacinação - Xt % População	Vacinação - Xt-1 % População	Tempo	Delta Xt
1976	21,15		-	
1977	22,50	21,15	1	1,350
1978	24,30	22,50	2	1,800
1979	27,90	24,30	3	3,600
1980	30,60	27,90	4	2,700
1981	32,40	30,60	5	1,800
1982	35,10	32,40	6	2,700
1983	36,90	35,10	7	1,800
1984	39,60	36,90	8	2,700
1985	41,40	39,60	9	1,800
1986	43,20	41,40	10	1,800
1987	45,90	43,20	11	2,700
1988	48,60	45,90	12	2,700
1989	51,30	48,60	13	2,700
1990	54,90	51,30	14	3,600
1991	56,70	54,90	15	1,800
1992	57,60	56,70	16	0,900
1993	60,30	57,60	17	2,700
1994	63,90	60,30	18	3,600
1995	64,80	63,90	19	0,900
1996	67,50	64,80	20	2,700
1997	68,40	67,50	21	0,900
1998	69,30	68,40	22	0,900
1999	70,20	69,30	23	0,900
2000	72,00	70,20	24	1,800
2001	72,90	72,00	25	0,900
2002	74,70	72,90	26	1,800
2003	77,40	74,70	27	2,700
2004	78,30	77,40	28	0,900
2005	79,20	78,30	29	0,900

Teste "τ" de Dickey-Fuller

Modelo Tipo 1: $\Delta X_t = \psi X_{t-1} + \varepsilon_t$

Passeio Aleatório *versus* AR(1) **SEM** intercepto e **SEM** tendência temporal

H_0: $\psi \geq 0 \rightarrow$ Série tem Raiz Unitária

H_1: $\psi < 0 \rightarrow$ Série **NÃO** tem Raiz Unitária

ANOVA 1: Estimadores Amostrais

	Coeficientes	*Erro padrão*	*Stat t*
Interseção	0	#N/D	#N/D
Variável X1: X(t-1)	0,032390672	0,004354989	7,437601845

Modelo Estimado 1:

$$\Delta \hat{X}_t = 0{,}0324 \times (X_{t-1})$$

Teste "τ" de Dickey-Fuller

Teste de Hipóteses 1: Avaliação de Estimadores

$H_0: \psi \geq 0$

$H_1: \psi < 0$

Estatística de Teste:

$$\tau^{calc} = \frac{(b_X - \psi)}{Erro\ \ Padrão\ \ b_X} = \frac{(0{,}0324 - 0)}{0{,}0044} = +7{,}4376$$

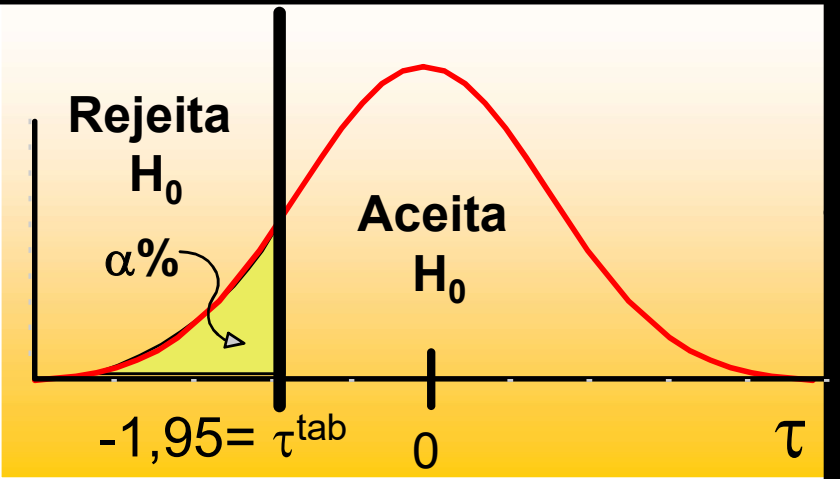
$\alpha = 5\%$

gl = n – 1 – k = 28

valor crítico: $\tau^{tab} = -1{,}95$

Comparativo: $\tau^{tab} \leq \tau^{calc}$

$\tau^{tab} = -1{,}95 < \tau^{calc} = +7{,}4376$



Decisão: Com 95% confiança, **NÃO** se rejeita H_0

Conclusão: A série EM NÍVEL possui raiz unitária, logo NÃO é estacionária.

Teste "τ" de Dickey-Fuller

Modelo Tipo 2: $\Delta X_t = \xi_X + \psi X_{t-1} + \varepsilon_t$

Passeio Aleatório *versus* AR(1) **COM** intercepto e **SEM** tendência temporal

H_0: $\psi \geq 0 \rightarrow$ Série tem Raiz Unitária

H_1: $\psi < 0 \rightarrow$ Série **NÃO** tem Raiz Unitária

ANOVA 2: Estimadores Amostrais

	Coeficientes	*Erro padrão*	*Stat t*
Interseção	3,015335595	0,482004816	6,255820477
Variável X1: X(t-1)	-0,019469934	0,008760902	-2,222366331

Modelo Estimado 2:

$$\Delta \hat{X}_t = 3{,}0153 - 0{,}0195 \times (X_{t-1})$$

Teste "τ" de Dickey-Fuller

Teste de Hipóteses 2: Avaliação de Estimadores

$H_0: \psi \geq 0$

$H_1: \psi < 0$

Estatística de Teste:

$$\tau^{calc} = \frac{(b_X - \psi)}{Erro\ \ Padrão\ \ b_X} = \frac{(0{,}0195 - 0)}{0{,}0088} = -2{,}2224$$

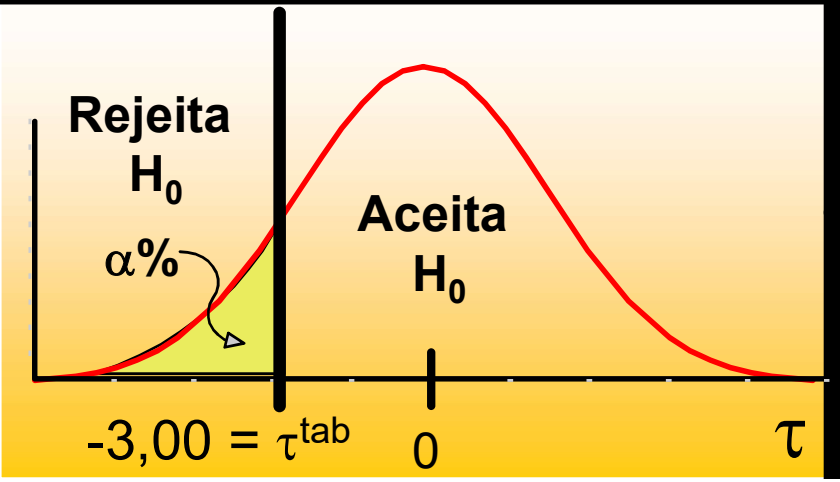
$\alpha = 5\%$

$gl = n - 1 - k = 28$

valor crítico: $\tau^{tab} = -3{,}00$

Comparativo: $\tau^{tab} \leq \tau^{calc}$

$\tau^{tab} = -3{,}00 < \tau^{calc} = -2{,}2224$



Decisão: Com 95% confiança, **NÃO** se rejeita H_0

Conclusão: A série EM NÍVEL possui raiz unitária, logo NÃO é estacionária.

Teste "τ" de Dickey-Fuller

Modelo Tipo 3: $\Delta X_t = \xi_X + \psi X_{t-1} + \lambda t + \varepsilon_t$

Passeio Aleatório *versus* AR(1) **COM** intercepto e **COM** tendência temporal

H_0: $\psi \geq 0 \rightarrow$ Série tem Raiz Unitária

H_1: $\psi < 0 \rightarrow$ Série **NÃO** tem Raiz Unitária

ANOVA 3: Estimadores Amostrais

	Coeficientes	*Erro padrão*	*Stat t*
Interseção	2,986749692	1,82948376	1,6325642
Variável X1: X(t-1)	-0,018040145	0,088597039	-0,203620184
Variável X2: Tempo	-0,003056625	0,188440105	-0,016220669

Modelo Estimado 3:

$$\Delta \hat{X}_t = 2{,}9867 - 0{,}0180 \times (X_{t-1}) - 0{,}0031 \times (t)$$

Teste "τ" de Dickey-Fuller

Teste de Hipóteses 3: Avaliação de Estimadores

H_0: $\psi \geq 0$

H_1: $\psi < 0$

Estatística de Teste:

$$\tau^{calc} = \frac{(b_X - \psi)}{Erro\ \ Padrão\ \ b_X} = \frac{(0{,}0180 - 0)}{0{,}0086} = -0{,}2036$$

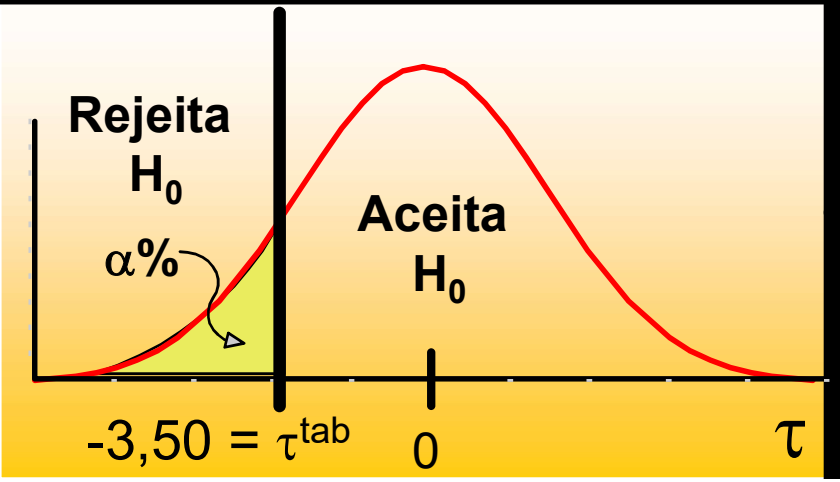
$\alpha = 5\%$

gl = n – 1 – k = 28

valor crítico: $\tau^{tab} = -3{,}60$

Comparativo: $\tau^{tab} \leq \tau^{calc}$

$\tau^{tab} = -3{,}60 < \tau^{calc} = -0{,}2036$

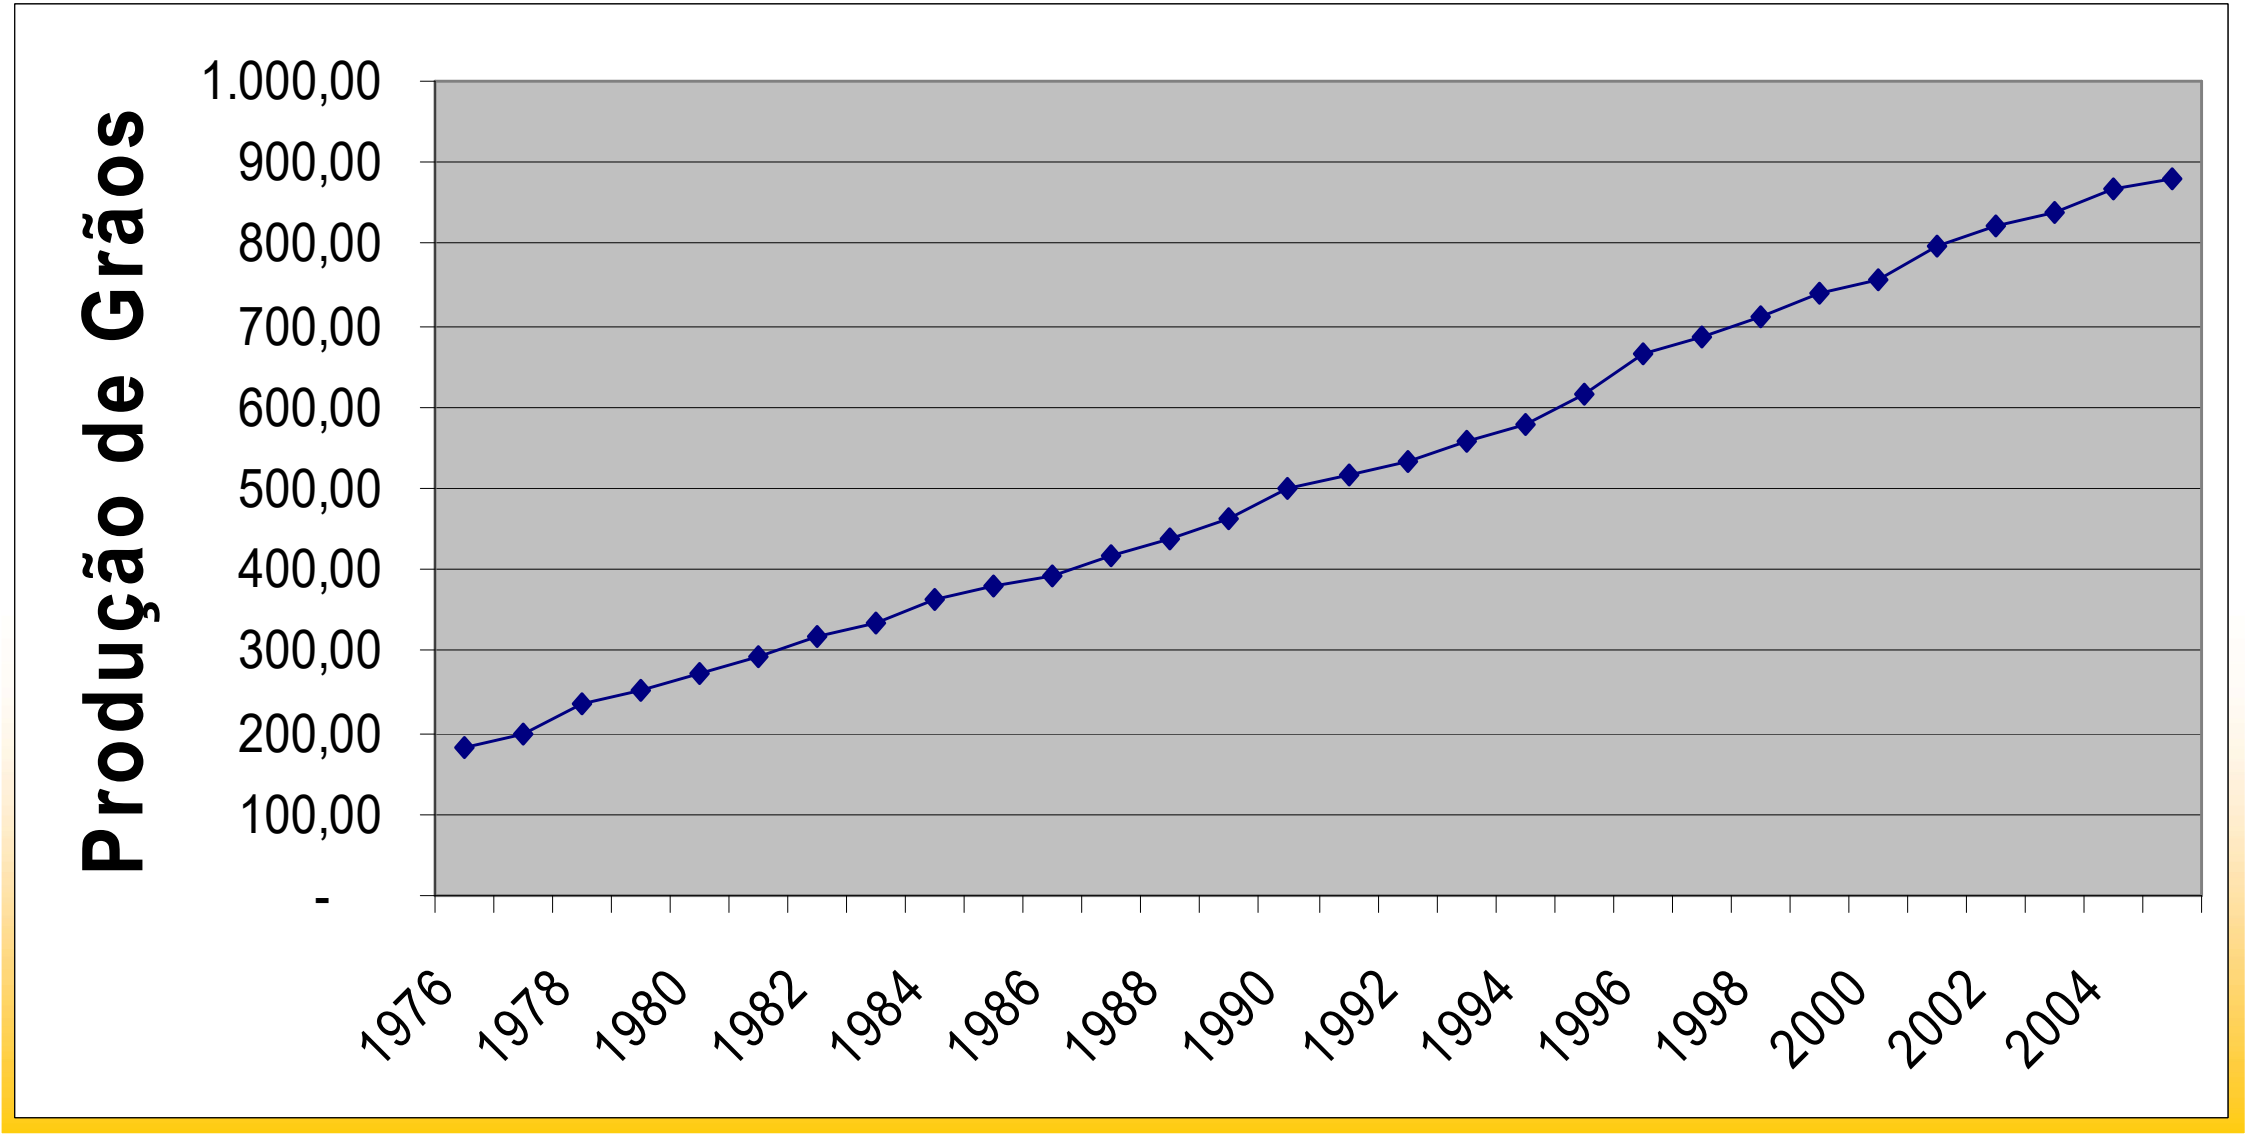


Decisão: Com 95% confiança, **NÃO** se rejeita H_0

Conclusão: A série EM NÍVEL possui raiz unitária, logo NÃO é estacionária.

Teste "τ" de Dickey-Fuller

Evolução Produção de Grãos em nível



Teste “τ” de Dickey-Fuller

Ano	Produção Grãos - Yt Toneladas 1.000	Produção Grãos - Yt-1 Toneladas 1.000	Tempo	Delta Yt
1976	183,60		-	
1977	198,00	183,60	1	14,400
1978	234,00	198,00	2	36,000
1979	252,00	234,00	3	18,000
1980	271,80	252,00	4	19,800
1981	291,60	271,80	5	19,800
1982	316,80	291,60	6	25,200
1983	336,60	316,80	7	19,800
1984	361,80	336,60	8	25,200
1985	379,80	361,80	9	18,000
1986	394,20	379,80	10	14,400
1987	415,80	394,20	11	21,600
1988	439,20	415,80	12	23,400
1989	460,80	439,20	13	21,600
1990	500,40	460,80	14	39,600
1991	518,40	500,40	15	18,000
1992	532,80	518,40	16	14,400
1993	558,00	532,80	17	25,200
1994	577,80	558,00	18	19,800
1995	613,80	577,80	19	36,000
1996	666,00	613,80	20	52,200
1997	685,80	666,00	21	19,800
1998	709,20	685,80	22	23,400
1999	739,80	709,20	23	30,600
2000	757,80	739,80	24	18,000
2001	795,60	757,80	25	37,800
2002	820,80	795,60	26	25,200
2003	840,60	820,80	27	19,800
2004	865,80	840,60	28	25,200
2005	882,00	865,80	29	16,200

Teste "τ" de Dickey-Fuller

Modelo Tipo 1: $\Delta Y_t = \psi Y_{t-1} + \varepsilon_t$

Passeio Aleatório *versus* AR(1) **SEM** intercepto e **SEM** tendência temporal

H_0: $\psi \geq 0 \rightarrow$ Série tem Raiz Unitária

H_1: $\psi < 0 \rightarrow$ Série **NÃO** tem Raiz Unitária

ANOVA 1: Estimadores Amostrais

	Coeficientes	*Erro padrão*	*Stat t*
Interseção	0	#N/D	#N/D
Variável Y 1: Y(t-1)	0,04168602	0,003986342	10,45721029

Modelo Estimado 1:

$$\Delta \hat{Y}_t = 0{,}0417 \times (Y_{t-1})$$

Teste "τ" de Dickey-Fuller

Teste de Hipóteses 1: Avaliação de Estimadores

$H_0: \psi \geq 0$

$H_1: \psi < 0$

Estatística de Teste:

$$\tau^{calc} = \frac{(b_Y - \psi)}{Erro \quad Padrão \quad b_Y} = \frac{(0{,}0417 - 0)}{0{,}0040} = +10{,}457$$

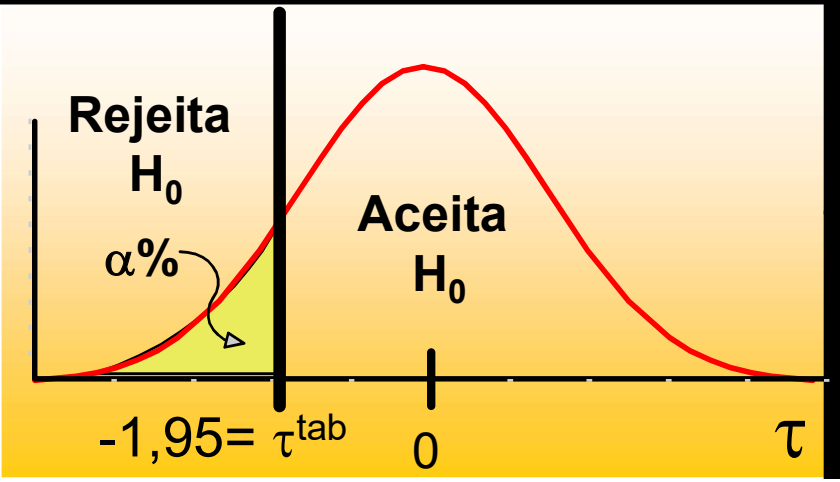
$\alpha = 5\%$

$gl = n - 1 - k = 28$

valor crítico: $\tau^{tab} = -1{,}95$

Comparativo: $\tau^{tab} \leq \tau^{calc}$

$\tau^{tab} = -1{,}95 < \tau^{calc} = +10{,}457$



Decisão: Com 95% confiança, **NÃO** se rejeita H_0

Conclusão: A série EM NÍVEL possui raiz unitária, logo NÃO é estacionária.

Teste "τ" de Dickey-Fuller

Modelo Tipo 2: $\Delta Y_t = \xi_Y + \psi Y_{t-1} + \varepsilon_t$

Passeio Aleatório *versus* AR(1) **COM** intercepto e **SEM** tendência temporal

H_0: $\psi \geq 0 \rightarrow$ Série tem Raiz Unitária

H_1: $\psi < 0 \rightarrow$ Série **NÃO** tem Raiz Unitária

ANOVA 2: Estimadores Amostrais

	Coeficientes	*Erro padrão*	*Stat t*
Interseção	20,71564686	4,371289647	4,73902407
Variável Y 1: Y(t-1)	0,006634207	0,007981441	0,831204155

Modelo Estimado 2:

$$\Delta \hat{Y}_t = 20,7156 - 0,0066 \times (Y_{t-1})$$

Teste "τ" de Dickey-Fuller

Teste de Hipóteses 2: Avaliação de Estimadores

H_0: $\psi \geq 0$

H_1: $\psi < 0$

Estatística de Teste:

$$\tau^{calc} = \frac{(b_Y - \psi)}{Erro \quad Padrão \quad b_Y} = \frac{(0{,}0066 - 0)}{0{,}0080} = +0{,}8312$$

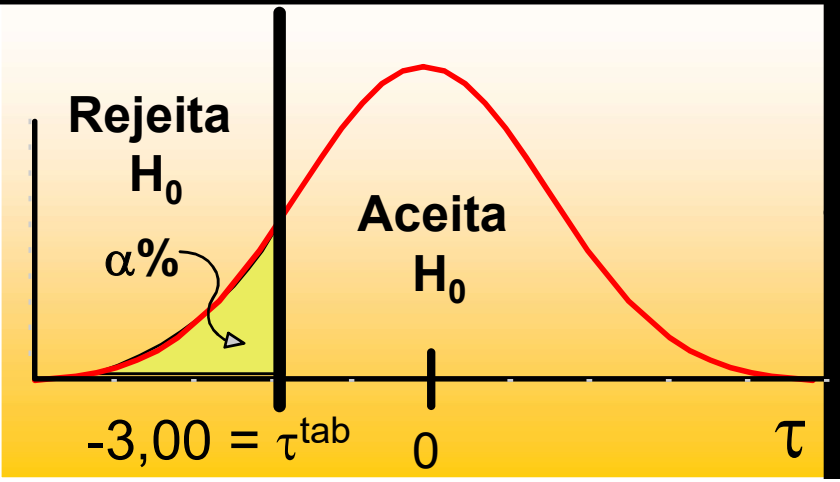
$\alpha = 5\%$

$gl = n - 1 - k = 28$

valor crítico: $\tau^{tab} = -3{,}00$

Comparativo: $\tau^{tab} \leq \tau^{calc}$

$\tau^{tab} = -3{,}00 < \tau^{calc} = +0{,}8312$



Decisão: Com 95% confiança, **NÃO** se rejeita H_0

Conclusão: A série EM NÍVEL possui raiz unitária, logo NÃO é estacionária.

Teste "τ" de Dickey-Fuller

Modelo Tipo 3: $\Delta Y_t = \xi_Y + \psi Y_{t-1} + \lambda t + \varepsilon_t$

Passeio Aleatório *versus* AR(1) **COM** intercepto e **COM** tendência temporal

H_0: $\psi \geq 0 \rightarrow$ Série tem Raiz Unitária

H_1: $\psi < 0 \rightarrow$ Série **NÃO** tem Raiz Unitária

ANOVA 3: Estimadores Amostrais

	Coeficientes	*Erro padrão*	*Stat t*
Interseção	47,99608446	14,90325185	3,220510862
Variável Y1: Y(t-1)	-0,191693416	0,104291912	-1,838046801
Variável Y2: Tempo	4,89189026	2,565561005	1,906752656

Modelo Estimado 3:

$$\Delta \hat{Y}_t = 47{,}996 - 0{,}192 \times (Y_{t-1}) + 4{,}892 \times (t)$$

Teste "τ" de Dickey-Fuller

Teste de Hipóteses 3: Avaliação de Estimadores

$H_0: \psi \geq 0$

$H_1: \psi < 0$

Estatística de Teste:

$$\tau^{calc} = \frac{(b_Y - \psi)}{Erro \;\; Padrão \;\; b_Y} = \frac{(-0{,}192 - 0)}{0{,}104} = -1{,}838$$

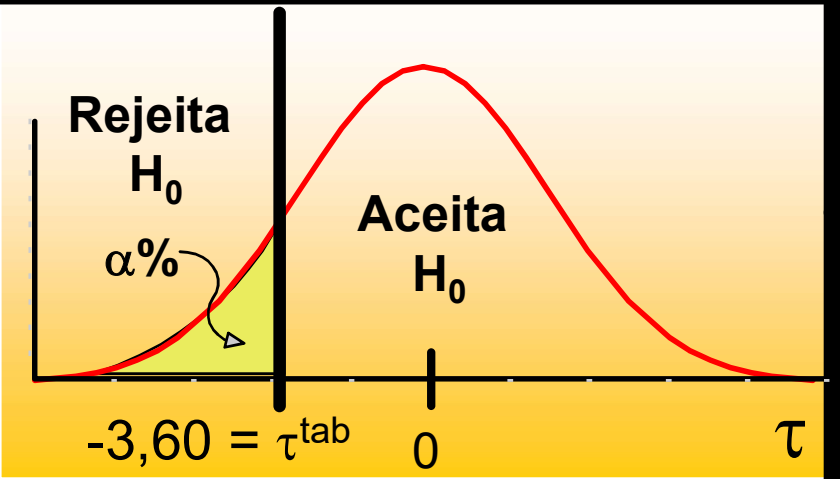
$\alpha = 5\%$

$gl = n - 1 - k = 28$

valor crítico: $\tau^{tab} = -3{,}60$

Comparativo: $\tau^{tab} \leq \tau^{calc}$

$\tau^{tab} = -3{,}60 < \tau^{calc} = -1{,}838$



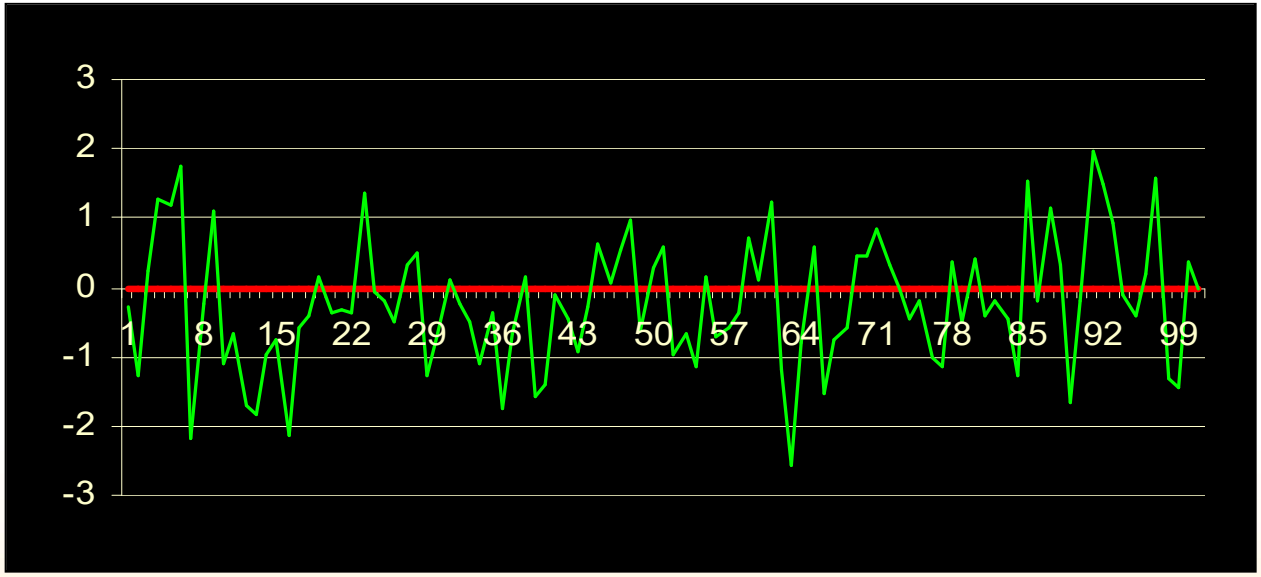
Decisão: Com 95% confiança, **NÃO** se rejeita H_0

Conclusão: A série EM NÍVEL possui raiz unitária, logo NÃO é estacionária.

Teste "τ" Dickey-Fuller **Aumentado**

- Teste "τ" Dickey-Fuller somente tem validade se o termo de erro seguir um processo de ruído branco

$$\varepsilon_t \sim RB(0\ ;\ \sigma_\varepsilon)$$



$E(\varepsilon_t) = 0$

$Var(\varepsilon_t) = E(\varepsilon_t \times \varepsilon_t)\ E(\varepsilon^2_t) = \ldots = \sigma^2_\varepsilon$

$Cov(\varepsilon_t\ ;\ \varepsilon_{t-k}) = E(\varepsilon_t \times \varepsilon_{t-k}) = 0,\ \ \forall\, k \neq 0$

Teste "τ" Dickey-Fuller **Aumentado**

- Dada a baixa probabilidade de o termo de erro seguir um processo de ruído branco
- Dickey and Fuller aprimoraram seus procedimentos e apresentaram a versão "aumentada" do teste D-F, a qual faz uso de *p* defasagens da variável xplicada
- O modelo aumentado é definido da seguinte forma:

$$\Delta X_t = \psi X_{t-1} + \sum_{i=1}^{p} \alpha_i \Delta X_{t-i} + \varepsilon_t$$

Obrigado por sua atenção!!!

Estatística Aplicada

Sistema de Avaliação

"Se eu escuto, eu esqueço.
Se eu vejo, eu lembro.
Se eu faço, eu entendo."

Confúcio
551 - 479 A.C.

Lista de Exercícios nº 11

1. Aplique o Teste de Raiz Unitária de Dickey-Fuller sobre a série temporal de resíduos gerada a partir do modelo de regressão linear proposto na questão 1 da lista de exercícios nr. 10. E conclua sobre a estacionariedade da série em questão.

Lista de Exercícios nº 11

2. No exemplo da aula de hoje sobre a aplicação do teste de Raiz Unitária de Dickey-Fuller, observou-se que os resultados indicaram não estacionariedade das séries temporais:
EXPLICATIVA (%PV): a vacinação contra febre amarela, mensurada em percentual da população do país, em nível

   EXPLICADA (PG): a produção de grãos, mensurada em milhares de toneladas, em nível,

   Então, pede-se que você diferencie as séries temporais: EXPLICATIVA (%PV) e EXPLICADA (PG), as quais devem assumir as seguinte simbologia:

   Δ%PV: a vacinação contra febre amarela, mensurada em percentual da população do país, em 1a. diferença.

   Δ PG: a produção de grãos, mensurada em milhares de toneladas, em 1a. diferença.

Lista de Exercícios nº 11

3) Aplique o Teste de Raiz Unitária de Dickey-Fuller às series temporais em 1a. Diferença, geradas a partir do exercício 2, e conclua sobre a sua estacionariedade.