ESTATÍSTICA APLICADA

AULA 12

PROFESSOR

João Carlos Félix Souza

Estatística Aplicada

Aula 12 - Agenda

- Cointegração
- Causalidade de Granger
- Modelos ARIMA
- Modelos GARCH

Estatística Aplicada

Aula 12 - Agenda

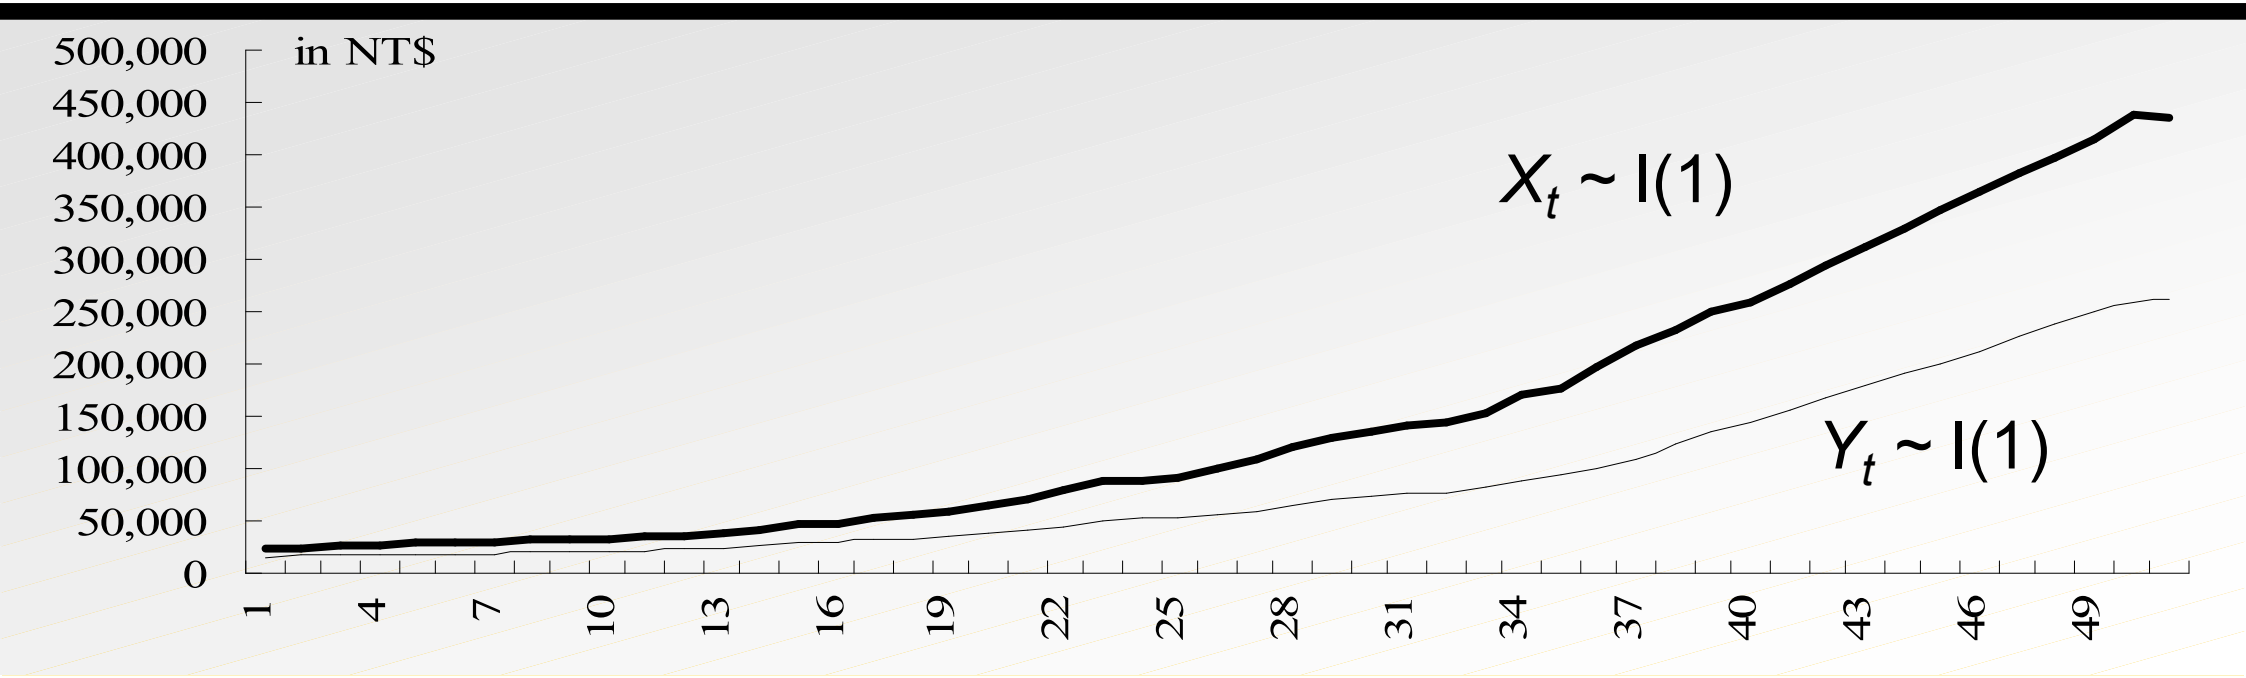
Cointegração

Regressão Espúria

- Sejam duas variáveis aleatórias, Y e X, com processos NÃO-estacionários de geração de dados

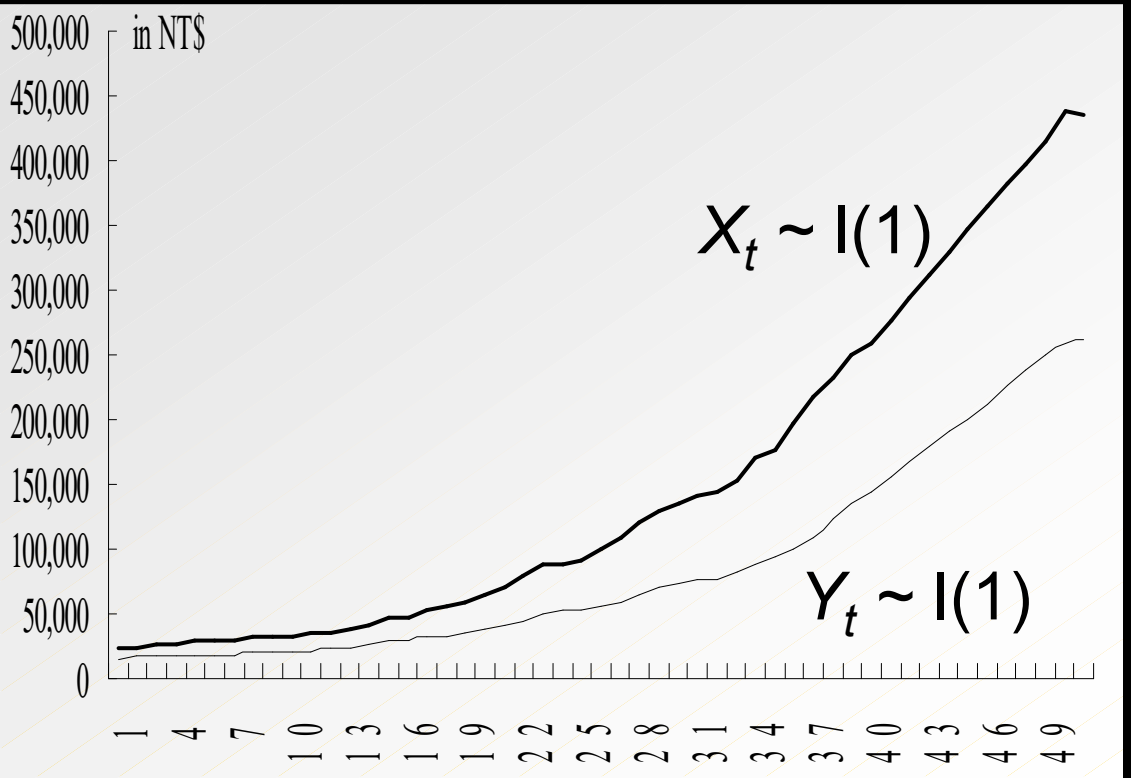
- Considere o modelo em que:
  - Y é variável EXPLICADA e
  - X é variável EXPLICATIVA

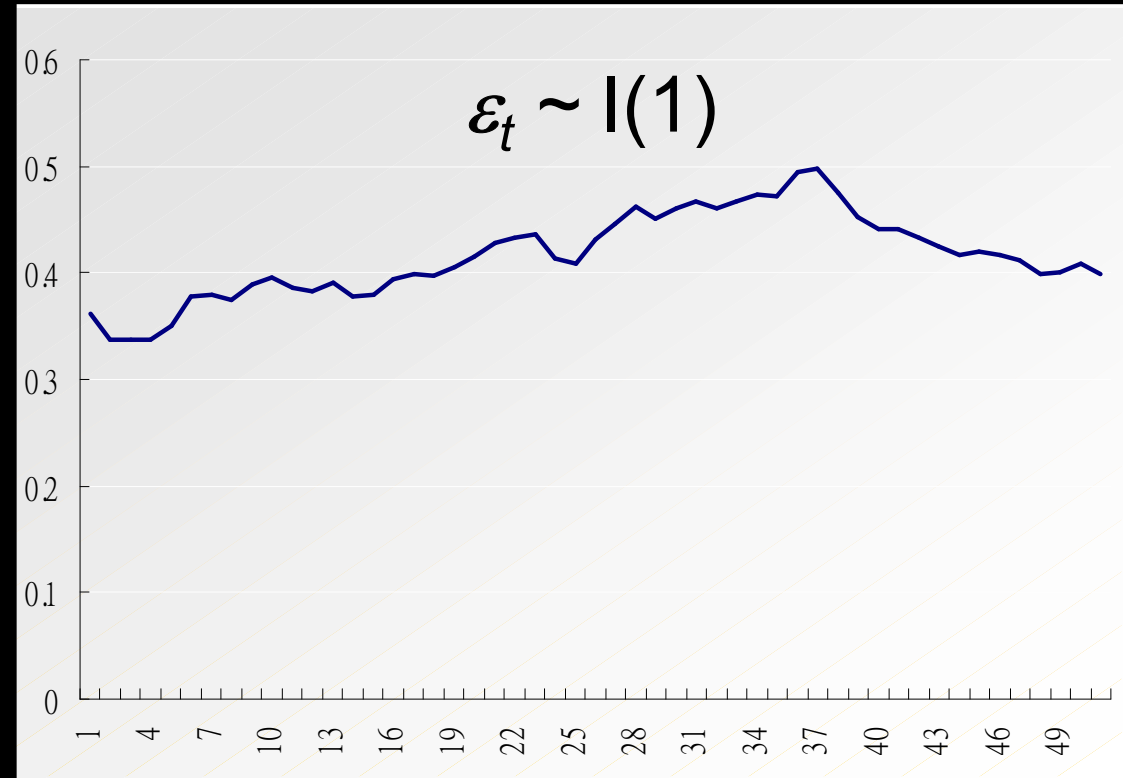
$$Y_t = \beta_0 + \beta_1 X_t + \varepsilon_t$$
$$\hat{Y}_t = b_0 + b_1 X_t + e_t$$



Regressão Espúria

- Se o termo de erro populacional (ε), estimado pelo resíduo amostral (e), for:
  - NÃO-estacionário
    - ✓ a regressão será **ESPÚRIA**





Regressão Espúria

- Duas séries X e Y formam regressão espúria se:
  - Ambas séries são NÃO-estacionárias em NÍVEL
  - Ambas séries são integradas de mesma ordem "d":
    - ✓ $Y_t \sim I(d)$
    - ✓ $X_t \sim I(d)$
  - Combinação linear das 2 séries é integrada de ordem "d":
    - ✓ $(Y_t - X_t) \sim I(d)$
  - Resíduos são NÃO-estacionários
    - ✓ Erro Aleatório: $\varepsilon_t \sim I(d)$
    - ✓ Resíduo: $e_t \sim I(d)$

Cointegração

Relação estável de longo prazo entre a variável EXPLICADA (Y) e a variável EXPLICATIVA (X)



Cointegração

Exemplos de relacionamentos cointegrados em Finanças

- preços à vista e preços futuros
- preços relativos e taxa de câmbio
- preços e ações e dividendos

Cointegração

Tanto a variável EXPLICADA (Y) quanto a variável EXPLICATIVA (X) são NÃO-estacionárias



Cointegração reflete correlação de longo prazo entre X e Y

Cointegração NÃO reflete causalidade entre X e Y

Cointegração

- Variáveis Y e X são NÃO-estacionárias
- Resíduos são estacionários

$$Y_t = \beta_0 + \beta_1 X_t + \varepsilon_t$$
$$\hat{Y}_t = b_0 + b_1 X_t + e_t$$

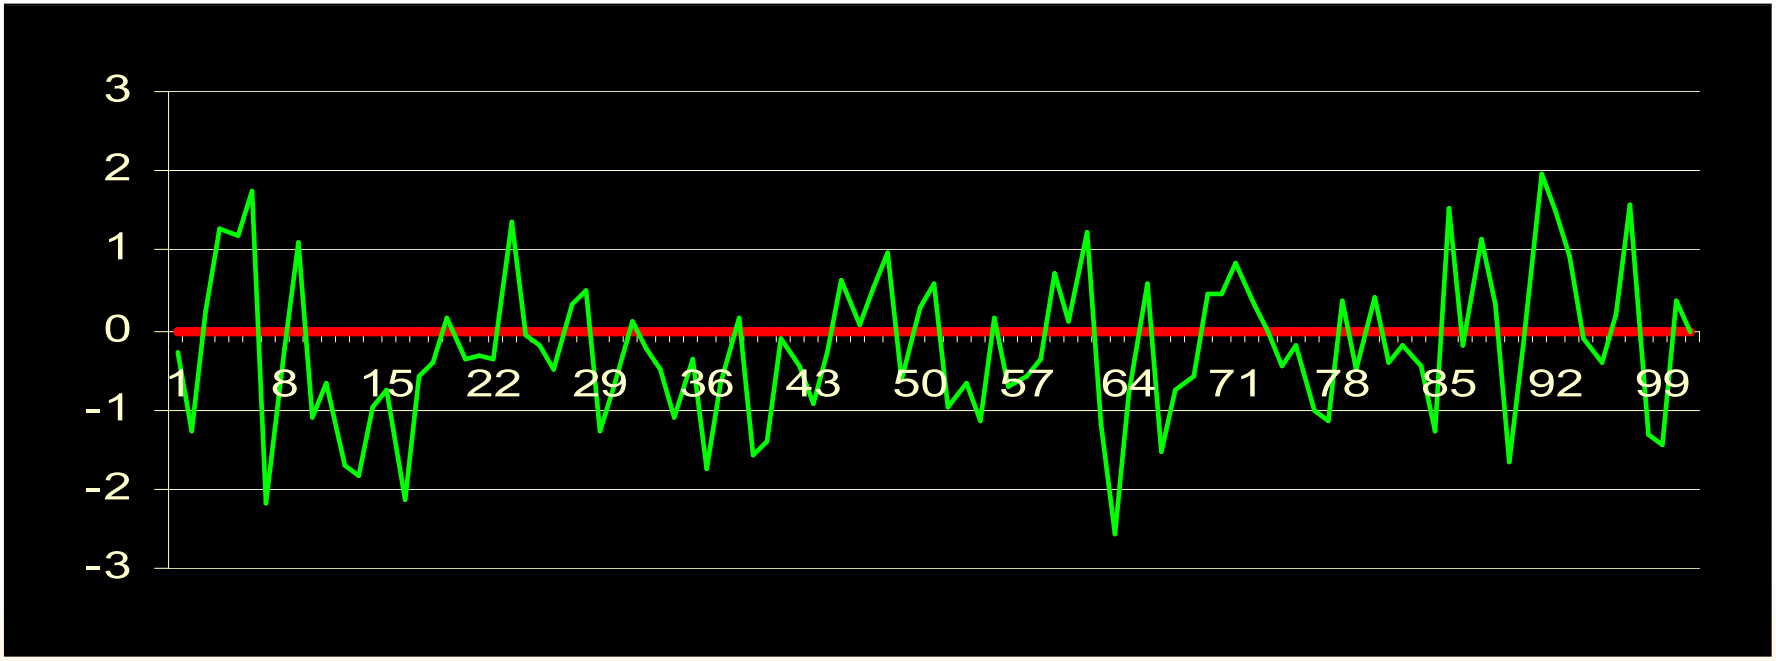
Consumo: $Y_t \sim I(1)$
Renda: $X_t \sim I(1)$
Erro Aleatório: $\varepsilon_t \sim I(0)$
Resíduo: $e_t \sim I(0)$



Cointegração NÃO reflete causalidade entre X e Y

Ruído Branco

$$\varepsilon_t \sim RB(0\ ;\ \sigma_\varepsilon)$$



$E(\varepsilon_t) = 0$

$Var(\varepsilon_t) = E(\varepsilon_t \times \varepsilon_t)\ E(\varepsilon^2_t) = \ldots = \sigma^2_\varepsilon$

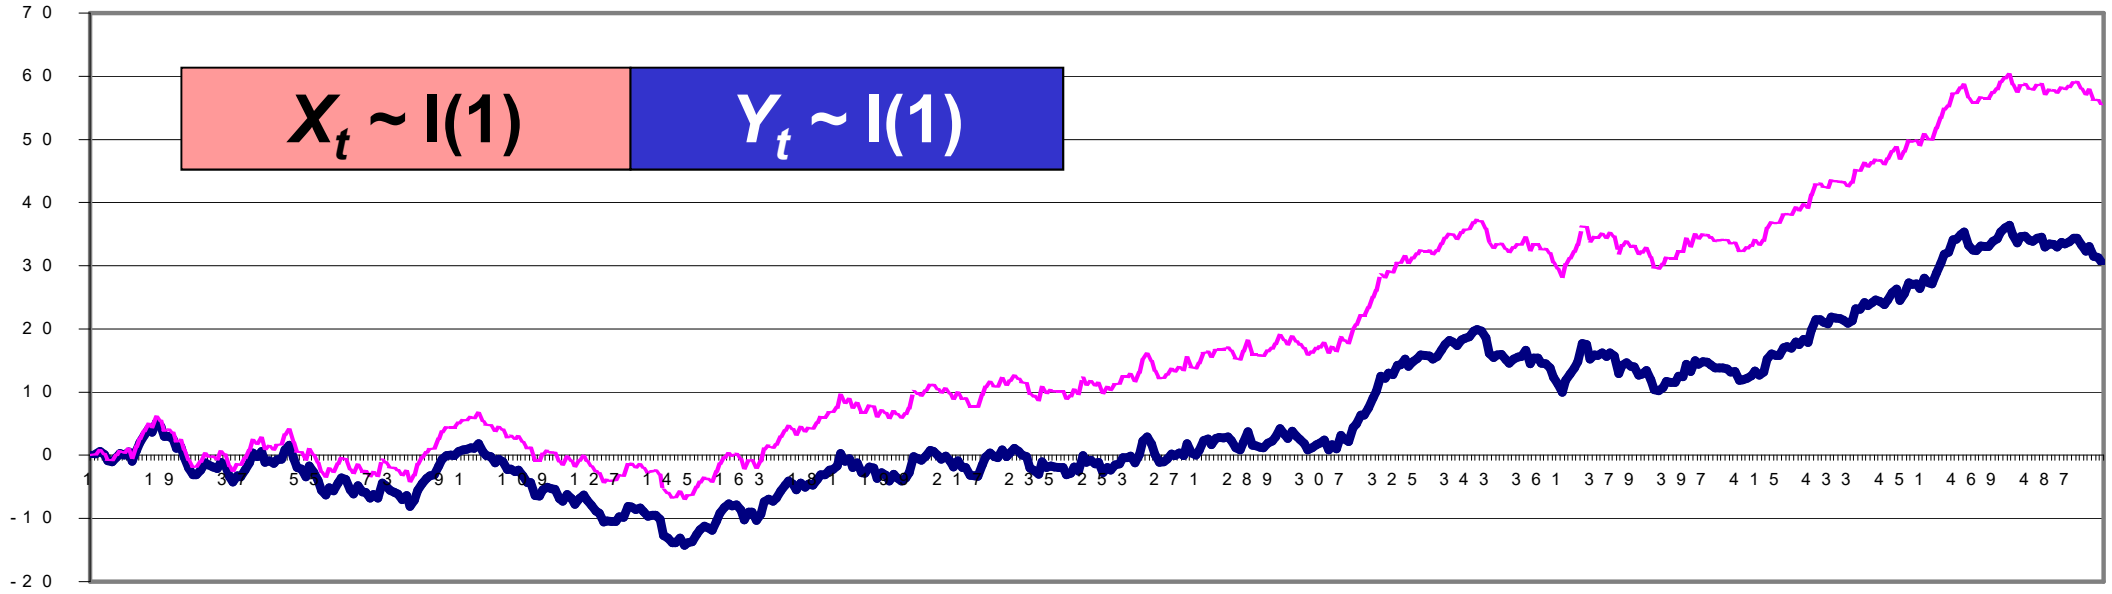
$Cov(\varepsilon_t\ ;\ \varepsilon_{t-k}) = E(\varepsilon_t \times \varepsilon_{t-k}) = 0,\ \ \forall\, k \neq 0$

Cointegração

- Sejam duas variáveis aleatórias, Y e X, com processos NÃO-estacionários de geração de dados

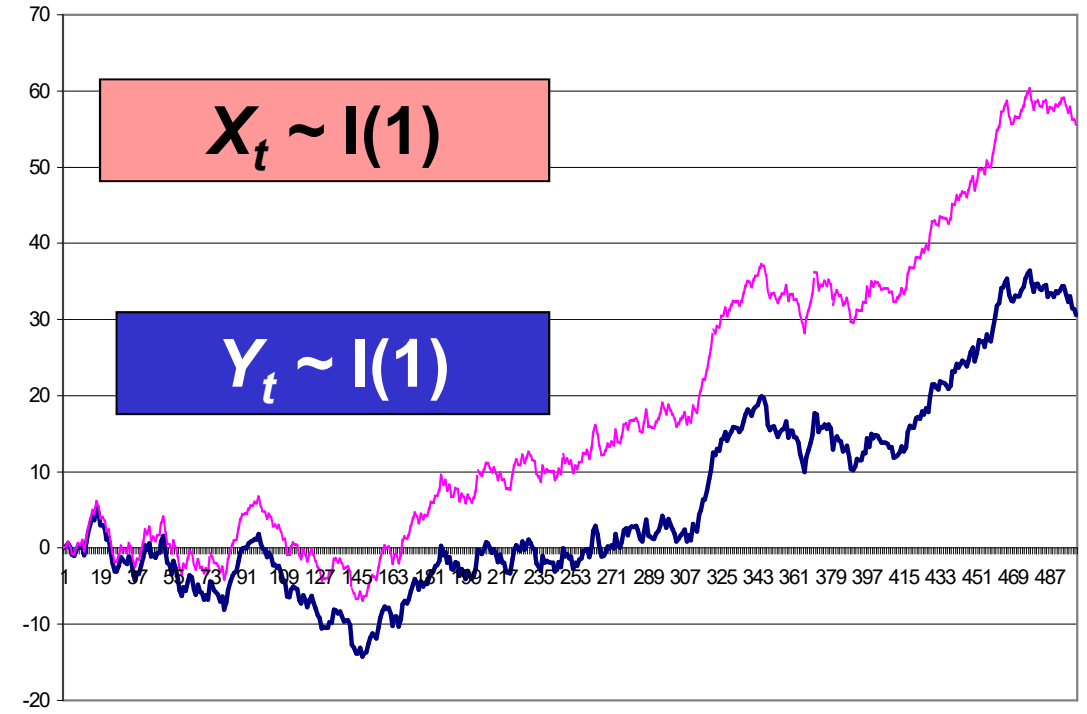
- Considere o modelo em que:
  - Y é variável EXPLICADA e
  - X é variável EXPLICATIVA

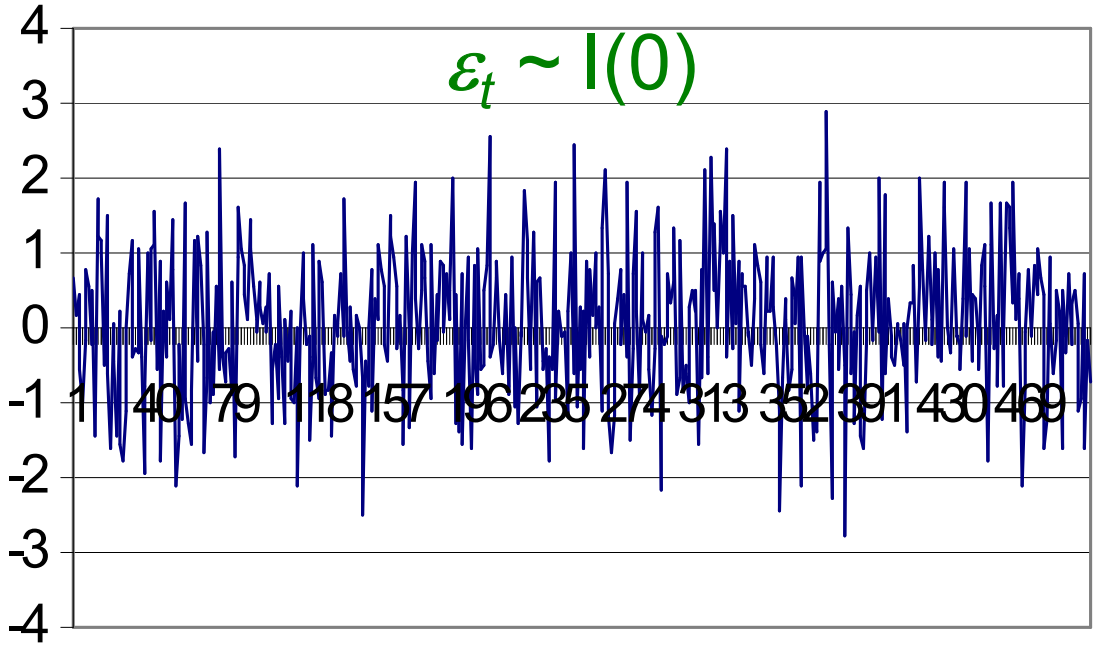
$$Y_t = \beta_0 + \beta_1 X_t + \varepsilon_t$$
$$\hat{Y}_t = b_0 + b_1 X_t + e_t$$



Cointegração

- Se o termo de erro populacional (ε), estimado pelo resíduo amostral (e), for:
  - estacionário
    - ✓ X e Y são variáveis **COINTEGRADAS**





Teste Cointegração Engle-Granger

- Duas séries X e Y são cointegradas se:
  - Ambas séries são NÃO-estacionárias em NÍVEL
    - ➔ Ambas séries são integradas de mesma ordem "1":
      - ✓ $Y_t \sim I(1)$
      - ✓ $X_t \sim I(1)$
  - Combinação linear das 2 séries é integrada de ordem "0":
    - ✓ $(Y_t - X_t) \sim I(0)$
  - Resíduos são estacionários
    - ✓ Erro Aleatório: $\varepsilon_t \sim I(0)$
    - ✓ Resíduo: $e_t \sim I(0)$

Exemplo

Considere os dados amostrais sobre a evolução da vacinação contra a febre amarela e a produção de grãos de determinado país nos últimos 30 anos.

1) Estime um modelo de regressão linear, considerando como variável:
EXPLICATIVA (%PV): a vacinação contra febre amarela, mensurada em percentual da população do país, em nível.

EXPLICADA (PG): a produção de grãos, mensurada em milhares de toneladas, em nível.

Testes de Estacionariedade

Resultados dos testes de Dickey-Fuller

- {%PV}: NÃO estacionária em nível
- {*PG*}: NÃO estacionária em nível
- {Resíduos}: NÃO estacionária em nível

Teste Cointegração Engle-Granger

Resultados dos testes de estacionariedade

- {Δ%PV} ~ I(0): Estacionária em 1ª. diferença
- {Δ*PG*} ~ I(0): Estacionária 1ª. diferença
- {ΔResíduo} ~ I(?): Avalie a estacionariedade da série de Resíduos em 1a. diferença

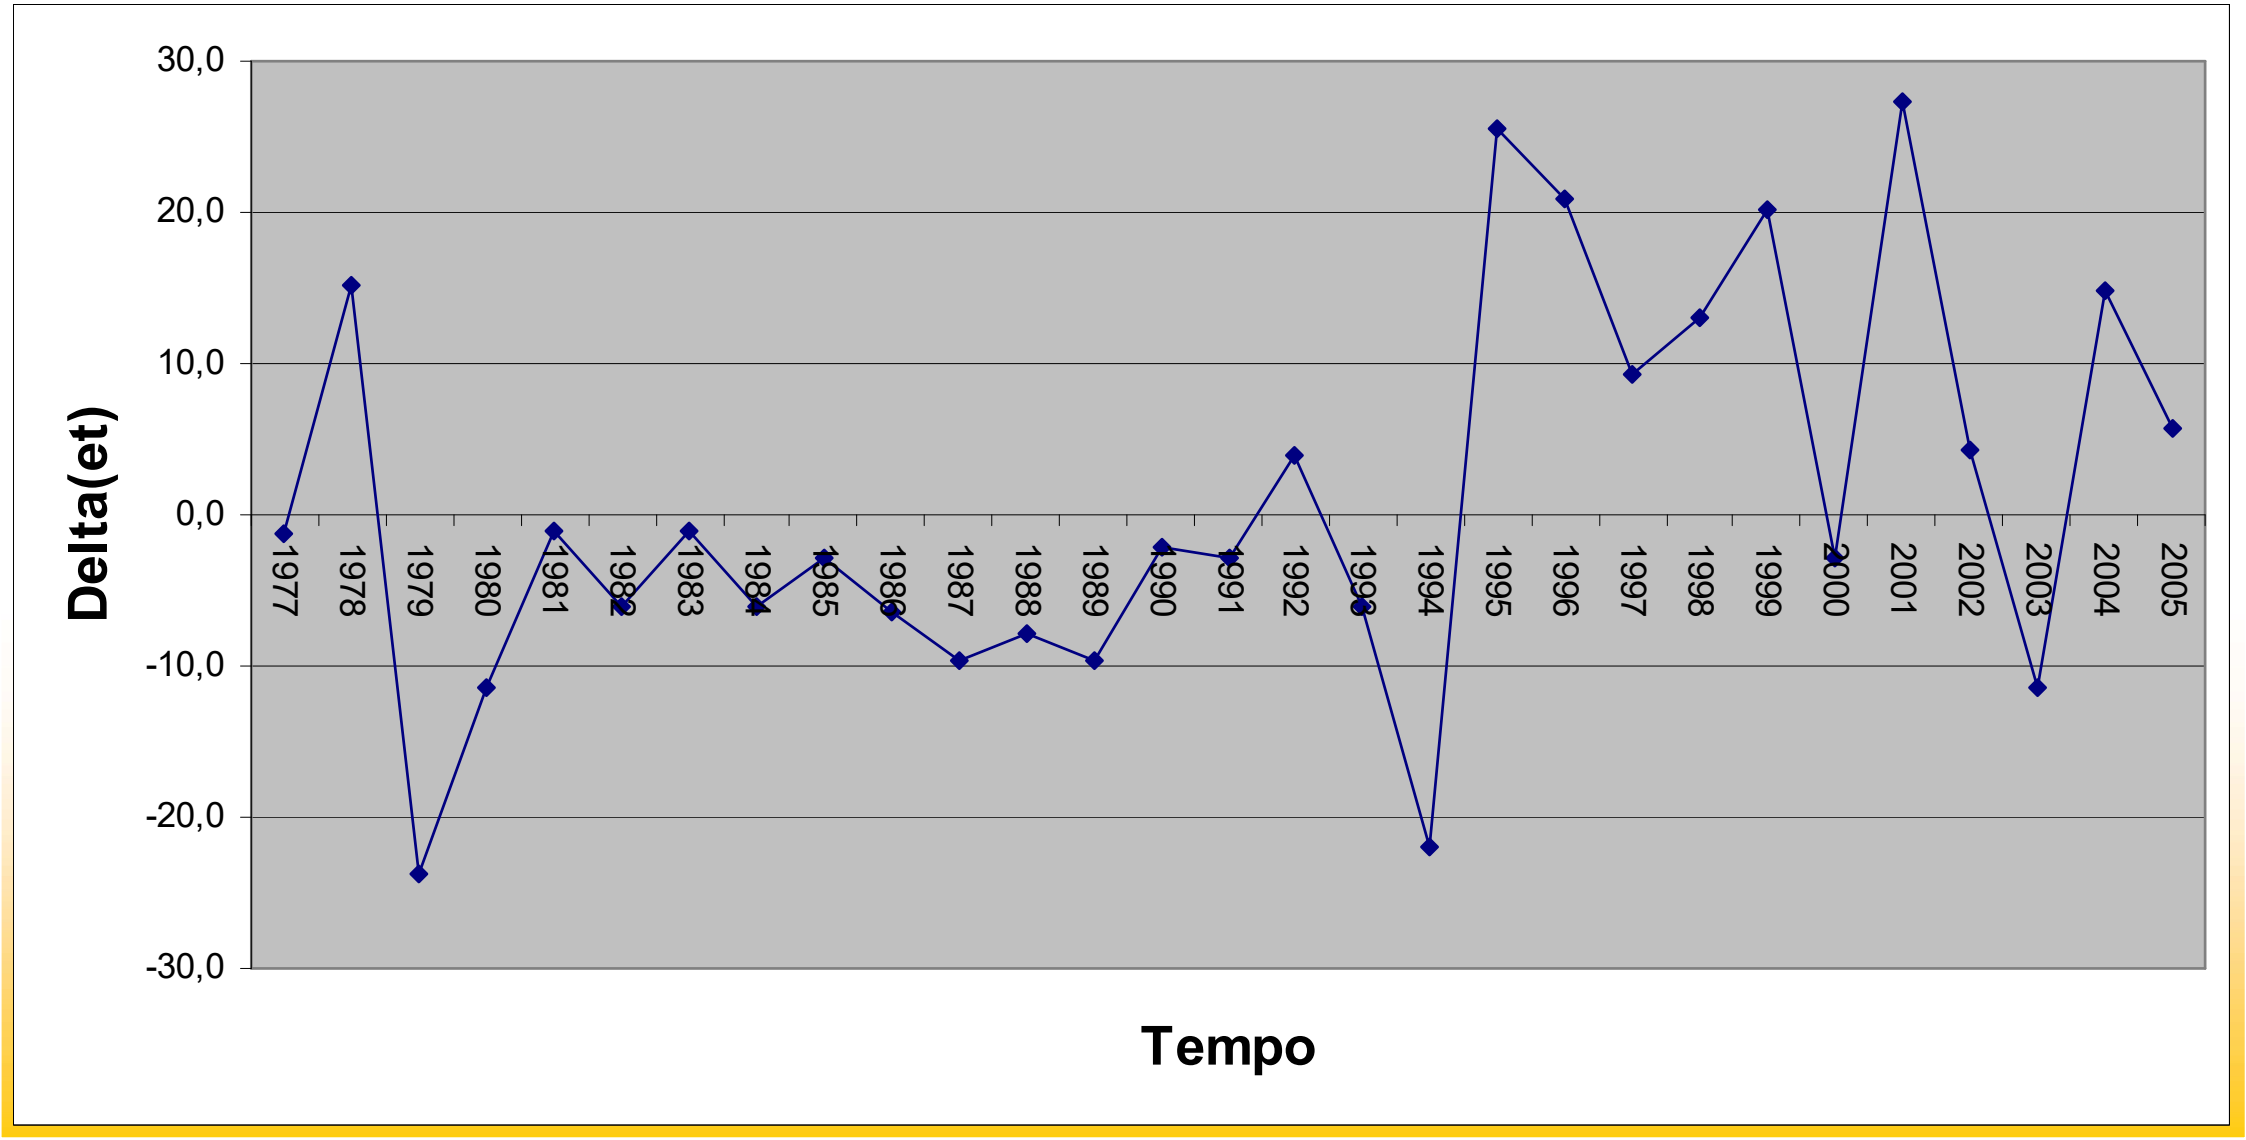
Lista de Exercícios nº 11

Evolução Resíduos do Modelo - 1a. Dif: Δe_t

Ano	Resíduo et	Resíduo et-1	Delta et
1976	32,20		
1977	30,95	32,20	(1,241)
1978	46,10	30,95	15,145
1979	22,39	46,10	(23,710)
1980	10,91	22,39	(11,483)
1981	9,85	10,91	(1,055)
1982	3,77	9,85	(6,083)
1983	2,71	3,77	(1,055)
1984	(3,37)	2,71	(6,083)
1985	(6,23)	(3,37)	(2,855)
1986	(12,68)	(6,23)	(6,455)
1987	(22,36)	(12,68)	(9,683)
1988	(30,25)	(22,36)	(7,883)
1989	(39,93)	(30,25)	(9,683)
1990	(42,04)	(39,93)	(2,110)
1991	(44,89)	(42,04)	(2,855)
1992	(40,92)	(44,89)	3,972
1993	(47,01)	(40,92)	(6,083)
1994	(68,92)	(47,01)	(21,910)
1995	(43,34)	(68,92)	25,572
1996	(22,43)	(43,34)	20,917
1997	(13,05)	(22,43)	9,372
1998	(0,08)	(13,05)	12,972
1999	20,09	(0,08)	20,172
2000	17,24	20,09	(2,855)
2001	44,61	17,24	27,372
2002	48,95	44,61	4,345
2003	37,47	48,95	(11,483)
2004	52,24	37,47	14,772
2005	58,02	52,24	5,772

Lista de Exercícios nº 11

Evolução Resíduos do Modelo - 1a. Dif: Δe_t



Ano	Tempo	Delta et	Delta et-1	Delta(Tempo)	Delta2(et)
1976	-				
1977	1	(1,241)			
1978	2	15,145	(1,241)	1	16,386
1979	3	(23,710)	15,145	1	(38,855)
1980	4	(11,483)	(23,710)	1	12,228
1981	5	(1,055)	(11,483)	1	10,428
1982	6	(6,083)	(1,055)	1	(5,028)
1983	7	(1,055)	(6,083)	1	5,028
1984	8	(6,083)	(1,055)	1	(5,028)
1985	9	(2,855)	(6,083)	1	3,228
1986	10	(6,455)	(2,855)	1	(3,600)
1987	11	(9,683)	(6,455)	1	(3,228)
1988	12	(7,883)	(9,683)	1	1,800
1989	13	(9,683)	(7,883)	1	(1,800)
1990	14	(2,110)	(9,683)	1	7,572
1991	15	(2,855)	(2,110)	1	(0,745)
1992	16	3,972	(2,855)	1	6,828
1993	17	(6,083)	3,972	1	(10,055)
1994	18	(21,910)	(6,083)	1	(15,828)
1995	19	25,572	(21,910)	1	47,483
1996	20	20,917	25,572	1	(4,655)
1997	21	9,372	20,917	1	(11,545)
1998	22	12,972	9,372	1	3,600
1999	23	20,172	12,972	1	7,200
2000	24	(2,855)	20,172	1	(23,028)
2001	25	27,372	(2,855)	1	30,228
2002	26	4,345	27,372	1	(23,028)
2003	27	(11,483)	4,345	1	(15,828)
2004	28	14,772	(11,483)	1	26,255
2005	29	5,772	14,772	1	(9,000)

Teste "τ" de Dickey-Fuller

Modelo Tipo 1: $\Delta^2 e_t = \psi(\Delta e_{t-1}) + u_t$

Passeio Aleatório *versus* AR(1) **SEM** intercepto e **SEM** tendência temporal

H_0: $\psi \geq 0 \rightarrow$ Série tem Raiz Unitária

H_1: $\psi < 0 \rightarrow$ Série **NÃO** tem Raiz Unitária

ANOVA 1: Estimadores Amostrais

	Coeficientes	*Erro padrão*	*Stat t*	*valor-P*
Interseção	0	#N/D	#N/D	#N/D
Variável X1: Delta(et-1)	-0,851114967	0,190958228	-4,45707407	0,013%

Modelo Estimado 1:

$$\Delta^2 \hat{e}_t = -0{,}8511 \times (\Delta e_{t-1})$$

Teste "τ" de Dickey-Fuller

Teste de Hipóteses 1: Avaliação de Estimadores

$H_0: \psi \geq 0$

$H_1: \psi < 0$

Estatística de Teste:

$$\tau^{calc} = \frac{(b_e - \psi)}{Erro\ \ Padrão\ \ b_e} = \frac{(-0{,}8511 - 0)}{0{,}0191} = -4{,}4571$$

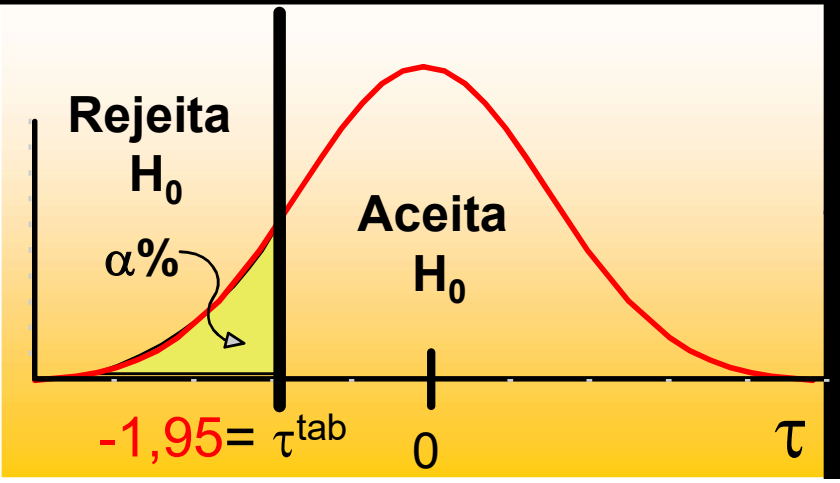
$\alpha = 5\%$

gl = 28 – 0 – k = 27

valor crítico: $\tau^{tab} = -1{,}95$

Comparativo: $\tau^{tab} \leq \tau^{calc}$

$\tau^{tab} = -1{,}95 > \tau^{calc} = -4{,}4571$



Decisão: Com 95% confiança, pode-se rejeitar H_0

Conclusão: A série em 1a. Dif. NÃO possui raiz unitária, logo é estacionária.

Teste "τ" de Dickey-Fuller

Modelo Tipo 2: $\Delta^2 e_t = C + \psi(\Delta e_{t-1}) + u_t$

Passeio Aleatório *versus* AR(1) **COM** intercepto e **SEM** tendência temporal

H_0: $\psi \geq 0 \rightarrow$ Série tem Raiz Unitária

H_1: $\psi < 0 \rightarrow$ Série **NÃO** tem Raiz Unitária

ANOVA 2: Estimadores Amostrais

	Coeficientes	*Erro padrão*	*Stat t*	*valor-P*
Interseção: Constante	0,862470906	2,526597285	0,341356698	73,558%
Variável X1: Delta(et-1)	-0,854772627	0,194456692	-4,395696627	0,017%

Modelo Estimado 2:

$$\Delta\hat{e}_t = 0{,}8625 - 0{,}8548 \times (\Delta e_{t-1})$$

Teste "τ" de Dickey-Fuller

Teste de Hipóteses 2: Avaliação de Estimadores

H_0: $\psi \geq 0$

H_1: $\psi < 0$

Estatística de Teste:

$$\tau^{calc} = \frac{(b_e - \psi)}{Erro\ \ Padrão\ \ b_e} = \frac{(-0{,}8548 - 0)}{0{,}1945} = -4{,}3957$$

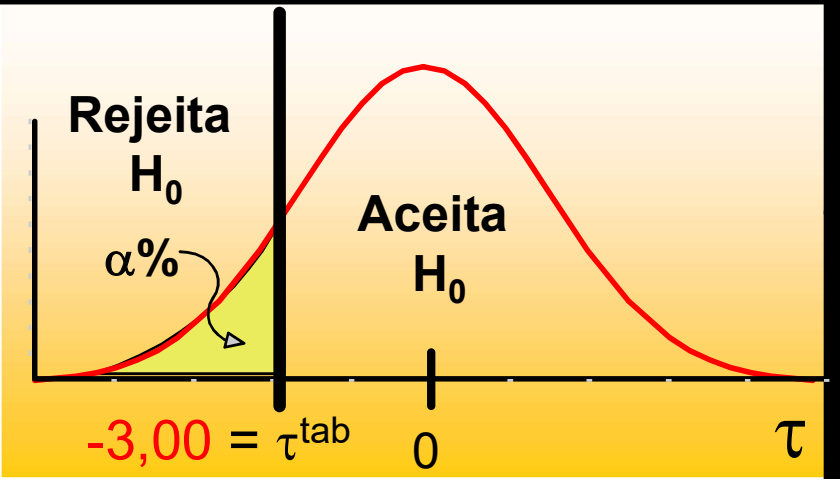
$\alpha = 5\%$

gl = 28 – 1 – k = 26

valor crítico: $\tau^{tab} = -3{,}00$

Comparativo: $\tau^{tab} \leq \tau^{calc}$

$\tau^{tab} = -3{,}00 > \tau^{calc} = -4{,}3957$



Decisão: Com 95% confiança, pode-se rejeitar H_0

Conclusão: A série em 1a. Dif. NÃO possui raiz unitária, logo é estacionária.

Teste "τ" de Dickey-Fuller

Modelo Tipo 3: $\Delta^2 e_t = \psi(e_{t-1}) + \lambda(\Delta t) + u_t$

Passeio Aleatório *versus* AR(1) **COM** intercepto e **COM** tendência temporal

H_0: $\psi \geq 0 \rightarrow$ Série tem Raiz Unitária

H_1: $\psi < 0 \rightarrow$ Série **NÃO** tem Raiz Unitária

ANOVA 3: Estimadores Amostrais

	Coeficientes	*Erro padrão*	*Stat t*	*valor-P*
Interseção	0	#N/D	#N/D	#N/D
Variável X1: Delta(et-1)	-0,854772627	0,194456692	-4,395696627	0,017%
Variável X2: Delta(Tempo)	0,862470906	2,526597285	0,341356698	73,558%

Modelo Estimado 3:

$$\Delta^2 \hat{e}_t = -0{,}8548\ (\Delta e_{t-1}) + 0{,}8625\ \times (\Delta t)$$

Teste "τ" de Dickey-Fuller

Teste de Hipóteses 3: Avaliação de Estimadores

H_0: $\psi \geq 0$

H_1: $\psi < 0$

Estatística de Teste:

$$\tau^{calc} = \frac{(b_e - \psi)}{Erro\ \ Padrão\ \ b_e} = \frac{(-0{,}8548 - 0)}{0{,}1945} = -4{,}3957$$

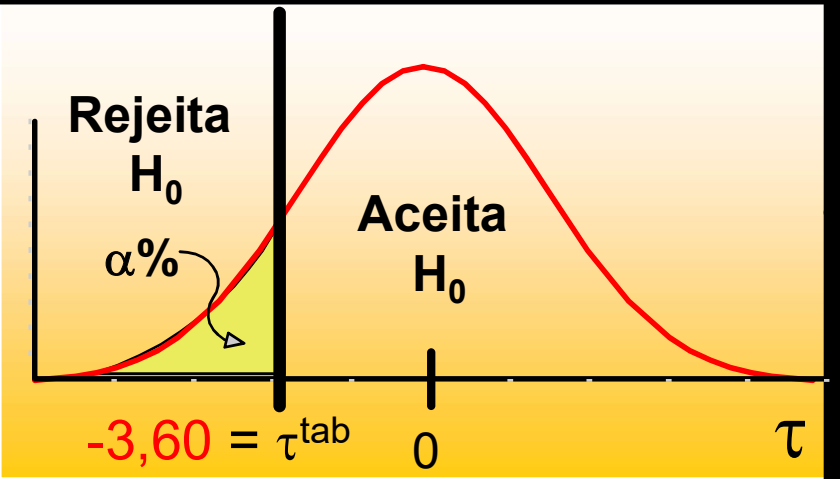
$\alpha = 5\%$

gl = 28 – 0 – k = 26

valor crítico: $\tau^{tab} = -3{,}60$

Comparativo: $\tau^{tab} \leq \tau^{calc}$

$\tau^{tab} = -3{,}60 > \tau^{calc} = -4{,}3957$



Decisão: Com 95% confiança, pode-se rejeitar H_0

Conclusão: A série em 1a. Dif. NÃO possui raiz unitária, logo é estacionária.

Teste Cointegração Engle-Granger

Resultados dos testes de estacionariedade

- {Δ%PV} ~ I(0): Estacionária em 1ª. diferença
- {Δ*PG*} ~ I(0): Estacionária 1ª. diferença
- {ΔResíduo} ~ I(0): Estacionária 1ª. diferença

Conclusão

- {Resíduo} NÃO estacionária em nível
- $\{\Delta^1$Resíduo$\}$ estacionária em 1a. diferença
- {Resíduo} contém 1 (uma) raiz unitária
- {Resíduo} ~ I(1)

Teste Cointegração Engle-Granger

Resultados dos testes de estacionariedade

- {%PV} ~ I(1): NÃO estacionária em nível
- {*PG*} ~ I(1): NÃO estacionária em nível
- {Resíduo} ~ I(1): NÃO estacionária em nível

{%PV} e {PG} não são cointegradas

Regressão Espúria

- Duas séries X e Y formam regressão espúria se:
  - Ambas as séires são NÃO-estacionárias
  - Ambas séries são integradas de mesma ordem “1”:
    - ✓ $Y_t \sim I(1)$
    - ✓ $X_t \sim I(1)$
  - Combinação linear das 2 séries é integrada de ordem “1”:
    - ✓ $(Y_t - X_t) \sim I(1)$
  - Resíduos são NÃO-estacionários
    - ✓ Erro Aleatório: $\varepsilon_t \sim I(1)$
    - ✓ Resíduo: $e_t \sim I(1)$

Exemplo

Considere os dados amostrais sobre a evolução da cotação do Ibovespa e do Merval 25 da Bolsa de Buenos Aires.

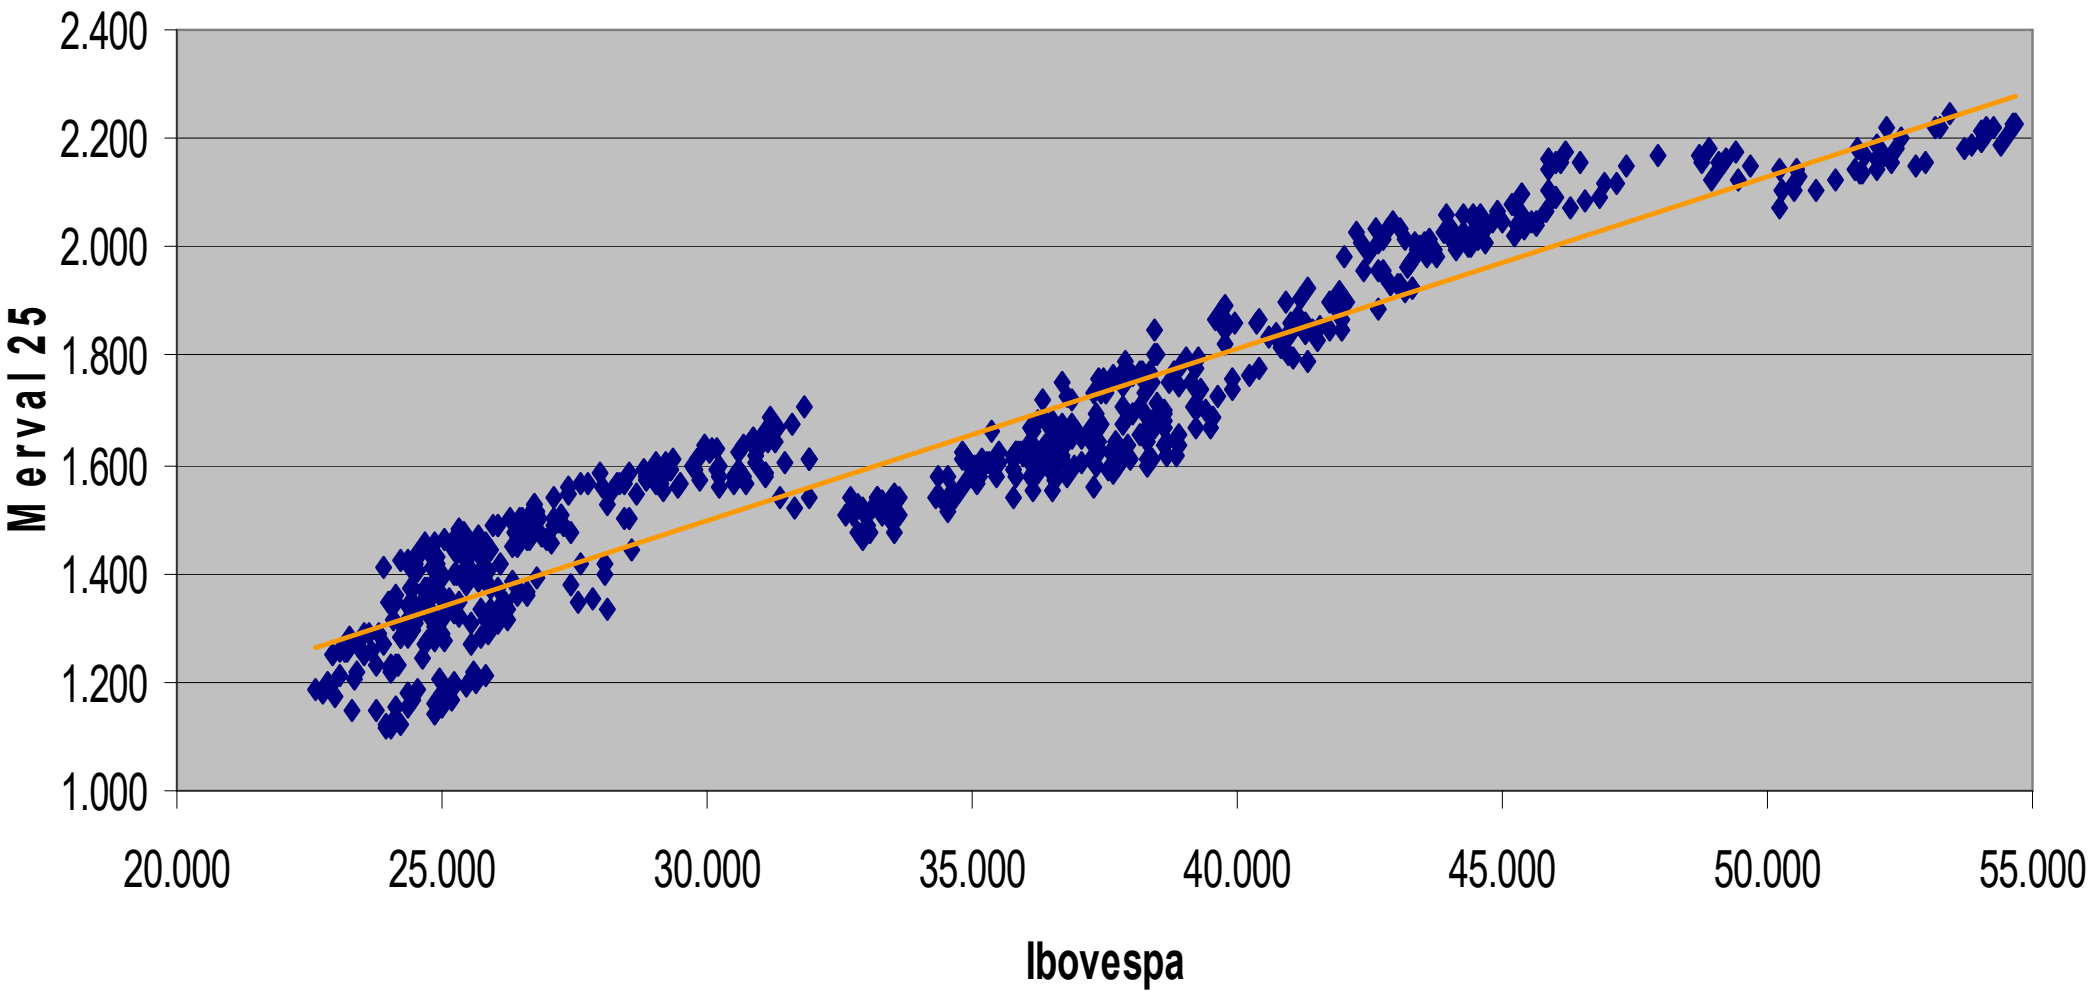
Estime o modelo e avalie os resultados das estatísticas.

Aplique o Teste de Raiz Unitária de Dickey-Fuller sobre as series temporais e conclua sobre a sua estacionariedade.

Avalie os resultados para fins de Cointegração entre as séries.

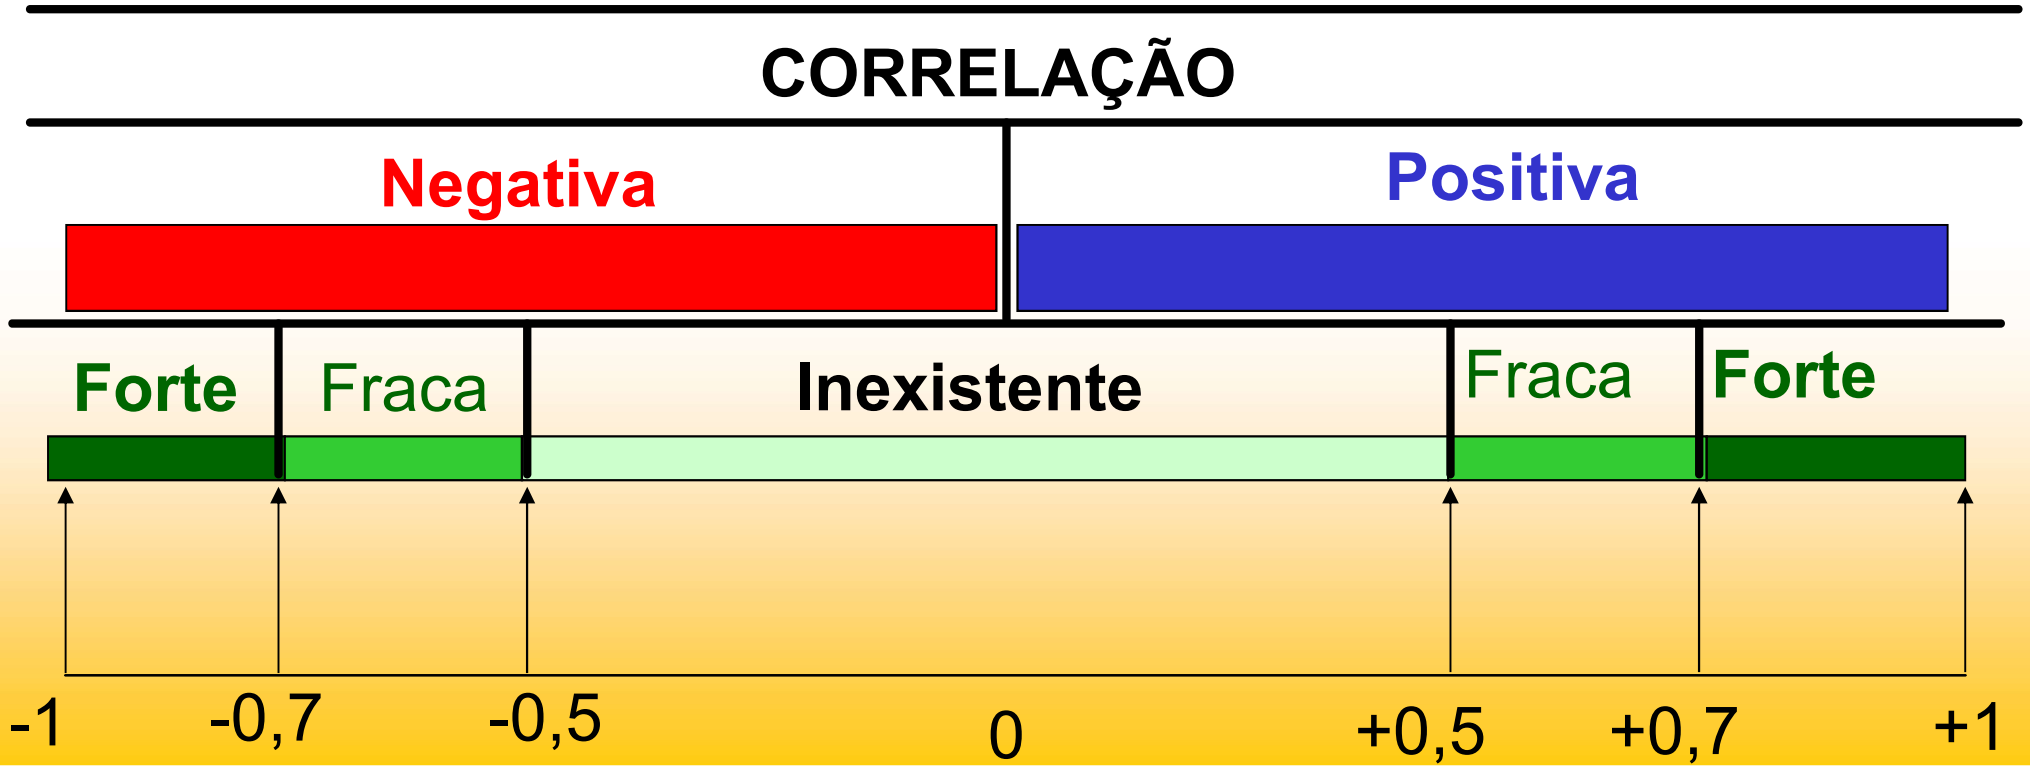
Inspeção Visual

Evolução Merval X Ibovespa ambos em nível



Análise de Estatísticas de Regressão

Estatística de regressão	
R múltiplo	0,952761558
R-Quadrado	0,907754587
R-quadrado ajustado	0,907620118
Erro padrão	84,37913792
Observações	688



Modelo Estimado

$$Merval_t = \beta_0 + \beta_1(Ibovespa_t) + \varepsilon_t$$

$$\hat{Merval}_t = b_0 + b_1(Ibovespa_t)$$

$$\hat{Merval}_t = 548{,}629 + 0{,}0315(Ibovespa_t)$$

	Coeficientes
Interseção	548,6291831
Variável X 1	0,031584315

Análise de Variância

Teste de Hipóteses

H_o: $Y = \beta_o + \varepsilon$, (Modelo estimado **NÃO** adequado)
H_1: $Y = \beta_o + \beta_1 X + \varepsilon$. (Modelo estimado adequado)

Objetiva-se concluir se as variáveis INDEPENDENTES (X) incluídas no modelo explicam (ou NÃO) de forma significativa o comportamento da variável DEPENDENTE (Y)

Quando $F^{Tabelado} < F^{Calculado}$, REJEITA-SE H_o,

Quanto maior $F^{Calculado}$ em relação a $F^{Tabelado}$,
maior a nossa crença no modelo: $Y = \beta_o + \beta_1 X + \varepsilon$.

Análise de Variância

Considerando α = 5%

	gl	*SQ*	*MQ*	*F*	*F de significação*
Regressão	1	48063783,59	48063783,59	6750,684131	0,00%
Resíduo	686	4884209,497	7119,838917		
Total	687	52947993,09			

H_0: $\beta_0 + \varepsilon$

H_1: $\beta_0 + \beta_1 X + \varepsilon$

$F^{Significância}$ = 0,00% < α = 5%, decide-se rejeitar H_0.

O modelo estimado **ADEQUADO**

Avaliação de Estimadores

Suponha $\alpha = 5\%$

H_0: $\beta_1 = 0$ (X NÃO "explica" Y)

H_1: $\beta_1 \neq 0$ (X "explica" Y)

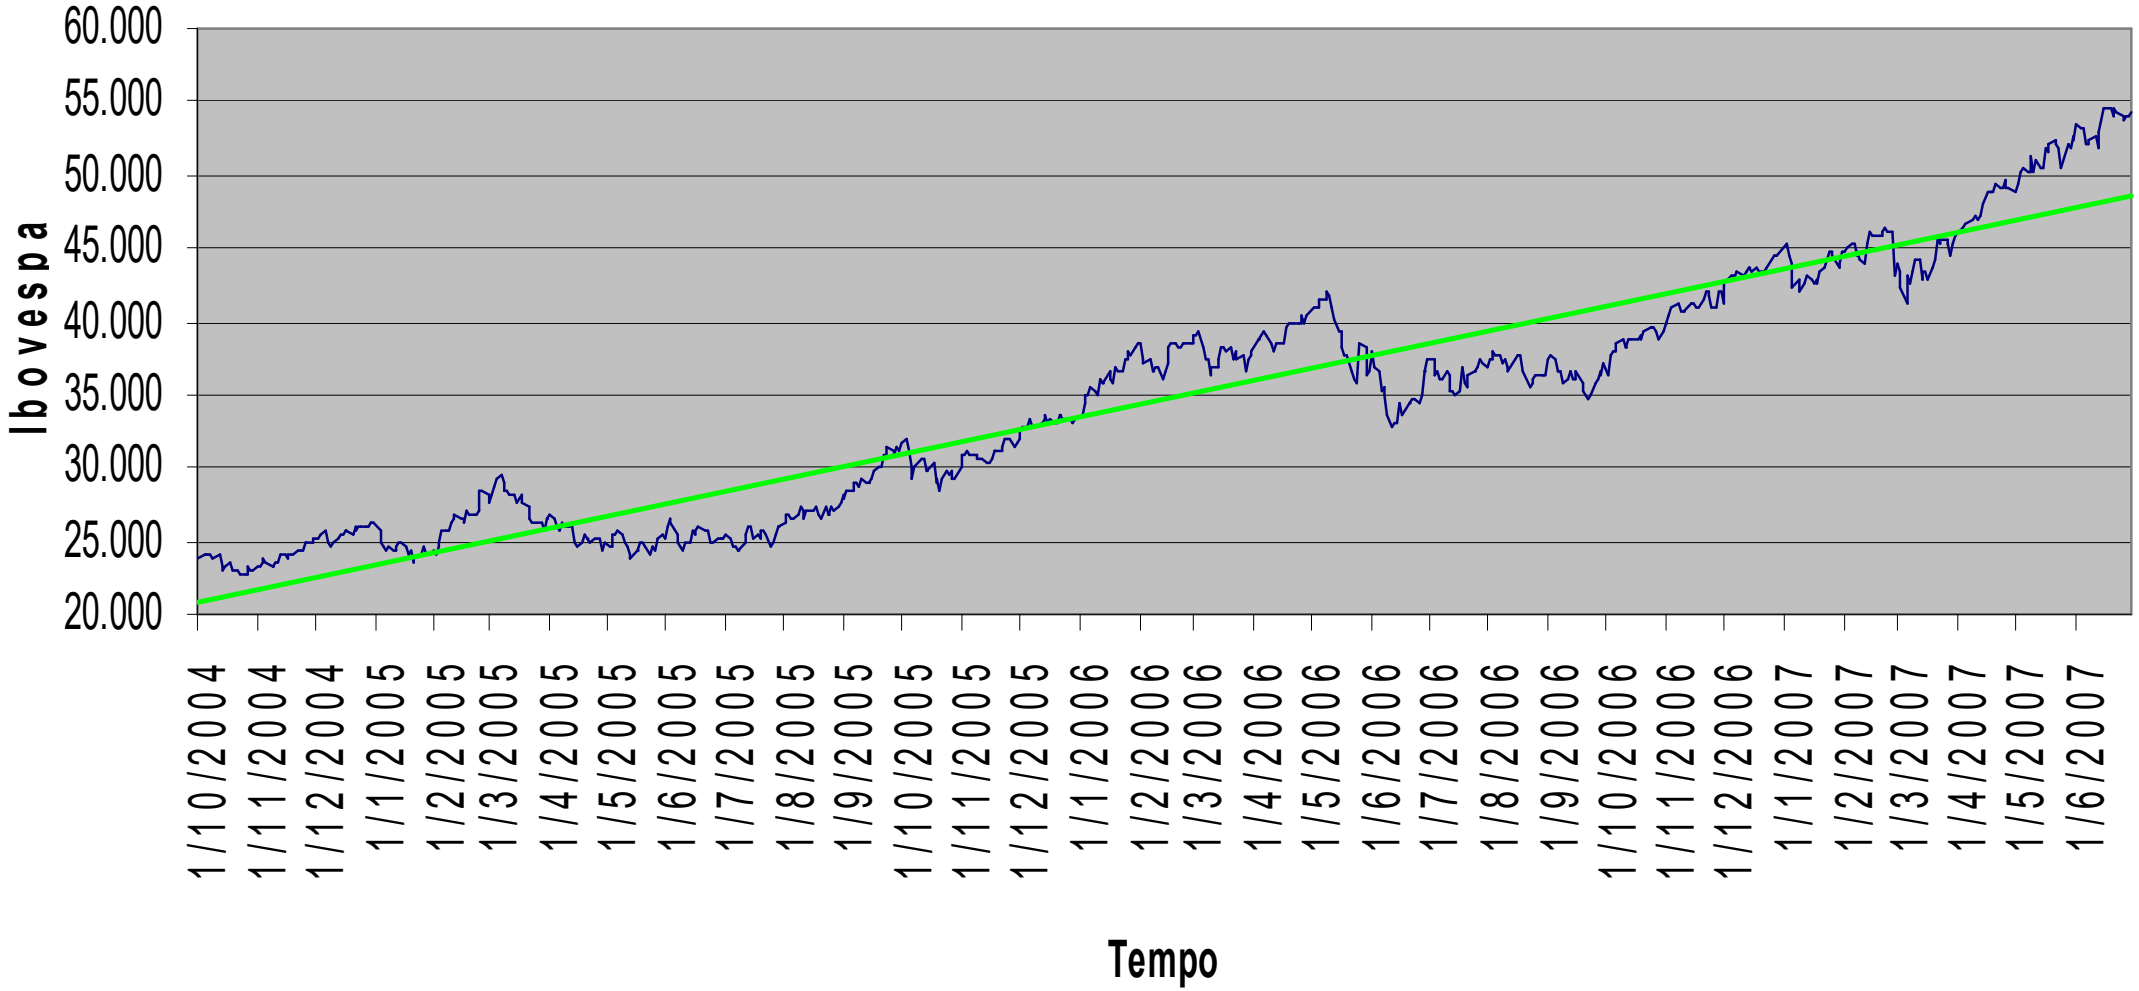
	Coeficientes	*Erro padrão*	*Stat t*	*valor-P*
Interseção	548,6291831	13,69262822	40,06748553	0,00%
Variável X 1	0,031584315	0,000384413	82,16254701	0,00%

Valor-P = 0,000% < α = 5%, decide-se rejeição H_0 .

Conclui-se que a variável explicativa X (Ibovespa) afeta a variável explicada Y (Merval).

Inspeção Visual

Evolução Ibovespa em nível



Teste "τ" de Dickey-Fuller

Ibovespa em nível

H_0: $\psi \geq 0 \rightarrow$ Série tem Raiz Unitária

H_1: $\psi < 0 \rightarrow$ Série **NÃO** tem Raiz Unitária

Modelo Tipo 3: $\Delta X_t = C + \psi X_{t-1} + \lambda(t) + \varepsilon_t$

Passeio Aleatório *versus* AR(1) **COM** intercepto e **COM** tendência temporal

	Coeficientes	*Erro padrão*	*Stat t*
Interseção	378,9369734	167,3885753	2,263816229
Variável X1: Ibovespa t-1	-0,01792178	0,007796282	-2,298759739
Variável X2: Tempo	0,830261337	0,327876168	2,532240579

Teste "τ" de Dickey-Fuller

Ibovespa em nível

$H_0: \psi \geq 0$

$H_1: \psi < 0$

Estatística de Teste:

$$\tau^{calc} = \frac{(b_X - \psi)}{Erro\ \ Padrão\ \ b_X} = \frac{(-0{,}0179 - 0)}{0{,}0078} = -2{,}299$$

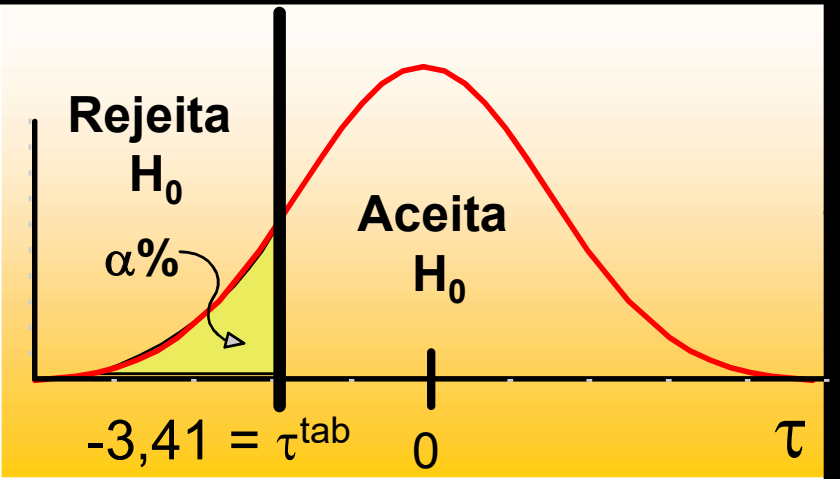
$\alpha = 5\%$

gl = n – 1 – k = 684

valor crítico: $\tau^{tab} = -3{,}41$

Comparativo: $\tau^{tab} \leq \tau^{calc}$

$\tau^{tab} = -3{,}41 < \tau^{calc} = -2{,}299$

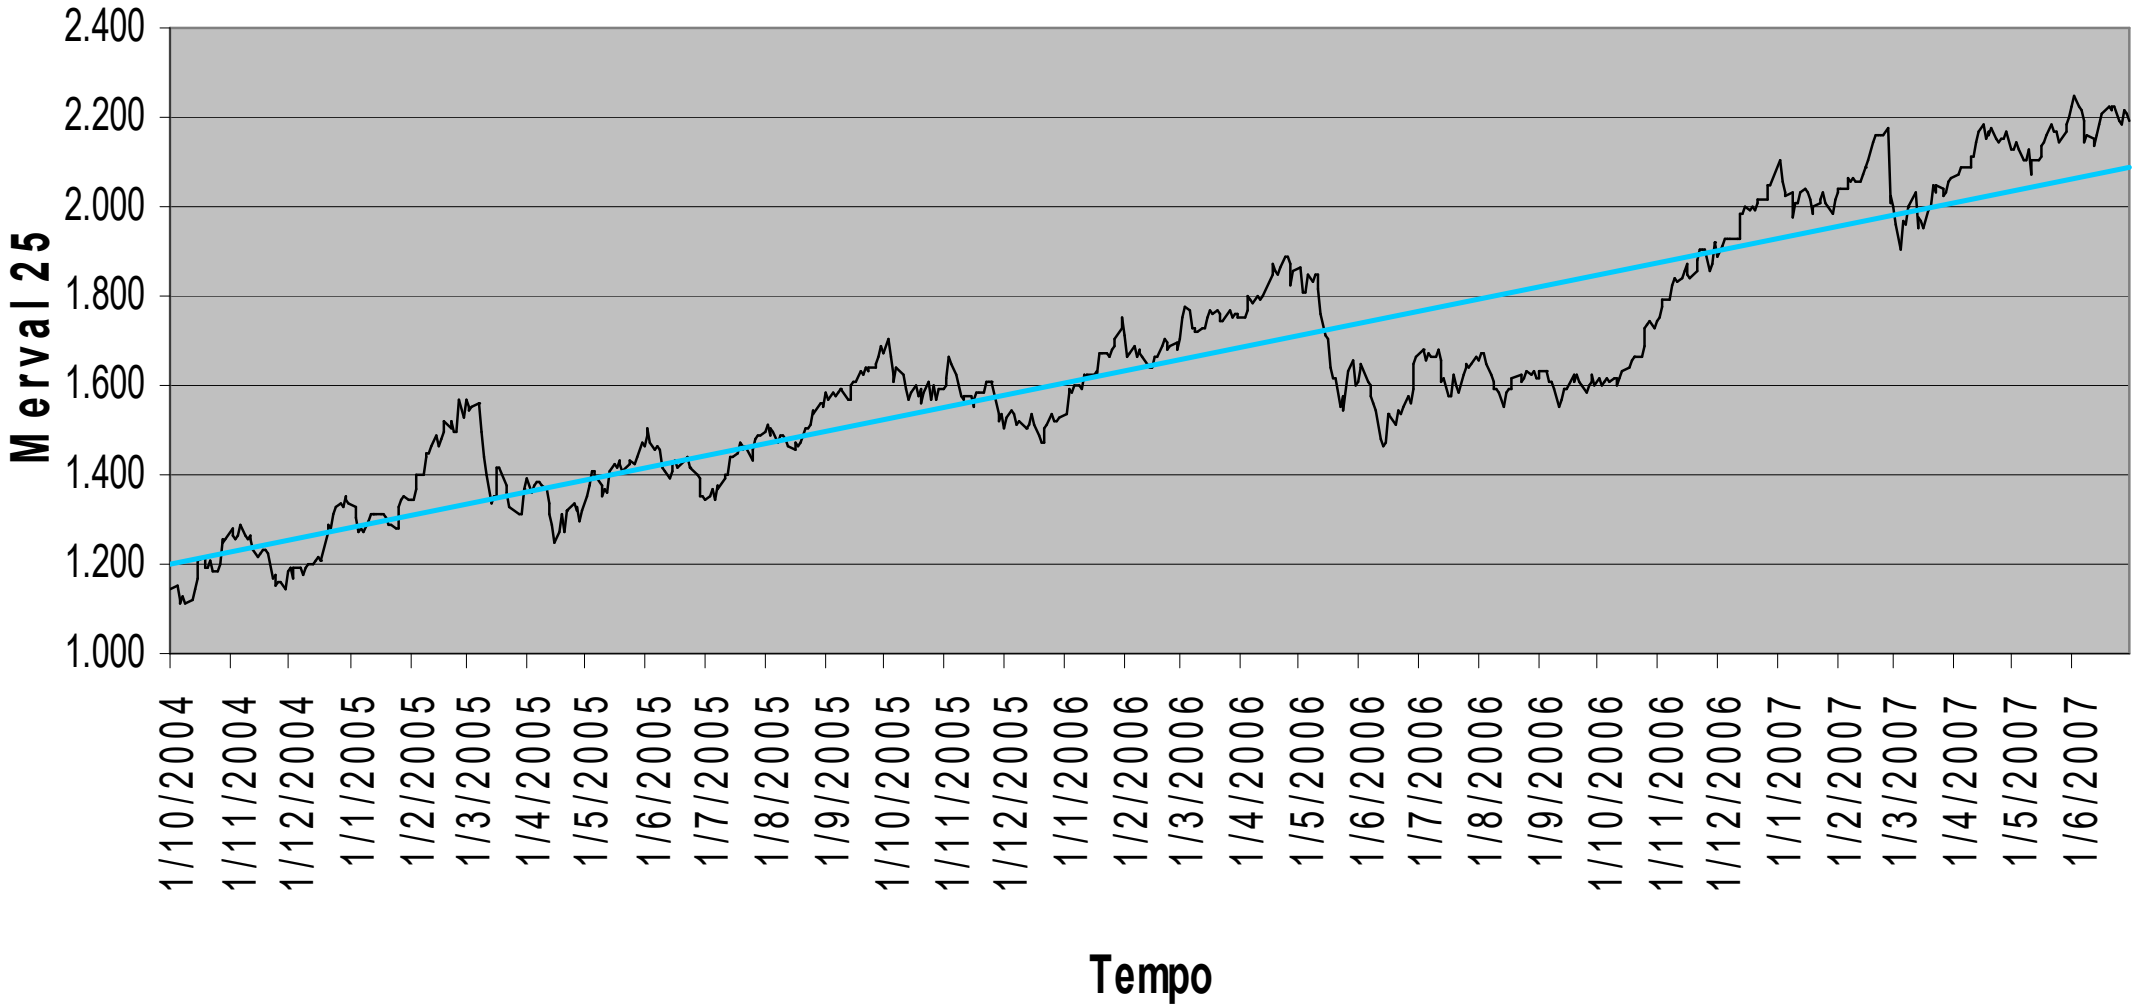


Decisão: Com 95% confiança, **NÃO** se rejeita H_0

Conclusão: A série EM NÍVEL possui raiz unitária, logo NÃO é estacionária.

Inspeção Visual

Evolução Merval 25 em Nível



Teste "τ" de Dickey-Fuller

Merval 25 em nível

H_0: $\psi \geq 0 \rightarrow$ Série tem Raiz Unitária

H_1: $\psi < 0 \rightarrow$ Série **NÃO** tem Raiz Unitária

Modelo Tipo 3: $\Delta X_t = C + \psi X_{t-1} + \lambda(t) + \varepsilon_t$

Passeio Aleatório *versus* AR(1) **COM** intercepto e **COM** tendência temporal

	Coeficientes	*Erro padrão*	*Stat t*
Interseção	27,77432662	9,865192333	2,815386227
Variável X1: Merval t-1	-0,022069637	0,008085525	-2,729524298
Variável X2: Tempo	0,028981386	0,011286213	2,567857428

Teste "τ" de Dickey-Fuller

Merval em nível

H_0: $\psi \geq 0$

H_1: $\psi < 0$

Estatística de Teste:

$$\tau^{calc} = \frac{(b_X - \psi)}{Erro\ \ Padrão\ \ b_X} = \frac{(-0{,}0221 - 0)}{0{,}0081} = -2{,}730$$

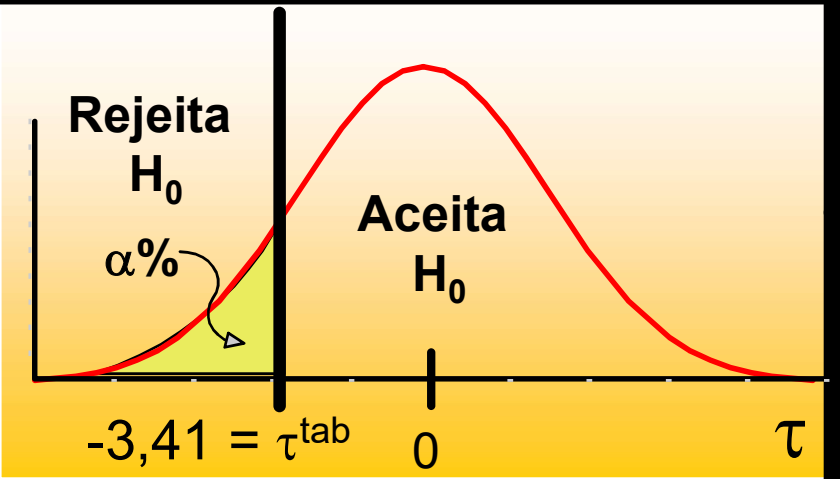
$\alpha = 5\%$

gl = n – 1 – k = 684

valor crítico: $\tau^{tab} = -3{,}41$

Comparativo: $\tau^{tab} \leq \tau^{calc}$

$\tau^{tab} = -3{,}41 < \tau^{calc} = -2{,}730$

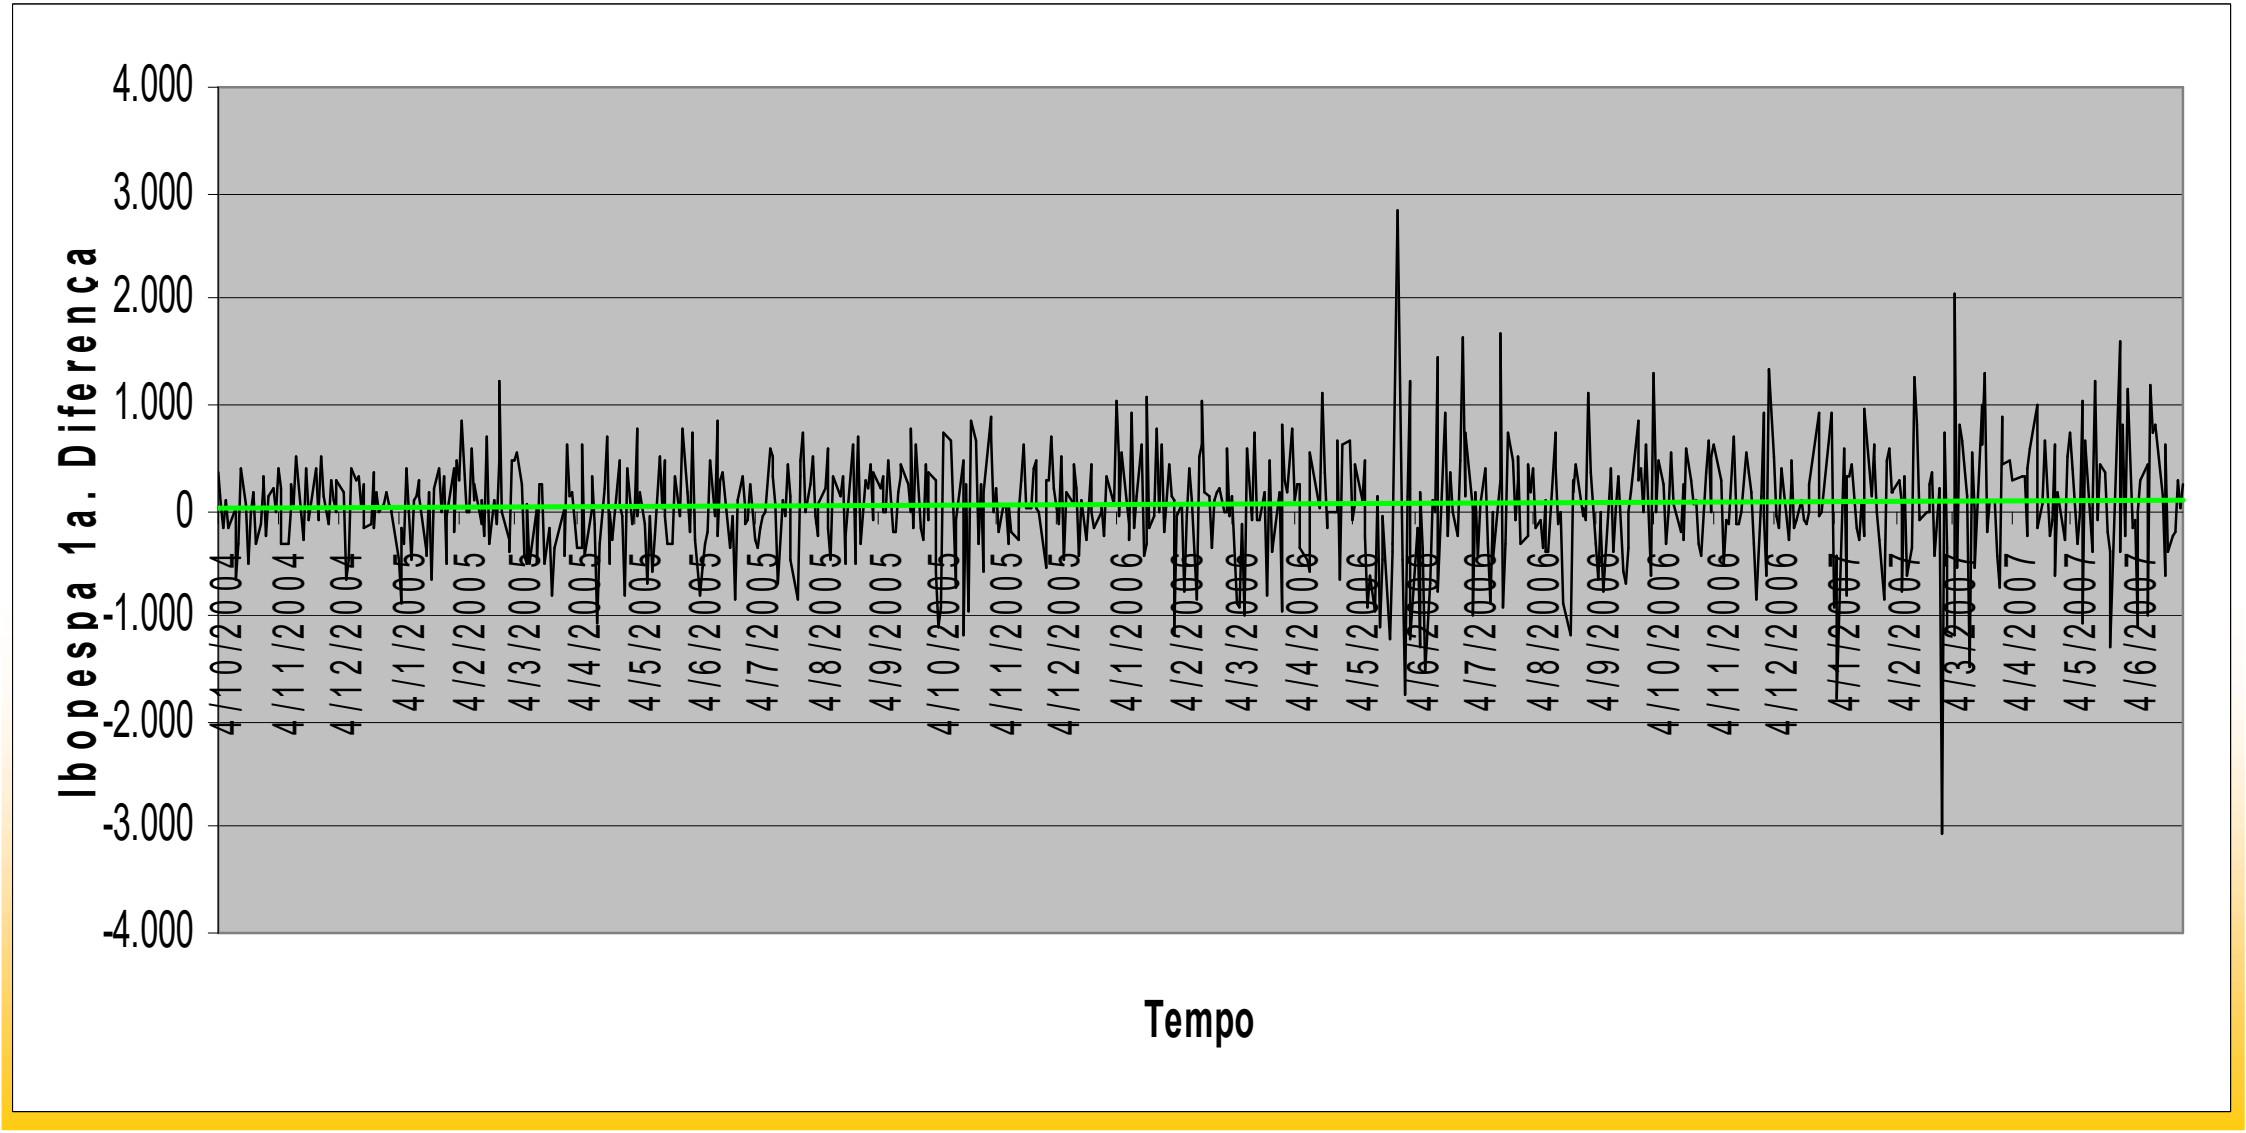


Decisão: Com 95% confiança, **NÃO** se rejeita H_0

Conclusão: A série EM NÍVEL possui raiz unitária, logo NÃO é estacionária.

Teste “τ” de Dickey-Fuller

Evolução Ibovespa em 1a. Diferença



Teste "τ" de Dickey-Fuller

Ibovespa em 1a. Diferença

H_0: $\psi \geq 0 \rightarrow$ Série tem Raiz Unitária

H_1: $\psi < 0 \rightarrow$ Série **NÃO** tem Raiz Unitária

Modelo Tipo 3: $\Delta X_t = C + \psi X_{t-1} + \lambda(t) + \varepsilon_t$

Passeio Aleatório *versus* AR(1) **COM** intercepto e **COM** tendência temporal

	Coeficientes	*Erro padrão*	*Stat t*
Interseção: Delta Tempo	45,959328	20,29589383	2,264464349
Variável X 1: Delta Ibovepa t-1	-1,042359145	0,038194887	-27,29054152

Teste "τ" de Dickey-Fuller

Ibovespa em 1a. Diferença

H_0: $\psi \geq 0$

H_1: $\psi < 0$

Estatística de Teste:

$$\tau^{calc} = \frac{(b_X - \psi)}{Erro\ \ Padrão\ \ b_X} = \frac{(-1{,}042 - 0)}{0{,}038} = -27{,}29$$

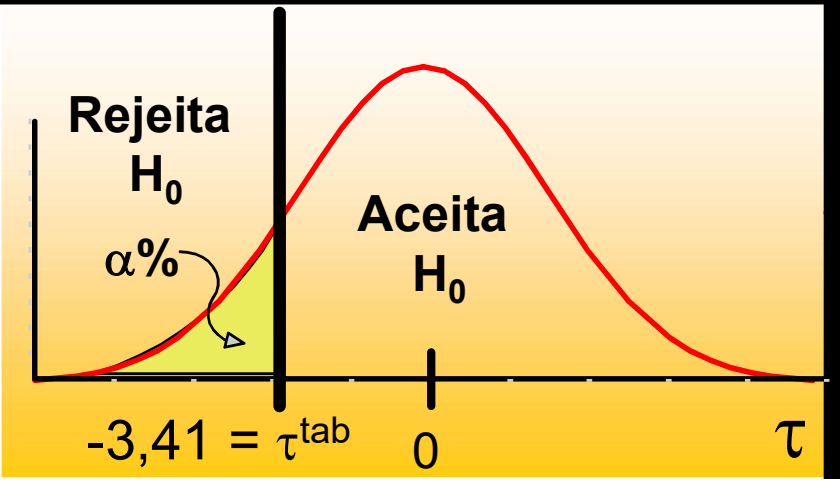
α = 5%

gl = n – 1 – k = 684

valor crítico: τ^{tab} = -3,41

Comparativo: $\tau^{tab} \leq \tau^{calc}$

τ^{tab} = -3,41 > τ^{calc} = -27,29

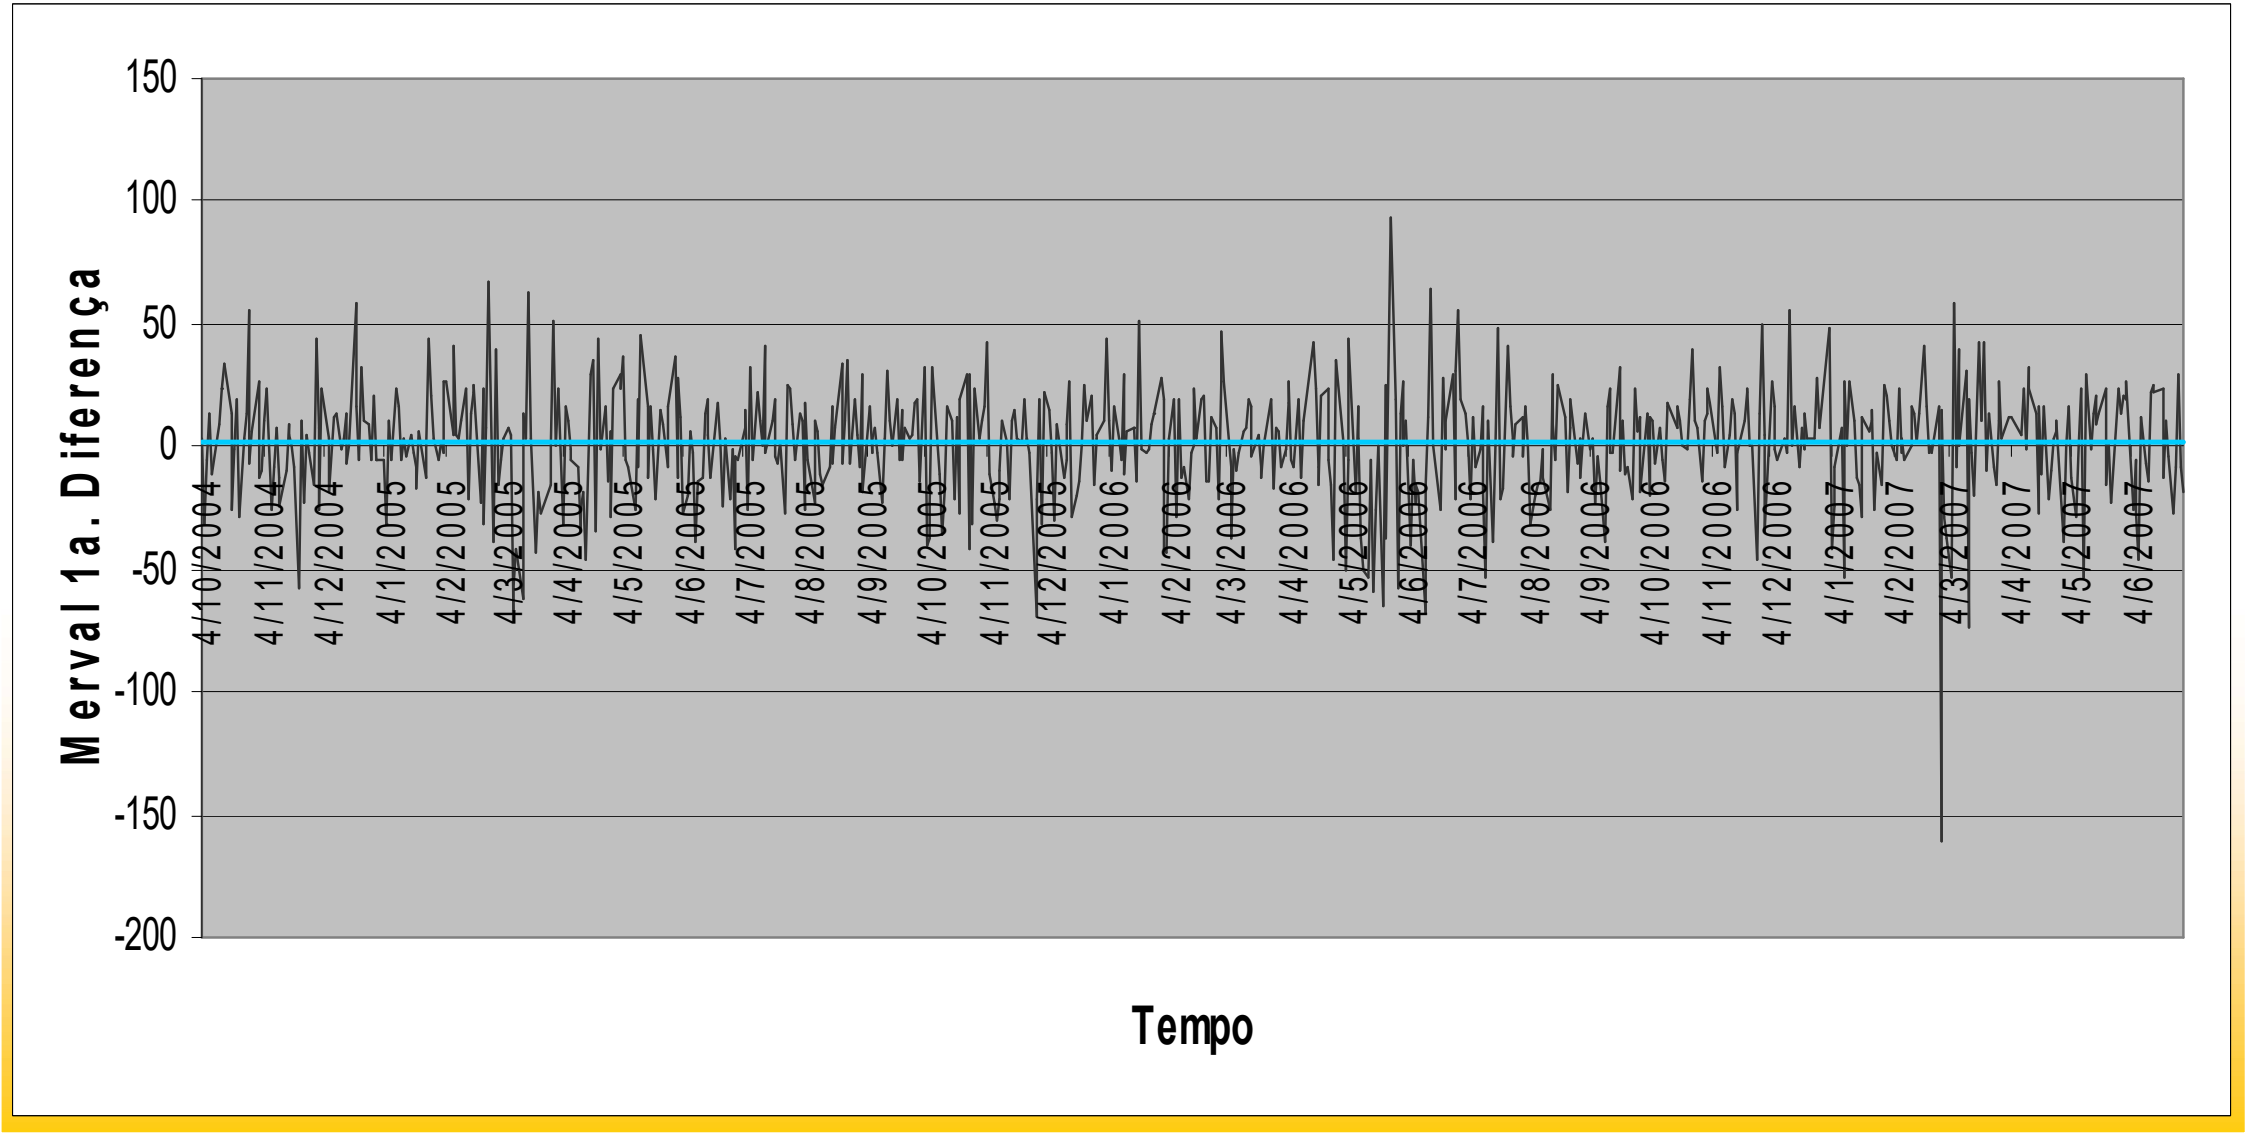


Decisão: Com 95% confiança, pode-se rejeitar H_0

Conclusão: A série EM 1a. DIF. NÃO possui raiz unitária, logo é estacionária.

Teste "τ" de Dickey-Fuller

Evolução Merval 25 em 1a. Diferença



Teste "τ" de Dickey-Fuller

Evolução Merval 25 em 1a. Diferença

H_0: $\psi \geq 0 \rightarrow$ Série tem Raiz Unitária

H_1: $\psi < 0 \rightarrow$ Série **NÃO** tem Raiz Unitária

Modelo Tipo 3: $\Delta X_t = C + \psi X_{t-1} + \lambda(t) + \varepsilon_t$

Passeio Aleatório *versus* AR(1) **COM** intercepto e **COM** tendência temporal

	Coeficientes	*Erro padrão*	*Stat t*
Interseção: Delta Tempo	1,519346617	0,892035842	1,703234944
Variável X 1: Delta Merval t-1	-1,00213714	0,038257256	-26,19469469

Teste "τ" de Dickey-Fuller

Evolução Merval 25 em 1a. Diferença

$H_0: \psi \geq 0$

$H_1: \psi < 0$

Estatística de Teste:

$$\tau^{calc} = \frac{(b_X - \psi)}{Erro\ \ Padrão\ \ b_X} = \frac{(-1{,}002 - 0)}{0{,}038} = -26{,}19$$

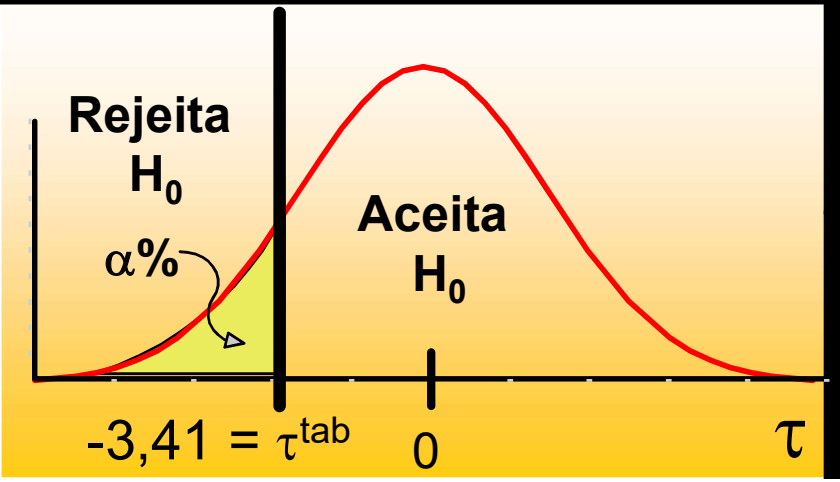
$\alpha = 5\%$

gl = n – 1 – k = 684

valor crítico: $\tau^{tab} = -3{,}41$

Comparativo: $\tau^{tab} \leq \tau^{calc}$

$\tau^{tab} = -3{,}41 > \tau^{calc} = -26{,}19$

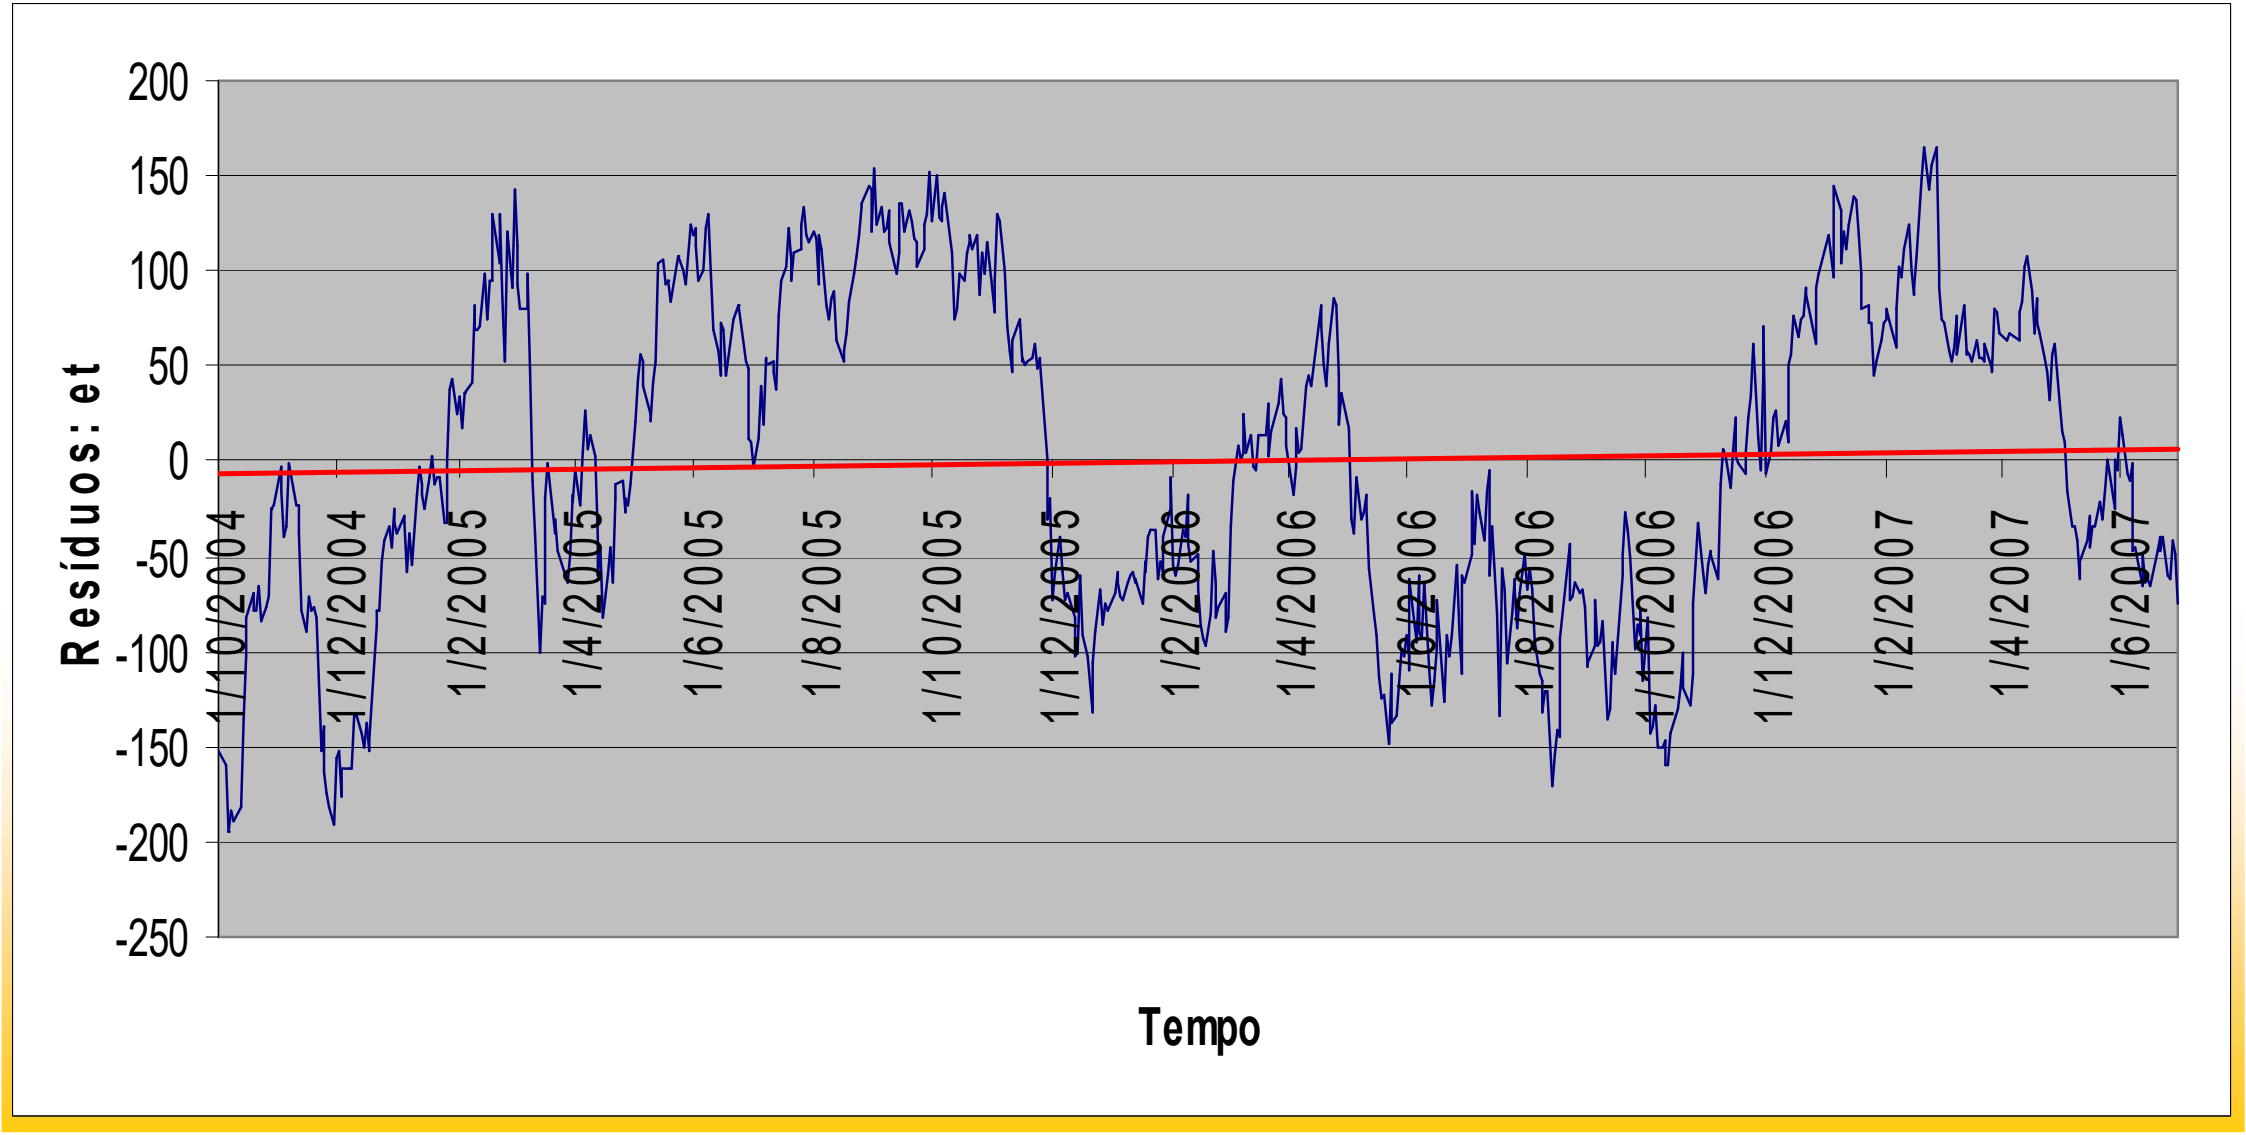


Decisão: Com 95% confiança, pode-se rejeitar H_0

Conclusão: A série EM 1a. DIF. NÃO possui raiz unitária, logo é estacionária.

Teste “τ” de Dickey-Fuller

Evolução Resíduos em nível



Teste "τ" de Dickey-Fuller

Resíduos em nível

H_0: $\psi \geq 0 \rightarrow$ Série tem Raiz Unitária

H_1: $\psi < 0 \rightarrow$ Série **NÃO** tem Raiz Unitária

Modelo Tipo 3: $\Delta X_t = C + \psi X_{t-1} + \lambda(t) + \varepsilon_t$

Passeio Aleatório *versus* AR(1) **COM** intercepto e **COM** tendência temporal

	Coeficientes	*Erro padrão*	*Stat t*
Interseção	0,89299942	1,618621359	0,551703717
Variável X1: et-1	-0,033578889	0,009596185	-3,499191676
Variável X2: Tempo	-0,002259183	0,004077532	-0,554056611

Teste "τ" de Dickey-Fuller

Resíduos em nível

H_0: $\psi \geq 0$

H_1: $\psi < 0$

Estatística de Teste:

$$\tau^{calc} = \frac{(b_X - \psi)}{Erro\ \ Padrão\ \ b_X} = \frac{(-0{,}0336 - 0)}{0{,}0096} = -3{,}499$$

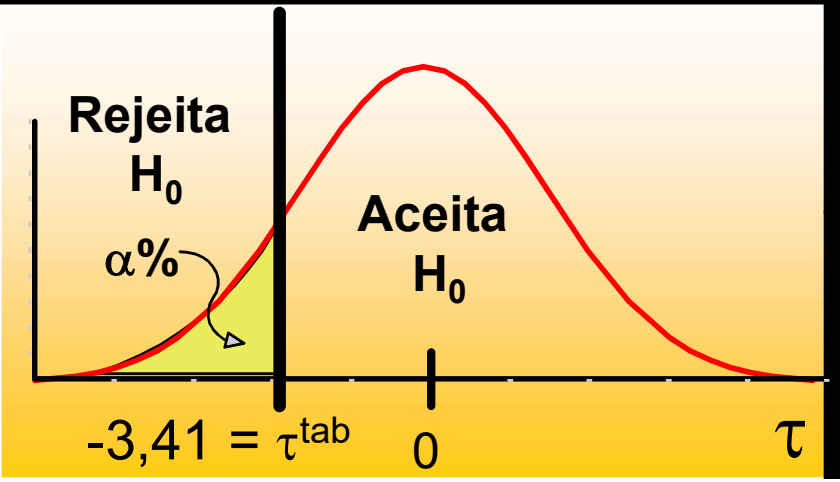
α = 5%

gl = n – 1 – k = 684

valor crítico: τ^{tab} = -3,41

Comparativo: $\tau^{tab} \leq \tau^{calc}$

τ^{tab} = -3,41 > τ^{calc} = -3,499



Decisão: Com 95% confiança, pode-se rejeitar H_0

Conclusão: A série EM NÍVEL NÃO possui raiz unitária, logo é estacionária.

Teste Cointegração Engle-Granger

Resultados dos testes de estacionariedade

- {Ibov} ~ I(1): NÃO estacionária em nível
- {Merv} ~ I(1): NÃO estacionária em nível
- {Resíduos} ~ I(0): estacionária em nível

{Ibov} e {Merv} são cointegradas

Estatística Aplicada

Aula 12 - Agenda

Causalidade de Granger

Causalidade *versus* Correlação

Regressão	Correlação
Especificação do relacionamento	Mensuração da força do relacionamento





Causalidade *versus* Correlação

- Lama e Chuva são dois conceitos relacionados
  - Mas, não se pode inferir que lama cause chuva
  - Porém, pode-se inferir que chuva cause lama
- A média de idade da Flórida é alta
  - Mas, não se pode afirmar que que o clima da Flórida faz as pessoas viverem mais
  - Porém, pode-se afirmar que muitas pessoas mudam-se pra lá quando se aposentam.

Causalidade de Granger

- A afirmação X “causa-Granger” Y **NÃO** significa existência de mecanismo econômico de geração de dados, tal que os futuros valores de Y sejam causados por X.

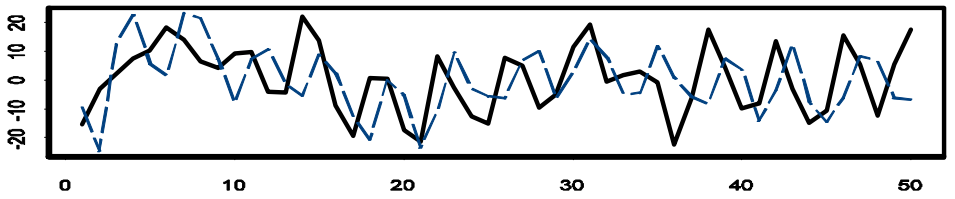
- O conceito de causalidade de Granger está vinculado com a idéia de ANTECEDÊNCIA

- Uma variável X “causa-Granger” uma variável Y se, na média, o evento Y é verificado toda vez que o evento X ocorreu algum período antes.

Causalidade de Granger

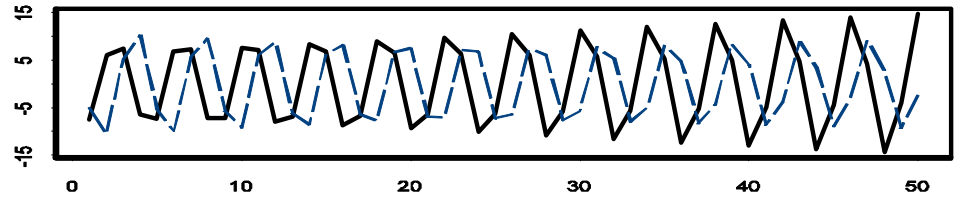
- A causalidade de Granger constitui-se em afirmação sobre a capacidade de X para prever os valores futuros de Y.
- Exemplo de regressão com
  - variável EXPLICADA “dias de chuva” e
  - variável EXPLICATIVA “meteorologista afirma que vai chover”
- Possivelmente, encontraremos causalidade de Granger.
- Todavia, sabemos que o meteorologista não causa a chuva, no sentido comum de “causa”.

Causalidade de Granger



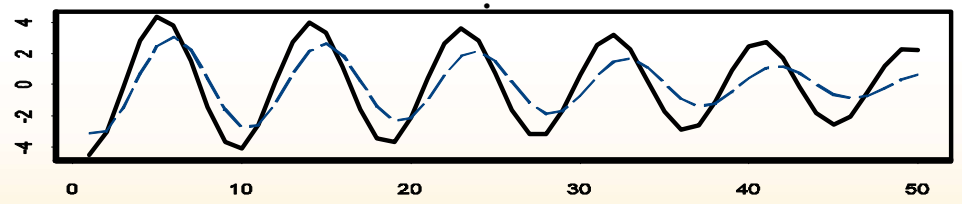
Causalidade de Granger

Dados de Alta Freqüência
Variações de Curto Prazo



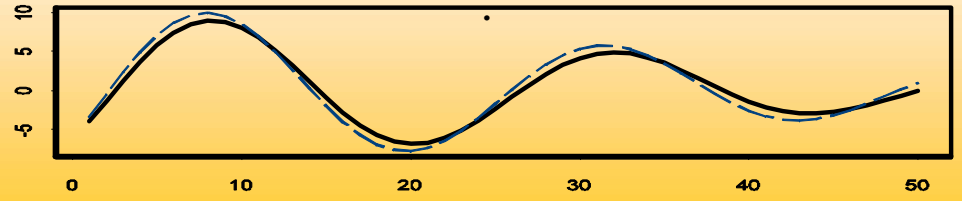
Causalidade de Granger

Dado de Média Freqüência
Variações de Médio Prazo



Causalidade de Granger

Dado de Baixa Freqüência
Variações de Longo Prazo



Causalidade de Granger

Causalidade de Granger

"A process X_t is said to Granger cause another process Y_t

if future values of Y_t can be predicted better using past values of X_t and Y_t

than using the past of Y_t alone."

Clive Granger

Prêmio Nobel de Economia em 2003

Teste de Causalidade de Granger

Objetivo

- Determinar o tipo de relacionamento entre duas variáveis. Exemplo:
  - Merval 25 e Ibovespa

- Questões:
  - Merval causa variações no Ibovespa?
  - Ibovespa causa variações no Merval?
  - Existe simultânea causalidade entre as variáveis?
  - Não existe causalidade entre as variáveis?

Teste de Causalidade de Granger

Objetivo

- Suponha como VERDADE
  - Merval causa variações no Ibovespa
    - Merval → Ibovespa
- Estime modelo AMPLO p/ Ibovespa:
  - Variáveis EXPLICATIVAS do modelo
    - valores defasados de Ibovespa e do Merval

$$Ibov_t = \alpha_1 Merv_{t-1} + \alpha_2 Merv_{t-2} + \ldots + \alpha_n Merv_{t-n} + \beta_1 Ibov_{t-1} + \beta_2 Ibov_{t-2} + \ldots + \beta_n Ibov_{t-n} + u_t$$

Teste de Causalidade de Granger

Análise de Variância Regressão **AMPLA**

$$Ibov_t = \alpha_1 Merv_{t-1} + \alpha_2 Merv_{t-2} + \ldots + \alpha_8 Merv_{t-8} + \beta_1 Ibov_{t-1} + \beta_2 Ibov_{t-2} + \ldots + \beta_8 Ibov_{t-8} + u_t$$

Estatística de regressão	
R múltiplo	0,998019271
R Quadrado	0,996042464
R-quadrado ajustado	0,994447038
Erro padrão	530,7025703
Observações	680

	Coeficientes	*Erro padrão*	*Stat t*	*valor-P*
Variável Merval (t-1)	-0,257623616	1,020428373	-0,252466143	80,1%
Variável Merval (t-2)	2,921582448	1,380201641	2,116779434	3,5%
Variável Merval (t-3)	-2,741066098	1,384119766	-1,980367715	4,8%
Variável Merval (t-4)	0,986229635	1,390850556	0,709083827	47,9%
Variável Merval (t-5)	-1,608788763	1,39031854	-1,157136812	24,8%
Variável Merval (t-6)	-0,041599896	1,386972747	-0,029993305	97,6%
Variável Merval (t-7)	1,229490867	1,38483299	0,887826096	37,5%
Variável Merval (t-8)	-0,42656801	1,005627501	-0,424180931	67,2%
Variável Ibovespa (t-1)	0,960643682	0,044404103	21,63411956	0,0%
Variável Ibovespa (t-2)	-0,050567806	0,059342306	-0,852137537	39,4%
Variável Ibovespa (t-3)	0,019889845	0,059487575	0,334352922	73,8%
Variável Ibovespa (t-4)	0,038979863	0,059549221	0,654582246	51,3%
Variável Ibovespa (t-5)	-0,032880678	0,059369783	-0,553828497	58,0%
Variável Ibovespa (t-6)	0,050880785	0,059177014	0,859806562	39,0%
Variável Ibovespa (t-7)	0,002294524	0,059117697	0,038812805	96,9%
Variável Ibovespa (t-8)	0,009536112	0,044858739	0,212580927	83,2%

Teste de Causalidade de Granger

Análise de Variância Regressão **AMPLA**

$$Ibov_t = \alpha_1 Merv_{t-1} + \alpha_2 Merv_{t-2} + \ldots + \alpha_8 Merv_{t-8} + \beta_1 Ibov_{t-1} + \beta_2 Ibov_{t-2} + \ldots + \beta_8 Ibov_{t-8} + u_t$$

	gl	*SQ*	*MQ*	*F*	*F de significação*
Regressão	16	47.067.754.777,67	2.941.734.673,60	10.444,82	0,0%
Resíduo	664	187.012.424,82	281.645,22		
Total	680	47.254.767.202,49			

Teste de Causalidade de Granger

Objetivo

- Suponha como VERDADE
  - Merval causa variações Ibovespa
    - Merval → Ibovespa.
- Estime modelo **RESTRITO** p/ Ibovespa:
  - Variáveis EXPLICATIVAS do modelo
    - **SOMENTE** valores defasados de Ibovespa

$$Ibov_t = \beta_1 Ibov_{t-1} + \beta_2 Ibov_{t-2} + \ldots + \beta_n Ibov_{t-n} + u^*_t$$

Teste de Causalidade de Granger

Análise de Variância Regressão **RESTRITA**

$$Ibov_t = \beta_1 Ibov_{t-1} + \beta_2 Ibov_{t-2} + \ldots + \beta_8 Ibov_{t-8} + u^*_t$$

Estatística de regressão	
R múltiplo	0,997991918
R-Quadrado	0,995987869
R-quadrado ajustado	0,99445798
Erro padrão	531,1604755
Observações	680

	Coeficientes	*Erro padrão*	*Stat t*	*valor-P*
Variável Ibovespa (t-1)	0,952174604	0,03852662	24,71471921	0,0%
Variável Ibovespa (t-2)	0,014930381	0,053196704	0,280663645	77,9%
Variável Ibovespa (t-3)	-0,022903004	0,053180549	-0,430665061	66,7%
Variável Ibovespa (t-4)	0,047945605	0,053148703	0,902103015	36,7%
Variável Ibovespa (t-5)	-0,059068355	0,053147443	-1,111405385	26,7%
Variável Ibovespa (t-6)	0,040083067	0,053187854	0,753613163	45,1%
Variável Ibovespa (t-7)	0,016160028	0,053264447	0,303392394	76,2%
Variável Ibovespa (t-8)	0,012340735	0,038629038	0,319467837	74,9%

Teste de Causalidade de Granger

Análise de Variância Regressão **RESTRITA**

$$Ibov_t = \beta_1 Ibov_{t-1} + \beta_2 Ibov_{t-2} + \ldots + \beta_8 Ibov_{t-8} + u^*_t$$

	gl	*SQ*	*MQ*	*F*	*F de significação*
Regressão	8	47.065.174.867,57	5.883.146.858,45	20.852,50	0,0%
Resíduo	672	189.592.334,92	282.131,45		
Total	680	47.254.767.202,49			

Teste de Causalidade de Granger

Teste de Hipóteses

H_0: $\Sigma\alpha_i = 0 \rightarrow$ Merval "NÃO causa-Granger" Ibovespa

H_1: $\Sigma\alpha_i \neq 0 \rightarrow$ Merval "causa-Granger" Ibovespa

Objetiva-se testar a significância conjunta de parâmetros vinculados à variável explicativa Merval.

Quando $F^{Crítico} < F^{Calculado}$, REJEITA-SE H_0.

Quanto maior $F^{Calculado}$ em relação a $F^{Crítico}$, maior a nossa crença no modelo

Teste de Causalidade de Granger

Teste de Hipóteses

H_0: $\Sigma\alpha_i = 0 \rightarrow$ Merval "NÃO causa-Granger" Ibovespa

H_1: $\Sigma\alpha_i \neq 0 \rightarrow$ Merval "causa-Granger" Ibovespa

Estatística de Teste: $$F^{Calculado} = \frac{[(SQRes_{RESTRITO} - SQRes_{AMPLO}) \div m]}{[SQRes_{AMPLO} \div (n-k)]}$$

$F \sim F(\alpha$; m gl numerador; n - k gl denominador)

m: quantidade de termos defasados da variável Merval

n: tamanho da amostra

k: quantidade parâmetros estimados na Regressão AMPLA

Teste de Causalidade de Granger

H_0: $\Sigma\alpha_i = 0 \rightarrow$ Merval "NÃO causa-Granger" Ibovespa

H_1: $\Sigma\alpha_i \neq 0 \rightarrow$ Merval "causa-Granger" Ibovespa

Parâmetro	Valores
Nível de Significância do Teste	5%
SQResíduos Anova AMPLA	187.012.424,82
SQResíduos Anova RESTRITA	189.592.334,92
Amostra (n)	680
Termos Defasados de Merval (m)	8
Parâmetros Estimados Regressão AMPLA (k)	16
Graus de Liberdade NUMERADOR	8
Graus de Liberdade DENOMINADOR	664
F Calculado	1,1294
F Crítico	1,95
H0: Merval "NÃO causa Granger" Ibovespa	**VERDADEIRO**

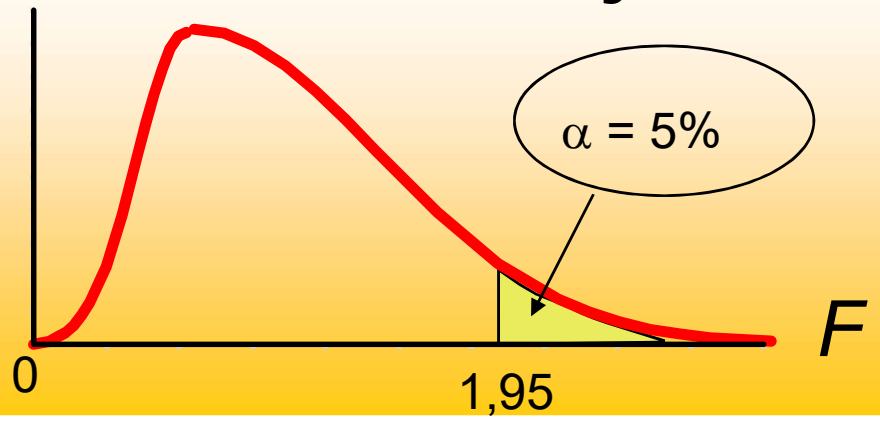
Verificação:

$F^{Calculado} = 1,13 < F^{Crítico} = 1,95$

Decisão:

Com 95% confiança, NÃO se pode rejeitar H_0

Distribuição F



Conclusão:

NÃO existe evidência de que Merval ***"causa-Granger"*** Ibovespa.

Teste de Causalidade de Granger

Objetivo

- Agora, suponha como VERDADE
  - Ibovespa causa variações Merval
    - Ibovespa $\rightarrow$ Merval.
- Estime modelo AMPLO para Merval:
  - Variáveis EXPLICATIVAS do modelo
    - valores defasados de Ibovespa e Merval

$$Merv_t = \lambda_1 Merv_{t-1} + \lambda_2 Merv_{t-2} + \ldots + \lambda_n Merv_{t-n} + \delta_1 Ibov_{t-1} + \delta_2 Ibov_{t-2} + \ldots + \delta_n Ibov_{t-n} + v_t$$

Teste de Causalidade de Granger

Análise de Variância Regressão **AMPLA**

$$Merv_t = \lambda_1 Merv_{t-1} + \lambda_2 Merv_{t-2} + \ldots + \lambda_8 Merv_{t-8} + \delta_1 Ibov_{t-1} + \delta_2 Ibov_{t-2} + \ldots + \delta_8 Ibov_{t-8} + v_t$$

Estatística de regressão	
R múltiplo	0,996506025
R-Quadrado	0,993024258
R-quadrado ajustado	0,99136065
Erro padrão	23,10760695
Observações	680

	Coeficientes	*Erro padrão*	*Stat t*	*valor-P*
Variável Merval (t-1)	0,904071011	0,044431022	20,3477427	0,0%
Variável Merval (t-2)	0,105126309	0,060096104	1,749303223	8,1%
Variável Merval (t-3)	0,045643624	0,060266706	0,757360525	44,9%
Variável Merval (t-4)	-0,078788601	0,060559774	-1,301005519	19,4%
Variável Merval (t-5)	-0,032186755	0,06053661	-0,531690744	59,5%
Variável Merval (t-6)	0,063645093	0,060390929	1,053884986	29,2%
Variável Merval (t-7)	0,034996749	0,06029776	0,580398824	56,2%
Variável Merval (t-8)	-0,045083001	0,04378657	-1,029607974	30,4%
Variável Ibovespa (t-1)	0,007765785	0,001933423	4,016598818	0,0%
Variável Ibovespa (t-2)	-0,0050787	0,002583855	-1,965551286	5,0%
Variável Ibovespa (t-3)	-0,003257685	0,002590181	-1,257705889	20,9%
Variável Ibovespa (t-4)	0,002050105	0,002592865	0,790671875	42,9%
Variável Ibovespa (t-5)	-0,003657047	0,002585052	-1,414689999	15,8%
Variável Ibovespa (t-6)	0,000692555	0,002576658	0,268780305	78,8%
Variável Ibovespa (t-7)	0,000278353	0,002574076	0,108137213	91,4%
Variável Ibovespa (t-8)	0,00136111	0,001953219	0,696854876	48,6%

Teste de Causalidade de Granger

Análise de Variância Regressão **AMPLA**

$$Merv_t = \lambda_1 Merv_{t-1} + \lambda_2 Merv_{t-2} + \ldots + \lambda_8 Merv_{t-8} + \delta_1 Ibov_{t-1} + \delta_2 Ibov_{t-2} + \ldots + \delta_8 Ibov_{t-8} + v_t$$

	gl	*SQ*	*MQ*	*F*	*F de significação*
Regressão	16	50.471.648,95	3.154.478,06	5.907,69	0,0%
Resíduo	664	354.550,44	533,96		
Total	680	50.826.199,39			

Teste de Causalidade de Granger

Objetivo

- Suponha como VERDADE
  - Ibovespa causa variações Merval
    - Ibovespa $\rightarrow$ Merval.
- Estime modelo **RESTRITO** para Merval:
  - Variáveis EXPLICATIVAS do modelo
    - **SOMENTE** valores defasados de Merval

$$Merv_t = \lambda_1 Merv_{t-1} + \lambda_2 Merv_{t-2} + \ldots + \lambda_n Merv_{t-n} + v^*_t$$

Teste de Causalidade de Granger

Análise de Variância Regressão **RESTRITA**

$$Merv_t = \lambda_1 Merv_{t-1} + \lambda_2 Merv_{t-2} + \ldots + \lambda_8 Merv_{t-8} + v^*_t$$

Estatística de regressão	
R múltiplo	0,996396076
R-Quadrado	0,992805141
R-quadrado ajustado	0,991242099
Erro padrão	23,32761439
Observações	680

	Coeficientes	*Erro padrão*	*Stat t*	*valor-P*
Variável Merval (t-1)	0,995933929	0,038574576	25,81840224	0,0%
Variável Merval (t-2)	0,035974662	0,054436185	0,660859342	50,9%
Variável Merval (t-3)	0,026197001	0,054404604	0,481521753	63,0%
Variável Merval (t-4)	-0,081812954	0,05440339	-1,503820884	13,3%
Variável Merval (t-5)	-0,061558935	0,054397197	-1,131656393	25,8%
Variável Merval (t-6)	0,078308754	0,054435456	1,438561551	15,1%
Variável Merval (t-7)	0,02695639	0,054470603	0,494879602	62,1%
Variável Merval (t-8)	-0,019157191	0,03863961	-0,49579151	62,0%

Teste de Causalidade de Granger

Análise de Variância Regressão **RESTRITA**

$$Merv_t = \lambda_1 Merv_{t-1} + \lambda_2 Merv_{t-2} + \ldots + \lambda_8 Merv_{t-8} + v^*_t$$

	gl	*SQ*	*MQ*	*F*	*F de significação*
Regressão	8	50.460.512,05	6.307.564,01	11.591,00	0,0%
Resíduo	672	365.687,34	544,18		
Total	680	50.826.199,39			

Teste de Causalidade de Granger

Teste de Hipóteses

H_0: $\Sigma\delta_j = 0 \rightarrow$ Ibovespa “NÃO causa-Granger” Merval

H_1: $\Sigma\delta_j \neq 0 \rightarrow$ Ibovespa “causa-Granger” Merval

Objetiva-se testar a significância conjunta de parâmetros vinculados à variável explicativa Ibovespa.

Quando $F^{Crítico} < F^{Calculado}$, REJEITA-SE H_0.

Quanto maior $F^{Calculado}$ em relação a $F^{Crítico}$,
maior a nossa crença no modelo

Teste de Causalidade de Granger

Teste de Hipóteses

H_0: $\Sigma\delta_j = 0 \rightarrow$ Ibovespa “NÃO causa-Granger” Merval

H_1: $\Sigma\delta_j \neq 0 \rightarrow$ Ibovespa “causa-Granger” Merval

Estatística de Teste:

$$F^{Calculado} = \frac{[(SQRes_{RESTRITO} - SQRes_{AMPLO}) \div m]}{[SQRes_{AMPLO} \div (n-k)]}$$

$F \sim F[\alpha$; m gl numerador ; (n - k) gl denominador]

m: quantidade de termos defasados da variável Ibovespa

n: tamanho da amostra

k: quantidade parâmetros estimados na Regressão AMPLA

Teste de Causalidade de Granger

H_0: $\Sigma\delta_j = 0 \rightarrow$ Ibovespa “NÃO causa-Granger” Merval

H_1: $\Sigma\delta_j \neq 0 \rightarrow$ Ibovespa “causa-Granger” Merval

Parâmetro	Valores
Nível de Significância do Teste	5%
SQResíduos Anova AMPLA	354.550,44
SQResíduos Anova RESTRITA	365.687,34
Amostra (n)	680
Termos Defasados de Ibovespa (m)	8
Parâmetros Estimados Regressão AMPLA (k)	16
Graus de Liberdade NUMERADOR	8
Graus de Liberdade DENOMINADOR	664
F Calculado	2,5277
F Crítico	1,95
H0: Ibovespa "NÃO causa Granger" Merval	**FALSO**

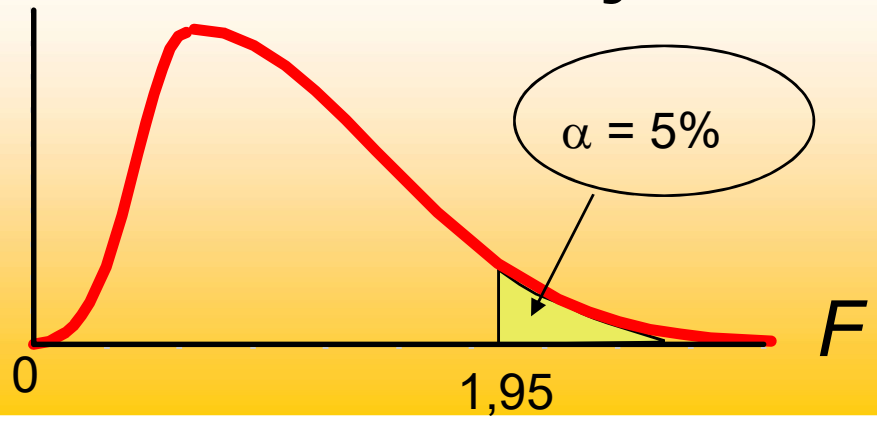
Verificação:

$F^{Calculado} = 2,53 > F^{Crítico} = 1,95$

Decisão:

Com 95% confiança, pode-se rejeitar H_0

Distribuição F



Conclusão:

Existe evidência de que Ibovespa ***“causa-Granger”*** Merval.

Estatística Aplicada

Aula 12 - Agenda

Modelos ARIMA

Modelos ARIMA

- Objetivo de modelar o processo estocástico gerador dos dados da série temporal
  - Descrição de quantidade razoável de séries temporais
  - Aplicação para períodos curtos

- Previsão baseada SOMENTE em padrões históricos de comportamento da série temporal
  - Y_t = Padrão + ε_t

- PADRÃO pode assumir as seguintes características:
  - Movimento de Tendência - *T*
  - Variações Cíclicas - *C*
  - Variações Sazonais - *S*

$$Y_t = f(T, C, S) + \varepsilon_t$$

Modelos ARIMA

- Componente Auto-Regressivo: AR(p)
  - Indica que processo gerador de dados da variável aleatória é função do comportamento de seus valores passados e presentes
    - ✓ Presença de autocorrelação entre as observações
- Componente Média Móvel: MA(q)
  - Indica que processo gerador de dados da variável aleatória é função dos efeitos dos erros aleatórios passados, os quais continuam a reverberar ao longo do tempo
    - ✓ Presença de autocorrelação entre os resíduos
- Componente Integração: I(d)
  - Indica que processo gerador de dados da variável aleatória é NÃO-estacionário em nível.

Série Temporal Estacionária

Autocorrelação POPULACIONAL

- Função Autocorrelação (FAC) indica correlação entre X_t e X_{t-k}
- De forma geral, tem-se:

$$\rho_k = \frac{\gamma_k}{\gamma_0} = \frac{\text{cov}(X_t; X_{t-k})}{\text{cov}(X_t; X_{t-0})} = \frac{\text{cov}(X_t; X_{t-k})}{\text{cov}(X_t; X_t)} = \frac{\text{cov}(X_t; X_{t-k})}{\text{var}(X_t)}$$

$$\gamma_k = \text{cov}(X_t; X_{t-k}) = \frac{\sum_{t=1}^{N-k}(X_t - \mu)(X_{t-k} - \mu)}{N}$$

$$\gamma_0 = \text{var}(X_t) = \frac{\sum_{t=1}^{N}(X_t - \mu)(X_t - \mu)}{N} = \frac{\sum_{t=1}^{N}(X_t - \mu)^2}{N}$$

$$\mu = \frac{\sum_{t=1}^{N} X_t}{N}$$

Série Temporal Estacionária

Autocorrelação POPULACIONAL

$$\rho_k = \frac{\gamma_k}{\gamma_0} = \frac{\operatorname{cov}(X_t; X_{t-k})}{\operatorname{var}(X_t)} = \frac{\dfrac{\sum_{t=1}^{N-k}(X_t - \mu)(X_{t-k} - \mu)}{N}}{\dfrac{\sum_{t=1}^{N}(X_t - \mu)^2}{N}}$$

$$\rho_k = \frac{\gamma_k}{\gamma_0} = \frac{\sum_{t=1}^{N-k}(X_t - \mu)(X_{t-k} - \mu)}{\sum_{t=1}^{N}(X_t - \mu)^2}$$

$$\mu = \frac{\sum_{t=1}^{N} X_t}{N}$$

Série Temporal Estacionária

Autocorrelação AMOSTRAL

- Função Autocorrelação (FAC) indica correlação entre X_t e X_{t-k}
- Substitui-se:
  - N = tamanho da população por n = tamanho da amostra
  - μ = média da população por $\overline{X}$ = média da amostra

$$r_k = \hat{\rho}_k = \frac{\hat{\gamma}_k}{\hat{\gamma}_0} = \frac{\sum_{t=1}^{n-k}\left(X_t - \overline{X}\right)\left(X_{t-k} - \overline{X}\right)}{\sum_{t=1}^{n}\left(X_t - \overline{X}\right)^2}$$

$$\overline{X} = \frac{\sum_{t=1}^{n} X_t}{n}$$

- Observe que $\hat{\gamma}_0$ INDEPENDE do valor de *k*.
  - Denominador da equação é CONSTANTE.

Autocorrelação PARCIAL

- Mede a intensidade da relação entre duas observações da série, controlando (mantendo constante) o efeito das demais.

- Valores de $\hat{\phi}_{kk}$ são determinados pelos coeficientes de índice *kk* das regressões:
  - $Y_t = \beta_{11} Y_1 + \varepsilon_t \Rightarrow \phi_{11} = \beta_{11}$
  - $Y_t = \beta_{11} Y_1 + \beta_{22} Y_2 + \varepsilon_t \Rightarrow \phi_{22} = \beta_{22}$
  - $Y_t = \beta_{k1} Y_1 + \beta_{k2} Y_2 + \ldots + \beta_{kk} Y_k + \varepsilon_t \Rightarrow \phi_{kk} = \beta_{kk}$

- A representação grafica de $\hat{\phi}_{kk}$ contra *k* é conhecida como correlograma amostral da FACP

Modelos Auto-Regressivos
AR(p)

Modelos Auto-Regressivos

1a. Ordem: AR(1)

$$x_t = \xi + \phi_1 x_{t-1} + \varepsilon_t$$

Valor de *X* no instante *t* depende de:

- ξ: tendência.
- x_{t-1}: valor observado em *X* no instante anterior.
- ϕ_1: parâmetro vinculado à 1a. defasagem de *X*.
- ε_t: erro aleatório no instante *t*: $\varepsilon_t = x_t - E(x_t)$.

Modelo AR(1) - Parâmetros

Média: $E(x_t) = \frac{\xi}{(1-\phi_1)} = \mu$

Variância: $Var(x_t) = \frac{\sigma^2}{[1-(\phi_1)^2]}$

Covariância: $Cov(x_t; x_{t-s}) = \frac{[\sigma^2 \times (\phi_1)^s]}{[1-(\phi_1)^2]} = \gamma_s$

Observação: γ_0 = variância de x_t

Modelo AR(1) - Parâmetros

Média: $E(x_t) = \frac{\xi}{(1-\phi_1)} = \mu$

Variância: $Var(x_t) = \frac{\sigma^2}{[1-(\phi_1)^2]}$

Covariância: $Cov(x_t; x_{t-s}) = \frac{[\sigma^2 \times (\phi_1)^s]}{[1-(\phi_1)^2]} = \gamma_s$

Condição de Estacionariedade: $|\phi_1| < 1$

Modelos Auto-Regressivos

2a. Ordem: AR(2)

$$x_t = \xi + \phi_1 x_{t-1} + \phi_2 x_{t-2} + \varepsilon_t$$

Média: $E(x_t) = \dfrac{\xi}{(1 - \phi_1 - \phi_2)} = \mu$

Condição de Estacionariedade: $\phi_1 + \phi_2 < 1$

Modelo AR(1) - Parâmetros

Média: $E(x_t) = \frac{\xi}{(1-\phi_1)} = \mu$

Variância: $Var(x_t) = \frac{\sigma^2}{[1-(\phi_1)^2]}$

Covariância: $Cov(x_t; x_{t-s}) = \frac{[\sigma^2 \times (\phi_1)^s]}{[1-(\phi_1)^2]} = \gamma_s$

Condição de Estacionariedade: $|\phi_1| < 1$

Modelos Auto-Regressivos

Ordem “p”: AR(p)

$$x_t = \xi + \phi_1 x_{t-1} + \phi_2 x_{t-2} + \ldots + \phi_2 x_{t-p} + \varepsilon_t$$

Média: $$E(x_t) = \frac{\xi}{(1 - \phi_1 - \phi_2 - \ldots - \phi_p)} = \mu$$

Condição Estacionariedade: $\phi_1 + \phi_2 + \ldots + \phi_p < 1$

Modelo AR(1) - Parâmetros

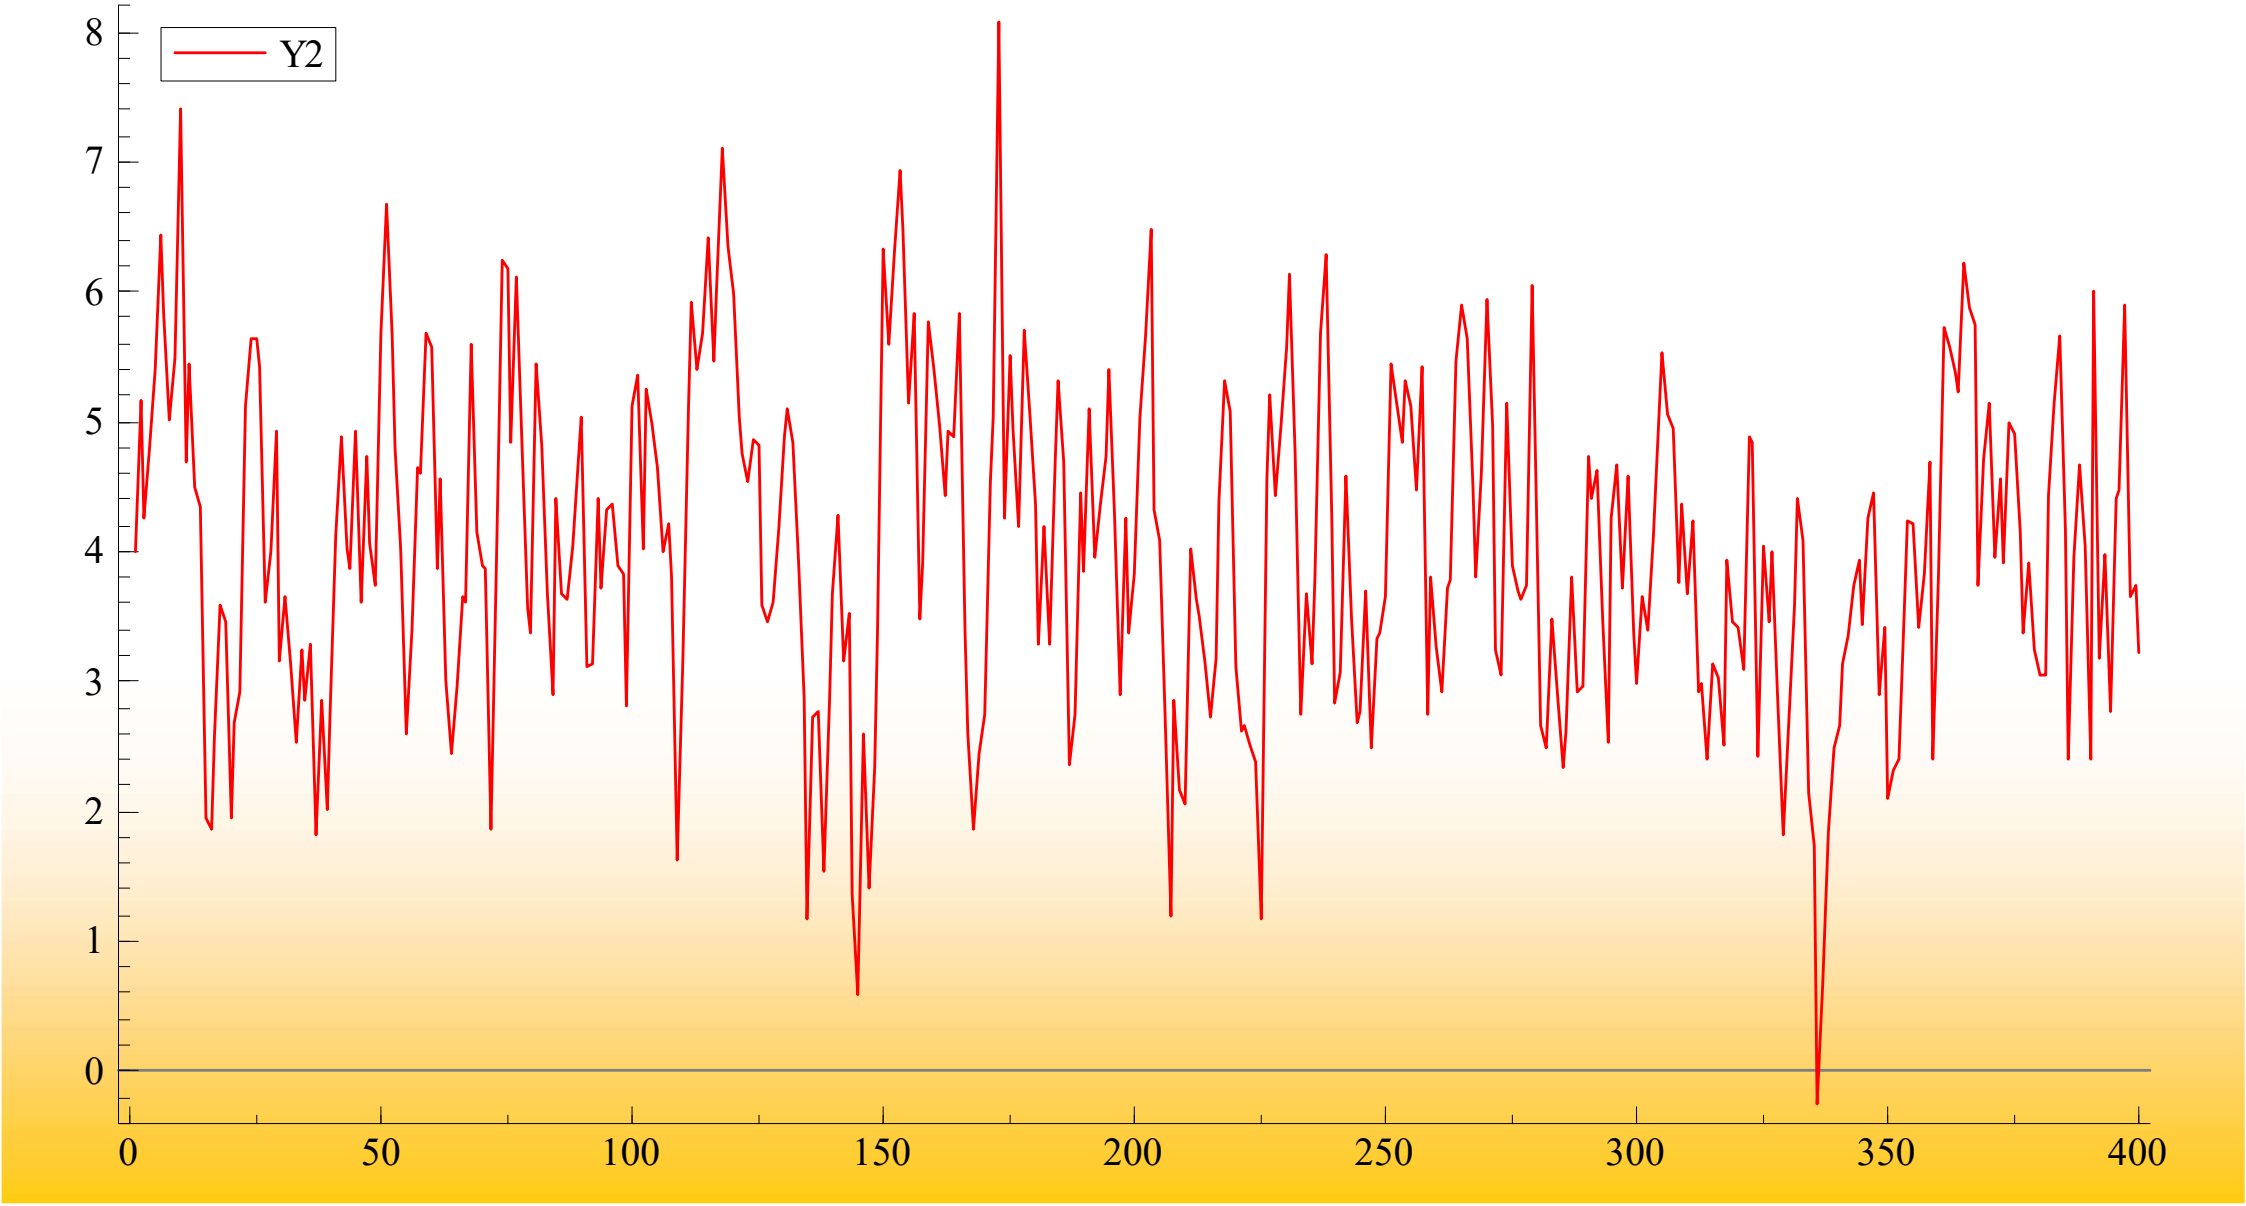
Média: $E(x_t) = \frac{\xi}{(1-\phi_1)} = \mu$

Variância: $Var(x_t) = \frac{\sigma^2}{[1-(\phi_1)^2]}$

Covariância: $Cov(x_t; x_{t-s}) = \frac{[\sigma^2 \times (\phi_1)^s]}{[1-(\phi_1)^2]} = \gamma_s$

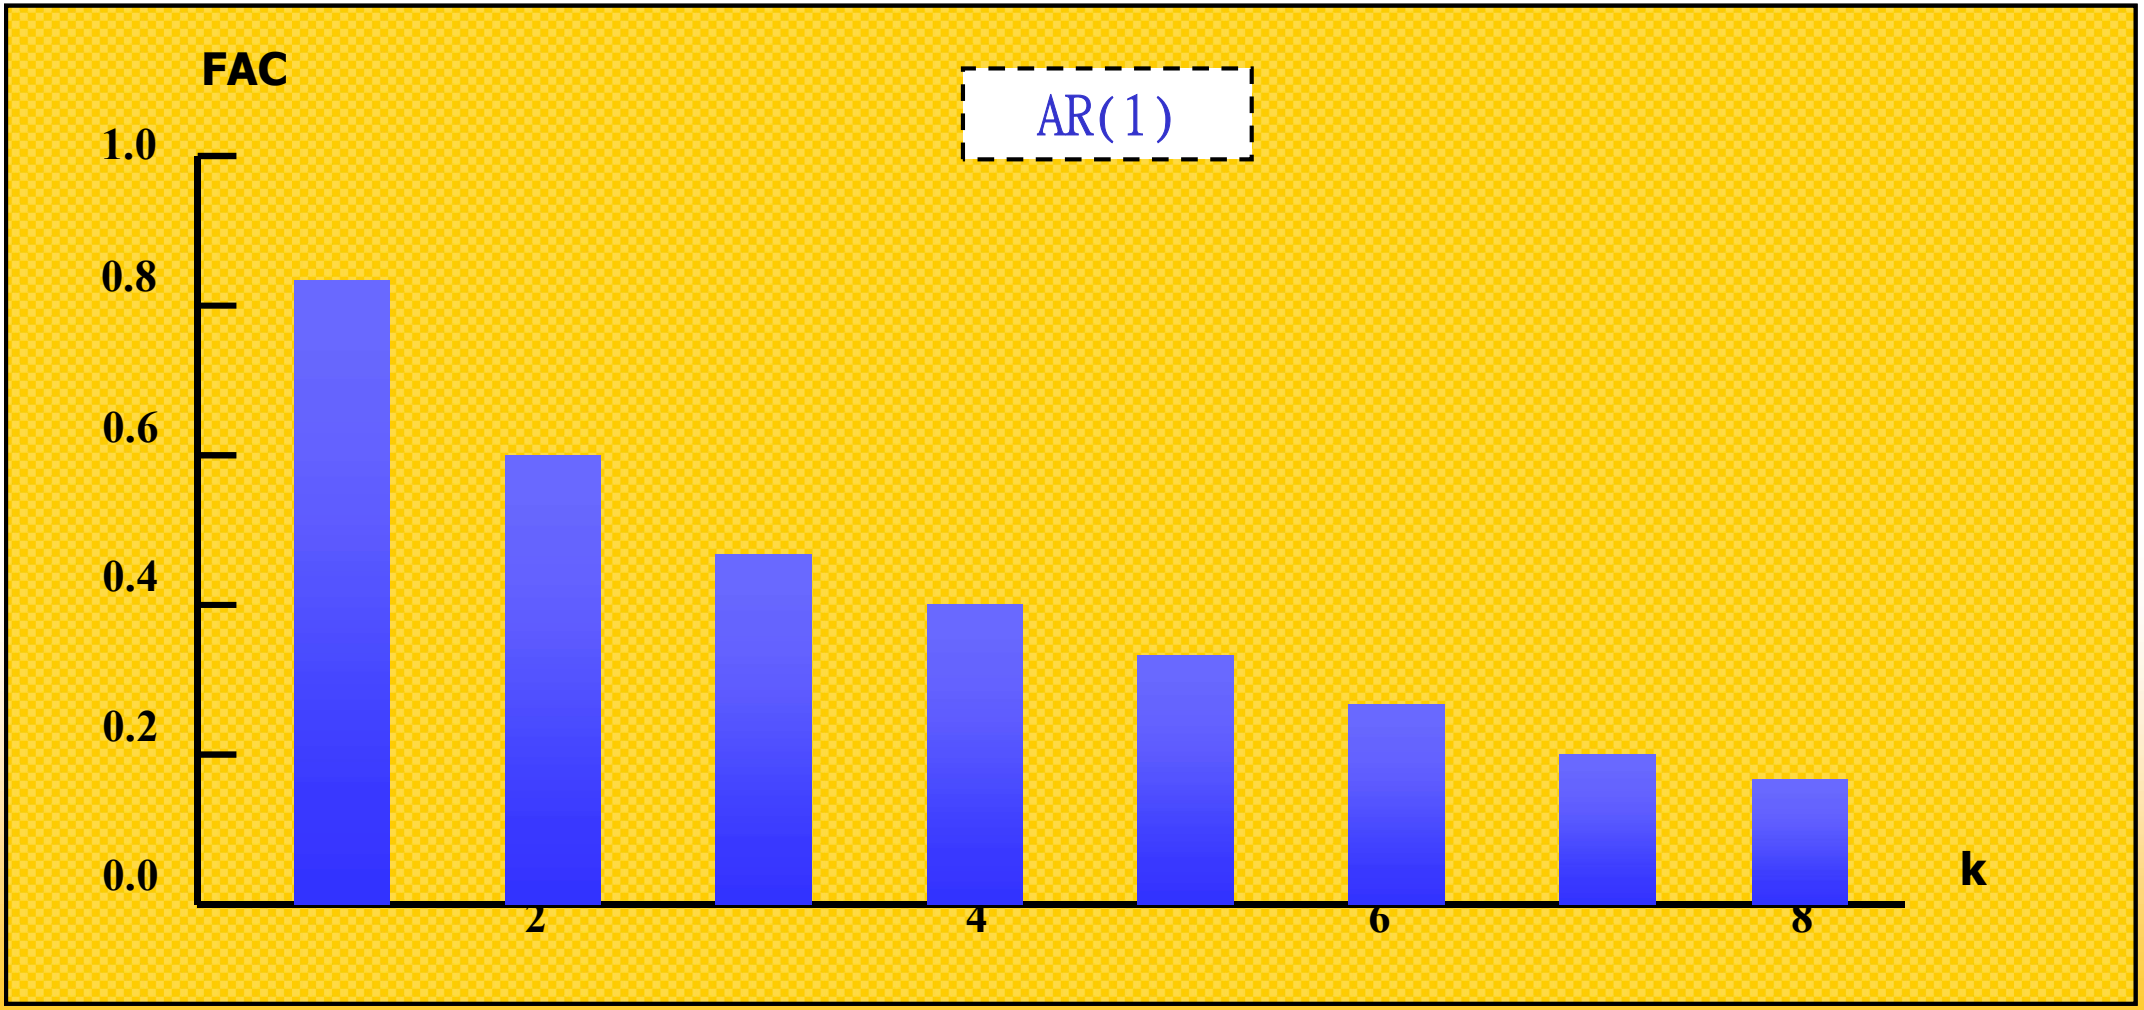
Condição de Estacionariedade: $|\phi_1| < 1$

Modelos Auto-Regressivos



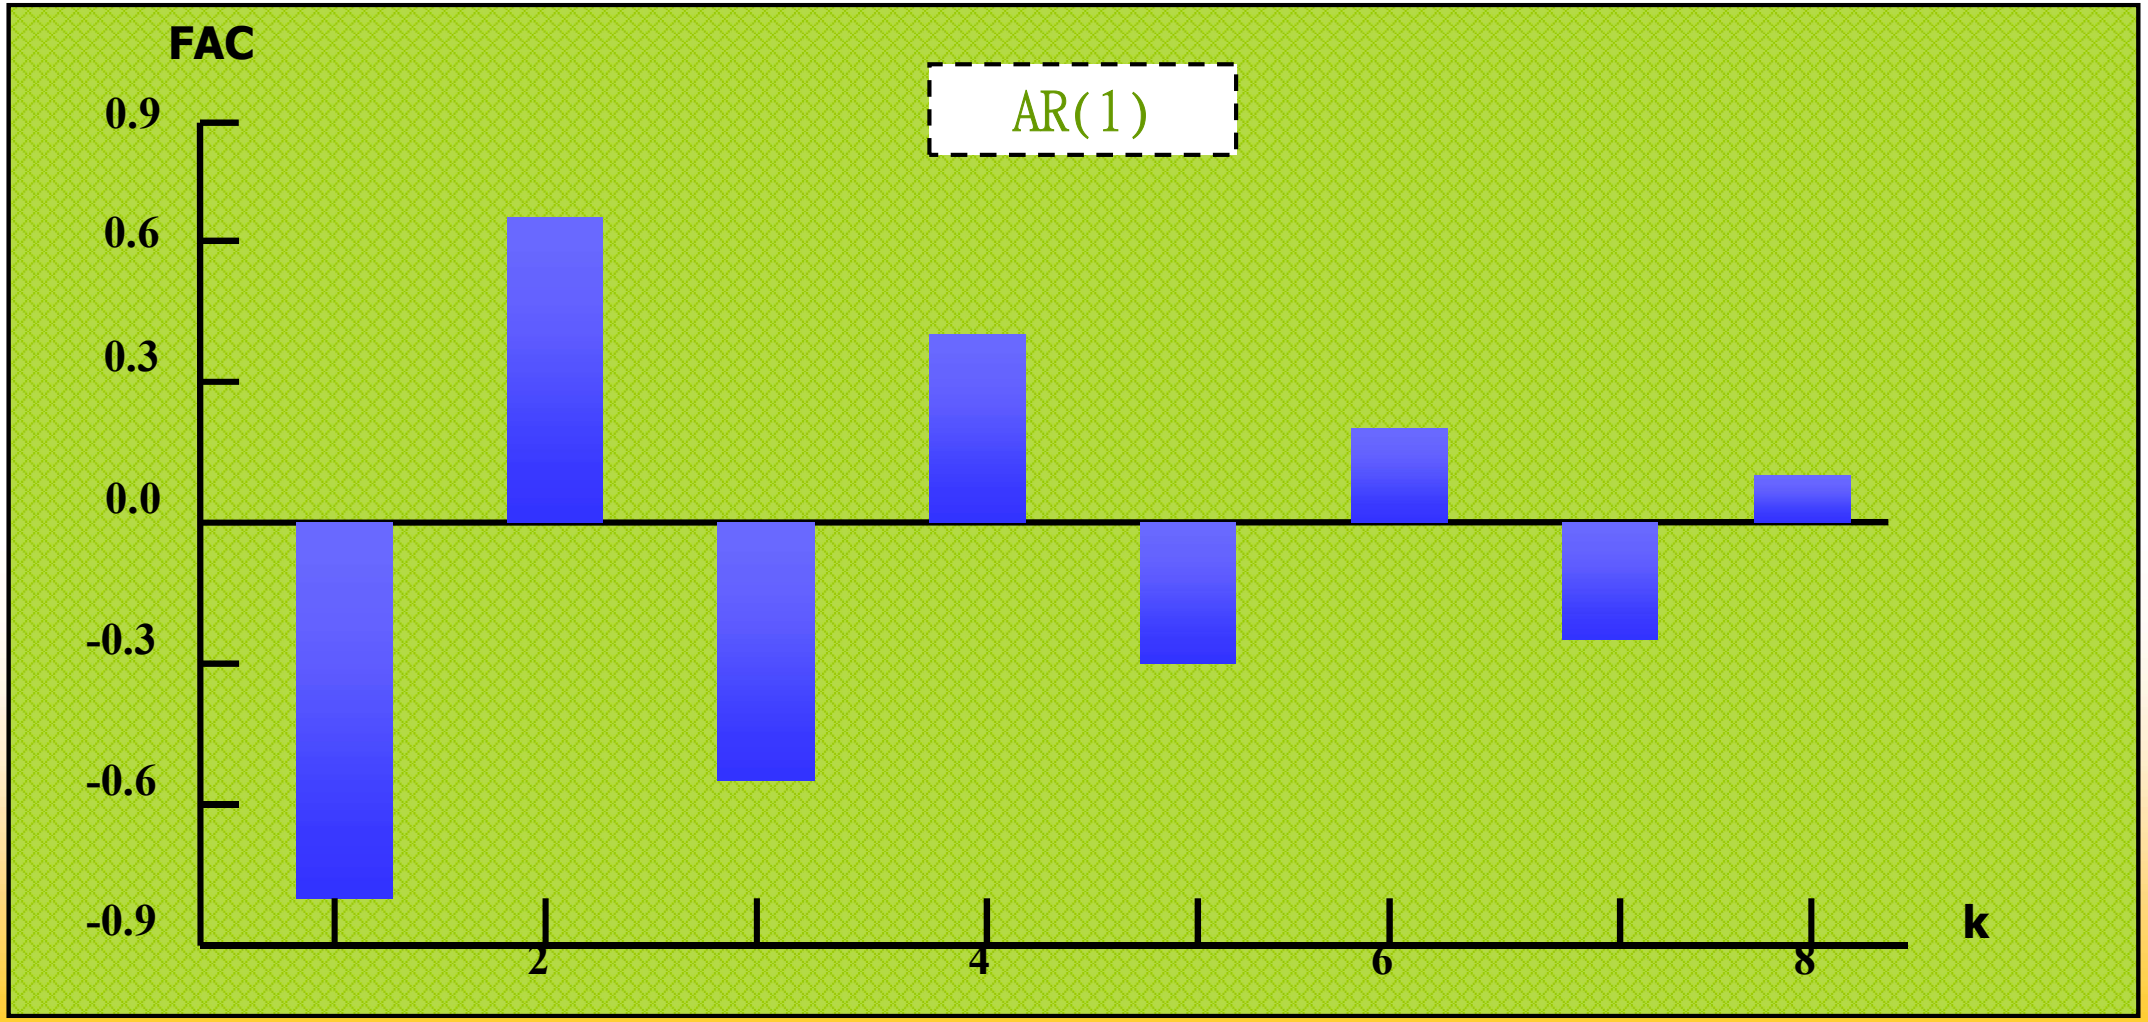
Função de Autocorrelação

AR(1): $x_t = \xi + \phi_1 x_{t-1} + \varepsilon_t$



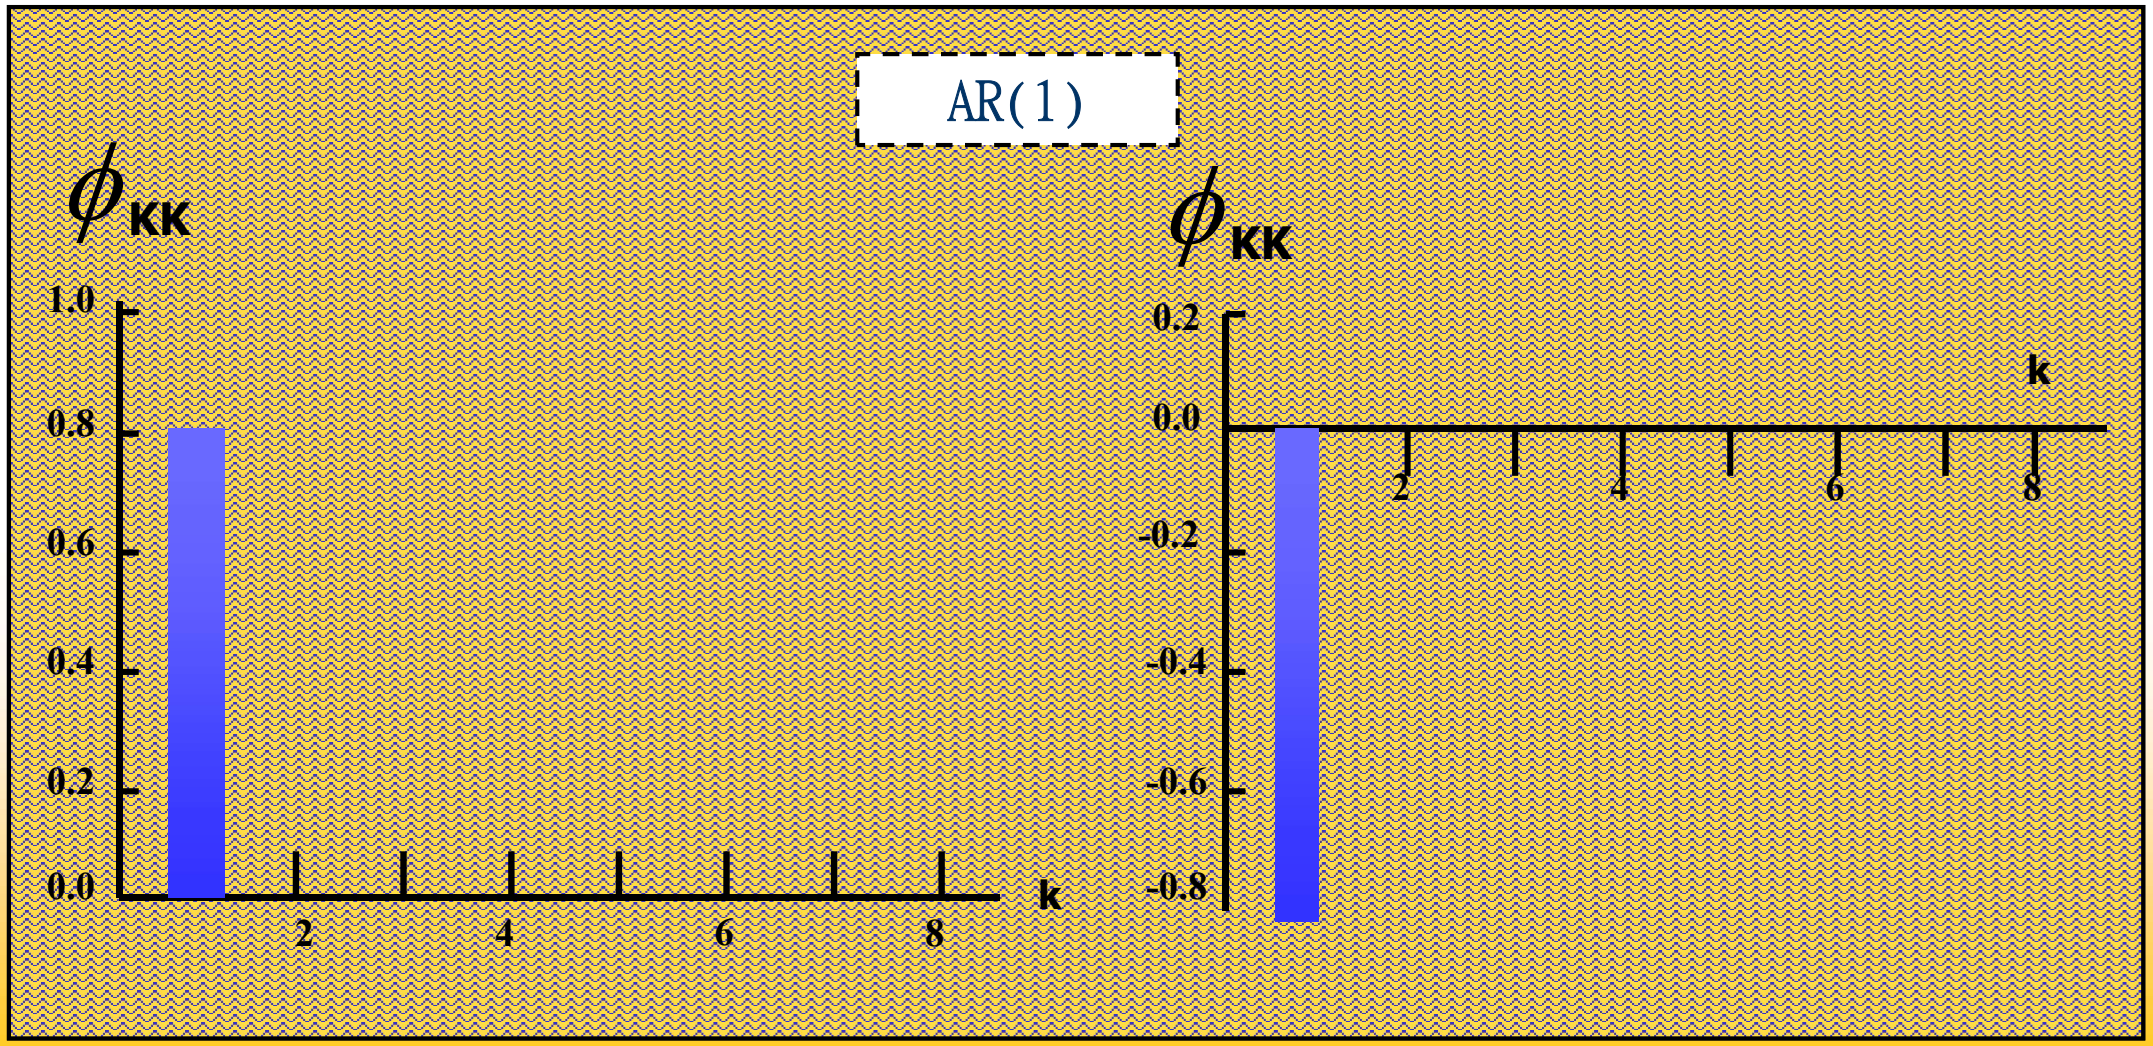
Função de Autocorrelação

AR(1): $x_t = \xi + \phi_1 x_{t-1} + \varepsilon_t$



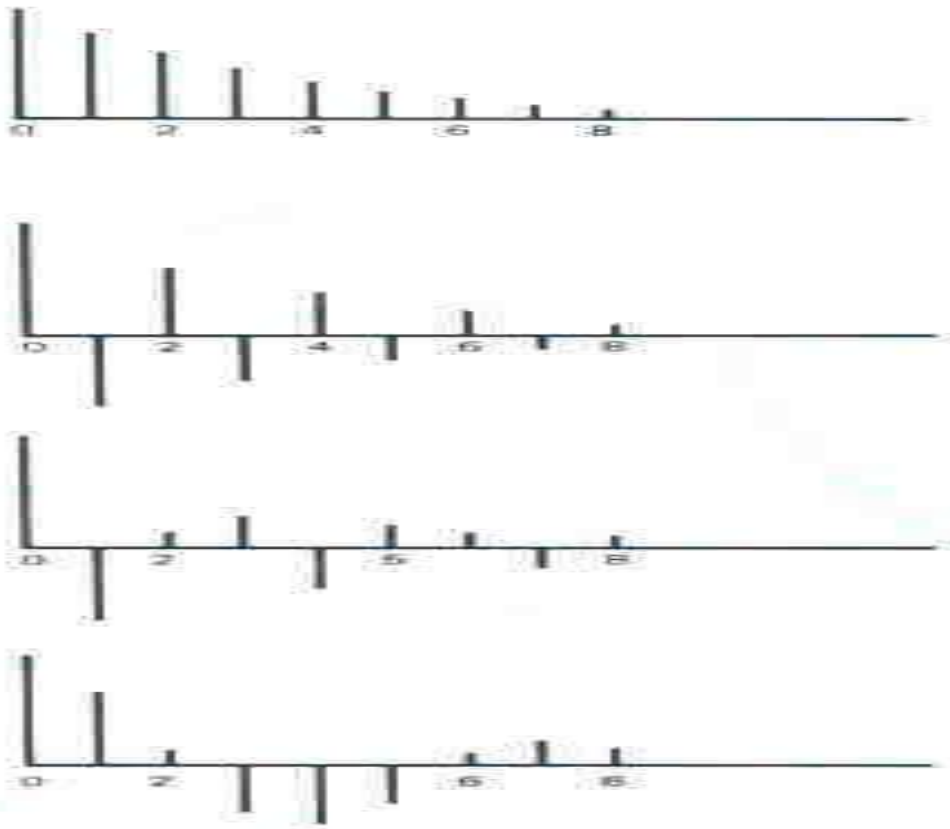
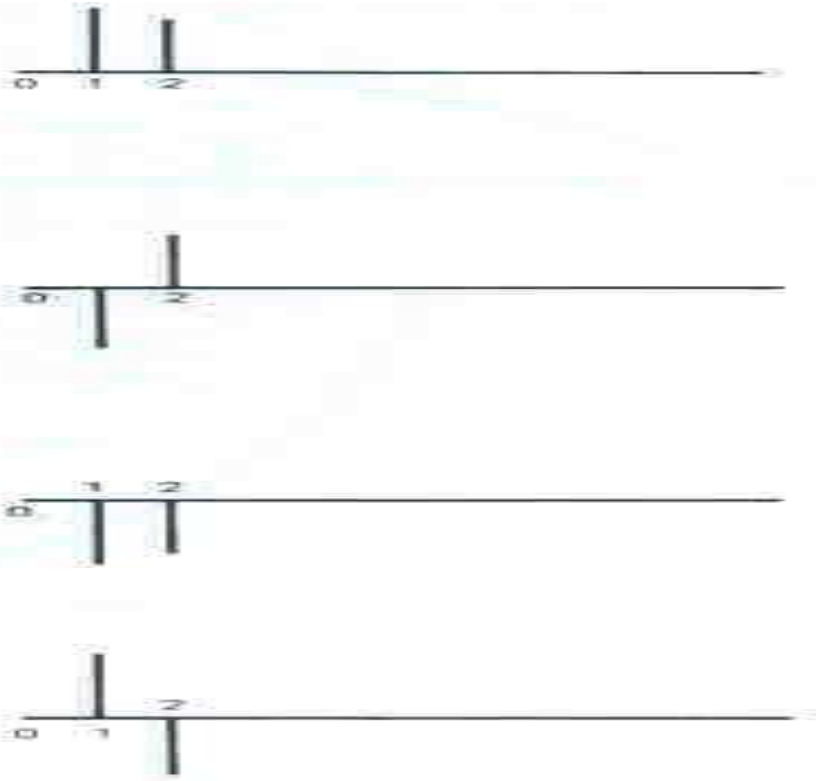
Função de Autocorrelação PARCIAL

AR(1): $x_t = \xi + \phi_1 x_{t-1} + \varepsilon_t$



FAC & FACP

AR(2): $x_t = \xi + \phi_1 x_{t-1} + \phi_2 x_{t-2} + \varepsilon_t$

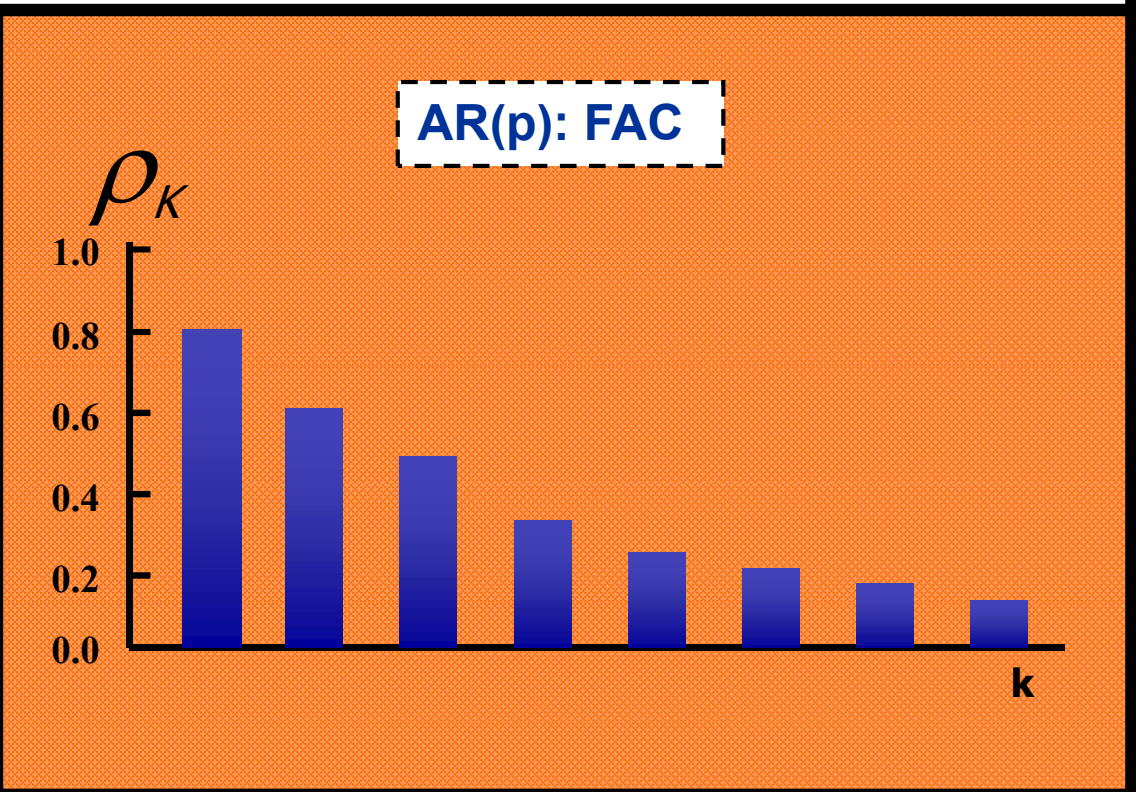
FAC	FACP
	

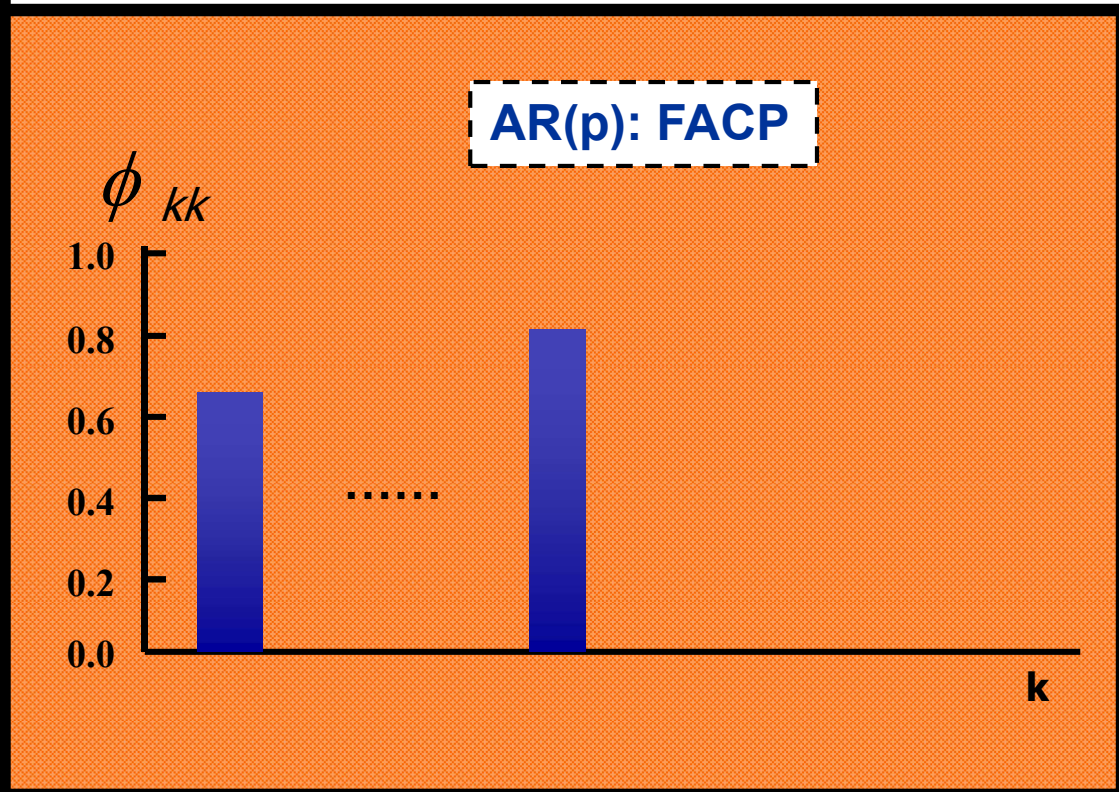
FAC & FACP

AR(p): $x_t = \xi + \phi_1 x_{t-1} + \phi_2 x_{t-2} + \ldots + \phi_2 x_{t-p} + \varepsilon_t$

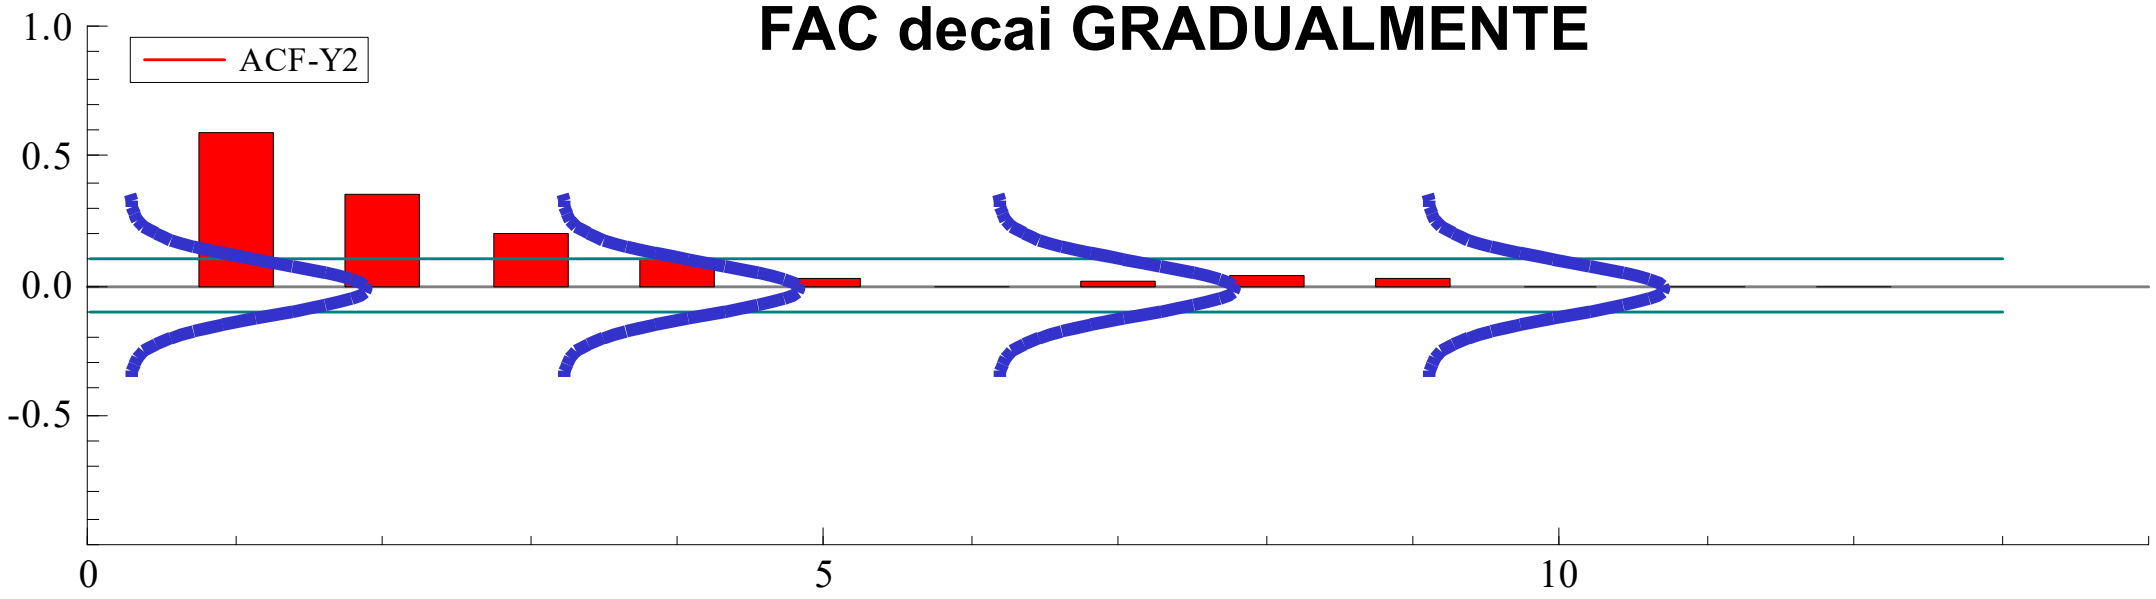
FAC decai GRADUALMENTE

FACP possui *k* primeiros *lags* SIGNIFICATIVAMENTE diferentes de zero

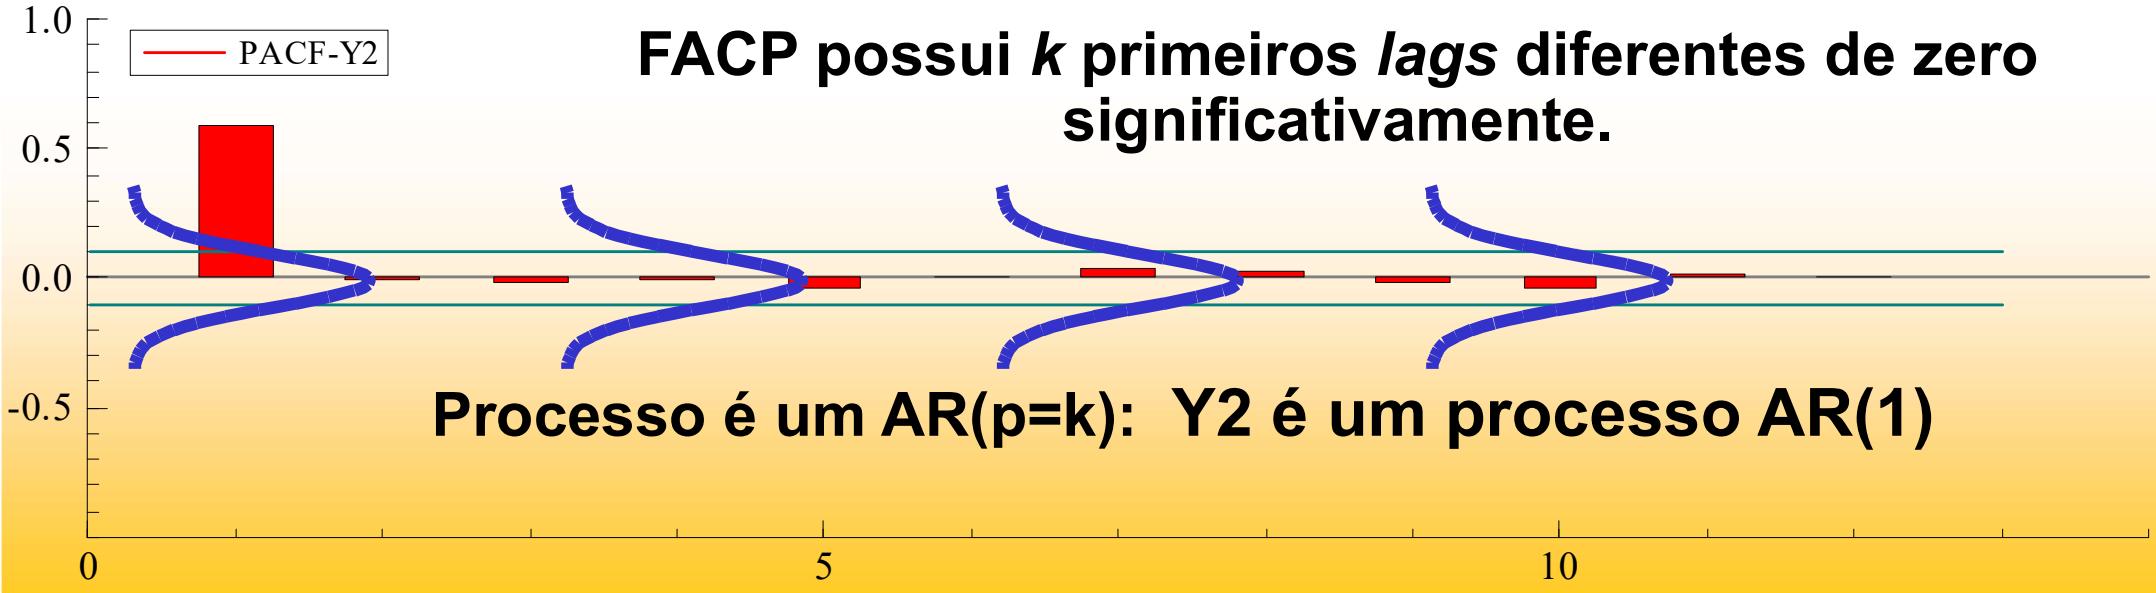




Modelos Auto-Regressivos



FAC decai GRADUALMENTE



FACP possui *k* primeiros *lags* diferentes de zero significativamente.

Processo é um AR(p=k): Y2 é um processo AR(1)

FACP

Interpretação

- Suponha uma série mensal em que os valores de x_t sejam fortemente correlacionados com os valores de x_{t-12} .
- Então a função de autocorrelação parcial (FACP) deveria exibir um pico na defasagem 12.
- Ademais, nenhum valor significativo nas demais.

AR(12): $x_t = \xi + \phi_1 x_{t-1} + \phi_2 x_{t-2} + \ldots + \phi_{12} x_{t-12} + \varepsilon_t$

Identificação

Evolução da Dívida Pública

Considere os dados amostrais sobre a evolução da dívida pública de determinado país nos últimos 40 anos.

Identifique a natureza do processo, usando correlogramas de:

i) Função de Autocorrelação (FAC) e

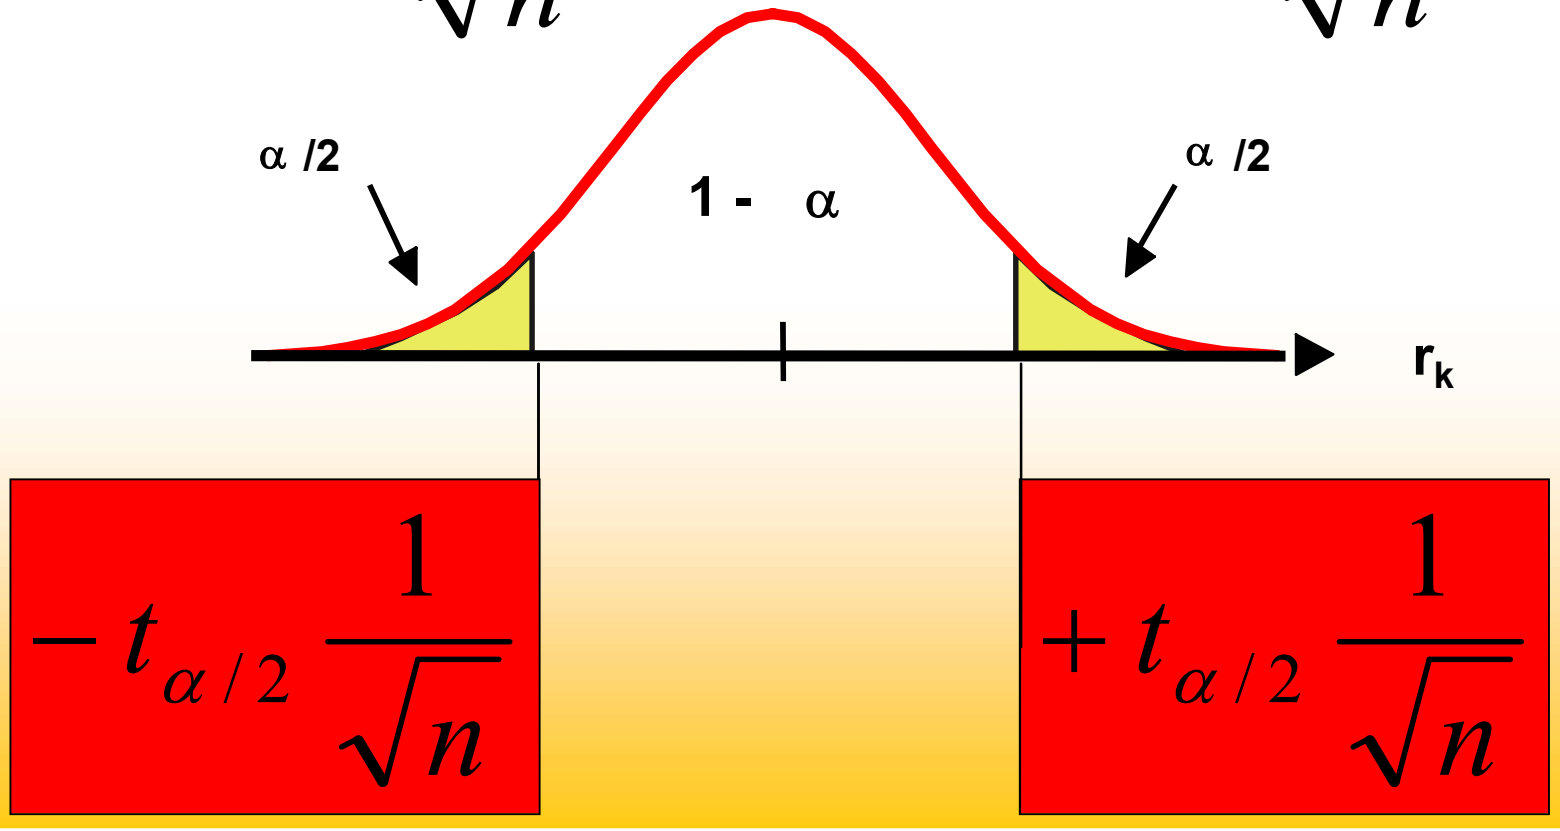
ii) Função de Autocorrelação Parcial (FACP).

Ano	Div Púb - Xt % PIB	Div Púb - Xt-1 % PIB	Div Púb - Xt-2 % PIB	Div Púb - Xt-3 % PIB	Div Púb - Xt-4 % PIB	Div Púb - Xt-5 % PIB
1966	32,20	-	-	-		
1967	32,70	32,20	-	-		
1968	31,40	32,70	32,200	-		
1969	34,20	31,40	32,700	32,200		
1970	32,80	34,20	31,400	32,700	32,200	
1971	35,10	32,80	34,200	31,400	32,700	32,200
1972	33,50	35,10	32,800	34,200	31,400	32,700
1973	32,10	33,50	35,100	32,800	34,200	31,400
1974	32,70	32,10	33,500	35,100	32,800	34,200
1975	31,70	32,70	32,100	33,500	35,100	32,800
1976	34,40	31,70	32,700	32,100	33,500	35,100
1977	36,30	34,40	31,700	32,700	32,100	33,500
1978	37,50	36,30	34,400	31,700	32,700	32,100
1979	38,00	37,50	36,300	34,400	31,700	32,700
1980	35,90	38,00	37,500	36,300	34,400	31,700
1981	35,00	35,90	38,000	37,500	36,300	34,400
1982	35,50	35,00	35,900	38,000	37,500	36,300
1983	34,70	35,50	35,000	35,900	38,000	37,500
1984	36,40	34,70	35,500	35,000	35,900	38,000
1985	37,90	36,40	34,700	35,500	35,000	35,900
1986	36,50	37,90	36,400	34,700	35,500	35,000
1987	35,10	36,50	37,900	36,400	34,700	35,500
1988	36,40	35,10	36,500	37,900	36,400	34,700
1989	36,80	36,40	35,100	36,500	37,900	36,400
1990	35,30	36,80	36,400	35,100	36,500	37,900
1991	37,10	35,30	36,800	36,400	35,100	36,500
1992	38,20	37,10	35,300	36,800	36,400	35,100
1993	37,50	38,20	37,100	35,300	36,800	36,400
1994	34,70	37,50	38,200	37,100	35,300	36,800
1995	34,80	34,70	37,500	38,200	37,100	35,300
1996	32,40	34,80	34,700	37,500	38,200	37,100
1997	33,50	32,40	34,800	34,700	37,500	38,200
1998	31,80	33,50	32,400	34,800	34,700	37,500
1999	32,00	31,80	33,500	32,400	34,800	34,700
2000	32,40	32,00	31,800	33,500	32,400	34,800
2001	32,60	32,40	32,000	31,800	33,500	32,400
2002	31,60	32,60	32,400	32,000	31,800	33,500
2003	33,00	31,60	32,600	32,400	32,000	31,800
2004	32,90	33,00	31,600	32,600	32,400	32,000
2005	33,30	32,90	33,000	31,600	32,600	32,400

Teste para Correlação

Intervalo de Confiança Bilateral

$$\left[-t_{\alpha/2}\frac{1}{\sqrt{n}} < \rho_k < +t_{\alpha/2}\frac{1}{\sqrt{n}}\right]$$

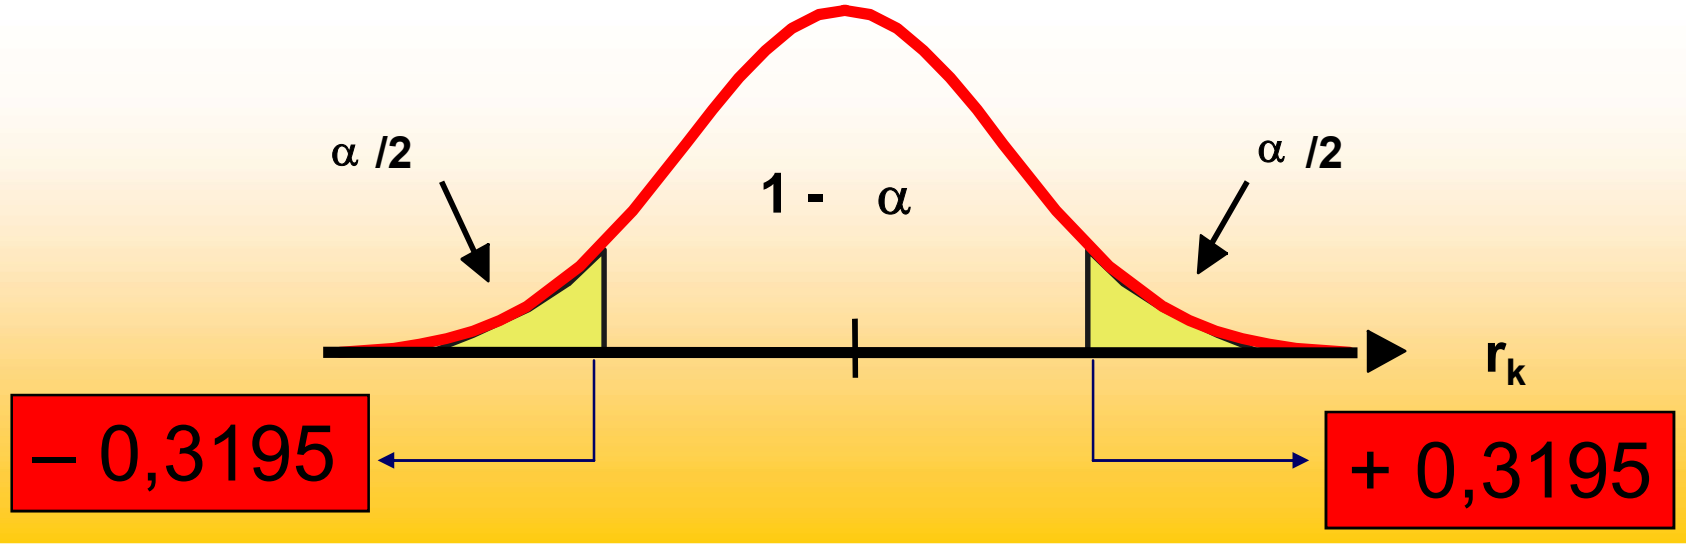


Teste para Correlação

Intervalo de Confiança Bilateral

$\alpha = 5\%$, n = 40 e gl = 38 $\rightarrow$ $t^{tabelado} = 2{,}021$

$$[-2{,}021 \frac{1}{\sqrt{40}} < \rho_k < +2{,}021 \frac{1}{\sqrt{40}}]$$



Série Temporal Estacionária

Autocorrelação AMOSTRAL

❖Seja ***k* = 0**. Então, $r_0 = 1$, conforme abaixo:

$$r_0 = \hat{\rho}_0 = \frac{\hat{\gamma}_0}{\hat{\gamma}_0} = \frac{\sum_{t=1}^{n-0}\left(X_t - \overline{X}\right)\left(X_{t-0} - \overline{X}\right)}{\sum_{t=1}^{n}\left(X_t - \overline{X}\right)^2} = \frac{\sum_{t=1}^{n}\left(X_t - \overline{X}\right)\left(X_t - \overline{X}\right)}{\sum_{t=1}^{n}\left(X_t - \overline{X}\right)^2} = \frac{\text{cov}(X_t; X_{t-0})}{\text{var}(X_t)}$$

$$r_0 = \hat{\rho}_0 = \frac{\hat{\gamma}_0}{\hat{\gamma}_0} = \frac{\sum_{t=1}^{n}\left(X_t - \overline{X}\right)^2}{\sum_{t=1}^{n}\left(X_t - \overline{X}\right)^2} = \frac{\text{cov}(X_t; X_{t-0})}{\text{var}(X_t)} = \frac{\text{var}(X_t)}{\text{var}(X_t)} = \frac{4{,}2882}{4{,}2882} = 1$$

Série Temporal Estacionária

Autocorrelação AMOSTRAL

- Seja ***k* = 1**. Então, tem-se:

$$r_1 = \hat{\rho}_1 = \frac{\hat{\gamma}_1}{\hat{\gamma}_0} = \frac{\sum_{t=1}^{n-1}\left(X_t - \overline{X}\right)\left(X_{t-1} - \overline{X}\right)}{\sum_{t=1}^{n}\left(X_t - \overline{X}\right)^2} = \frac{\text{cov}(X_t; X_{t-1})}{\text{var}(X_t)} = \frac{3{,}3359}{4{,}2882} = 0{,}7779$$

- Observe que $\hat{\gamma}_0$ INDEPENDE do valor de k.
  - $\hat{\gamma}_0$ é uma CONSTANTE.

$$\hat{\gamma}_0 = \sum_{t=1}^{n}\left(X_t - \overline{X}\right)^2 = Cons\,\text{tan}\,te$$

Série Temporal Estacionária

Autocorrelação AMOSTRAL

- Seja ***k* = 2**. Então, tem-se:

$$r_2 = \hat{\rho}_2 = \frac{\hat{\gamma}_2}{\hat{\gamma}_0} = \frac{\sum_{t=1}^{n-2}(X_t - \overline{X})(X_{t-2} - \overline{X})}{\sum_{t=1}^{n}(X_t - \overline{X})^2} = \frac{\text{cov}(X_t; X_{t-2})}{\text{var}(X_t)} = \frac{2,7551}{4,2882} = 0,6425$$

- Observe que $\hat{\gamma}_0$ INDEPENDE do valor de k.
  - $\hat{\gamma}_0$ é uma CONSTANTE.

$$\hat{\gamma}_0 = \sum_{t=1}^{n}(X_t - \overline{X})^2 = Cons\,\text{tan}\,te$$

Série Temporal Estacionária

Autocorrelação AMOSTRAL

❖ Seja ***k* = 3**. Então, tem-se:

$$r_3 = \hat{\rho}_3 = \frac{\hat{\gamma}_3}{\hat{\gamma}_0} = \frac{\sum_{t=1}^{n-3}\left(X_t - \overline{X}\right)\left(X_{t-3} - \overline{X}\right)}{\sum_{t=1}^{n}\left(X_t - \overline{X}\right)^2} = \frac{\text{cov}(X_t; X_{t-3})}{\text{var}(X_t)} = \frac{1{,}8239}{4{,}2882} = 0{,}4253$$

❖ Observe que $\hat{\gamma}_0$ INDEPENDE do valor de k.

➢ $\hat{\gamma}_0$ é uma CONSTANTE.

$$\hat{\gamma}_0 = \sum_{t=1}^{n}\left(X_t - \overline{X}\right)^2 = Cons\,\text{tan}\,te$$

Série Temporal Estacionária

Autocorrelação AMOSTRAL

- Seja ***k* = 4**. Então, tem-se:

$$r_4 = \hat{\rho}_4 = \frac{\hat{\gamma}_4}{\hat{\gamma}_0} = \frac{\sum_{t=1}^{n-4}\left(X_t - \overline{X}\right)\left(X_{t-4} - \overline{X}\right)}{\sum_{t=1}^{n}\left(X_t - \overline{X}\right)^2} = \frac{\text{cov}(X_t; X_{t-4})}{\text{var}(X_t)} = \frac{1{,}2608}{4{,}2882} = 0{,}2940$$

- Observe que $\hat{\gamma}_0$ INDEPENDE do valor de k.
  - $\hat{\gamma}_0$ é uma CONSTANTE.

$$\hat{\gamma}_0 = \sum_{t=1}^{n}\left(X_t - \overline{X}\right)^2 = Cons\,\text{tan}\,te$$

Série Temporal Estacionária

Autocorrelação AMOSTRAL

❖ Seja ***k* = 5**. Então, tem-se:

$$r_5 = \hat{\rho}_5 = \frac{\hat{\gamma}_5}{\hat{\gamma}_0} = \frac{\sum_{t=1}^{n-5}(X_t - \overline{X})(X_{t-5} - \overline{X})}{\sum_{t=1}^{n}(X_t - \overline{X})^2} = \frac{\text{cov}(X_t; X_{t-5})}{\text{var}(X_t)} = \frac{0{,}9472}{4{,}2882} = 0{,}2209$$

❖ Observe que $\hat{\gamma}_0$ INDEPENDE do valor de k.

➢ $\hat{\gamma}_0$ é uma CONSTANTE.

$$\hat{\gamma}_0 = \sum_{t=1}^{n}(X_t - \overline{X})^2 = Cons\,\text{tan}\,te$$

FAC

Intervalo de Confiança Bilateral

H_0: $\rho_k = 0$: **NÃO** associação

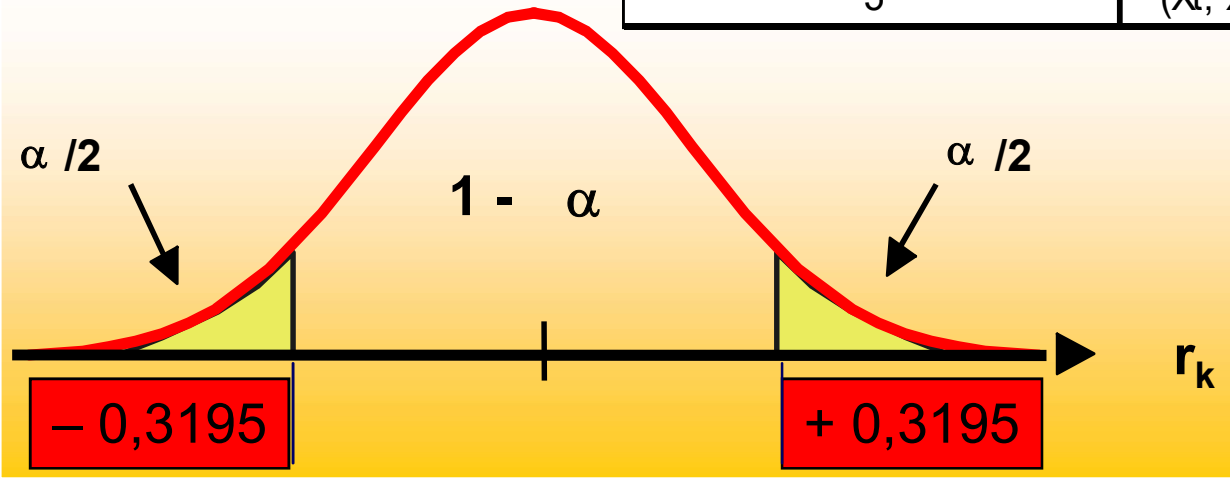
H_1: $\rho_k \neq 0$: associação

α= 5%, n = 40

gl = n – 2 = 38

$t^{tabelado}$ = 2,021

Defasagens (k)	Séries Temporais	FAC (Xt; Xt-k)	Rejeita H_0	
0	(Xt; Xt-0)	1,0000	1	SIM
1	(Xt; Xt-1)	0,7779	1	SIM
2	(Xt; Xt-2)	0,6425	1	SIM
3	(Xt; Xt-3)	0,4253	1	SIM
4	(Xt; Xt-4)	0,2940	0	NÃO
5	(Xt; Xt-5)	0,2209	0	NÃO



Autocorrelação PARCIAL

- Mede a intensidade da relação entre duas observações da série, controlando (mantendo constante) o efeito das demais.

- Valores de $\hat{\phi}_{kk}$ são determinados pelos coeficientes de índice *kk* das regressões:
  - $Y_t = \beta_{11} Y_1 + \varepsilon_t \Rightarrow \phi_{11} = \beta_{11}$
  - $Y_t = \beta_{11} Y_1 + \beta_{22} Y_2 + \varepsilon_t \Rightarrow \phi_{22} = \beta_{22}$
  - $Y_t = \beta_{k1} Y_1 + \beta_{k2} Y_2 + \ldots + \beta_{kk} Y_k + \varepsilon_t \Rightarrow \phi_{kk} = \beta_{kk}$

- A representação grafica de $\hat{\phi}_{kk}$ contra *k* é conhecida como correlograma amostral da FACP

Série Temporal Estacionária

Autocorrelação AMOSTRAL

- Seja ***k* = 1**. Então, tem-se:
  - $Y_t = \beta_{11} Y_1 + \varepsilon_t \Rightarrow \phi_{11} = \beta_{11}$

	Coeficientes
Interseção	8,818336919
Variável X 1	0,745043031

- FACP: $\hat{\phi}_{11} = +0,7450$

Série Temporal Estacionária

Autocorrelação AMOSTRAL

- Seja ***k* = 2**. Então, tem-se:
  - $Y_t = \beta_{11} Y_1 + \beta_{22} Y_2 + \varepsilon_t \Rightarrow \phi_{22} = \beta_{22}$

	Coeficientes
Interseção	8,124100851
Variável X 1	0,675287157
Variável X 2	0,089988033

- FACP: $\hat{\phi}_{22} = +0{,}0900$

Série Temporal Estacionária

Autocorrelação AMOSTRAL

- Seja ***k* = 3**. Então, tem-se:
  - $Y_t = \beta_{11} Y_1 + \beta_{22} Y_2 + \beta_{33} Y_3 + \varepsilon_t \Rightarrow \phi_{33} = \beta_{33}$

	Coeficientes
Interseção	10,27558134
Variável X 1	0,686665763
Variável X 2	0,173315985
Variável X 3	-0,155689755

- FACP: $\hat{\phi}_{33} = -0{,}1557$

Série Temporal Estacionária

Autocorrelação AMOSTRAL

- Seja ***k* = 4**. Então, tem-se:
  - $Y_t = \beta_{11}Y_1 + \beta_{22}Y_2 + \beta_{33}Y_3 + \beta_{44}Y_4 + \varepsilon_t \Rightarrow \phi_{44} = \beta_{44}$

	Coeficientes
Interseção	8,76928185
Variável X 1	0,734756646
Variável X 2	0,143967314
Variável X 3	-0,13986872
Variável X 4	0,007503043

- FACP: $\hat{\phi}_{44} = +0,0075$

Série Temporal Estacionária

Autocorrelação AMOSTRAL

- Seja ***k* = 5**. Então, tem-se:
  - $Y_t = \beta_{11}Y_1 + \beta_{22}Y_2 + \beta_{33}Y_3 + \beta_{44}Y_4 + \beta_{55}Y_5 + \varepsilon_t \Rightarrow \phi_{55} = \beta_{55}$

	Coeficientes
Interseção	8,566472607
Variável X 1	0,773497802
Variável X 2	0,096649607
Variável X 3	-0,142437957
Variável X 4	-0,076701323
Variável X 5	0,102328098

- FACP: $\hat{\phi}_{44} = +0{,}1023$

FACP

Intervalo de Confiança Bilateral

H_0: $\phi_{kk} = 0$: **NÃO** associação

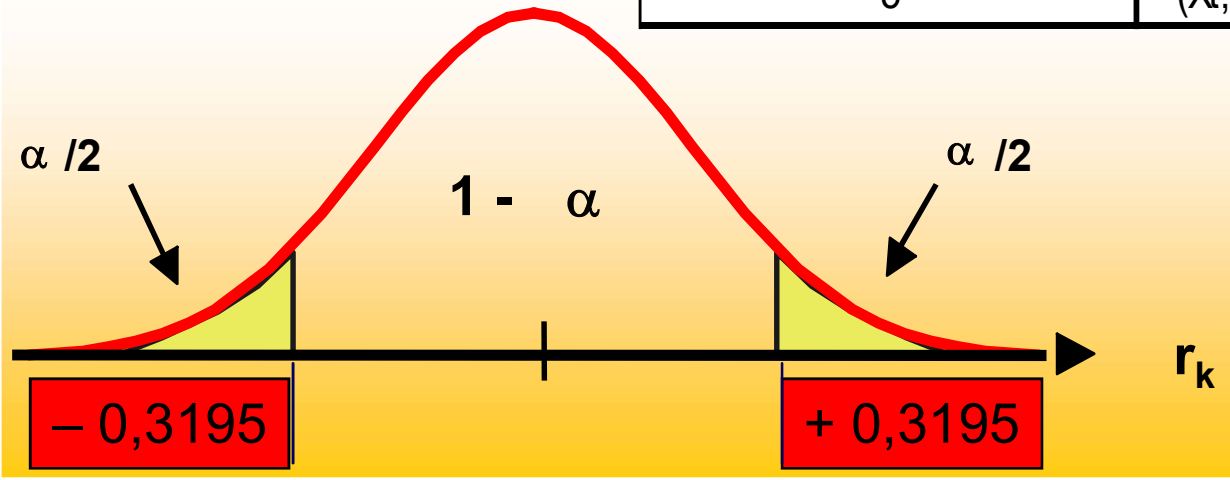
H_1: $\phi_{kk} \neq 0$: associação

$\alpha = 5\%$, n = 40

gl = n – 2 = 38

$t^{tabelado} = 2{,}021$

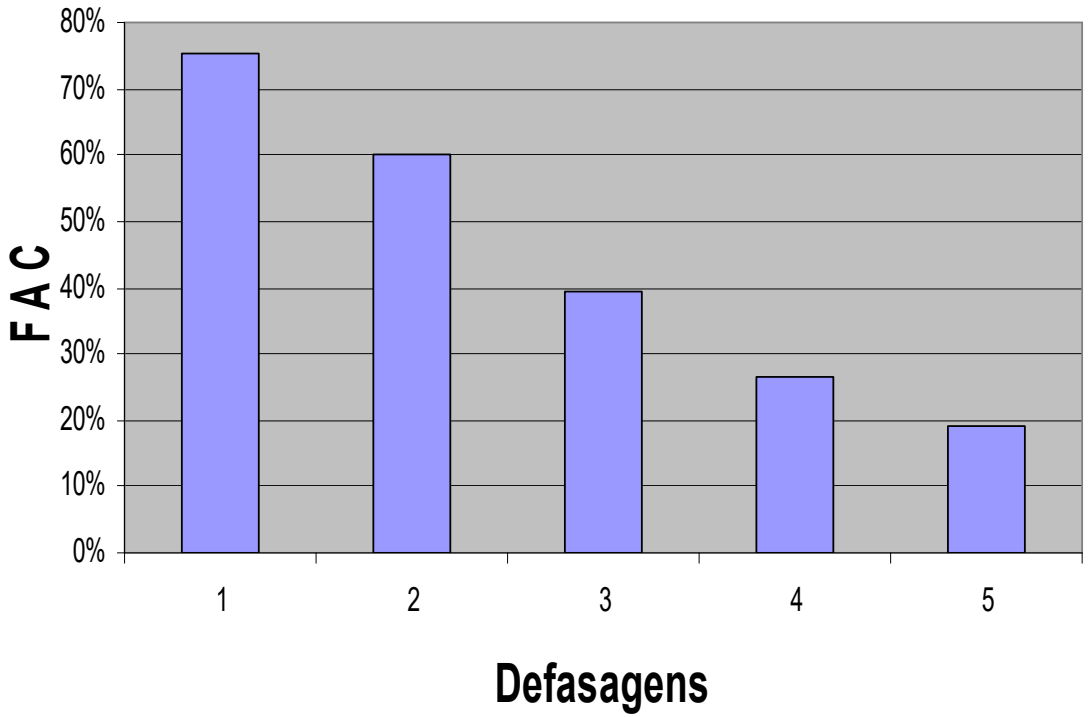
Defasagens (k)	Séries Temporais	FACP (Xt; Xt-k)	Rejeita H_0	
1	(Xt; Xt-1)	0,7450	1	SIM
2	(Xt; Xt-2)	0,0900	0	NÃO
3	(Xt; Xt-3)	-0,1557	0	NÃO
4	(Xt; Xt-4)	0,0075	0	NÃO
5	(Xt; Xt-5)	0,1023	0	NÃO



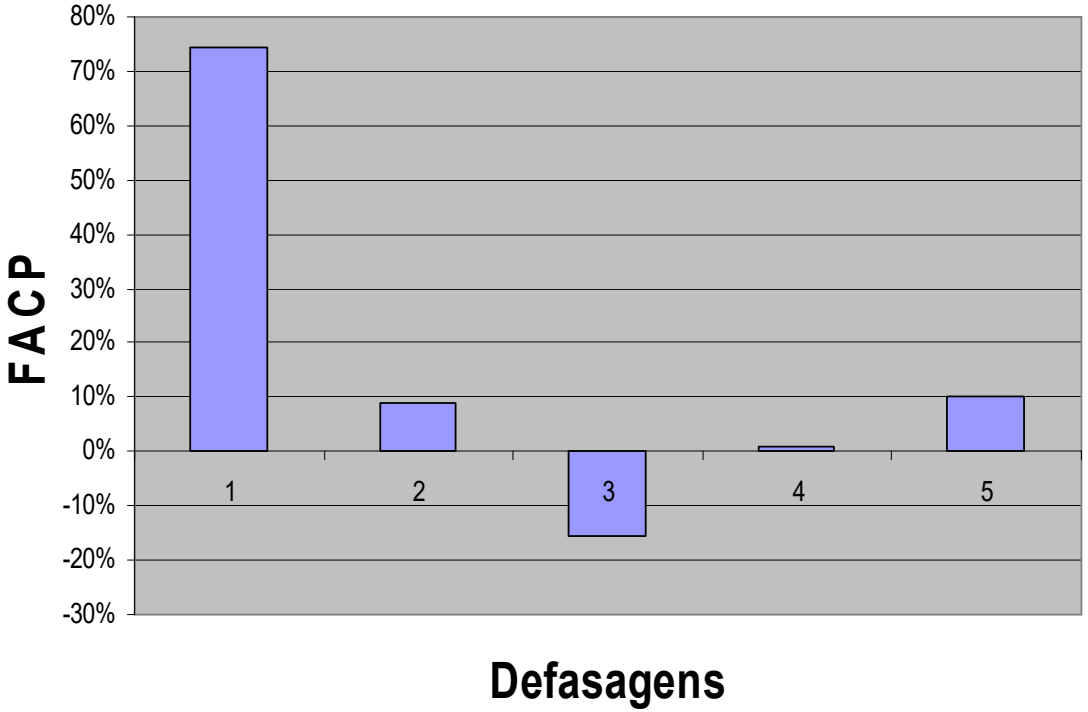
FAC & FACP

AR(1): $X_t = \xi + \phi_1 X_{t-1} + \varepsilon_t$

FAC decai GRADUALMENTE



FACP possui 1a. defasagem SIGNIFICATIVAMENTE diferente de zero



Identificação

Evolução da Dívida Pública

Então, temos um AR(1), pois:

i) FAC declinante e

ii) FACP truncada em 1: a queda de ϕ_1 para ϕ_2 é abrupta e todos os valores a partir de ϕ_2 ficam bem abaixo do valor crítico.

Modelos de Média Móvel
MA(q)

Modelos de Média Móvel

1a. Ordem: MA(1)

$$x_t = \mu + \varepsilon_t - \theta_1 \varepsilon_{t-1}$$

Valor de *X* no instante *t* depende de:

- μ: média.
- ε_t: erro aleatório no instante *t*: $\varepsilon_t = x_t - E(x_t)$.
- θ_1: parâmetro vinculado à 1a. defasagem de *X*.

Processo estacionário por NATUREZA.
Função linear de variáveis aleatórias independentes ou NÃO correlacionadas

Modelo AR(1) - Parâmetros

Média: $E(x_t) = \frac{\xi}{(1-\phi_1)} = \mu$

Variância: $Var(x_t) = \frac{\sigma^2}{[1-(\phi_1)^2]}$

Covariância: $Cov(x_t; x_{t-s}) = \frac{[\sigma^2 \times (\phi_1)^s]}{[1-(\phi_1)^2]} = \gamma_s$

Condição de Estacionariedade: $|\phi_1| < 1$

Modelos de Média Móvel

2a. Ordem: MA(2)

$$x_t = \mu + \varepsilon_t - \theta_1 \varepsilon_{t-1} - \theta_2 \varepsilon_{t-2}$$

Processo estacionário por NATUREZA.
Função linear de variáveis aleatórias independentes ou NÃO correlacionadas

Modelo AR(1) - Parâmetros

Média: $E(x_t) = \frac{\xi}{(1-\phi_1)} = \mu$

Variância: $Var(x_t) = \frac{\sigma^2}{[1-(\phi_1)^2]}$

Covariância: $Cov(x_t; x_{t-s}) = \frac{[\sigma^2 \times (\phi_1)^s]}{[1-(\phi_1)^2]} = \gamma_s$

Condição de Estacionariedade: $|\phi_1| < 1$

Modelos de Média Móvel

Ordem “q”: MA(q)

$$x_t = \mu + \varepsilon_t - \theta_1 \varepsilon_{t-1} - \theta_2 \varepsilon_{t-2} - \ldots - \theta_q \varepsilon_{t-q}$$

Processo estacionário por NATUREZA.
Função linear de variáveis aleatórias independentes ou NÃO correlacionadas

Modelo AR(1) - Parâmetros

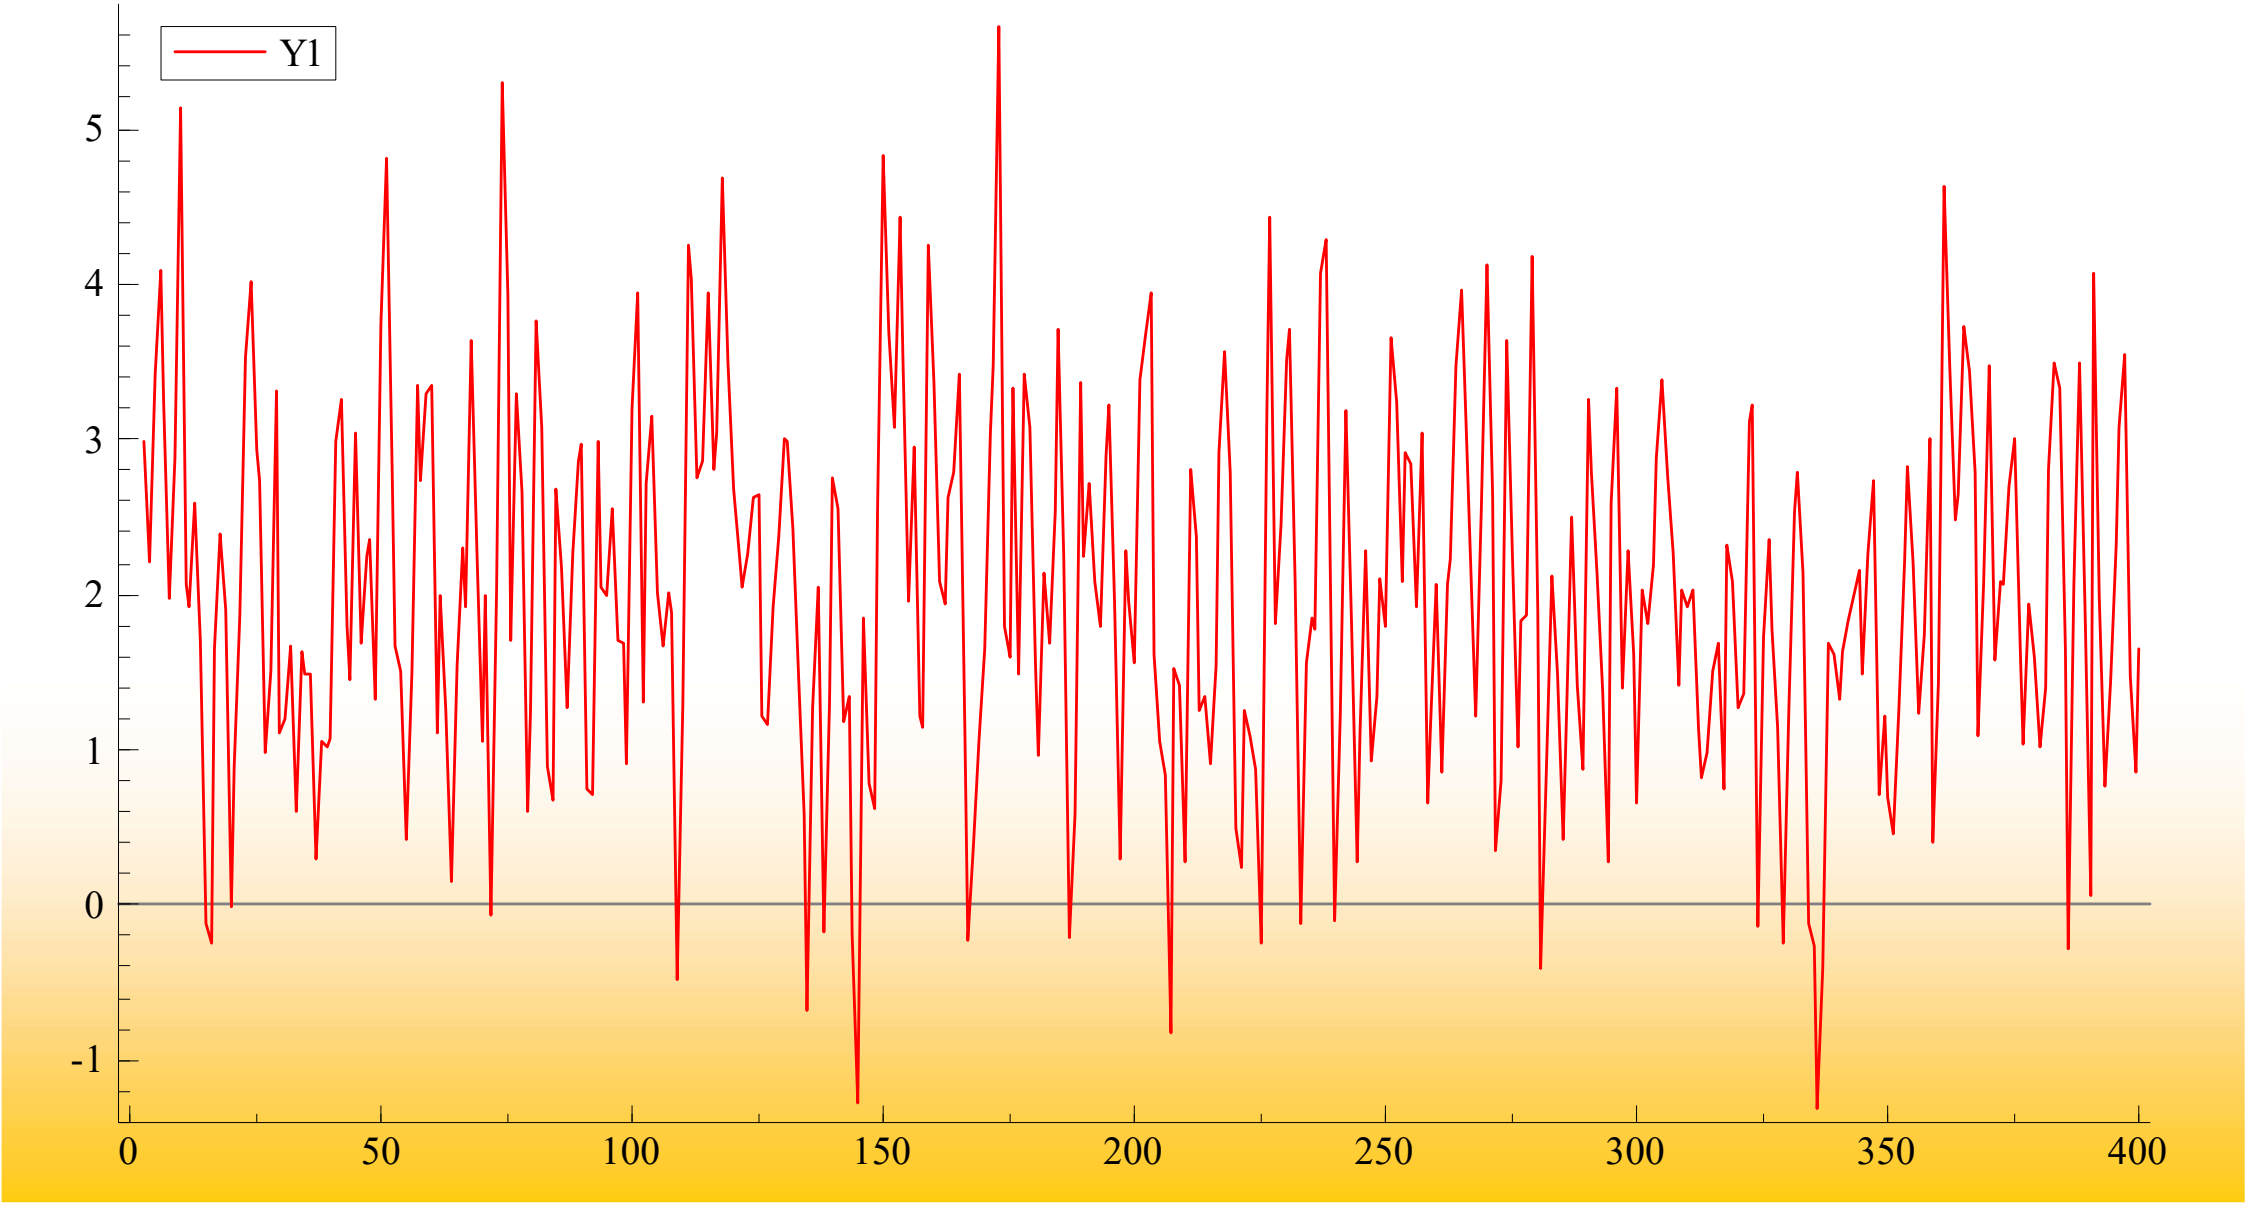
Média: $E(x_t) = \frac{\xi}{(1-\phi_1)} = \mu$

Variância: $Var(x_t) = \frac{\sigma^2}{[1-(\phi_1)^2]}$

Covariância: $Cov(x_t; x_{t-s}) = \frac{[\sigma^2 \times (\phi_1)^s]}{[1-(\phi_1)^2]} = \gamma_s$

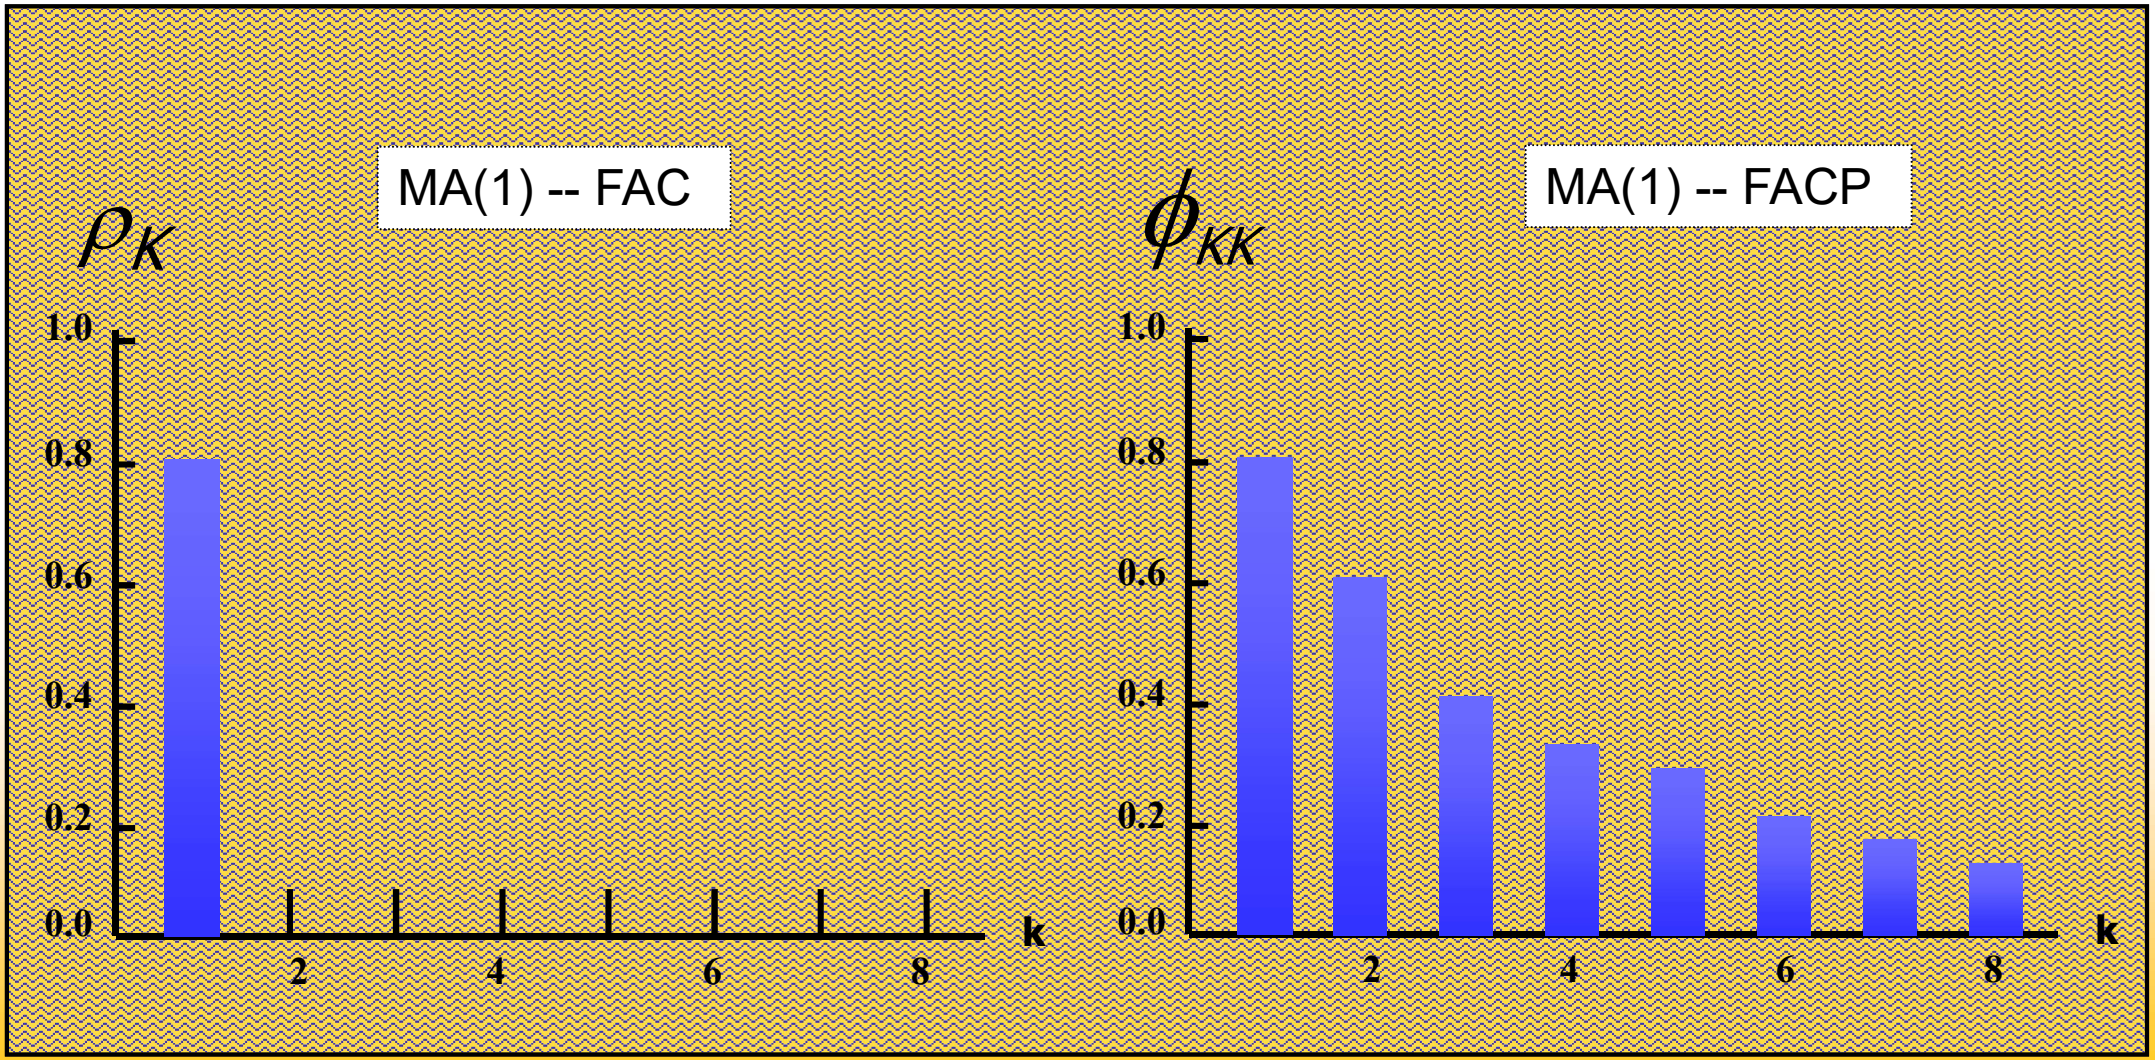
Condição de Estacionariedade: $|\phi_1| < 1$

Modelos de Média Móvel



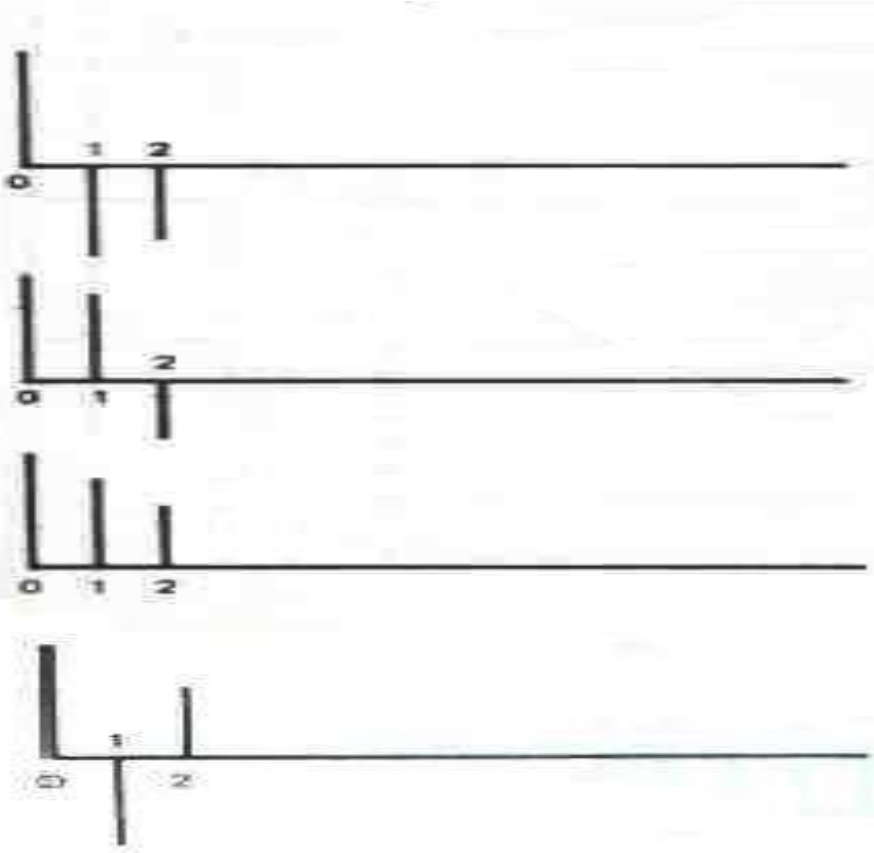
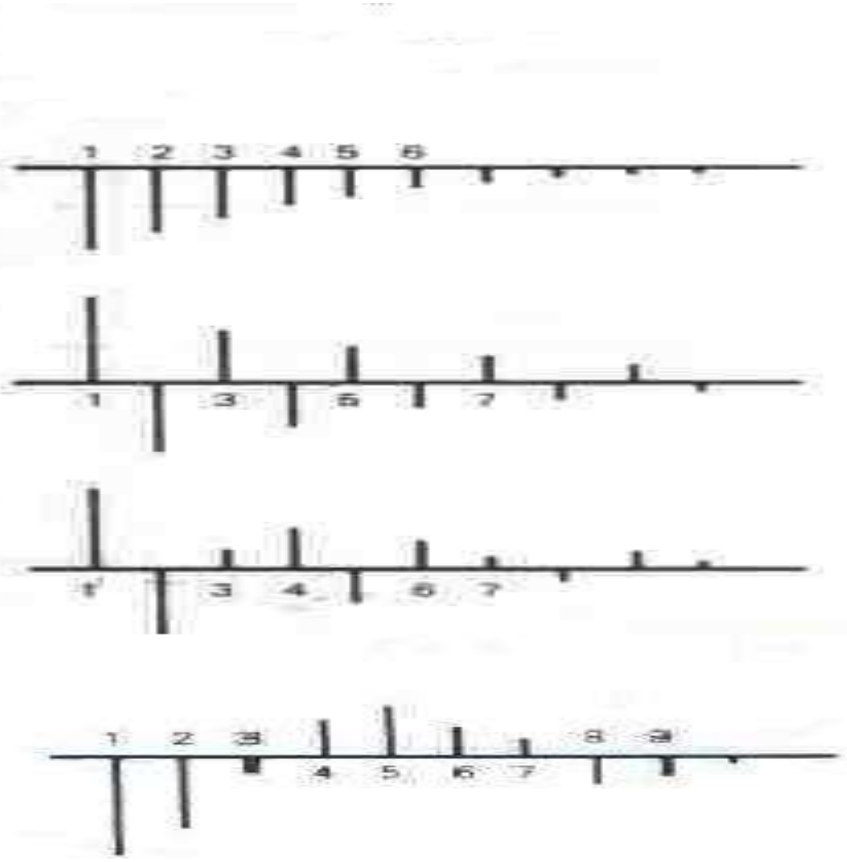
FAC & FACP

MA(1): $x_t = \mu + \varepsilon_t - \theta_1 \varepsilon_{t-1}$



FAC & FACP

MA(2): $x_t = \mu + \varepsilon_t - \theta_1 \varepsilon_{t-1} - \theta_2 \varepsilon_{t-2}$

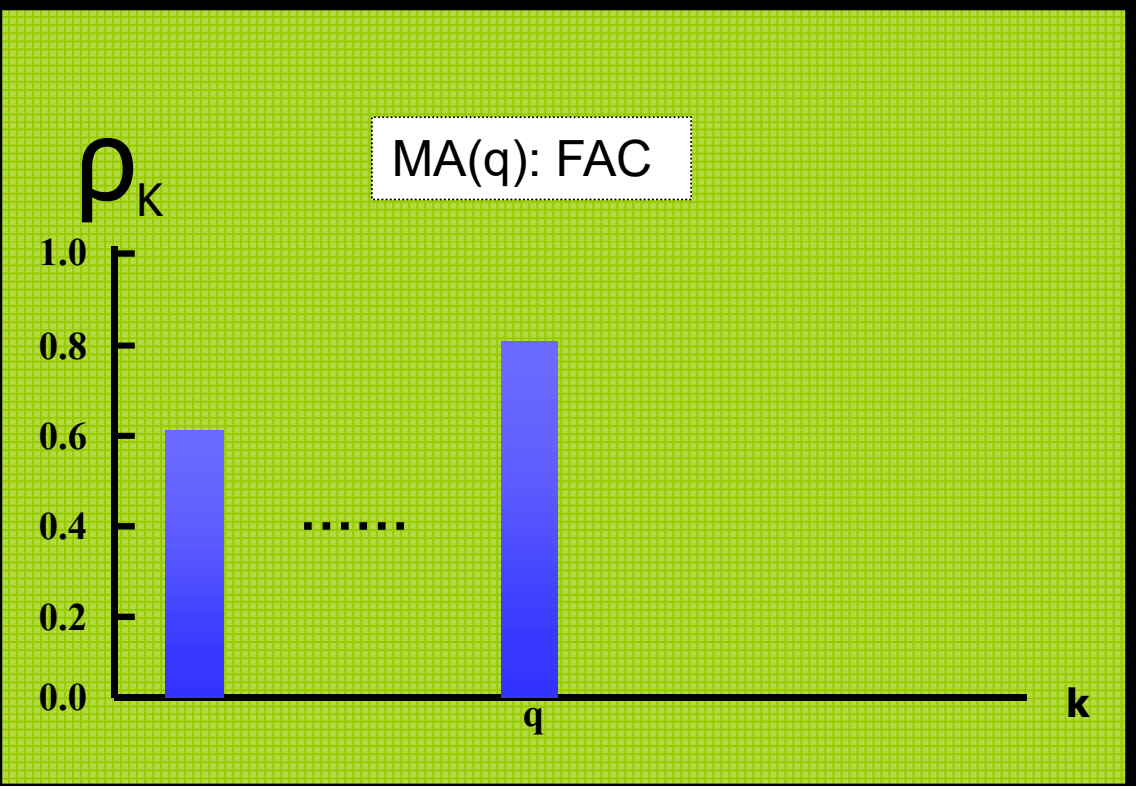
FAC	FACP
	

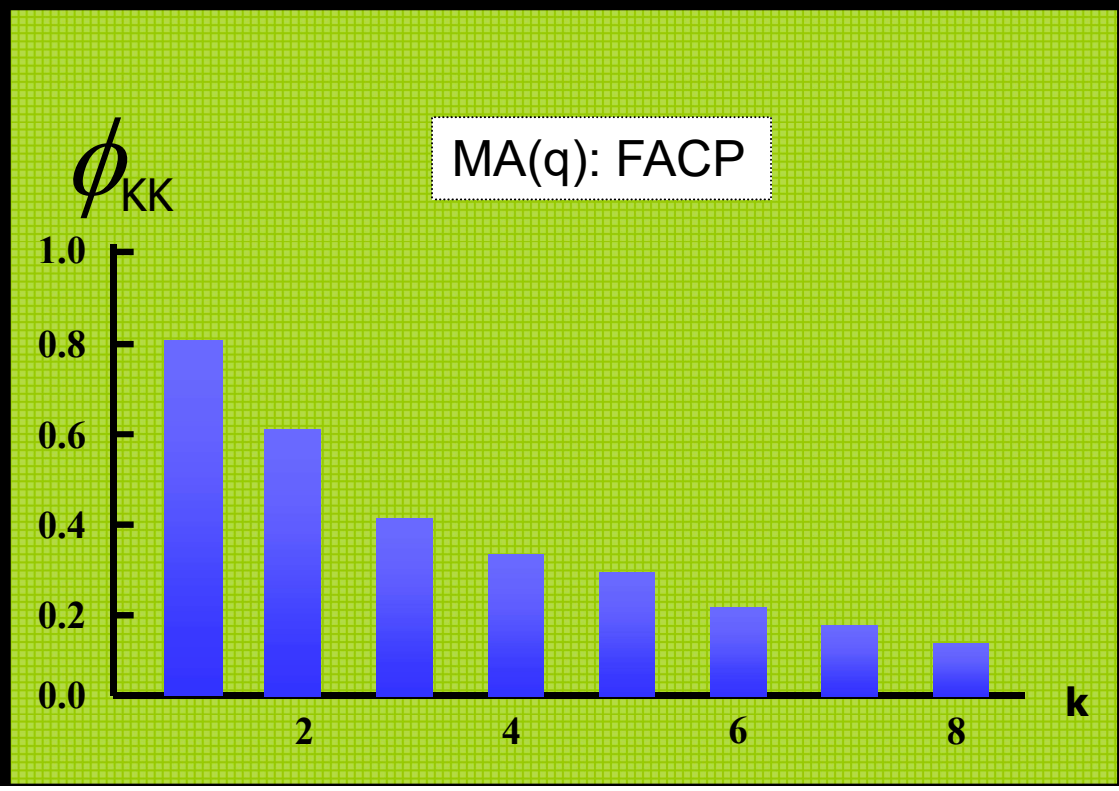
FAC & FACP

MA(q): $x_t = \mu + \varepsilon_t - \theta_1 \varepsilon_{t-1} - \theta_2 \varepsilon_{t-2} - \ldots - \theta_q \varepsilon_{t-q}$

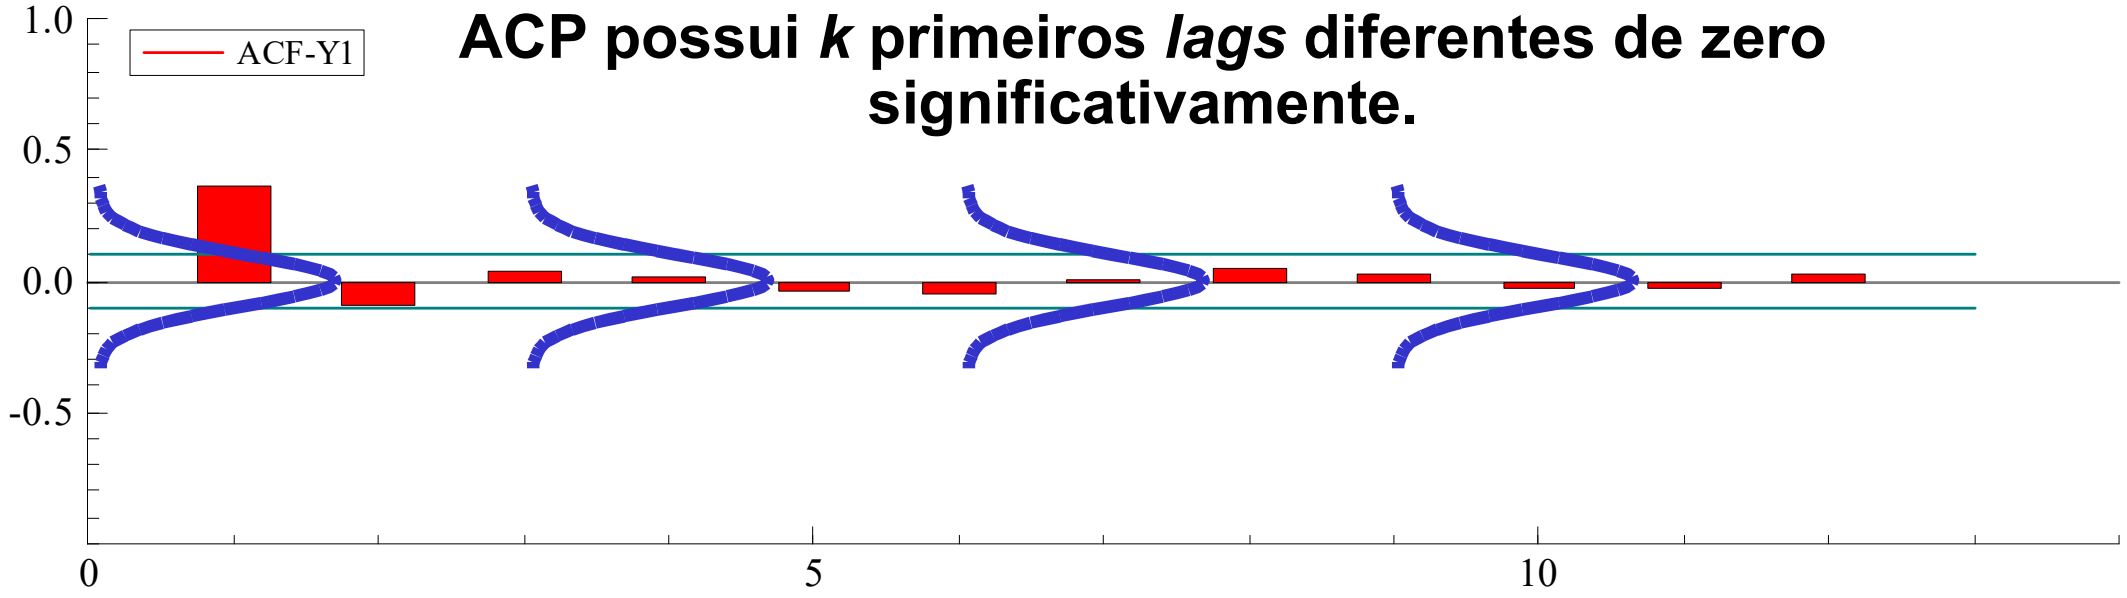
FAC possui *k* primeiros *lags* SIGNIFICATIVAMENTE diferentes de zero

FACP decai GRADUALMENTE

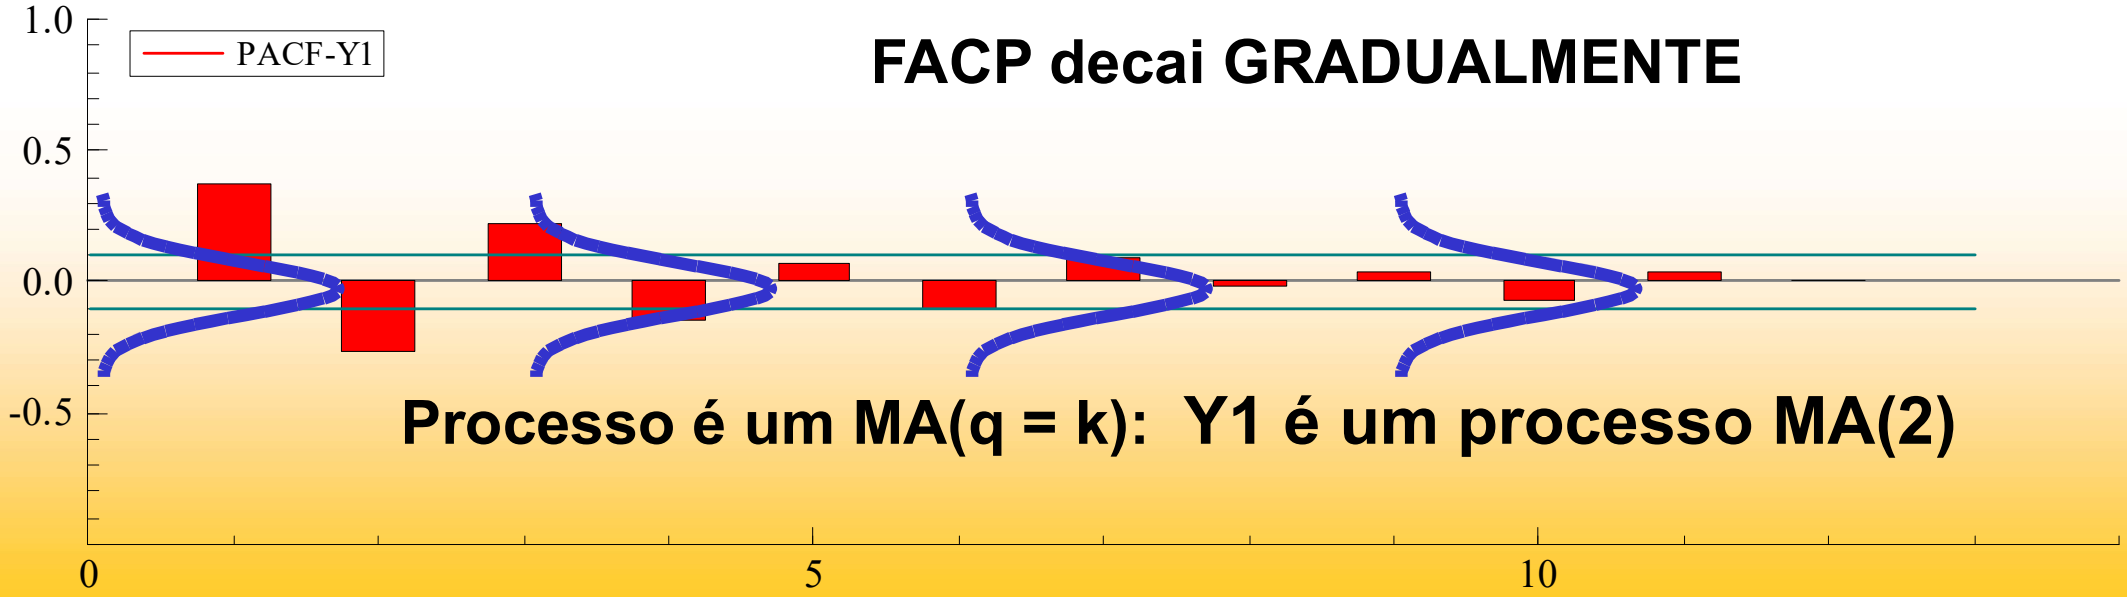




Modelos de Média Móvel



ACP possui *k* primeiros *lags* diferentes de zero significativamente.



FACP decai GRADUALMENTE

Processo é um MA(q = k): Y1 é um processo MA(2)

Modelos de Média Móvel

Evolução do Produto Interno Bruto

Considere os dados amostrais sobre a evolução do PIB de determinado país durante 40 anos.

Identifique a natureza do processo, usando correlogramas de:

i) Função de Autocorrelação (FAC) e

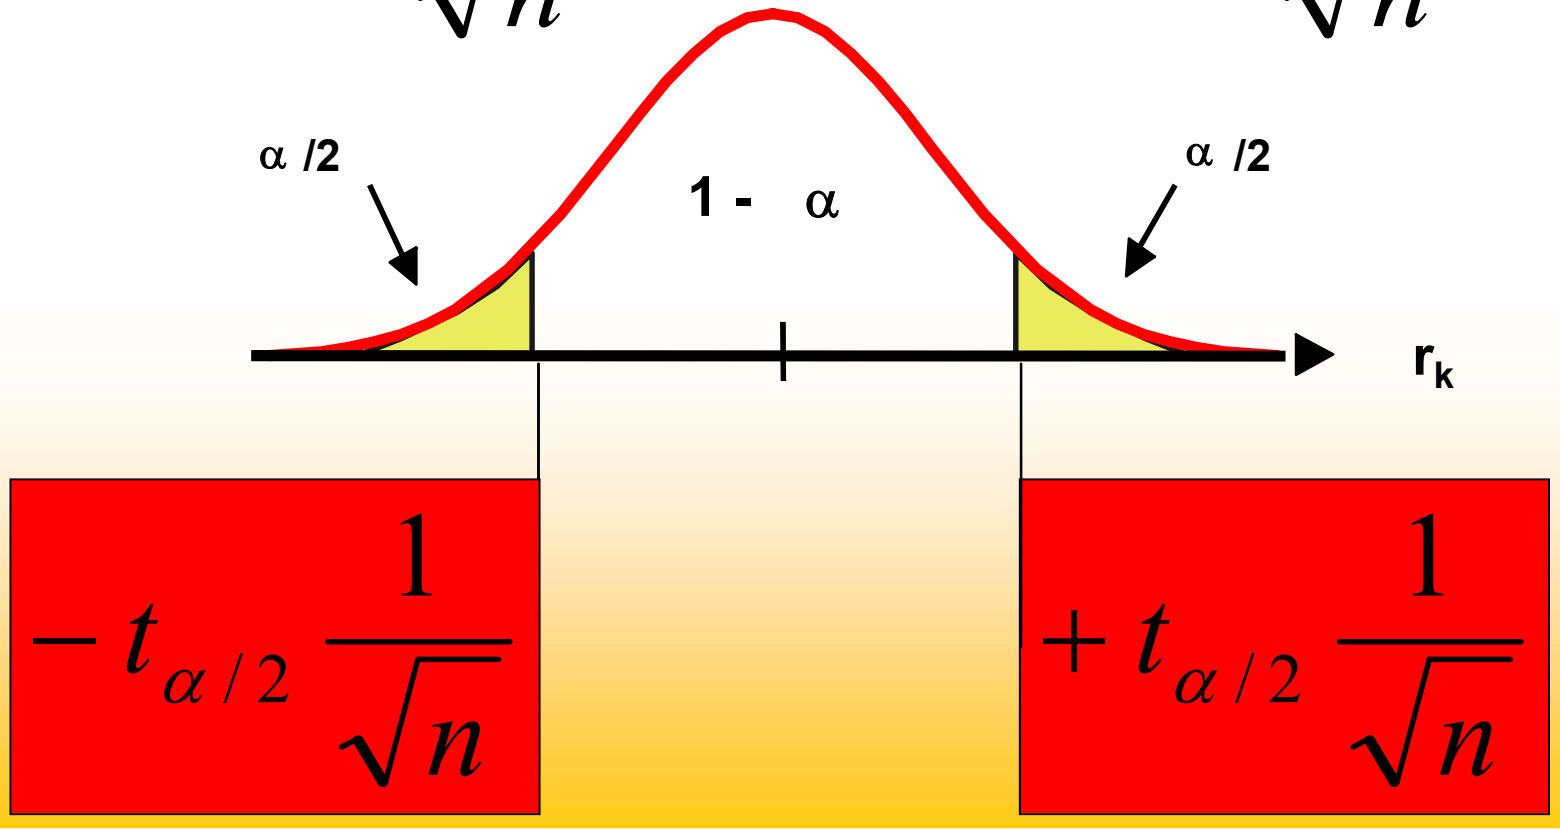
ii) Função de Autocorrelação Parcial (FACP).

Ano	PIB - Xt % anual	PIB - Xt-1 % anual	PIB - Xt-2 % anual	PIB - Xt-3 % anual	PIB - Xt-4 % anual	PIB - Xt-5 % anual
1966	3,80					
1967	2,90	3,80				
1968	3,30	2,90	3,800			
1969	0,40	3,30	2,900	3,800		
1970	0,40	0,40	3,300	2,900	3,800	
1971	3,10	0,40	0,400	3,300	2,900	3,800
1972	5,40	3,10	0,400	0,400	3,300	2,900
1973	0,80	5,40	3,100	0,400	0,400	3,300
1974	(0,70)	0,80	5,400	3,100	0,400	0,400
1975	(0,60)	(0,70)	0,800	5,400	3,100	0,400
1976	(1,30)	(0,60)	(0,700)	0,800	5,400	3,100
1977	(1,10)	(1,30)	(0,600)	(0,700)	0,800	5,400
1978	0,80	(1,10)	(1,300)	(0,600)	(0,700)	0,800
1979	4,30	0,80	(1,100)	(1,300)	(0,600)	(0,700)
1980	4,10	4,30	0,800	(1,100)	(1,300)	(0,600)
1981	(0,50)	4,10	4,300	0,800	(1,100)	(1,300)
1982	(0,10)	(0,50)	4,100	4,300	0,800	(1,100)
1983	1,10	(0,10)	(0,500)	4,100	4,300	0,800
1984	(1,00)	1,10	(0,100)	(0,500)	4,100	4,300
1985	2,50	(1,00)	1,100	(0,100)	(0,500)	4,100
1986	2,00	2,50	(1,000)	1,100	(0,100)	(0,500)
1987	1,30	2,00	2,500	(1,000)	1,100	(0,100)
1988	2,80	1,30	2,000	2,500	(1,000)	1,100
1989	4,60	2,80	1,300	2,000	2,500	(1,000)
1990	4,00	4,60	2,800	1,300	2,000	2,500
1991	2,50	4,00	4,600	2,800	1,300	2,000
1992	1,90	2,50	4,000	4,600	2,800	1,300
1993	1,20	1,90	2,500	4,000	4,600	2,800
1994	(1,10)	1,20	1,900	2,500	4,000	4,600
1995	(1,60)	(1,10)	1,200	1,900	2,500	4,000
1996	3,30	(1,60)	(1,100)	1,200	1,900	2,500
1997	0,70	3,30	(1,600)	(1,100)	1,200	1,900
1998	0,20	0,70	3,300	(1,600)	(1,100)	1,200
1999	4,30	0,20	0,700	3,300	(1,600)	(1,100)
2000	4,70	4,30	0,200	0,700	3,300	(1,600)
2001	3,80	4,70	4,300	0,200	0,700	3,300
2002	4,60	3,80	4,700	4,300	0,200	0,700
2003	3,30	4,60	3,800	4,700	4,300	0,200
2004	4,50	3,30	4,600	3,800	4,700	4,300
2005	3,00	4,50	3,300	4,600	3,800	4,700
SOMA	77,60	74,60	70,10	66,80	62,20	58,40

Teste para Correlação

Intervalo de Confiança Bilateral

$$\left[-t_{\alpha/2}\frac{1}{\sqrt{n}} < \rho_k < +t_{\alpha/2}\frac{1}{\sqrt{n}}\right]$$

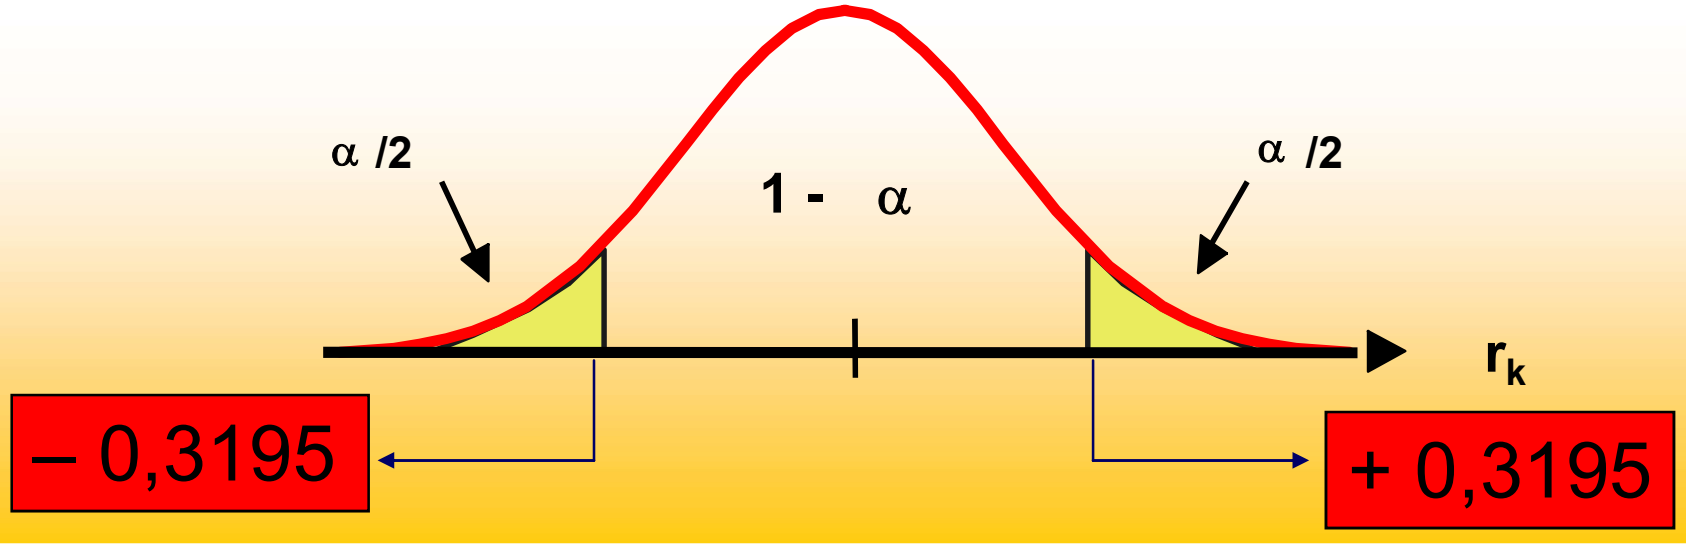


Teste para Correlação

Intervalo de Confiança Bilateral

$\alpha = 5\%$, n = 40 e gl = 38 $\rightarrow$ $t^{tabelado} = 2{,}021$

$$[-2{,}021 \frac{1}{\sqrt{40}} < \rho_k < +2{,}021 \frac{1}{\sqrt{40}}]$$



Série Temporal Estacionária

Autocorrelação AMOSTRAL

❖Seja ***k* = 0**. Então, $r_0 = 1$, conforme abaixo:

$$r_0 = \hat{\rho}_0 = \frac{\hat{\gamma}_0}{\hat{\gamma}_0} = \frac{\sum_{t=1}^{n-0}\left(X_t - \overline{X}\right)\left(X_{t-0} - \overline{X}\right)}{\sum_{t=1}^{n}\left(X_t - \overline{X}\right)^2} = \frac{\sum_{t=1}^{n}\left(X_t - \overline{X}\right)\left(X_t - \overline{X}\right)}{\sum_{t=1}^{n}\left(X_t - \overline{X}\right)^2} = \frac{\text{cov}(X_t; X_{t-0})}{\text{var}(X_t)}$$

$$r_0 = \hat{\rho}_0 = \frac{\hat{\gamma}_0}{\hat{\gamma}_0} = \frac{\sum_{t=1}^{n}\left(X_t - \overline{X}\right)^2}{\sum_{t=1}^{n}\left(X_t - \overline{X}\right)^2} = \frac{\text{cov}(X_t; X_{t-0})}{\text{var}(X_t)} = \frac{\text{var}(X_t)}{\text{var}(X_t)} = \frac{4{,}2266}{4{,}2266} = 1$$

Série Temporal Estacionária

Autocorrelação AMOSTRAL

- Seja ***k* = 1**. Então, tem-se:

$$r_1 = \hat{\rho}_1 = \frac{\hat{\gamma}_1}{\hat{\gamma}_0} = \frac{\sum_{t=1}^{n-1}\left(X_t - \overline{X}\right)\left(X_{t-1} - \overline{X}\right)}{\sum_{t=1}^{n}\left(X_t - \overline{X}\right)^2} = \frac{\text{cov}(X_t; X_{t-1})}{\text{var}(X_t)} = \frac{2{,}0743}{4{,}2266} = 0{,}4908$$

- Observe que $\hat{\gamma}_0$ INDEPENDE do valor de k.
  - $\hat{\gamma}_0$ é uma CONSTANTE.

$$\hat{\gamma}_0 = \sum_{t=1}^{n}\left(X_t - \overline{X}\right)^2 = Cons\,\text{tan}\,te$$

Série Temporal Estacionária

Autocorrelação AMOSTRAL

- Seja ***k* = 2**. Então, tem-se:

$$r_2 = \hat{\rho}_2 = \frac{\hat{\gamma}_2}{\hat{\gamma}_0} = \frac{\sum_{t=1}^{n-2}(X_t - \overline{X})(X_{t-2} - \overline{X})}{\sum_{t=1}^{n}(X_t - \overline{X})^2} = \frac{\text{cov}(X_t; X_{t-2})}{\text{var}(X_t)} = \frac{0{,}2204}{4{,}2266} = 0{,}0522$$

- Observe que $\hat{\gamma}_0$ INDEPENDE do valor de k.
  - $\hat{\gamma}_0$ é uma CONSTANTE.

$$\hat{\gamma}_0 = \sum_{t=1}^{n}(X_t - \overline{X})^2 = Cons\,\text{tan}\,te$$

Série Temporal Estacionária

Autocorrelação AMOSTRAL

- Seja ***k* = 3**. Então, tem-se:

$$r_3 = \hat{\rho}_3 = \frac{\hat{\gamma}_3}{\hat{\gamma}_0} = \frac{\sum_{t=1}^{n-3}\left(X_t - \overline{X}\right)\left(X_{t-3} - \overline{X}\right)}{\sum_{t=1}^{n}\left(X_t - \overline{X}\right)^2} = \frac{\text{cov}(X_t; X_{t-3})}{\text{var}(X_t)} = \frac{0{,}1611}{4{,}2266} = 0{,}0381$$

- Observe que $\hat{\gamma}_0$ INDEPENDE do valor de k.
  - $\hat{\gamma}_0$ é uma CONSTANTE.

$$\hat{\gamma}_0 = \sum_{t=1}^{n}\left(X_t - \overline{X}\right)^2 = Cons\,\text{tan}\,te$$

Série Temporal Estacionária

Autocorrelação AMOSTRAL

- Seja ***k* = 4**. Então, tem-se:

$$r_4 = \hat{\rho}_4 = \frac{\hat{\gamma}_4}{\hat{\gamma}_0} = \frac{\sum_{t=1}^{n-4}\left(X_t - \overline{X}\right)\left(X_{t-4} - \overline{X}\right)}{\sum_{t=1}^{n}\left(X_t - \overline{X}\right)^2} = \frac{\text{cov}(X_t; X_{t-4})}{\text{var}(X_t)} = \frac{-0{,}5288}{4{,}2266} = -0{,}1251$$

- Observe que $\hat{\gamma}_0$ INDEPENDE do valor de k.
  - $\hat{\gamma}_0$ é uma CONSTANTE.

$$\hat{\gamma}_0 = \sum_{t=1}^{n}\left(X_t - \overline{X}\right)^2 = Cons\,\text{tan}\,te$$

Série Temporal Estacionária

Autocorrelação AMOSTRAL

- Seja ***k* = 5**. Então, tem-se:

$$r_5 = \hat{\rho}_5 = \frac{\hat{\gamma}_5}{\hat{\gamma}_0} = \frac{\sum_{t=1}^{n-5}(X_t - \overline{X})(X_{t-5} - \overline{X})}{\sum_{t=1}^{n}(X_t - \overline{X})^2} = \frac{\text{cov}(X_t; X_{t-5})}{\text{var}(X_t)} = \frac{-1{,}1748}{4{,}2266} = -0{,}2780$$

- Observe que $\hat{\gamma}_0$ INDEPENDE do valor de k.
  - $\hat{\gamma}_0$ é uma CONSTANTE.

$$\hat{\gamma}_0 = \sum_{t=1}^{n}(X_t - \overline{X})^2 = Cons\,\text{tan}\,te$$

FAC

Intervalo de Confiança Bilateral

H_0: $\rho_k = 0$: **NÃO** associação

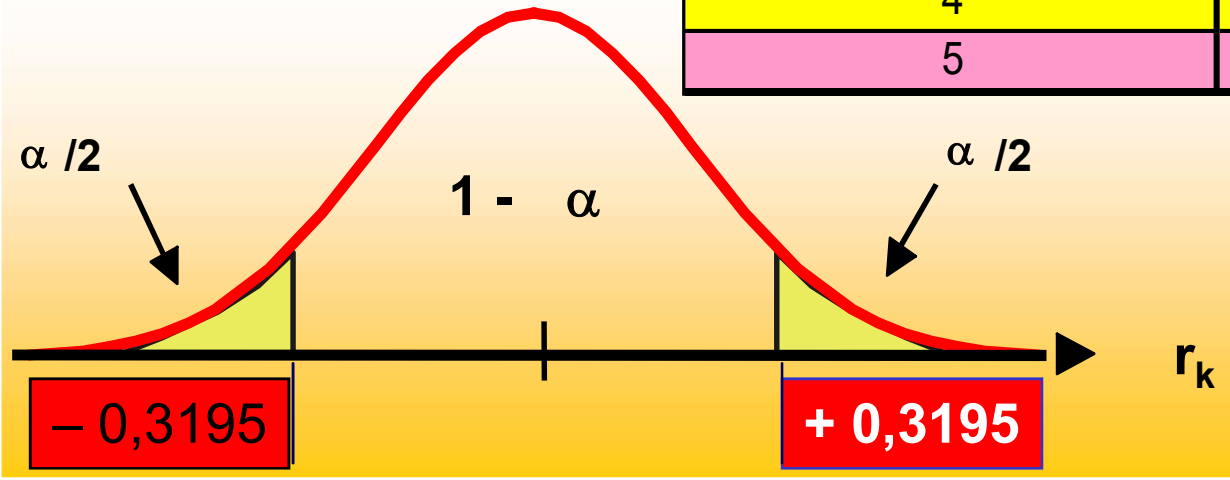
H_1: $\rho_k \neq 0$: associação

$\alpha = 5\%$, n = 40

gl = n – 2 = 38

$t^{tabelado} = 2{,}021$

Defasagens (k)	Séries Temporais	FAC (Xt; Xt-k)	Rejeita H_0	
0	(Xt; Xt-0)	1,0000	1	SIM
1	(Xt; Xt-1)	0,4908	1	SIM
2	(Xt; Xt-2)	0,0522	0	NÃO
3	(Xt; Xt-3)	0,0381	0	NÃO
4	(Xt; Xt-4)	(0,1251)	0	NÃO
5	(Xt; Xt-5)	(0,2780)	0	NÃO



Autocorrelação PARCIAL

- Mede a intensidade da relação entre duas observações da série, controlando (mantendo constante) o efeito das demais.

- Valores de $\hat{\phi}_{kk}$ são determinados pelos coeficientes de índice *kk* das regressões:
  - $Y_t = \beta_{11} Y_1 + \varepsilon_t \Rightarrow \phi_{11} = \beta_{11}$
  - $Y_t = \beta_{11} Y_1 + \beta_{22} Y_2 + \varepsilon_t \Rightarrow \phi_{22} = \beta_{22}$
  - $Y_t = \beta_{k1} Y_1 + \beta_{k2} Y_2 + \ldots + \beta_{kk} Y_k + \varepsilon_t \Rightarrow \phi_{kk} = \beta_{kk}$

- A representação grafica de $\hat{\phi}_{kk}$ contra *k* é conhecida como correlograma amostral da FACP

Série Temporal Estacionária

Autocorrelação AMOSTRAL

- Seja ***k* = 1**. Então, tem-se:
  - $Y_t = \beta_{11} Y_1 + \varepsilon_t \Rightarrow \phi_{11} = \beta_{11}$

	Coeficientes
Interseção	0,994187034
Variável X 1	0,469526886

- FACP: $\hat{\phi}_{11} = +0{,}4695$

Série Temporal Estacionária

Autocorrelação AMOSTRAL

- Seja ***k* = 2**. Então, tem-se:
  - $Y_t = \beta_{11} Y_1 + \beta_{22} Y_2 + \varepsilon_t \Rightarrow \phi_{22} = \beta_{22}$

	Coeficientes
Interseção	1,209115884
Variável X 1	0,569133521
Variável X 2	-0,218845319

- FACP: $\hat{\phi}_{22} = -0,2188$

Série Temporal Estacionária

Autocorrelação AMOSTRAL

- Seja ***k* = 3**. Então, tem-se:
  - $Y_t = \beta_{11} Y_1 + \beta_{22} Y_2 + \beta_{33} Y_3 + \varepsilon_t \Rightarrow \phi_{33} = \beta_{33}$

	Coeficientes
Interseção	1,017584604
Variável X 1	0,601577295
Variável X 2	-0,322728544
Variável X 3	0,15717326

- FACP: $\hat{\phi}_{33} = +0{,}1572$

Série Temporal Estacionária

Autocorrelação AMOSTRAL

- Seja ***k* = 4**. Então, tem-se:
  - $Y_t = \beta_{11}Y_1 + \beta_{22}Y_2 + \beta_{33}Y_3 + \beta_{44}Y_4 + \varepsilon_t \Rightarrow \phi_{44} = \beta_{44}$

	Coeficientes
Interseção	1,289160412
Variável X 1	0,672575037
Variável X 2	-0,433420118
Variável X 3	0,362738226
Variável X 4	-0,28990024

- FACP: $\hat{\phi}_{44} = -0,2899$

Série Temporal Estacionária

Autocorrelação AMOSTRAL

- Seja ***k* = 5**. Então, tem-se:
  - $Y_t = \beta_{11} Y_1 + \beta_{22} Y_2 + \beta_{33} Y_3 + \beta_{44} Y_4 + \beta_{55} Y_5 + \varepsilon_t \Rightarrow \phi_{55} = \beta_{55}$

	Coeficientes
Interseção	1,342757351
Variável X 1	0,668001068
Variável X 2	-0,428839399
Variável X 3	0,348678358
Variável X 4	-0,270432533
Variável X 5	-0,042315708

- FACP: $\hat{\phi}_{44} = -0,0423$

FACP

Intervalo de Confiança Bilateral

H_0: $\phi_{kk} = 0$: **NÃO** associação

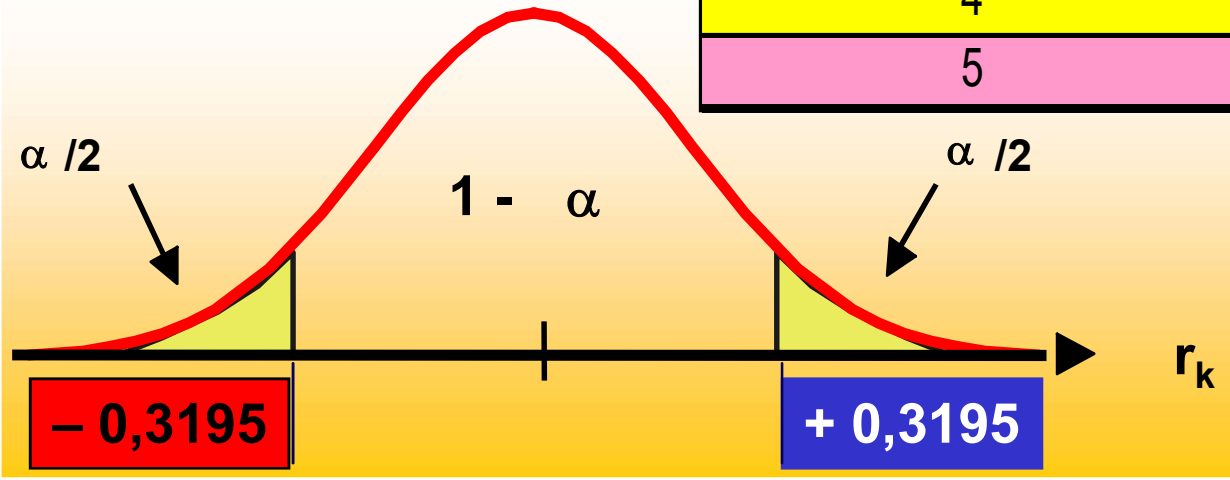
H_1: $\phi_{kk} \neq 0$: associação

$\alpha = 5\%$, n = 40

gl = n – 2 = 38

$t^{tabelado} = 2{,}021$

Defasagens (k)	Séries Temporais	FACP (Xt; Xt-k)	Rejeita H_0	
1	(Xt; Xt-1)	0,4695	1	SIM
2	(Xt; Xt-2)	-0,2188	0	NÃO
3	(Xt; Xt-3)	0,1572	0	NÃO
4	(Xt; Xt-4)	-0,2899	0	NÃO
5	(Xt; Xt-5)	-0,0423	0	NÃO

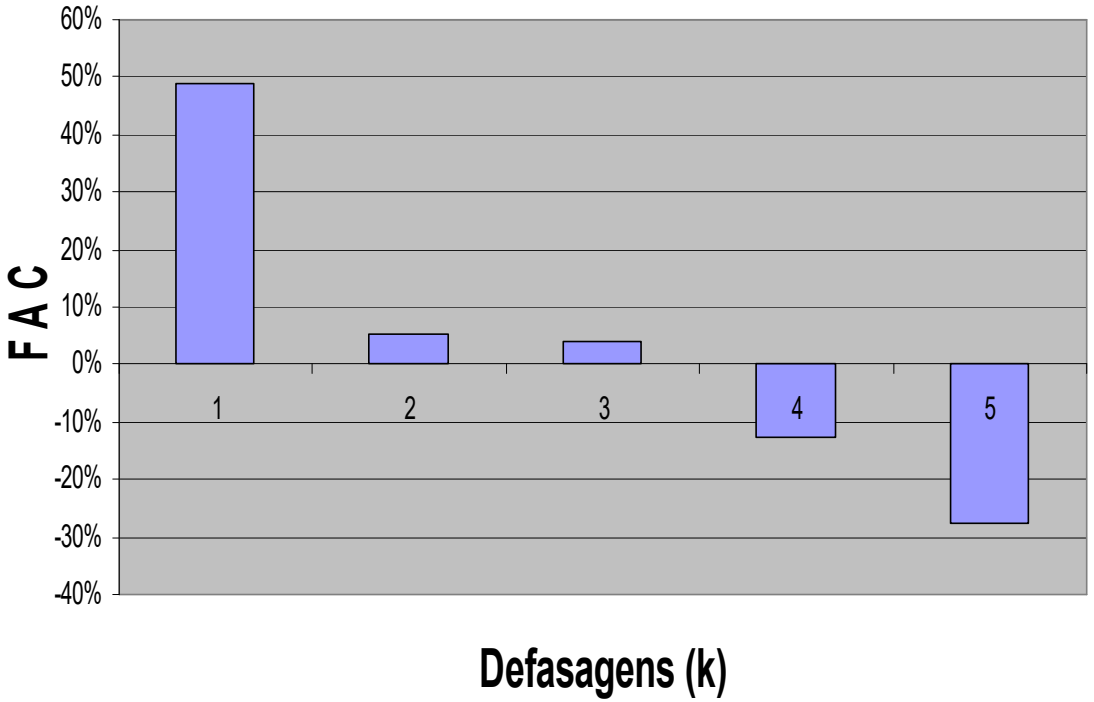


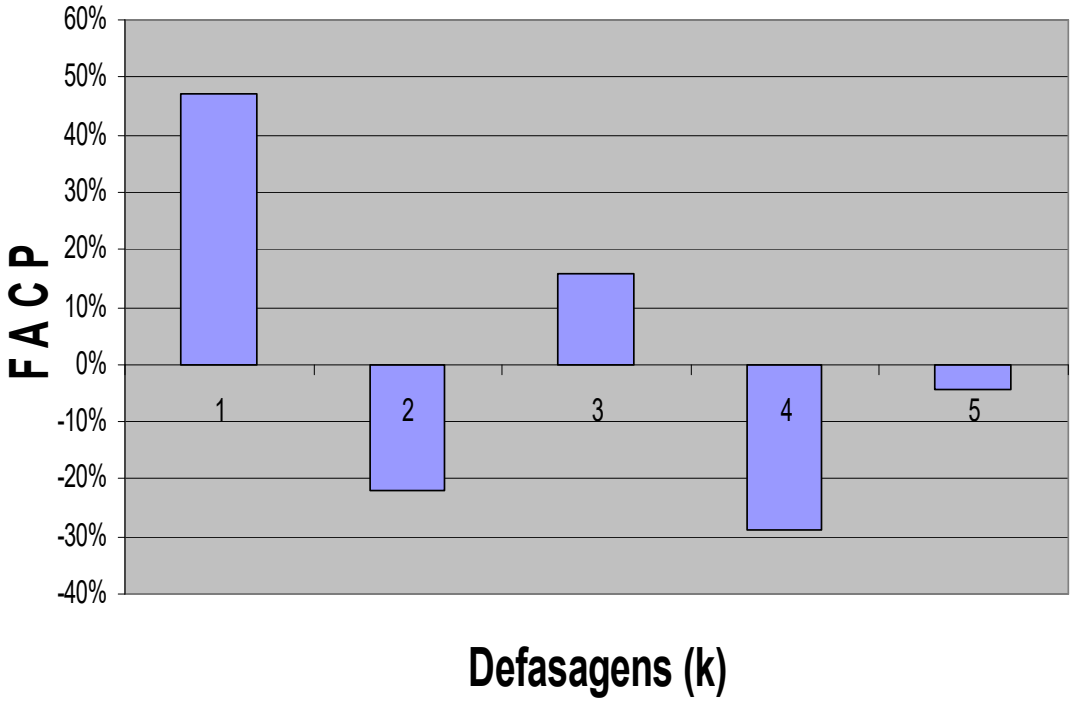
FAC & FACP

MA(1): $X_t = \mu + \varepsilon_t - \theta_1 \varepsilon_{t-1}$

FAC possui 1a. defasagem SIGNIFICATIVAMENTE diferentes de zero

FACP decai GRADUALMENTE





Identificação

Evolução do Produto Interno Bruto

Então, temos um MA(1), pois:

i) FAC truncada em 1: a queda de ϕ_1 para ϕ_2 é abrupta e todos os valores a partir de ϕ_2 ficam bem abaixo do valor crítico.

ii) FACP declinante

Modelos Autoregressivos e de Média Móvel ARMA(p,q)

Modelos ARMA

1a. Ordem: ARMA(1,1)

$$x_t = \phi_1 x_{t-1} + \xi + \varepsilon_t - \theta_1 \varepsilon_{t-1}$$

Valor de *X* no instante *t* depende de:

- ξ: tendência.
- x_{t-1}: valor observado em *X* no instante anterior.
- ϕ_1: parâmetro vinculado à 1a. defasagem de *X*.
- θ_1: parâmetro vinculado à 1a. defasagem de ε.
- ε_t: erro aleatório no instante *t:* $\varepsilon_t = x_t - E(x_t)$.

Modelos ARMA

1a. Ordem: ARMA(1,1)

$$x_t = \phi_1 x_{t-1} + \xi + \varepsilon_t - \theta_1 \varepsilon_{t-1}$$

Média: $$E(x_t) = \frac{\xi}{(1-\phi_1)} = \mu$$

Condição de Estacionariedade: $| \phi_1 | < 1$

Modelo AR(1) - Parâmetros

Média: $E(x_t) = \frac{\xi}{(1-\phi_1)} = \mu$

Variância: $Var(x_t) = \frac{\sigma^2}{[1-(\phi_1)^2]}$

Covariância: $Cov(x_t; x_{t-s}) = \frac{[\sigma^2 \times (\phi_1)^s]}{[1-(\phi_1)^2]} = \gamma_s$

Condição de Estacionariedade: $|\phi_1| < 1$

Modelos ARMA

2a. Ordem: ARMA(2,2)

$$x_t = \phi_1 x_{t-1} + \phi_2 x_{t-2} + \xi + \varepsilon_t - \theta_1 \varepsilon_{t-1} - \theta_2 \varepsilon_{t-2}$$

Média: $E(x_t) = \dfrac{\xi}{(1 - \phi_1 - \phi_2)} = \mu$

Condição de Estacionariedade: $\phi_1 + \phi_2 < 1$

Modelo AR(1) - Parâmetros

Média: $E(x_t) = \frac{\xi}{(1-\phi_1)} = \mu$

Variância: $Var(x_t) = \frac{\sigma^2}{[1-(\phi_1)^2]}$

Covariância: $Cov(x_t; x_{t-s}) = \frac{[\sigma^2 \times (\phi_1)^s]}{[1-(\phi_1)^2]} = \gamma_s$

Condição de Estacionariedade: $|\phi_1| < 1$

Modelos ARMA

Ordem “p,q”: ARMA(p,q)

$$x_t = \phi_1 x_{t-1} + \ldots + \phi_p x_{t-p} + \xi + \varepsilon_t - \theta_1 \varepsilon_{t-1} - \ldots - \theta_p \varepsilon_{t-p}$$

Média: $$E(x_t) = \frac{\xi}{(1 - \phi_1 - \phi_2 - \ldots - \phi_p)} = \mu$$

Condição Estacionariedade: $\phi_1 + \phi_2 + \ldots + \phi_p < 1$

Modelo AR(1) - Parâmetros

Média: $E(x_t) = \frac{\xi}{(1-\phi_1)} = \mu$

Variância: $Var(x_t) = \frac{\sigma^2}{[1-(\phi_1)^2]}$

Covariância: $Cov(x_t; x_{t-s}) = \frac{[\sigma^2 \times (\phi_1)^s]}{[1-(\phi_1)^2]} = \gamma_s$

Condição de Estacionariedade: $|\phi_1| < 1$

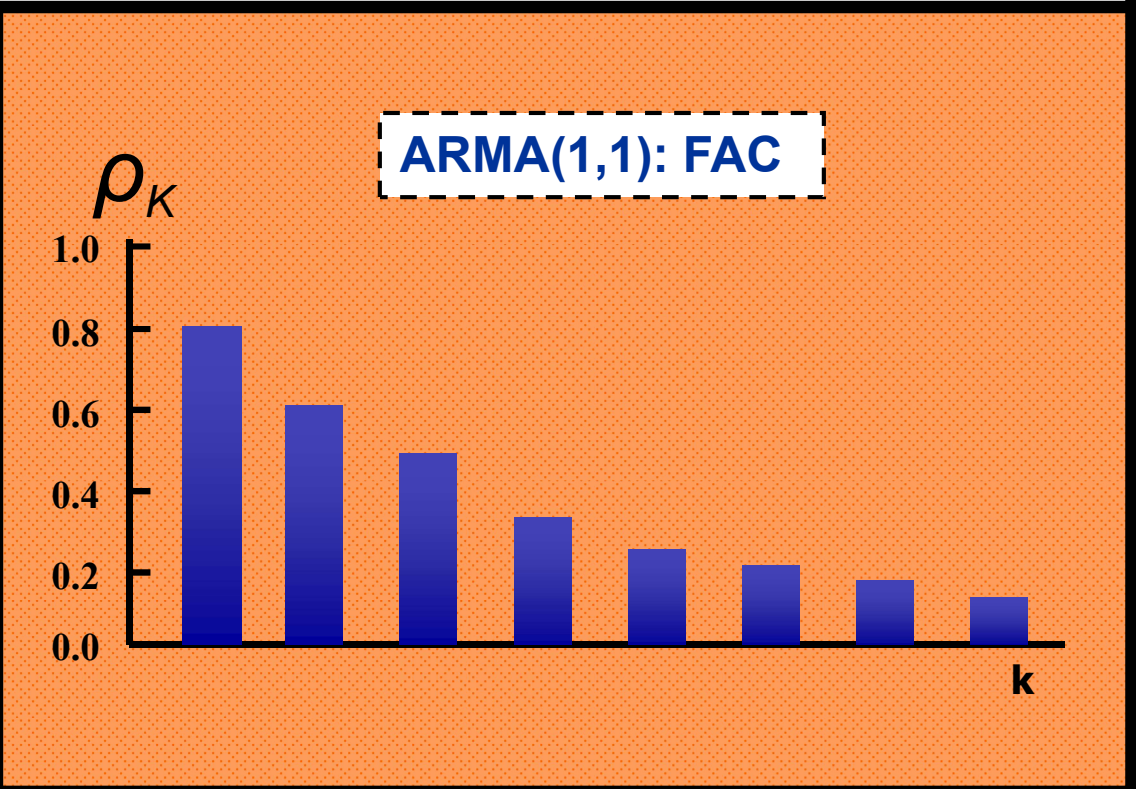
FAC & FACP

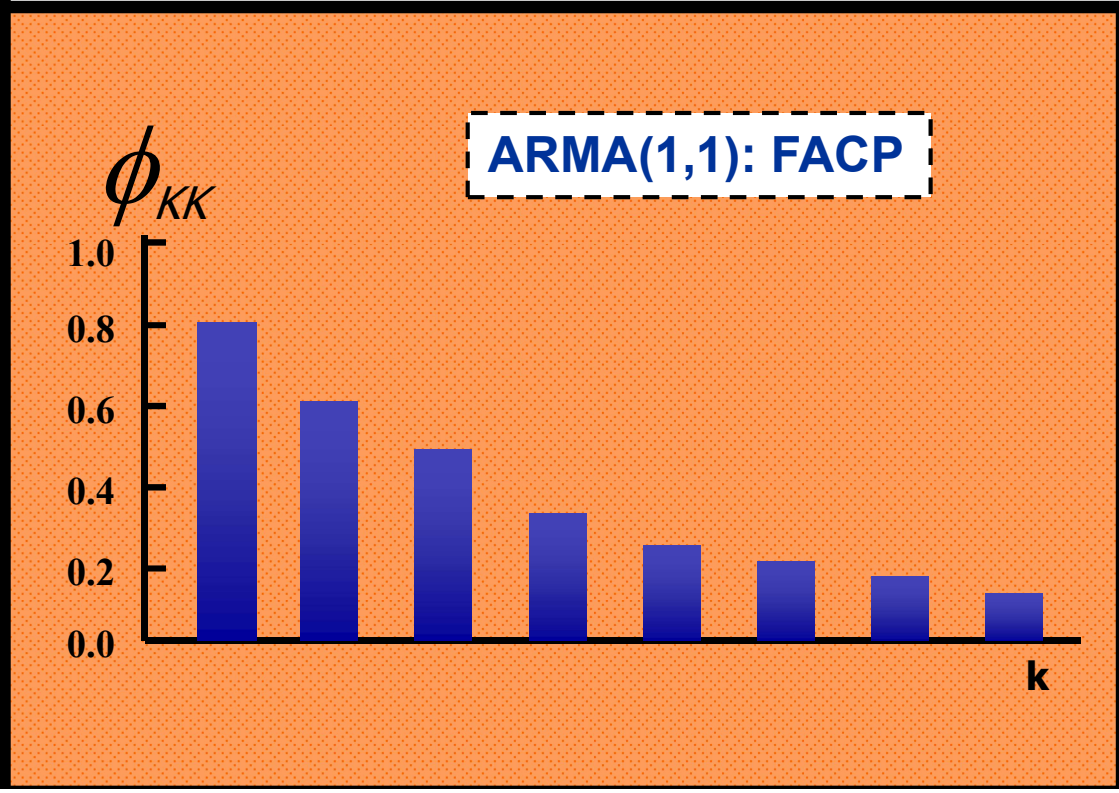
ARMA(1;1): $x_t = \phi_1 x_{t-1} + \xi + \varepsilon_t - \theta_1 \varepsilon_{t-1}$

Conte termos AR e MA significantemente diferentes de ZERO

FAC decai GRADUALMENTE
Para termos MA, conte FAC

FACP decai GRADUALMENTE
Para termos AR conte FACP

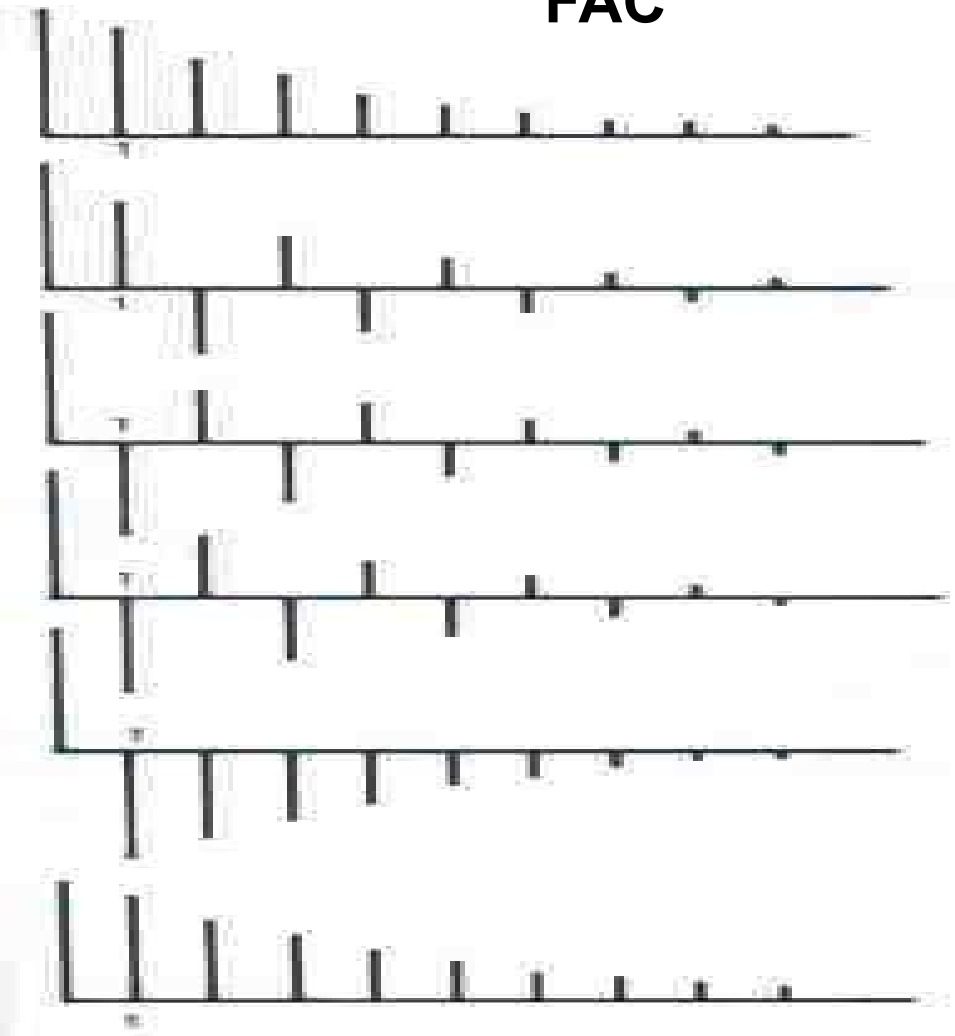




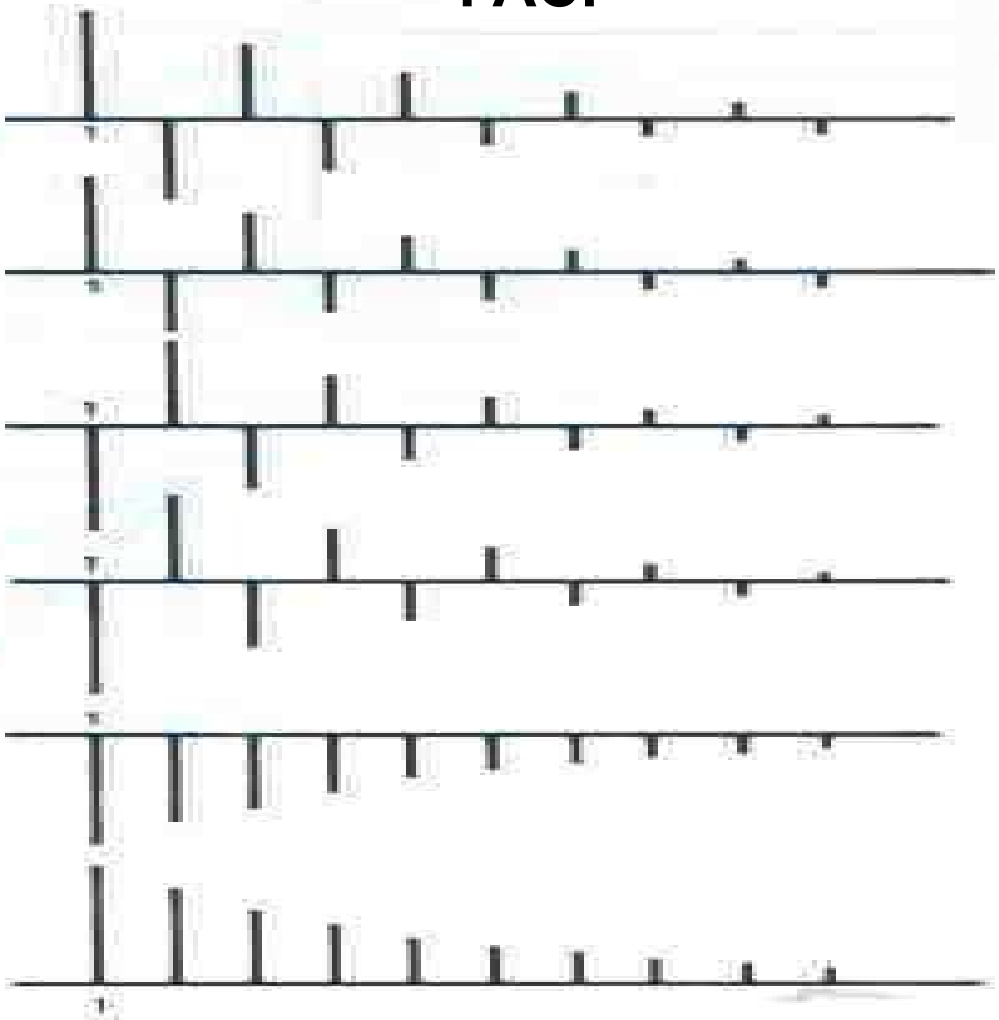
Modelos ARMA

ARMA(1;1): $x_t = \phi_1 x_{t-1} + \xi + \varepsilon_t - \theta_1 \varepsilon_{t-1}$

FAC



FACP



Modelos Autoregressivos, Integrados e de Média Móvel ARIMA(p,d,q)

Modelos ARIMA

Ordem “p,d,q”: ARIMA(p,d,q)

- Série NÃO estacionária
- Séries NÃO estacionárias devem ser estabilizadas através de diferenciação.
- Diferenciar a série original dos dados *d* vezes até obter uma série estacionária

Modelos ARIMA

Ordem “p,d,q”: ARIMA(p,d,q)

- Em geral: $d \leq 2$
- Série DIFERENCIADA:
  - denominada por “*z*” e
  - modelada por processo ARMA(p,q)
- Série ORIGINAL: processo ARIMA(p,d,q)

Modelos ARIMA

Ordem “p,d,q”: ARIMA(p,q)

- Procedimento de Integração (I)
  - número de diferenciações(d) exigidas para atingir a estacionariedade

- Ordem da série integrada: I(d)

Estatística Aplicada

Aula 12 - Agenda

Modelos GARCH

Modelo ARCH

- Engle (1982)

- Objetiva capturar:
  - autocorrelação
  - heterocedasticidade

- A previsão da variância é baseada em
  - Constante de longo prazo
  - Termo ARCH
    - ✓ Média ponderada formada por "*q*" observações

- Quanto mais antiga a observação, menor seu peso

Modelo ARCH

$$\sigma^2{}_t = \varpi + \alpha_1 \varepsilon^2_{t-1} + \alpha_2 \varepsilon^2_{t-2} + \ldots + \alpha_q \varepsilon^2_{t-q} ,$$

$$\sigma^2{}_t = \varpi + \sum_{i=1}^{q} \alpha_i \varepsilon^2_{t-i} ,$$

$$\sigma_t = \sqrt{\sigma^2{}_t} ,$$

$$\varepsilon_{t-i} = z_{t-i} \sigma_{t-i} ,$$

$$z_{t-i} \sim iid(0, 1),$$

$$E[\varepsilon_{t-m} \varepsilon_{t-n}] = 0 , m \neq n ,$$

$$\varepsilon_t \left| \Psi_{t-1} \right. \sim N(0, \sigma^2{}_t).$$

Modelo ARCH

- Condições de Não-Negatividade da Variância

  i) $\varpi > 0$

  ii) $\alpha_i \geq 0$, *i = 1, 2, ..., q*

- Condição de Estacionariedade do Processo

$$\left| \sum_{i=1}^{q} \alpha_i \right| < 1$$

Modelo GARCH

- Bollerslev (1986)
- Generaliza o modelo ARCH
- A previsão da variância é baseada em
  - Constante de longo prazo
  - Termo ARCH: auto-regressivo
  - Termo GARCH: média móvel

Modelo GARCH

$$\sigma^2{}_t = \varpi + \alpha_1 \varepsilon^2_{t-1} + \alpha_2 \varepsilon^2_{t-2} + \ldots + \alpha_{q-1} \varepsilon^2_{t-q+1} + \alpha_q \varepsilon^2_{t-q} + \beta_1 \sigma^2_{t-1} + \beta_2 \sigma^2_{t-2} + \ldots + \beta_p \sigma^2_{t-p},$$

$$\sigma^2{}_t = \varpi + \sum_{i=1}^{q} \alpha_i \varepsilon^2_{t-i} + \sum_{j=1}^{p} \beta_j \sigma^2_{t-j},$$

$$\sigma_t = \sqrt{\sigma^2{}_t}\ ,$$

$$\varepsilon_{t-i} = z_{t-i} \sigma_{t-i}\ ,$$

$$z_{t-i} \sim iid(0,\ 1),$$

$$E[\varepsilon_{t-m} \varepsilon_{t-n}] = 0\ ,\ m \neq n\ ,$$

$$\varepsilon_t \left| \Psi_{t-1} \right. \sim N(0,\ \sigma^2{}_t\ ).$$

Modelo GARCH

- Condições de Não-Negatividade da Variância

  i) $\varpi > 0$

  ii) $\alpha_i \geq 0$, *i = 1, 2, ..., q*

  iii) $\beta_j \geq 0$, *j = 1, 2, ..., p*.

- Condição de Estacionariedade do Processo

$$\left| \sum_{i=1}^{q} \alpha_i + \sum_{j=1}^{p} \beta_j \right| < 1$$

Modelo EWMA

- Caso particular de GARCH(1,1)
- Captura rapidamente variações na volatilidade
- NÃO demanda muitas observações
- Fórmula comumente usada:

$$\sigma_t^2 = (1-\lambda) r_t^2 + \lambda \sigma_{t-1}^2$$

- Fator ótimo de decaimento exponencial: λ^*
  - Minimizar RMSE
  - Variando λ

$$RMSE = \sqrt{\frac{1}{T} \cdot \sum_{t=1}^{T} \left(r_{t+1}^2 - \sigma_{t+1|t}^2(\lambda) \right)^2}$$

Obrigado por sua atenção!!!

Estatística Aplicada

Sistema de Avaliação

"Se eu escuto, eu esqueço.
Se eu vejo, eu lembro.
Se eu faço, eu entendo."

Confúcio
551 - 479 A.C.

Trabalho de Conclusão

A sua Equipe de Estudo deverá redigir uma nota técnica com os seguinte itens:

- INFORMAÇÕES: descrever (i) as séries temporais utilizadas e o período a que se refere a amostragem, (ii) o fundamento teórico que embasa a utilização das variáveis, (iii) o modelo funcional de regressão linear simples e (iv) os testes estatísticos aplicados no Estudo de Caso.
- ANÁLISE: (i) aplicar Estudo de Caso, e (ii) avaliar os resultados dos testes estatísticos.
- CONCLUSÃO: apresentar (i) as conclusões do trabalho e (ii) propostas de futuras pesquisas.

Data para Entrega: 30/11/2008.